

Masterarbeit

Auf dem Weg zum autonom fahrenden Fahrrad: Eine videogestützte Regelung des Weges mit Webbots

Amine Karabila

Sommersemester 2025

Contents

1	Einleitung	4
1.1	Problemstellung	4
1.2	Stand der Technik	4
1.3	Bisherige Arbeiten	6
1.3.1	Anna Ranz (2021) – Hardware-Grundlagen	6
1.3.2	Amine Karabila (2022) – Erste funktionierende Regelung	7
1.3.3	Jonah Zander (2023) – Optimierte PID-Balanceregung	8
1.3.4	Yasin Giray (2024) – YOLO + MPC-Fahrtrichtung	8
2	Grundlagen	10
2.1	PID-Regelung – Prinzip und Eignung für das Balance-Problem	10
2.2	MPC-Regelung – Prinzip und Eignung für das Fahrtrichtungsproblem	11
2.3	YOLO-Grundlagen und Segmentierung	12
3	Webots-Simulationsumgebung	14
3.1	Überblick	14
3.2	Struktur der Simulationsumgebung	15
3.3	Das Fahrradmodell	17
3.4	Sensoren	18
3.4.1	Inertialmesseinheit (IMU)	18
3.4.2	Kamera (Videosensor)	20
3.4.3	Motorsensoren (Inkrementalgeber)	22
3.5	Aktuatoren	24
3.6	Controller	28
3.7	Angebundene GUI	31
4	Kombinierte Regelung	33
4.1	Portierung des Balance-PID (Zander)	33
4.2	Portierung des Fahrtrichtungs-MPC (Giray)	34
4.3	Strategien der Spurführung	37
4.3.1	YOLO-Segmentierung (YOLOv8) + MPC	37
4.3.2	Fallback-Strategie (Kanten/ROI) + MPC	41
4.4	Gesamtregelung	43

5	Ergebnisse	44
5.1	Fahrrad Datenblatt	44
5.2	Teststrecken	45
5.2.1	Kurvenfahrt	45
5.2.2	S-Kurve	50
5.2.3	Gerade Strecke mit Seitenwind	51
5.2.4	Gerade Strecke mit Höhenunterschied	51
5.3	Balance-Stabilität	51
5.4	Spurtreue & Querabweichung	51
5.5	Rechenzeit & Echtzeitfähigkeit	51
6	Grenzen der Arbeit	52
7	Zukünftige Arbeiten (Sensor-Fusion, Reinforcement Learning, Hardware-in-the-Loop)	53
8	Fazit	54
9	Literaturverzeichnis	55

1 Einleitung

1.1 Problemstellung

Dieses Kapitel präzisiert die zentrale Herausforderung dieser Arbeit. Ein selbstbalancierendes Fahrrad stellt aufgrund seiner Bauart ein nichtlinear instabiles System dar. Ohne regelnden Eingriff kippt ein Fahrrad im Stand oder bei niedriger Geschwindigkeit. Erst durch die Kombination aus gyroskopischen Effekten der rotierenden Räder, dem Nachlauf der Lenkgeometrie und einem aktiven Regler lässt sich eine stabile Fahrt realisieren. Die vorliegenden Arbeiten verfolgen daher das Ziel, ein autonomes fahrendes Fahrrad zu entwickeln, das sich sowohl selbst balancieren als auch eine vorgegebene Strecke verfolgen kann. Hierfür wurde eine hochrealistische Simulationsumgebung in Webots aufgebaut, die eine duale Reglerarchitektur abbildet. Ein schneller Balance-Controller, implementiert in C, stabilisiert den Rollwinkel mit einer Abtastzeit von 2 ms (500 Hz) und gibt einen Lenkwinkel an den Antrieb weiter. Parallel dazu extrahiert ein Vision-Controller in Python mit niedrigerer Frequenz (20 Hz) Informationen aus Kamerabildern, plant eine Trajektorie und überträgt entsprechende Lenkwinkel- und Geschwindigkeitsbefehle. Die Herausforderung besteht darin, diese beiden Regelschleifen so zu koppeln, dass das Fahrzeug stabil bleibt und zugleich auf visuelle Reize reagiert. Darüber hinaus soll die simulierte Physik so realitätsnah sein, dass die Ergebnisse auf reale Fahrversuche übertragbar sind. Die Arbeit adressiert damit die Verbindung von Regelungs- und Computer-Vision-Methoden für ein komplexes, unteraktuiertes Fahrzeug.

Abgrenzung. Die Arbeit bleibt simulationsbasiert (Webots) und betrachtet nur eine monokulare Kamera ohne dynamische Hindernisumfahrung; die Geschwindigkeit ist vorgegeben, die Kamera starr montiert. Hardware-Effekte (z. B. Sensordrift, Antriebsnachgiebigkeit) sowie Multi-Sensor-Fusion sind nicht Gegenstand der Arbeit.

1.2 Stand der Technik

Die Entwicklung selbstbalancierender Fahrräder ist seit einigen Jahren Gegenstand intensiver Forschung. Bereits 2005 analysierte K.J. Åström und Anders Lennartsson [40] die Fahrdynamik von Fahrrädern und zeigten, dass ein geeignetes Lenkverhalten, insbesondere das Hineinlenken in die Fallrichtung, zur Stabilisierung genutzt werden kann. Dieses Prinzip, oft als "Steer into the Fall" (STF) bezeichnet, bildet die Grundlage vieler Balance-Regelungen. Allgemein sind Fahrräder ohne Fahrer inhärent instabil und verhalten sich ähnlich einem umgekehrten Pendel, das aktiv ausbalanciert werden muss. Aufbauend auf diesem Verständnis wurden verschiedene Methoden entwickelt, um ein fahrerloses Fahrrad im Gleichgewicht zu halten. Die mit Abstand einfachste Variante nutzt die Lenksteuerung, den durch gezieltes Verdrehen des Lenkers wird das Rad unter den Schwerpunkt manövriert, um Kippbewegungen auszugleichen. Zahlreiche Prototypen erreichen auf diese Weise dynamische Stabilisierung, erfordern jedoch eine gewisse Vorwärtsgeschwindigkeit. So demonstrierten beispielsweise Andreo, D. and Cerone schon 2010 einen nichtlinearen Regler, der mittels Vorderradlenkung ein autonomes Fahrrad stabilisieren konnte [16]. Ähnlich zeigte Deng et al. (2018), dass bereits ein einfacher PID- bzw. LQR-basierter Lenkwinkelregler ¹ ausreicht, um ein frei fahrendes Fahrrad aufrecht zu habitablen [9]. Andere Arbeiten nutzen erweiterte Verfahren: Andreo et al. (2009) realisierten eine Fahrstabilisierung mit einem LPV-Regler (linear parametrisch variierend), der verschiedene Fahrzustände abdecken konnte [1]. Shafiekhani et al.

¹Ein LQR-Regler stabilisiert ein lineares System optimal, indem er Zustandsfehler und Stellaufwand minimiert.

(2015) implementierten einen neuro-fuzzy Regler, der durch adaptive Optimierung robuste Balance auch bei Modellunsicherheiten erzielte [32]. Darüber hinaus wurden Sliding-Mode-Verfahren (Gleitmodusregelung) vorgeschlagen, um gegen unbekannte Störungen unempfindlich zu sein. Insgesamt zeigt sich, dass klassische Regelungsansätze (PID, LQR) wie auch moderne Verfahren (MPC, adaptive und robuste Regelungen) erfolgreich zur Stabilisierung selbstbalancierender Fahrräder eingesetzt werden können [9, 23, 32]. Neben der Lenkung existieren alternative Mechanismen zur aktiven Stabilisierung. Historisch wurden vor allem zwei Ansätze untersucht: Zum einen die Verwendung beweglicher Massen, zum anderen gyroskopische Effekte. **Bewegte Masse:** Hierbei wird ein Zusatzgewicht lateral verschoben oder als invertiertes Pendel im Rahmen angebracht, um durch Gewichtsverlagerung das Gleichgewicht zu halten. Diese Methode kann insbesondere bei sehr niedrigen Geschwindigkeiten oder im Stillstand für Stabilität sorgen, erhöht jedoch das Systemgewicht beträchtlich und ist dynamisch träge [33]. **Gyroskopische Stützung:** Durch schnell rotierende Schwunghmassen wird ein Kreiseffekt erzeugt, der dem Umkippen entgegenwirkt. Zwei Varianten sind verbreitet: ein Reaktionsrad, das entlang der Längsachse montiert ist und durch Beschleunigen/Abbremsen Stabilisierungsmomente erzeugt, sowie ein Control Moment Gyroscope (CMG), bei dem ein rotierendes Schwungrad um eine Achse geschwenkt wird. Ein einzelnes Kreiselgerät erzeugt allerdings neben dem Stabilisierungs-Moment oft unerwünschte seitliche Drehmomente, weshalb Park und Yi (2020) beispielsweise ein gepaartes (scissored pair) Kreisel-System einsetzten, das Störmomente kompensiert [30]. Mit einem solchen doppelten CMG konnte sogar stationäre Balance (ohne Vorwärtsfahrt) realisiert werden [30]. Reaktionsräder wiederum sind in der Lage, ein Fahrrad aus dem Stand aufzurichten, erfordern dafür jedoch große Drehmomente und energiestarke Aktuatoren, was ihren Einsatzbereich begrenzt [23]. Trotz dieser technischen Herausforderungen konnte Lam und Sin (2011) bereits ein kleines Roboterfahrrad mit Einzel-Schwungrad stabilisieren [25]. Tamaldin et al. (2017) präsentierten einen Gesamtentwurf eines selbstbalancierenden Fahrrads, der verschiedene solcher Stabilisierungsprinzipien in Betracht zog [33]. Aktuell konzentriert sich die Forschung vermehrt darauf, Balancekontrolle mit Fahrtrajektorie zu verknüpfen – also ein selbstbalancierendes Fahrrad gezielt entlang einer vorgegebenen Spur oder Fahrspur zu steuern. Frühere Arbeiten adressierten bereits das Spurhalten: So gelang Saguchi et al. (2009) eine stabile Geradeausfahrt durch automatische Lenkregelung, während Aphiratsakun und Techakittiroj (2013) einen autonomen Fahrrad-Prototyp (AUSB2) vorstellten, der neben dem Balancieren auch einfache Trajektorien nachfahren konnte [2]. Kanjanawanishkul (2015) kombinierte sogar eine stationäre Balance-Regelung mit einem MPC-basierten Pfadverfolger, sodass sein Fahrrad im Stillstand balancieren und bei Fahrt einer vorgegebenen Strecke folgen konnte [23]. Ein weiterer Meilenstein ist die Arbeit von Xiong et al. (2024), die ein vollautonomes Fahrrad mit minimalem Aktuatoraufwand realisierten: Durch einen analytisch entworfenen linearen Lenkregler wurde das Fahrzeug sowohl im Geradeauslauf als auch im Kurvenfahren stabil gehalten, ohne dass zusätzliche Kreisel oder Gewichte nötig waren [37]. Diese Ergebnisse zeigen, dass eine intelligente Lenkregelung prinzipiell ausreicht, um sowohl Balance als auch Spurhaltung zu gewährleisten – was für die angestrebte Fahrspurhaltung essentiell ist. Neben der Regelungstechnik spielt die Sensorik und Umfeldwahrnehmung eine wachsende Rolle im Stand der Technik. Für das autonome Fahren müssen Umgebung und Fahrspur erkannt werden. Hunziker (2019) koppelte z.B. Inertialsensoren mit GPS-Daten und setzte einen modellprädiktiven Regler ein, um ein elektrisches Fahrrad ohne Fahrer entlang eines vorgegebenen Kurses zu steuern [20]. In neueren Projekten werden Kameras und Computer Vision integriert, um Fahrspuren oder Hindernisse zu detektieren. Ein prominentes Beispiel ist ein am Tsinghua-Universität entwickeltes autonomes Fahrrad, das mittels KI-Chip (Tianjic) sowohl selbstbalanciert als auch Objekterkennung und Sprachbefehle umsetzt. Wissenschaftlich dokumentiert ist die Arbeit von Ghidai (2024), der ein video- und sensorgestütztes autonomes Fahrsystem für ein selbstbalancierendes E-Bike realisierte [12]. Dabei

dienen Kamerabilder zur Spurhaltung (Lane Keeping), während zusätzliche Sensorfusion die Stabilität gewährleistet. Dieses Projekt stellt einen aktuellen Stand der Technik dar und zeigt, dass die Kombination aus Lageregelung (Balance-Controller) und Fahrspur-Assistent (Vision-basierte Steuerung) inzwischen machbar ist. Abschließend ist festzuhalten, dass sich das Forschungsfeld rasant entwickelt. Zahlreiche Forschungsprototypen weltweit – vom LPV-geregelten Rad von Andreo (2009) bis zum neuesten visionbasierten E-Bike von Ghidai (2024) – haben die Machbarkeit des selbstbalancierenden, spurgeführten Fahrrads demonstriert. Auch an der Goethe-Universität Frankfurt wurde in den letzten Jahren der Grundstein gelegt: Ranz (2021) entwickelte einen ersten selbstbalancierenden Fahrrad-Prototyp [31], Karabila (2022) implementierte eine Balance-Regelung dafür [24], und Zander (2023) verbesserte das Reglerdesign weiter [38]. Auf diesem Vorwissen aufbauend erweitert die vorliegende Arbeit den Stand der Technik um eine robuste Fahrspurhaltung, indem aktuelle Methoden der Regelungstechnik und Bildverarbeitung zusammengeführt werden.

1.3 Bisherige Arbeiten

Die im vorherigen Abschnitt dargestellten Forschungsarbeiten zeigen, dass sowohl klassische als auch moderne Regelungsverfahren prinzipiell geeignet sind, ein selbstbalancierendes Fahrrad zu stabilisieren und mit Trajektorienfolgeregelungen zu kombinieren. Während sich diese Studien überwiegend auf externe Forschungsgruppen beziehen, existieren auch an der Goethe-Universität Frankfurt eine Reihe aufeinander aufbauender Abschlussarbeiten, die wesentlich zur Entwicklung des hier untersuchten Systems beigetragen haben.

1.3.1 Anna Ranz (2021) – Hardware-Grundlagen

Die Bachelorarbeit von Anna Ranz bildete den Startpunkt des Projekts. Ihr Ziel war die Konstruktion eines lauffähigen Prototyps, mit dem grundlegende physikalische Eigenschaften eines selbstbalancierenden Fahrrads untersucht werden konnten. Kern der Hardware ist ein BeagleBone Black, der den Lenkmotor mittels MD49-Controller (EMG49) über UART und die Inertialmesseinheit BNO055 über I²C ansteuert. Ergänzt wurde das System durch einen Nabennmotor am Hinterrad, der eine konstante Vorwärtsfahrt sicherstellte. Damit standen erstmals sowohl die mechanische Plattform als auch die notwendigen Sensor- und Aktor-Schnittstellen zur Verfügung, um regelungstechnische Konzepte praktisch zu erproben.

Ranz implementierte erste PID-Regelkreise, validierte die Sensorik in separaten Testprogrammen und analysierte die Dynamik des Gesamtsystems in Bezug auf Massenträgheit, Raddynamik und Lenkkinematik. Von besonderer Bedeutung war die Untersuchung des Zusammenspiels zwischen Trägheitsmoment, Lenkwinkel und Rückstellkräften, da diese Größen die Stabilität maßgeblich beeinflussen. Darüber hinaus wurden Messreihen durchgeführt, um die Qualität der BNO055-IMU zu bewerten und deren Eignung für die Rollwinkelbestimmung zu prüfen. Diese Kalibrierung stellte sicher, dass die Daten mit ausreichend geringer Latenz und Genauigkeit für eine spätere Regelung verwendet werden konnten.

Die umfangreiche Dokumentation enthält Schaltpläne, 3D-Modelle und Messaufnahmen und bildet damit die hardwareseitige Grundlage für alle späteren Arbeiten [31]. Besonders hervorzuheben ist, dass Ranz nicht nur eine funktionierende Testplattform aufbaute, sondern auch systematisch deren Grenzen aufzeigte, etwa die eingeschränkte Reaktionsgeschwindigkeit des MD49-Motorcontrollers oder die Latenz der UART-Kommunikation. Diese Erkenntnisse waren für die nachfolgenden Arbeiten entscheidend, da sie Verbesserungsbedarf aufzeigten und konkrete Ansatzpunkte für die Weiterentwicklung lieferten.

Damit markierte die Arbeit von Ranz den entscheidenden Übergang von theoretischen Überlegungen hin zu einer realen Forschungsplattform: Erst durch die von ihr geschaffene Hardware-Basis und die Analyse der physikalischen Dynamik war es möglich, in den darauffolgenden Arbeiten sowohl Regelungsalgorithmen als auch softwareseitige Optimierungen im praktischen Betrieb zu validieren.

1.3.2 Amine Karabila (2022) – Erste funktionierende Regelung

Amine Karabila schloss 2022 unmittelbar an den Hardware-Prototyp von Ranz an und überführte das System von einzelnen Stellversuchen zu einem geschlossenen, echtzeitfähigen Regelkreis. Kernbestandteil ist eine dreistufige P-Regelung auf dem BeagleBone Black, die den Rollwinkel der BNO055-IMU [3] und die Lenkerstellung des MD49-Encoders [10] auswertet, während ein hinterer Nabenmotor die Vortriebsdrehzahl konstant hält [24]. Damit gelang erstmals eine softwareseitig realisierte Balancekontrolle, die den Forschungsprototyp in eine echte Versuchsplattform verwandelte.

Ein erstes Hindernis war die Strombegrenzung des MD49, die den EMG49-Lenkmotor zu langsam ansprechen ließ. Karabila ersetzte deshalb den Leistungsteil durch eine BTS7960-H-Brücke [21] und verwendete den MD49 nur noch zur hochauflösenden Wegmessung. Nicht-blockierende UART-Aufrufe verkürzten die Encoderabfrage von rund 4 ms auf knapp 1 ms, sodass die Gesamttransportzeit des Reglers auf etwa 2 ms sank. Diese Optimierungen verdeutlichen die besonderen Herausforderungen eingebetteter Systeme: Ein stabiler Regelkreis erfordert nicht nur gute Algorithmen, sondern auch eine Hardware- und Softwarearchitektur, die minimale Verzögerungen gewährleistet.

Die erste Regelversion koppelte die Motorgeschwindigkeit über einen gestreckten tanh-Verlauf an die Verweildauer des Rollwinkels in einer „habitablen Zone“. Außerhalb des Labors erwies sich dieses Verfahren jedoch als zu träge: Der Lenker schlug regelmäßig an die Endanschläge, und Stützräder mussten das Fahrrad vor dem Kippen bewahren. Die finale Lösung verknüpfte dagegen den gemessenen Rollwinkel direkt mit einem geschwindigkeitsabhängigen Soll-Encoderwert. Dadurch pendelte der Lenker nur noch mit etwa acht Ticks Amplitude um die Nullposition; ein integrierter Dämpfungsanteil reduzierte die Motordrehzahl automatisch, sobald sich das System seiner Soll-Lage näherte.

Validiert wurde der Regler im Hof des Informatikgebäudes ($\approx 9.5 \times 26.5$ m, fünf Prozent Steigung). Bei Sollgeschwindigkeiten von 6–10 km/h blieb das Fahrrad während aller aussagekräftigen Fahrten aufrecht; Tip-Over-Events traten nicht auf. Die erfolgreichste Versuchsfahrt bei 10 km/h zeigte Spitzen von unter acht Encoder-Ticks und eine Querabweichung, die optisch kaum wahrnehmbar war. Diese erfolgreiche Fahrt dokumentiert die Funktionsfähigkeit der entwickelten Regelung.

Damit bewies Karabilas Arbeit erstmals die Realisierbarkeit einer selbstbalancierenden Regelung und schuf die Grundlage für die PID-Optimierungen von Zander sowie die MPC-Navigation von Giray. Insbesondere machte sie deutlich, dass die Regelgüte stark von niedrigen Latenzen und einer robusten Kopplung zwischen Sensoren und Aktoren abhängt – ein zentrales Motiv, das auch in den nachfolgenden Arbeiten beibehalten und weiterentwickelt wurde.

1.3.3 Jonah Zander (2023) – Optimierte PID-Balanceregung

Zander knüpfte 2023 an die Vorarbeiten an und formulierte als Kernziel, das Fahrrad mindestens 60s auf ebener Strecke ohne Bodenkontakt der Stützräder stabil fahren zu lassen [38]. Die Arbeit positioniert sich zwischen eingebetteter Echtzeit-Software und Regelungsentwurf: Latenz, Jitter und Sättigungseffekte sollten so adressiert werden, dass eine robuste Balance auch bei Richtungsänderungen möglich ist. Grundlage waren Ranz’ Hardware und Karabilas erste geschlossene Regelstrecke [24, 31].

Zur Umsetzung entwickelte Zander eine modular aufgebaute C-Software auf dem BeagleBone Black (Debian), in der Multi-Threading Sensor-/Aktor-I/O, Reglerkern und Logging entkoppelt. Zeitkritische Abtast- und Vorverarbeitungsaufgaben wurden in die Programmable Realtime Units (PRUs) verlagert, wodurch deterministische Lesezyklen für Fahr- und Lenkwinkel im zweistelligen kHz-Bereich möglich wurden. Die effektive Transportverzögerung zwischen Messung und Stellgröße sank dadurch deutlich, was die Stabilitätsreserven des Reglers erhöhte [38].

Die Balanceregung realisierte Zander als klassisch ausgelegten PID-Regler, dessen Parameter iterativ auf Basis umfangreicher Mess- und Logdaten optimiert wurden. Gegenüber der zuvor genutzten dreistufigen P-Logik [24] steigerten Integral- und D-Anteil Ausregelgüte und Dämpfung. In der Software wurden robuste Elemente berücksichtigt, unter anderem Begrenzung und Glättung des Lenkmotor-Solls (Rate- und Amplitudenlimits), sorgfältige Filterung der Eingangssignale (Encoder/IMU) zur Rauschunterdrückung bei erhaltener Phasenreserve sowie latenzarme Pfade zwischen PRU-Puffern und Reglerkern zur Minimierung von Jitter. Das Loggingsystem zeichnete synchronisierte Sensor- und Aktordaten auf und erlaubte eine systematische Auswertung der Reglerwirkung [38].

Neben dem Reglerkern stärkte Zander die Betriebssicherheit: Zwei Notausschalter (separate Lenkungs- bzw. Gesamtabschaltung), eine Reißleine zur sofortigen Trennung der Lenkungsversorgung in kritischen Situationen sowie ein Fail-Safe für den RC-Empfänger (Stop bei Signalverlust) begrenzen Risiken unkontrollierter Lenkereinschläge und mechanischer Schäden [38].

In experimentellen Fahrttests blieb das Fahrrad über mehr als 60s stabil in Balance, ohne dass die Stützräder den Boden berührten; die Zielvorgabe wurde erfüllt und überschritten. Bei konstanter Geschwindigkeit auf ebenem Untergrund waren zudem gesteuerte Richtungsänderungen per Fernbedienung möglich, ohne die Balance zu verlieren [38]. Damit erzielte Zander den bis dahin längsten autonom balancierten Fahrbetrieb des Prototyps.

Für die vorliegende Arbeit ist diese PID-Basis maßgeblich: Die in [38] entworfene Regelung wurde nach *Webots* portiert und bildet die innere Schleife der dualen Reglerarchitektur. Darauf aufbauend wird die vision- und trajektorienbasierte Fahrgelung in der äußeren Schleife integriert. Diese klare Schichtung (Balance innen, Fahrspur außen) ist zentral für die Kopplung von Regelungs- und Computer-Vision-Methoden im Gesamtsystem.

1.3.4 Yasin Giray (2024) – YOLO + MPC-Fahrtrichtung

Aufbauend auf der in [38] erreichten stabilen Balanceregung verlagerte Giray (2024) [12] den Schwerpunkt auf die autonome Fahrtrichtungswahl mittels Computer Vision und modellprädiktiver Regelung. Ziel war eine monokamera-basierte Pipeline, die in Echtzeit auf eingebetteter Hardware lauffähig ist und aus Bilddaten eine Referenztrajektorie ableitet, der das Fahrrad folgen kann, ohne die Balance zu verlieren.

Die Wahrnehmungskomponente setzt auf ein effizientes Segmentierungsmodell aus der YOLOv8-Familie [22]. Nach einer Evaluation alternativer Verfahren (u. a. FastSAM [39]) fiel die Wahl aufgrund des guten Verhältnisses von Genauigkeit und Latenz auf ein Ultralytics-Modell in der Segmentation-Variante. Das Netz wurde mit einem angepassten Datensatz trainiert und für die Inferenz mittels TensorRT auf dem NVIDIA Jetson Nano beschleunigt, sodass die Bildauswertung in Zyklen von etwa 100 ms erfolgen konnte. Aus den segmentierten Szenen werden Stützpunkte extrahiert und über Spline-Interpolation zu einer glatten Referenzspur verdichtet, die die gewünschte Fahrlinie repräsentiert.

Für die Fahrregelung implementierte Giray einen Model Predictive Controller (MPC) auf Basis eines Einspurmodells [20]. Der MPC minimiert über einen endlichen Horizont Abweichungen von der Referenzspur bei gleichzeitig moderatem Stellaufwand und berücksichtigt Nebenbedingungen des Systems. In jedem Rechenzyklus wird das Optimierungsproblem mit der aktuellen Zustandsschätzung gelöst; angewandt wird jeweils nur die erste Stellgröße (receding horizon), bevor der Vorgang mit aktualisierten Messdaten wiederholt wird. Modellierung, Trajektorien-Interpolation und MPC-Optimierung wurden zunächst in Python umgesetzt und auf die Jetson-Plattform portiert.

In Simulationen zeigte die Pipeline, dass Fahrbahnkanten und einfache Hindernisse zuverlässig detektiert und Referenzspuren generiert werden können; das Fahrrad folgte diesen Spuren stabil, solange die äußere MPC-Schleife die innere Balanceregulierung nicht überfordert. Sichtbar wurden zugleich Grenzen und Folgearbeiten: Eine explizite Kollisionsvermeidung war noch nicht integriert; Tiefe stand nur implizit über Bildgeometrie zur Verfügung. Als Verbesserungen werden daher die Anreicherung um Tiefeninformationen (Stereo oder monocular depth) sowie eine kameraseitige Stabilisierung gegen Rollneigung (z. B. Gimbal) genannt. Ebenso ist mit neueren Segmentierungsansätzen und leistungsfähigeren Edge-Plattformen eine weitere Reduktion der Latenz zu erwarten [22, 39].

Für die vorliegende Arbeit ist die Einordnung klar: Die von Zander übernommene PID-Balanceregulierung bildet die innere Schleife, während Girays MPC-basierter Spurhalter als äußere Schleife in *Webots* integriert wird. Diese Schichtung erlaubt es, die Kopplung von Balancehaltung und visionbasierter Trajektorienverfolgung systematisch zu untersuchen und in einer realitätsnahen Simulation zu kalibrieren, bevor reale Fahrversuche erfolgen.

2 Grundlagen

Dieses Kapitel führt die theoretischen und methodischen Grundlagen ein, die für das Verständnis der im Folgenden vorgestellten Reglerarchitekturen und Bildverarbeitungsverfahren notwendig sind. Zunächst wird die PID-Regelung als klassischer Vertreter der linearen Regelungstechnik erläutert und ihre Eignung zur Stabilisierung des unteraktuierten Balance-Problems des Fahrrads diskutiert. Anschließend folgt eine Einführung in das Prinzip der modellprädiktiven Regelung (MPC), die eine vorausschauende Berechnung von Stellgrößen erlaubt und somit für die Fahrtrichtungsregelung prädestiniert ist. Abschließend werden die Grundlagen der Objekterkennung mit YOLO sowie der Bildsegmentierung vorgestellt, um die visuelle Wahrnehmung und Spurführung des autonomen Fahrrads zu ermöglichen.

2.1 PID-Regelung – Prinzip und Eignung für das Balance-Problem

Die Proportional-Integral-Differential (PID)-Regelung ist der am weitesten verbreitete Ansatz der klassischen Regelungstechnik. Ein PID-Regler ermittelt die Stellgröße $u(t)$ aus dem Fehler $e(t)$ zwischen Sollwert SP und dem gemessenen Istwert PV nach

$$u(t) = K_P e(t) + K_I \int_0^t e(\tau) d\tau + K_D \frac{de(t)}{dt} \quad (1)$$

wobei K_P , K_I und K_D die Verstärkungsparameter für proportionale, integrale und derivative Anteile sind. Der proportionale Anteil erzeugt eine Stellgröße proportional zur momentanen Fehlergröße und reduziert so die Anstiegszeit. Der Integrator akkumuliert den Fehler und eliminiert stationäre Abweichungen, kann aber langsame Dynamik verursachen [19]. Die Derivative wirkt der Änderung des Fehlers entgegen und dämpft dadurch Überschwinger; sie erhöht jedoch die Empfindlichkeit gegenüber Messrauschen, weshalb in vielen Anwendungen filternde Maßnahmen erforderlich sind.

PID-Regler werden eingesetzt, wenn eine robuste und einfach implementierbare Rückführung gefordert ist und das Systemverhalten hinreichend durch lineare Modelle beschrieben werden kann. In der Literatur wird die PID-Regelung häufig als Standardlösung für nicht integrierende Prozesse bezeichnet. Ihre Parametrierung erfordert eine sorgfältige Abwägung zwischen Ansprechverhalten und Stabilitätsreserve: Eine Erhöhung des proportionalen Anteils verringert die Regelabweichung, kann aber zu Instabilitäten führen; ein zu hoher Integrationsanteil kann Integrator-Windup verursachen; die derivativen Anteile sind besonders rauschanfällig.

Beim selbstbalancierenden Fahrrad lässt sich die Balanceproblematik auf das klassische inverses-Pendel-Problem zurückführen. Ein Rad, dessen Schwerpunkt über der Aufstandsfläche liegt, befindet sich in einem instabilen Gleichgewicht; kleinste Störungen führen zum Kippen. Um das System aufrecht zu halten, muss der Regler in Echtzeit Stellmomente applizieren, die den kippspezifischen Drehmomenten entgegenwirken. Die Anforderungen an geringe Latenz und hohe Abtastrate werden etwa beim inversen Pendel mit Updatefrequenzen von mehreren Kilohertz umgesetzt. Dies verdeutlicht, dass auch beim Fahrrad eine schnelle Regelungsschleife erforderlich ist, wie sie beispielsweise in den Bachelorarbeiten von Karabila und Zander implementiert wurde. Beide Arbeiten basieren auf P- bzw. PID-Reglern, die den Neigungswinkel mittels IMU messen und über den Lenkmotor oder den Antrieb korrigieren [4].

Insgesamt ist die PID-Regelung für das Balance-Problem des autonomen Fahrrads wegen ihrer geringen Komplexität und Rechenlast, der einfachen Implementierung auf Mikrocontrollern und der guten Robustheit gegenüber Modellunsicherheiten geeignet. Die Nichtlinearität des Fahrverhaltens

und die starken Störmomente durch Schräglagen erfordern jedoch eine sorgfältige Abstimmung der Parameter und gegebenenfalls Erweiterungen wie Anti-Windup-Mechanismen oder Filterung der derivativen Komponente, um die Regelung stabil und performant zu halten.

2.2 MPC-Regelung – Prinzip und Eignung für das Fahrtrichtungsproblem

Model predictive control (MPC) nutzt ein internes Modell des Systems, um dessen zukünftiges Verhalten über einen endlichen Zeithorizont vorherzusagen. Auf Grundlage dieser Vorhersage und des aktuellen gemessenen bzw. geschätzten Zustands werden optimale Stellgrößen berechnet, die einen definierten Kostenfunktional minimieren und gleichzeitig die Systembeschränkungen einhalten. Nach jedem Abtastintervall wird nur die erste Stellgröße angewendet und die Optimierung mit vorwärts verschobenem Horizont neu gelöst, weshalb man auch von *receding horizon control* spricht. Zu den wesentlichen Vorteilen von MPC zählen die proaktive Reaktion auf künftige Störungen, die Möglichkeit nichtlineare Modelle ohne Linearisierung zu berücksichtigen und die explizite Berücksichtigung von physikalischen und sicherheitsrelevanten Beschränkungen. Im Gegensatz zu reaktiven PID-Reglern kann MPC damit frühzeitig gegensteuern und gleichzeitig harte Grenzen, etwa Stellweg- oder Geschwindigkeitsbeschränkungen, einhalten [11].




Figure 1: MPC-Regler

Beim selbstbalancierenden Fahrrad besteht das Fahrtrichtungsproblem darin, aus Kamerainformationen einen Sollkurs abzuleiten und das Fahrzeug mit begrenztem Lenkradius und Lenkrate entlang dieser Trajektorie zu führen. Der in der Vision-Regelung verwendete `VisionMPCController` modelliert das Fahrzeug als einfaches Fahrraddynamikmodell mit Zustandsvektor $x = [x, y, v, \psi]$ für Position, Geschwindigkeit und Gierwinkel sowie Eingangsvektor $u = [a, \delta]$ für Beschleunigung und Lenkwinkel. Aus dem aktuellen Zustand und dem lateral gemessenen Fehler wird ein Referenzpfad erzeugt (Ziel-Yaw proportional zum Fehler), der über einen Horizont T vorwärts projiziert wird. Anschließend löst der MPC ein konvexes Optimierungsproblem, das die Abweichung von diesem Pfad, die Eingangsgrößen sowie deren zeitliche Änderung in einer quadratischen Kostenfunktion gewichtet und durch Beschränkungen auf maximalen Lenkwinkel, Lenkrate, Geschwindigkeitsbereich und Beschleunigung ergänzt. Stehen geeignete Optimierungslöser (z. B. `cvxpy`) zur Verfügung,

werden aus diesem Problem kontinuierliche Stellgrößen $\delta \in [-\delta_{\max}, \delta_{\max}]$ und a berechnet; andernfalls fällt der Controller auf eine einfache P-Regelung zurück. Vor der Weitergabe an den schnellen Balance-Controller werden die resultierenden

Lenkwinkel und Beschleunigungen normiert, geglättet und auf Änderungsraten begrenzt, um ruckfreie Übergänge zu gewährleisten [14].

Die Eignung der MPC Regelung für das Fahrtrichtungsproblem ergibt sich aus der Vorhersagefähigkeit und der Einbeziehung von Beschränkungen. Das Fahrradsystem ist nichtlinear und unteraktuiert; um einer gekrümmten Spur zu folgen, muss der Regler zukünftige Kurvenverläufe berücksichtigen und gleichzeitig mechanische Limits (Lenkeinschlag, Lenkrate) respektieren. MPC kann diese Randbedingungen explizit in das Optimierungsproblem integrieren und die Stellgrößen so wählen, dass sowohl die Trajektorienabweichung als auch der Stellaufwand minimiert werden. In Yasin Girays Masterarbeit wurde der visionbasierte MPC-Regler mit einem Horizont von $T = 3$ und den genannten Zuständen und Eingängen implementiert und mit Gewichten auf Zustände, Eingänge und deren Differenzen parametrisiert. Simulationen zeigten, dass das Fahrrad mithilfe des MPC gleichmäßig entlang der aus der Bildsegmentierung abgeleiteten Spur navigierte und dabei die mechanischen Limits einhielt. Somit stellt MPC einen geeigneten Ansatz dar, um das autonome Fahrrad stabil und vorausschauend [34] entlang einer vorgegebenen Fahrtrichtung zu steuern.

2.3 YOLO-Grundlagen und Segmentierung

You Only Look Once (YOLO) ist eine Reihe von Echtzeit-Objekterkennungsverfahren, die auf Convolutional Neural Networks basieren. Das ursprüngliche YOLO wurde 2015 von Redmon et al. vorgestellt und erfordert im Gegensatz zu region-proposal-basierten Ansätzen nur einen Vorwärtsdurchlauf durch das Netz, um Klassen und Bounding Boxes für alle Objekte in einem Bild zu bestimmen [36]. Neuere Versionen wie YOLOv8 erweitern diese Architektur und bieten neben der Objekterkennung auch Bildklassifikation und Instanzsegmentierung; sie verwenden eine moderne Backbone-Struktur, einen ankerfreien Detektionskopf und eine verbesserte Verlustfunktion und sind auf verschiedenen Hardwareplattformen effizient einsetzbar [29].

Bei der Bildsegmentierung wird jedem Pixel eines Bildes ein Label zugeordnet. Semantic Segmentation ordnet jedem Pixel eine Objektklasse zu, ohne zwischen einzelnen Instanzen zu unterscheiden, während Instance Segmentation jedes Pixel einer individuellen Objektinstanz zuordnet [35]. Panoptic Segmentation kombiniert beide Ansätze, indem sie sowohl die Klasse als auch die Instanz für jedes Pixel identifiziert [35]. In der Instanzsegmentierung liefert das Netzwerk neben Bounding Boxes auch Masken, die die Form jedes erkannten Objekts abbilden.

YOLOv8 integriert eine Instanzsegmentierungskomponente, deren Kopf auf dem YOLACT-Konzept basiert und die zu den Detektionsausgängen zusätzliche Masken pro Objekt berechnet [29]. Durch diese Erweiterung kann ein Modell in einem einzigen Forward-Pass sowohl Objekte lokalisieren als auch deren pixelgenauen Umrisse bestimmen. Wie bei früheren YOLO-Versionen werden Varianten unterschiedlicher Größe bereitgestellt (Nano, Small, Medium, Large usw.), um den Kompromiss zwischen Geschwindigkeit und Genauigkeit zu steuern [29].

In dieser Arbeit wird eine YOLOv8-basierte Segmentierung für die Umfeldwahrnehmung genutzt. Das Modell ist auf vier Klassen trainiert – Wiese („meadow“), Hindernis („obstacle“), Hauptfahrbahn („street_main“) und Seitenfahrbahn („street_side“) [13] – und liefert pro Klasse ein Pixelmasken Overlay sowie die zugehörigen Bounding Boxes. Anschließend wird aus dem Segment „street_main“ der laterale Fehler bestimmt, der als Eingang für die Pfadverfolgung dient. Die

genauen Details zur Modellauswahl, Datensatzgenerierung und Implementierung werden in einem späteren Kapitel beschrieben. Hier soll lediglich hervorgehoben werden, dass die Kombination aus schneller YOLO-Detektion und Instanzsegmentierung eine effiziente und genaue Grundlage für die kamerabasierte Fahrspurerkennung bildet.



Figure 2: YOLO-Segmentierung

3 Webots-Simulationsumgebung

Hier wird die in Webots realisierte Simulationsumgebung vorgestellt, die als zentraler Versuchsstand für Entwurf, Parametrierung und Evaluation der kombinierten Regelung des selbstbalancierenden Fahrrads dient. Ziel ist es, ein reproduzierbares und sicheres Testbett zu schaffen, in dem das physikalische Fahrverhalten, die sensorgeführte Pfadverfolgung sowie die Kopplung von schneller Balance-Regelung und langsamer Vision-/Trajektorienplanung unter kontrollierten Bedingungen untersucht werden können. Webots bietet dafür eine deterministische Dynamiksimulation auf Basis von ODE, eine hierarchische Szenenbeschreibung und eine klare Trennung von Geometrie, Physik, Sensorik, Aktuatorik und Controllern – Eigenschaften, die systematische Parameterstudien, Logging und automatisierte Auswertung wesentlich erleichtern [5].

Das Kapitel ist wie folgt strukturiert: Zunächst wird ein Überblick über Webots und die genutzten Kernfunktionen gegeben. Anschließend wird die konkrete Szenenstruktur der Weltdatei erläutert, einschließlich globaler Simulationsparameter und der Organisation der Knoten. Darauf aufbauend folgt die Beschreibung des Fahrradmodells mit seinen Gelenken, Kontakt- und Masseneigenschaften sowie der eingesetzten Sensoren und Aktuatoren. Abschließend werden die Controller-Prozesse und deren Interaktion skizziert sowie die angebundene GUI bzw. Auswertepfade beschrieben. Diese Gliederung macht transparent, wie ausgehend von einem konsistenten physikalischen Modell die Regelungsalgorithmen iterativ entwickelt, validiert und für den späteren Transfer auf den Realprototyp vorbereitet werden.

3.1 Überblick

Webots ist ein frei verfügbares, quelloffenes und plattformunabhängiges Robotik Simulationsprogramm, das seit 1998 kontinuierlich gepflegt wird und in Forschung, Lehre und Industrie breite Anwendung findet [5, 28]. Es kombiniert eine moderne QtBenutzeroberfläche mit einer Mehrkörper-Dynamiksimulation auf Basis der *Open Dynamics Engine* (ODE) sowie einer OpenGLgestützten RenderingPipeline. Dadurch lassen sich fotorealistische 3DSzenen mit deterministischem Integrationschema und feingranularer Kontrolle der Simulationszeit schrittgenau ausführen [5].

Kern des WebotsModells ist die hierarchische Szenenrepräsentation in *WorldDateien* (*.wbt; VRML-basiert). Eine Welt kapselt globale Parameter (z. B. Zeitauflösung, Kontakt und Reibungsmodelle), Umgebungsobjekte (Boden, Licht, Hintergrund) sowie Roboter-knoten mit Sensorik, Aktuatorik und Masseneigenschaften. Geräte (z. B. Kamera, IMU, Lidar, *RotationalMotor*) sind als Nodes mit klar definierten Schnittstellen realisiert; ihre Parameter (Auflösung, Bildfrequenz, Dämpfung, Grenzwerte) sind reproduzierbar konfigurierbar. Controller laufen als getrennte Prozesse in C/C++, Python, Java oder MATLAB und kommunizieren zur Laufzeit über wohldefinierte APIs mit der Simulationswelt; mittels ROS 2Bridge ist zudem eine Einbettung in verteilte Robotik-Stacks möglich [5, 17]. Eine spezielle *SupervisorAPI* erlaubt höherwertige Eingriffe (Positionsreset, automatisiertes Logging, MetrikAuswertung) und bildet die Grundlage für reproduzierbare BenchmarkingPipelines [5].

Für regelungsorientierte Studien bietet Webots drei Eigenschaften, die in dieser Arbeit zentral sind: (i) *Determinismus* durch festen Zeitschritt und explizite Integrationsreihenfolge, was faire Parameterstudien ermöglicht; (ii) *Modularität* durch die Trennung von Geometrie, Physik, Sensorik/Aktuatorik und Controllern, wodurch Varianten (z. B. Reibungskoeffizienten, Trägheiten, Abtastraten) isoliert untersucht werden können; (iii) *Automatisierbarkeit* über den Supervisor, u. a. für Szenario-Resets, Störgrößeninjizierung, BatchRuns und standardisierte Ergebnisberichte [5].

Relevanz für *fahrdynamische Einspurfahrzeuge*: In jüngeren Arbeiten wird Webots gezielt zur Simulation von Fahrrädern und Motorrädern eingesetzt. Das OpenSourceAddon *WeBikes* erweitert Webots um ein konfigurierbares, physikalisch fundiertes Einspurfahrzeugmodell (Geometrie, Masseverteilung, Reifenkontakt, Steuerkinematik) und demonstriert, dass typische Phänomene wie Selbststabilisierung, Lenkdynamik und Kurvenfahrt reproduzierbar abgebildet werden können [26]. Damit wird ein freier, reproduzierbarer Vergleich zu Spezialwerkzeugen ermöglicht und eine Brücke zwischen Regelungsentwurf (z.B. Balanceregulung, MPCTrajektorienplanung) und virtuellen Fahrversuchen geschlagen. Über den gleichen Mechanismus nutzen weitere Studien Webots als DigitalTwinPlattform für komplexe, materialabhängige Systeme (z. B. weiche Greifer), was die Übertragbarkeit auf neuartige Robotertypen unterstreicht [18].

Für diese Arbeit ist Webots folglich ein geeignetes Testbett, um die Kopplung einer schnellen BalanceRegelung (PID, $\approx$ kHzSkala) mit einer langsameren vision bzw. modellprädiktiven Pfadföhrung (tens of Hz) systematisch zu entwerfen, zu parametrieren und zu evaluieren. Die klare Trennung der Subsysteme (Physik, Sensorik, Controller) erlaubt ablationartige Studien (z. B. Variation von Zeitschritt/Reibung, Sensorausfall, Verzögerungen), während die SupervisorSchnittstelle reproduzierbare Kampagnen mit konsistentem Logging unterstützt [5].

3.2 Struktur der Simulationsumgebung

Die verwendete Simulationsumgebung basiert auf Webots und damit auf einer hierarchisch organisierten Szenenbeschreibung im VRML-Format. Eine *.wbt*-Datei kapselt sämtliche Entitäten der virtuellen Welt – von globalen Parametern (Zeitaufölsung, Kontaktmodelle) über Umgebungsobjekte (Boden, Hintergrund, Lichtquellen) bis hin zu Robotern mitsamt deren Sensorik, Aktuatorik und Controllern [5, 17]. Jeder Knoten (Node) kann wiederum Unterknoten besitzen, sodass sich komplexe Systeme modular aus standardisierten Bausteinen zusammensetzen lassen. Für die vorliegende Arbeit ist diese Hierarchie entscheidend, weil sie erlaubt, (i) das physikalische Verhalten des Fahrrads getrennt von (ii) der Szenengeometrie und (iii) den übergeordneten Reglerprozessen zu modellieren. Änderungen an einem Teilbereich – etwa an den Reibungsparametern der Reifen oder an der Position einer Kamera – bleiben somit lokal und beeinträchtigen die übrigen Komponenten nicht.

Ausgangspunkt der Welt ist eine rechteckige Bodenarena mit texturierter Fahrbahnoberfläche, die als Referenzstrecke für die visuelle Spurföhrung dient. Globale Kontakt- und Reibungsparameter sind hier definiert, um das Zusammenspiel zwischen Reifen und Untergrund konsistent zu halten. Ein fester Zeitschritt im Millisekundenbereich stellt sicher, dass sowohl die Balancebewegungen des Fahrrads als auch die Bildverarbeitungsschleifen deterministisch und in Echtzeit simuliert werden können [5]. Die Kameraperspektive des Betrachters (Viewpoint) folgt dem Fahrrad aus erhöhter Position, was die visuelle Analyse der Fahrmanöver während der Versuche erleichtert.

Das zentrale Element der Szene ist der Roboterknoten *BICYCLE*, der das selbstbalancierende Fahrrad repräsentiert. Sein Geometriemodell wurde aus CAD-Daten übernommen und mit vereinfachten Kollisionsvolumina (Boxen und Zylinder) hinterlegt, um die Physiksimulation effizient zu halten. Die Massen- und Trägheitsparameter der Baugruppen (Rahmen, Räder, Gabel) sind explizit angegeben, sodass die Dynamik – insbesondere Roll- und Nickbewegungen – realitätsnah nachgebildet wird. Bewegliche Komponenten sind über Hinge-Joints angebunden: Das Hinterrad wird über einen Rotationsmotor für den Vortrieb angesteuert, die Lenkbewegung des Vorderrads erfolgt über ein zweites Gelenk mit eigenem Servomotor. Ergänzend existiert ein Kurbel-/Pedalgelenk, das in erster Linie der geometrischen Vollständigkeit und nicht der Antriebserzeugung dient.

Zur Zustandserfassung sind Sensorschnittstellen integriert: Eine Inertialmesseinheit (IMU) liefert dem Balance-Regler fortlaufend Orientierung und Rollwinkel [3]; eine am Fahrrad montierte Kamera kann genutzt werden, um on-board visuelle Informationen auszuwerten. Ein Display-Modul steht optional für Debug- oder Visualisierungszwecke zur Verfügung. Die Kommunikation zwischen Fahrrad und übergeordnetem Regler erfolgt über ein Paar aus **Emitter** und **Receiver**, die einen leichten, paketbasierten Nachrichtenaustausch innerhalb von Webots ermöglichen.

Übergeordnet ist ein *Supervisor*-Knoten angelegt. Dieser spezielle Robotertyp besitzt in Webots weitreichende Eingriffsmöglichkeiten auf Welt-Ebene (z. B. Position-Reset, Logging, automatisierte Auswertung) und dient hier als externe Beobachter- und Steuerinstanz. Der Supervisor trägt eine statisch in der Szene platzierte Kamera, die die Fahrbahn aus einer globalen Perspektive erfasst. Auf Basis dieser Bilder führt der Python-basierte Vision-Controller eine Spurdetektion (YOLO) durch und berechnet über ein modellprädiktives Regelungsverfahren (MPC) Lenksollwerte bzw. Trajektorien. Diese Kommandos werden per Funkkanal (Emitter) an den Balance-Controller des Fahrrads übertragen, der sie in konkrete Motorbefehle umsetzt. Umgekehrt sendet das Fahrrad Statusdaten zurück, die der Supervisor für Evaluations- und Loggingzwecke speichert. Dieses Zusammenspiel zweier Controller-Prozesse – ein echtzeitnaher PID-Regler in C auf Roboterseite und ein bildverarbeitungsgetriebener MPC-Regler in Python auf Supervisorebene – bildet die Kernstruktur der kombinierten Regelung.

Die gewählte Struktur der Simulationsumgebung verfolgt zwei Ziele: Erstens ermöglicht sie reproduzierbare und sichere Experimente in verschiedensten Fahrszenarien (Geradeausfahrt mit Störimpuls, Slalomkurse, Kurvenfahrten mit Steigung), ohne das reale Hardware-Risiko des Umkippen oder der Beschädigung einzugehen. Zweitens gestattet die klare Trennung von physikalischem Modell, Sensorebene und Reglerlogik eine gezielte Variation einzelner Parameter (z. B. Reibung, Zeitschritt, Bildauflösung), um deren Einfluss auf die Gesamtpformance systematisch zu untersuchen. Webots fungiert damit als flexibles Testbett, in dem sowohl Balance- als auch Spurführungsalgorithmen iterativ entwickelt, validiert und optimiert werden können, bevor sie auf den realen Prototyp übertragen werden. 

3.3 Das Fahrradmodell

Das folgende Kapitel führt in das in Webots implementierte Fahrradmodell ein, wie es in der `.wbt`-Datei spezifiziert ist. Das Modell ist als kinematischer Baum aus starren Körpern (`Solid`) aufgebaut, die über eindimensionale Drehgelenke (`HingeJoint`) verbunden sind. Die sichtbare Geometrie (`CadShape`) ist vom physikrelevanten Kollisionsmodell (`boundingObject` mit einfachen Primitiven) getrennt; Masse, Schwerpunkt und Trägheit sind im `Physics`-Block definiert. An ausgewählten Gelenken wirken `RotationalMotor`-Aktuatoren, während Dämpfung und Haftreibung über `HingeJointParameters` festgelegt sind. In den nachfolgenden Unterabschnitten werden die Baugruppen des Fahrrads entlang der Knotenstruktur der Weltdatei beschrieben und deren Parameter hinsichtlich ihres Einflusses auf die Dynamik (Lenkung, Rad-Boden-Kontakt, Eigendämpfung) erläutert.



Figure 3: Das Fahrradmodell in Webots.

Der Knoten `rear_wheel` ist Teil des Gesamtfahrrads und definiert das angetriebene Hinterrad (`HingeJoint`). Die `HingeJointParameters` beschreiben das Lager des Hinterrads. Der `anchor 0 0.5312 0` gibt die Position der Radachse im Elternkoordinatensystem an. Die `dampingConstant 0.8` ist die viskose Dämpfung des Lagers: höher bedeutet mehr Beruhigung gegen Schwingungen, aber eine trägere Rotation. Die `staticFriction 0.1` ist die Haftreibung im Lager: sie verhindert kleines Flattern nahe Stillstand, erhöht jedoch das zum Anfahren nötige Drehmoment. Das `endPoint Solid` ist der vom Gelenk bewegte starre Körper auf der Kind-Seite des `HingeJoint`. Er rotiert um den am Gelenk definierten Anker/Achse und bildet damit das eigentliche Bauteil (hier: das Hinterrad), das durch die Bewegung betroffen ist. In der Hierarchie gilt: Elternteil $\rightarrow$ Gelenk $\rightarrow$ `endPoint Solid`; alles, was hier angehängt ist, bewegt sich mit. Das `boundingObject` definiert die kollisions- und kontaktrelevante Geometrie des Hinterrads, unabhängig vom sichtbaren Mesh. Es bestimmt, wo das Rad den Boden „berührt“, wo Kräfte eingeleitet werden und wie Kollisionen erkannt werden. Im Modell ist es ein einfacher Zylinder, der per `Pose`-Rotation (entspricht Drehung um die y -Achse um 90°) in die Radebene gedreht wird; so bildet er die Kontaktfläche des Reifens ab. Zusammen mit dem `contactMaterial` (z. B. `"wheel"`) entstehen daraus die Reib- und Rückpralleigenschaften im Kontakt mit dem Untergrund. Größe und Ausrichtung des `boundingObject` sollten zur realen Radgeometrie passen, da es die Kontaktlage und damit das Fahrverhalten maßgeblich beeinflusst.

Physik (Physics) Der `Physics`-Block definiert die Masseneigenschaften des Hinterrads. `density -1` bedeutet: Masse und Trägheit werden *nicht* aus dem `boundingObject` berechnet, sondern mit `mass`, `centerOfMass` und `inertiaMatrix` explizit vorgegeben. `mass 2` setzt die Gesamtmasse (kg), `centerOfMass [0 0 0]` positioniert den Schwerpunkt im Solid-Frame (hier an der Nabe), und `inertiaMatrix [0.122 0.122 0.245 0 0 0]` legt die Rotations-Trägheiten ($\text{kg} \cdot \text{m}^2$) fest; größere Werte bedeuten trägere Reaktion auf Dreh- bzw. Kippbewegungen. Die Off-Diagonale `0 0 0` zeigt an, dass Hauptachsen und Solid-Achsen ausgerichtet sind. Für automatische Berechnung könnte statt `density -1` eine positive Dichte verwendet werden (dann kommen Masse/Trägheit aus $\text{Volumen} \times \text{Dichte}$ des `boundingObject`).

Listing 1: Hinterrad—Kinematik, Kontakt und Physik (Auszug)

```

1  DEF rear_wheel HingeJoint {
2      jointParameters HingeJointParameters {
3          anchor 0 0.5312 0
4          dampingConstant 0.1
5          staticFriction 0.8
6      }
7      device [...] # RotationalMotor (siehe Kaptitel 4.5 Aktuatoren)
8      endPoint Solid {
9          children [
10             Transform {...} # visuelles Mesh (ohne Physik)
11         ]
12         contactMaterial "wheel"
13         boundingObject Pose {
14             rotation 0 1 0 1.5708
15             children [ Cylinder { height 0.05 radius 0.352 subdivision 72 } ]
16         }
17         physics Physics {
18             density -1, mass 2, centerOfMass [ 0 0 0 ],
19             inertiaMatrix [ 0.122 0.122 0.245 0 0 0 ]
20         }
21     }
22 }
23

```

3.4 Sensoren

Für die Stabilisierung und Spurführung des selbstbalancierenden Webots-Fahrrads kommen mehrere Sensorsysteme zum Einsatz. Zentral sind eine **Inertialmesseinheit** (IMU) am Fahrzeug zur Lageerfassung und eine **Kamera** zur optischen Fahrwegdetektion. Ergänzend liefern **Motorsensoren** (Encoder) an den Achsen Messgrößen wie Lenk- und Raddrehwinkel. Die IMU versorgt den inneren schnellen Regelkreis (Balance-PID) laufend mit dem aktuellen Rollwinkel, während die Kamera den äußeren, langsamer abtastenden Regelkreis (vision-basiertes MPC) mit Spurabweichungsinformationen speist. Beide Sensorströme werden anschließend in einfacher Weise fusioniert, um die Regelgrößen an die Aktuatoren (Lenkmotor und Antrieb) auszugeben [GitHubGitHub](#). Im Folgenden werden die einzelnen Sensoren hinsichtlich physikalischer Funktion, Modellierung in Webots, Rolle im Regelkreis und Integration im Quellcode beschrieben.

3.4.1 Inertialmesseinheit (IMU)

Physikalisches Prinzip: Eine Inertial Measurement Unit (IMU) erfasst Trägheitsgrößen des Fahrzeugs, typischerweise mit kombinierter **Beschleunigungsmessung** (Accelerometer) und **Drehratensensoren** (Gyroskope) auf drei Raumachsen [27]. Durch Fusion dieser Signale – oft ergänzt um einen Magnetometer-Kompass – lässt sich die Orientierung im Raum bestimmen. Im realen Prototyp kommt z.B. der IMU-Sensor **BNO055** zum Einsatz, der intern die Rohdaten filtert und direkt **Euler-Winkel** (Roll, Pitch, Yaw) bereitstellt [3]. Die Rollachse (Seitenneigung) ist beim Fahrrad die entscheidende Stabilitätsgröße. Reale IMUs liefern diese Winkel mit begrenzter Auflösung und unterliegen Rauschen sowie Drift, was meist durch Kalibrierung und Sensorfusion kompensiert werden muss. Die Ausgaberate moderner IMUs liegt im Bereich mehrerer hundert Hertz (der BNO055 etwa ~ 200 Hz [3]), was für eine schnelle Lagekontrolle ausreicht.

IMU-Modell in Webots: Webots stellt mit dem `InertialUnit`-Knoten ein abstraktes IMU-Modell bereit, das idealisierte Orientierungsdaten liefert. Konkret berechnet und aktualisiert das `InertialUnit`-Gerät in jeder Simulationsschleife den **Kipp- und Gierwinkel** des Roboters relativ zu einem globalen Bezugssystem [27]. Im Gegensatz zu einer realen IMU entfallen hier Kalibrierfehler und Rauschen – die Simulation liefert die Orientierungswinkel also praktisch **fehlerfrei und ohne Drift**. Das im Webots-Weltmodell definierte Gerät `imu` ist starr im Fahrradrahmen verbaut (an geeigneter Position, etwa nahe dem Schwerpunkt) und gibt standardmäßig Roll-, Pitch- und Yaw-Winkel in Radiant aus. Die Abtastung erfolgt synchron mit dem physikalischen Simulationsschrittschritt. Im vorliegenden Modell ist der `basicTimeStep` der Welt auf 2 ms gesetzt [15], was einer Messfrequenz von 500 Hz entspricht. Dadurch können selbst schnelle Kippbewegungen des Fahrrads in Echtzeit erfasst werden [15].




Figure 4: IMU-Knoten in Webots.

Rolle im Regelkreis: Der IMU-Sensor bildet die zentrale **Rückführung** für die **Balance-Regelung**. In jedem Simulationsschritt liest der PID-Regler den aktuellen Rollwinkel φ_{roll} aus der IMU und berechnet daraus die Stellgröße für den Lenkantrieb. Konkret fungiert der Rollwinkel als *Regelgröße* im inneren Regelkreis: weicht das Fahrrad nach links/rechts ab, soll durch einen entsprechenden Lenkeinschlag gegengesteuert werden, bis $\varphi_{\text{roll}} = 0$ (senkrechte Lage) erreicht ist. Die hohe Abtastrate der IMU erlaubt es, den **Regelkreis mit einer Zykluszeit von 2 ms** praktisch verzögerungsfrei zu schließen. Dadurch reagiert der PID-Regler sehr schnell auf Lageänderungen, was eine Grundvoraussetzung ist, um das instabile überhaupt beherrschen zu können. Im äußeren (vision-basierten) Regelkreis spielt die IMU direkt keine Rolle, allerdings fließen die Balancierinformationen indirekt ein, wenn die Vision-Steuerung, z. B. die Fahrgeschwindigkeit reduziert, sobald der Stabilitätsfaktor sinkt (starke Schräglage detektiert). Insgesamt sorgt die IMU dafür, dass die **Regelstrecke** mit hoher Güte beobachtet wird, und bildet so das Fundament der Stabilisierung.

Im C-Controller `balance_control.c` wird die IMU über die Webots-API initialisiert und ausgelesen. Listing 1 zeigt auszugsweise, wie das Gerät referenziert, aktiviert und genutzt wird. Zunächst wird der Device-Tag der IMU mit ihrem Namen `"imu"` angefordert und das Sensor-Sampling mit dem Simulationstimestep (2 ms) eingeschaltet. In der Hauptschleife ruft der Regler dann kontinuierlich die Funktion `wb_inertial_unit_get_roll_pitch_yaw()` auf, welche einen Vektor der Winkel zurückliefert. Der Rollwinkel (Index 0 des Arrays) wird extrahiert und in die Regelung eingespeist. Da die Webots-IMU per se idealisiert ist, entspricht dieser Winkel exakt der aktuellen Fahrzeugneigung ohne Messfehler. Im Code ist dennoch ein Fallback vorgesehen: Falls der Supervisor-Knoten verfügbar ist, wird alternativ dessen Orientierungsmatrix ausgewertet – dies diene experimentell der Verifikation der IMU-Daten und kann die gleiche Information liefern. Im Normalfall nutzt der

PID jedoch direkt die IMU-Daten. Der exemplarische Code zeigt, wie einfach die Orientierung in Webots abgefragt werden kann, verglichen mit einer realen IMU (wo man per I²C erst Rohdaten lesen und konvertieren müsste). Die geringe Latenz der `wb_inertial_unit_get_roll_pitch_yaw`-Funktion (nur ein Zeiger auf interne Simulationsdaten) trägt dazu bei, dass der Balance-Regelkreis praktisch ohne zusätzliche Verzögerung arbeitet.

Listing 2: IMU-Initialisierung und -Abfrage im C-Controller (Balance-Regelung)

```

1 // IMU-Geraet initialisieren (in init_devices)
2 imu_sensor = wb_robot_get_device("imu");
3 wb_inertial_unit_enable(imu_sensor, timestep); // Abtastrate = Welt-Zeitschritt (2 ms)
4
5 // ... (im Hauptprogramm der Balance-Regelung)
6
7 // Roll-, Pitch- und Gierwinkel vom IMU-Sensor abrufen
8 const double *rpy = wb_inertial_unit_get_roll_pitch_yaw(imu_sensor);
9 double roll_angle = rpy[0]; // aktueller Rollwinkel [Bogenmass]
10

```

3.4.2 Kamera (Videosensor)

Physikalisches Prinzip: Die Kamera dient als **optischer Sensor**, um die Strecke vor dem Fahrrad zu erkennen. Physikalisch basiert sie auf einem *digitalen Bildaufnehmer* (z.B. CMOS-Sensor), der durch eine Linse abgebildetes Licht in Pixelwerte umwandelt. In einem realen System würde eine am Fahrzeug montierte Weitwinkel-Kamera laufend **Videobilder** der Fahrbahn liefern. Wesentliche Parameter sind die **Auflösung** (Anzahl Pixel, bestimmt Detailgenauigkeit) und die **Bildrate** (Bilder pro Sekunde, bestimmt zeitliche Auflösung). Für eine stabile Spurhaltung in Echtzeitanwendungen genügen in der Regel zweistellige Bildfrequenzen ($\sim 10\text{--}30\text{ Hz}$), sofern das Fahrzeug nicht extrem schnell fährt. Die Kamera erfasst visuelle Merkmale der Umgebung – im vorliegenden Kontext insbesondere die **Straßenmarkierung** bzw. den Verlauf der Fahrspur – die dann von Bildverarbeitungsalgorithmen ausgewertet werden. Physikalisch können **Umgebungs-faktoren** wie Beleuchtung, Bewegungsunschärfe oder Linsenverzerrungen die Bildqualität beeinflussen, was eine robuste **Merkmalsextraktion** herausfordernd macht. Im Gegensatz dazu operiert eine Kamera jedoch **kontaktlos** und kann reichhaltige Umgebungsinformationen liefern, was sie ideal für die **Pfadführung** macht (im Vergleich zu z.B. lokalen Sensorsignalen eines Gyroskops).

Simulation in Webots: Webots simuliert Kameras über den **Camera-Node**, der virtuelle Renderings der 3D-Szene erzeugt. Im *Weltfile* ist für den Supervisor (die übergeordnete Instanz) eine Kamera mit definierter Position, Ausrichtung und Eigenschaften eingebettet. Diese sogenannte *Vision-Kamera* blickt aus erhöhter Perspektive nach vorne unten auf die Fahrbahn (vergleichbar mit einer Helm- oder Drohnenkamera, die dem Fahrrad folgt). Die in der Simulation gewählte Auflösung beträgt z.B. 640×360 Pixel bei einem Gesichtsfeld von ca. 114° (Field of View $\approx 2.0\text{ rad}$). Diese Einstellungen sind ein Kompromiss zwischen Sichtfeld und Bilddetail – ein breites Sichtfeld erfasst die S-Kurve vollständig, während die moderate Auflösung die Datenmenge und Rechenzeit begrenzt. Die Kamera liefert pro aktiviertem Zeitschritt ein Bild im **RGBA-Format** (Rot–Grün–Blau plus Alphakanal) als Array von Byte-Werten. In der Controller-Software muss die Kamera explizit aktiviert werden, wobei die Abtastrate frei wählbar ist. Der Vision-Controller nutzt eine Bildrate von rund 20 Hz, entsprechend einem Abtastintervall von 50 ms. Dies ist deutlich langsamer als der Balance-Regelkreis, spiegelt aber die realistische Anforderung wider, dass Bildverarbeitung

zeitaufwändiger ist und nicht in jedem Simulationsschritt erfolgen muss. Im Webots-Code wird die Kamera z. B. mit `camera.enable(50)` konfiguriert, sodass alle 50 ms ein neues Frame bereitgestellt wird. Jedes Frame kann vom Controller über `camera.getImage()` abgeholt und weiterverarbeitet werden. Zu beachten ist, dass Webots standardmäßig keine Kameraräusche oder Sensorschwächen simuliert – die gelieferten Bilder sind idealisiert (scharf, bei gleichbleibender Beleuchtung). Um Realismus zu erhöhen, könnten optional Rauschen oder Unschärfe simuliert werden; im gegebenen Modell wird jedoch auf eine idealisierte Spurenerkennung abgezielt.




Figure 5: Kamera-Knoten in Webots.

Rolle im Regelkreis: Die Kamera ist der **Schlüsseingang** für den vision-basierten äußeren Regelkreis. Ihre Aufgabe besteht darin, dem **MPC-Fahrtrichtungsregler** Informationen über den Verlauf der Fahrspur relativ zum Fahrzeug zu liefern. Im konkreten Szenario der S-Kurve extrahiert der Vision-Controller aus jedem Kamerabild den lateralen Positionsfehler e der Straße: also wie weit und in welche Richtung das Fahrrad von der gewünschten Spurmitte abweicht.

Diese Bildverarbeitung geschieht in mehreren Schritten:

1. **Merkmalsextraktion:** Zunächst werden relevante Bildmerkmale berechnet, etwa mittels **Segmentierung** der Straße. Im Projekt wurde hierzu ein vortrainiertes YOLO-Modell verwendet, das die Fahrbahn in der Vogelperspektive segmentiert. Falls kein KI-Modell verfügbar ist, greift ein Fallback auf klassische Bildverarbeitung: Kantenerkennung und Auswertung eines definierten *Region-of-Interest* liefern ebenfalls einen Schätzwert für die Spurmittellage. Ergebnis dieses Schritts ist der Querfehler e (in normierter Form, z. B. $-0.5 \dots + 0.5$ relativ zur Bildmitte) sowie ggf. zusätzliche Qualitätskennzahlen (etwa die erkannte Kontur oder den Bedeckungsgrad der Fahrbahnmaske).
2. **Spurführungsregelung:** Auf Basis des visuellen Fehlers bestimmt der Controller einen passenden **Lenksollwert**. Im entwickelten System kommt hierfür vorzugsweise ein **modell-prädiktiver Regler (MPC)** zum Einsatz, der das Fahrrad als dynamisches Modell (Zustand $\mathbf{x} = [x, y, v, \psi]$) vorausberechnet. Der MPC optimiert die Steuergröße Lenkwinkel δ (und ggf. Beschleunigung) über einen kurzen Zeithorizont so, dass der Querfehler minimiert und Fahrdynamikgrenzen (Lenkwinkel- und -ratenbegrenzung, Komfort) eingehalten werden.

Falls der MPC (etwa mangels Rechenpower) nicht verfügbar ist, kann ersatzweise ein einfacherer PID-Ansatz verwendet werden („*Vision-PID*“), der den Fehler e in einen Lenkwinkel

übersetzt. In beiden Fällen resultiert ein Soll-Lenkswinkel δ_{sol} bzw. ein normierter Lenkbefehl $u_{\text{vis}} \in [-1, 1]$, der an den Balance-Controller gesendet wird.

Zusätzlich kann die Vision-Einheit eine **Geschwindigkeitsempfehlung** v_w berechnen – z. B. wird bei großem Kurvenfehler eine niedrigere Fahrgeschwindigkeit empfohlen, um die Stabilität zu wahren.




Figure 6: Querfehler e der Straße.

Die Kamera beeinflusst den Balance-Regler auch indirekt, indem deren Messdaten den **Kurs der Fahrt** vorgeben. Wichtig ist, dass die Vision-Daten mit deutlich geringerer Frequenz ankommen als die IMU-Daten. Der Balance-Controller hält während der 50 ms zwischen zwei Kamerabildern die zuletzt empfangene Soll-Lenkvorgabe bei und stabilisiert weiterhin autonom. Sobald ein neues Bild ausgewertet ist, wird der Lenksollwert ggf. korrigiert. Dieses **zweistufige Regelungskonzept** (innere IMU-Schleife, äußere Vision-Schleife) sorgt dafür, dass das Fahrrad einerseits aufrecht bleibt, andererseits aber auch aktiv Richtungskorrekturen vornimmt, um einer kurvigen Referenzstrecke zu folgen. Ohne die Kamera wäre nur ein statisches Balancieren oder eine Geradeausfahrt möglich – erst der optische Sensor ermöglicht die *spurtreue Autonomie* des Modells.

3.4.3 Motorsensoren (Inkrementalgeber)

Physikalisches Prinzip: Neben IMU und Kamera, die den *Zustand* des Fahrzeugs in Bezug auf Lage und Umwelt erfassen, spielen sogenannte **Motorsensoren** eine wichtige Rolle für die interne Zustandsmessung. Gemeint sind hier **Winkelgeber (Encoder)** an den drehbaren Komponenten – konkret am Lenkmotor und am Antriebsrad. Physikalisch handelt es sich meist um *inkrementelle Drehgeber*, die auf der Motorachse montiert sind und pro Umdrehung eine bestimmte Anzahl Impulse (Zählschritte) liefern. Durch Mitzählen der Impulse kann der Steuerrechner den zurückgelegten Winkel bestimmen; über die Impulsfrequenz lässt sich auch die Drehgeschwindigkeit ermitteln. In echten Systemen werden beispielsweise **optische Encoder** (eine Scheibe mit Strichmuster und Fotodetektor) oder **Hall-Sensoren** (Magnet und Hallsensor für Umdrehungszählung) eingesetzt. Im Kontext unseres selbstbalancierenden Fahrrads wird der Lenkwinkel-Encoder benötigt,

um den aktuellen **Lenkeinschlag** zu kennen – wichtig etwa, um Lenkwinkelgrenzen nicht zu überschreiten und für die protokollierte Ausgabe. Der Hinterrad-Encoder erfasst die **Raddrehstellung** bzw. via Differenz auch die momentane Raddrehzahl, was zur Abschätzung der Fahrgeschwindigkeit dient. Physikalisch sind solche Sensoren sehr präzise (hochaufgelöste Encoder bieten > 1000 Impulse/Umdrehung) und liefern in schneller Abfolge Signale, typischerweise synchron zum Motor (Erfassung erfolgt im kHz-Bereich, Latenzen sind vernachlässigbar). Allerdings muss die Ansteuerungselektronik die Impulse auswerten (Interrupts zählen etc.), was in der realen Implementierung zusätzlichen Programmieraufwand bedeutet.

Rolle im Regelkreis: Die Positionssensoren werden vor allem zur **Überwachung und für abgeleitete Regelungsgrößen** genutzt. Der **Lenkwinkelsensor** gibt dem Balance-Controller Feedback, welchen Lenkeinschlag der Motor aktuell realisiert – dies ist nützlich, um z. B. einen *Sättigungseffekt* zu erkennen: Wenn der Soll-Lenkwinkel die mechanische Grenze erreicht, kann der Regler keine weitere Korrektur mehr bewirken. Im Code wird aus dem Verhältnis von aktuellem Lenkausschlag zu Maximalwinkel ein **Stabilitätsfaktor** berechnet, der als Indikator dient. Außerdem fließt der gemessene Lenkwinkel in die Logging-Daten ein, um das Reglerverhalten nachträglich analysieren zu können. Im laufenden Regler steckt der Lenkwert implizit schon in der Dynamik: Da der Lenkmotor in Webots im Positionsmodus betrieben wird, sorgt das System automatisch dafür, dass der Ist-Winkel dem Soll-Winkel folgt (siehe Abschnitt *Aktuatoren*). Ein separater Positionsregelkreis ist im Code also nicht implementiert – im realen System würde hier ein unterlagerter Motor-PID am Encoder hängen, aber in der Simulation übernimmt dies der Motorendpunkt.




Figure 7: Sensor- und Aktuator-API in Webots.

Der **Raddrehwinkelsensor** am Hinterrad wird primär genutzt, um die **Fahrgeschwindigkeit** zu ermitteln. Im Controller-Code wird aus der zeitlichen Differenz des Radwinkels $\Delta\theta/\Delta t$ die Winkelgeschwindigkeit ω berechnet und in km/h umgerechnet. Diese Information kann für verschiedene Zwecke dienen: einerseits zur **Ausgabe** (Anzeige der aktuellen Geschwindigkeit), andererseits könnte sie in einen Geschwindigkeitsregler zurückwirken. Tatsächlich wird im Balance-Controller ein einfacher Speed-Controller benutzt, der allerdings nicht die Ist-Geschwindigkeit, sondern den Vision-Lenkbefehl als Stellgröße nutzt (d. h. bei starkem Lenken wird die Sollgeschwindigkeit reduziert). Eine echte geschlossene Geschwindigkeitsregelung (Fahrgeschwindigkeit konstant halten) wäre ebenfalls denkbar – hierzu würde der Rad-Encoder den Ist-Wert für einen Geschwindigkeits-PID liefern, ähnlich wie im Hardware-Design mit Hall-Sensor beschrieben. Im aktuellen Simulationsmodell beschränkt sich die Nutzung also darauf, **Zustandsgrößen** zu erfassen und die Regelung zu überwachen, weniger auf direkte Korrektur. Dennoch sind die Encoder essenziell, um konsistente Zustandsinformationen zu haben: z. B. ermöglicht der Radencoder dem System zu erkennen, ob das Fahrrad fährt oder fast steht, was für die Balance eine Rolle spielen kann (bei zu niedriger Geschwindigkeit nimmt die Selbststabilisierung ab).

3.5 Aktuatoren

Das selbstbalancierende Fahrradmodell verfügt über zwei zentrale **Aktuatoren**, die als Stellglieder in die Dynamik des Systems eingreifen: einen **Lenkantrieb** an der Vorderradgabel und einen **Antriebsmotor** für das Hinterrad. Beide sind in Webots als **RotationalMotor**-Geräte realisiert und jeweils an einem drehbaren HingeJoint angebracht. Physikalisch handelt es sich um **elektrische Rotationsmotoren** (Gleichstrommotoren mit Getriebe), die in der Lage sind, Drehmomente aufzubringen und so entweder einen bestimmten Winkel (Servomodus) oder eine bestimmte Drehgeschwindigkeit einzustellen. Im Folgenden werden zunächst die realen Grundlagen dieser Aktuatoren betrachtet, dann ihre Umsetzung in der Simulation und schließlich ihr konkreter Einsatz im Regelungssystem mitsamt Code-Beispielen erläutert.

Physikalisches Wirkprinzip:

Bei **bürstenbehafteten DC-Motoren**, wie sie in vielen Robotikanwendungen Verwendung finden, erzeugt ein stromdurchflossener Anker in einem Magnetfeld ein Drehmoment (Lorentz-Kraftwirkung auf die Leiter). Das resultierende **Motordrehmoment** ist annähernd proportional zum Ankerstrom, während die Leerlauf-Drehzahl von der angelegten Spannung bestimmt wird. Im offenen Regelkreis würde ein DC-Motor also schneller drehen bei höherer Spannung und stärker drehen (mehr Kraft) bei höherem Strom.

Um präzise **Stellbewegungen** auszuführen, werden Motoren oft mit **Getrieben** (zur Erhöhung von Drehmoment und Auflösung) und mit **Sensoren** rückgekoppelt (Encodern, s. o.). So entsteht ein **Servoantrieb**: ein Motor-Getriebe-System mit interner Positions- oder Drehzahlregelung. Im realen selbstbalancierenden Fahrrad gibt es zwei solcher Antriebe:

- **Der Lenkmotor** (z. B. ein Getriebemotor mit MD49-Motorcontroller) verstellt den Lenkerwinkel. Er arbeitet im Prinzip als **Positionsantrieb**: auf einen Sollwinkel hin geregelt, mit einem begrenzten Arbeitsbereich (hier ca. $\pm 30^\circ$ mechanisch). Der Motorcontroller nutzt den Encoder am Lenkgetriebe, um den Winkel exakt einzustellen (geschlossener Regelkreis). Physikalisch bedeutet dies, dass bei Abweichung zwischen Soll- und Ist-Winkel ein proportional-integral-derivativer Korrekturstrom ins Motortreiber-Modul gegeben wird, bis der Lenker die gewünschte Position erreicht. Der Lenkwinkelantrieb muss schnell und kräftig genug sein, um das Fahrrad innerhalb von Sekundenbruchteilen stabilisieren zu können – in Jonah Zanders Hardware-Aufbau wurde z. B. ein starker 12 V-Motor mit Untersetzung verwendet, der $\pm 150^\circ$ in kurzer Zeit durchfahren kann.
- **Der Antriebsmotor** am Hinterrad (z. B. ein Nabenmotor oder kettengetriebener DC-Motor) sorgt für den Vortrieb. Dieser wird im Unterschied zum Lenker meist als **Drehzahl- bzw. Drehmomentantrieb** betrieben. Im realen System regelt man hier oft die Geschwindigkeit: Ein separater PID hält die Raddrehzahl konstant, indem er den Motorstrom anhand des Hall-Encoder-Feedbacks justiert. Physikalisch verleiht das rotierende Hinterrad dem System einen **gyroskopischen Effekt**, der stabilisierend wirkt, weshalb eine gewisse Grundgeschwindigkeit hilfreich ist. Gleichzeitig muss der Motor aber auch schnell drosseln oder bremsen können, um Kurven sicher zu durchfahren, ohne umzukippen.

Webots-Umsetzung: Webots stellt mit dem `RotationalMotor`-Node einen Aktuator zur Verfügung, der an einen `HingeJoint` gekoppelt Drehmomente ausüben kann. Im Hintergrund berechnet der Physik-Kernel (ODE) die Wirkung des Motors auf das Gelenk unter Berücksichtigung von Maximalmoment und Zielvorgabe. Jeder Rotationsmotor kann in drei Modi betrieben werden:




Figure 8: Aktuatoren im Fahrradmodell.

- **Positionsmodus:**

Der Motor strebt einen vorgegebenen Zielwinkel an (`setPosition(angle)`), wobei er innerhalb der konfigurierten Kraft- und Geschwindigkeitsgrenzen das nötige Drehmoment erzeugt, um diesen Winkel zu erreichen. Dieser Modus entspricht einem Servomechanismus. Im Webots-Modell ist der Lenkungsaktor in den Positionsmodus geschaltet. Dazu wird im Code einmalig `wb_motor_set_position(handlebars_motor, 0.0)` aufgerufen, um die Start-Sollposition (geradeaus) zu setzen. Anschließend erhält der Lenkmotor in jeder Regeliteration einen neuen Sollwinkel. Die Regelung der Position übernimmt Webots intern: der Motor wirkt wie eine Feder-Dämpfer-Kopplung ans Gelenk, die Differenz zwischen Ist- und Sollwinkel generiert ein entsprechendes Gegendrehmoment (virtueller P-Regler). Parameter wie `maxTorque` und `maxVelocity` im Weltfile bestimmen, wie schnell und kräftig das Soll nachgeführt wird. Im Modell sind z.B. für den Lenkmotor `maxTorque = 25Nm` festgelegt – ein Wert, der sicherstellt, dass genügend Kraft zum Aufrichten aus Schräglagen vorhanden ist, ohne das System zu unrealistisch zu machen.

- **Geschwindigkeitsmodus:**

Hier wird dem Motor eine Ziel-Angulargeschwindigkeit vorgegeben (`setVelocity(omega)`), während die Position auf unendlich gesetzt wird (`setPosition(INFINITY)`). In Webots bedeutet dies, dass der Motor keinen festen Endwinkel hat, sondern kontinuierlich dreht. Der Antriebsmotor des Hinterrads wird so betrieben: im Initialisierungscode wird `wb_motor_set_position(wheel_motor, INFINITY)` aufgerufen, was den Wechsel in den Geschwindigkeitsmodus bewirkt. Fortan interpretiert Webots den Befehl `wb_motor_set_velocity(wheel_motor, v)` als Soll-Drehzahl (in Rad/s) für das Rad. Intern wirkt wieder ein virtueller Regler, der das nötige Drehmoment aufbringt, um diese Geschwindigkeit zu erreichen/halten (bis zum max. Drehmoment). Im Weltmodell ist für den Hinterradmotor ein recht hohes maximales Drehmoment von 120Nm erlaubt, um Beschleunigungsvorgaben schnell umsetzen zu können. Allerdings ist die erreichbare Drehzahl in der Praxis auch durch die Antriebsspannung bzw. Webots-Parameter

`maxVelocity` limitiert. In S-Kurven-Simulationen wurde typischerweise eine Grundgeschwindigkeit von ca. 3–5 m/s gefahren, was durch den entsprechenden `velocity`-Wert in Rad/s vorgegeben wird.

- **Kraft-/Drehmomentmodus:** Alternativ kann man in Webots Motoren auch direkt ein Drehmoment vorgeben (`setTorque(t)`), um z. B. eigene Regelalgorithmen für die Positions- und Geschwindigkeitssteuerung umzusetzen. In unserem Modell wird dieser Modus nicht explizit genutzt, da die beiden in Steuerungsmodellen gängigen Modi bereits ausreichen. Dennoch ist es wichtig zu wissen, dass Webots stets mit Kräften/Momenten rechnet: Die Position- und Velocity-Modelle setzen letztlich ein solches Drehmoment um, das aus der jeweiligen Referenzgröße berechnet wird.

Die beiden Motoren sind im Weltfile als Geräte `handlebars motor` und `motor::wheel` deklariert und jeweils dem passenden HingeJoint zugeordnet. Webots erlaubt es, mehrere Motoren pro Gelenk zu definieren, doch hier ist jeweils nur einer aktiv.

Die Namensgebung `motor::wheel` für den Hinterradantrieb ist ein Spezialfall: Das Präfix `::` dient dazu, den Motor vom gleichnamigen (per DEF) vorderen Rad zu unterscheiden, welches ebenfalls als `wheel` benannt ist – so können Kollisionen in der Namensauflösung vermieden werden. Im Controller-Code greift man dann genau mit diesem Namen zu.

Rolle im Regelkreis

Die Aktuatoren setzen die vom Regler berechneten Sollgrößen in physikalische Bewegung um und schließen damit die **Wirkkette des Regelkreises**. Konkret berechnet der Balance-Controller in jedem Zeitschritt zwei Stellwerte:

- den **Lenksollwinkel** δ_{sol} (aus dem PID-Regler + Vision-Überlagerung), und
- die **Antriebs-Sollgeschwindigkeit** v_{sol} .

Diese Sollwerte werden direkt an die Motoren übergeben. Der Lenkwinkel-Sollwert stammt aus der Kombination des inneren und äußeren Regelkreises: Wie in Abschnitt *Sensoren* erläutert, fusioniert der Controller den **Balance-Anteil** (zur Selbstausrichtung) mit dem **Vision-Anteil** (zur Kurvenfahrt) zu einer endgültigen Vorgabe `final_steer`. Dieses `final_steer` entspricht einem Winkel in Radiant, der begrenzt auf den physikalisch möglichen Bereich (± 0.524 rad) an den Lenkmotor geschickt wird.

Der Hinterrad-Sollwert `target_speed` wird ebenfalls bestimmt – im aktuellen Konzept abhängig vom Lenkeinschlag (starker Lenkeinschlag $\rightarrow$ automatische Reduktion der Grundgeschwindigkeit). Damit fungiert der Balance-Controller gleichzeitig als einfacher **Geschwindigkeitsmanager**, der z. B. in Kurven abbremst, um die Balance nicht zu gefährden. Die Berechnung von `target_speed` erfolgt durch einen separaten Algorithmus (`speed_pid_compute`), der den Vision-Lenkbefehl in eine prozentuale Reduktion der Grundgeschwindigkeit umsetzt. Alternativ könnte hier ein echtes Geschwindigkeits-PID auf Basis der Encoder-Daten stehen – dies ist eine mögliche Erweiterung.

Sobald die Stellgrößen vorliegen, werden sie an die Motor-API übergeben. Damit findet die **Regler-Ausgabe** statt: Die Software schreibt die Sollwerte in die Motoren, und die Physiksimulation reagiert, indem sie die entsprechenden Kräfte auf das Modell einleitet.

Der **Lenkmotor** dreht die Vorderradgabel proportional zum Regelfehler – wenn das Fahrrad z. B. nach rechts kippt (positiver Rollwinkel), verlangt der PID einen Lenkeinschlag nach rechts, um einen stabilisierenden Lenkimpuls zu erzeugen (das Rad wird unter den Schwerpunkt gesteuert, ähnlich wie man einen fallenden Besen durch Vorziehen stabilisiert). Gleichzeitig berücksichtigt der Vision-Anteil, ob ggf. bewusst in eine Kurve gelenkt werden soll. Die resultierende Motorbewegung ist somit eine Überlagerung aus Stabilisieren und Navigieren.

Der **Hinterradmotor** liefert währenddessen den Vortrieb: Eine Grundgeschwindigkeit hält das Fahrrad in Bewegung (was das Balancieren erleichtert, da dynamische Stabilisierungskräfte wirken), und bei Bedarf wird verlangsamt. Im Geradeausfall (Vision inaktiv) regelt der Balance-Controller sogar nur die Balance und reduziert Geschwindigkeit auf ein Mindestmaß, falls keine Steuerkommandos kommen.

Insgesamt sorgen die Aktuatoren dafür, dass die vom Regler vorgegebenen Stellgrößen (Lenkwinkel, Antriebskraft) tatsächlich umgesetzt werden – sie sind somit die finalen Ausführungselemente des Reglers. Ohne ausreichende Aktuatorleistung könnte das beste Regelgesetz das Fahrrad nicht stabilisieren; in der Simulation sind sie jedoch so gewählt, dass die Anforderungen erfüllt werden.

Implementierung und Code-Integration: Die Ansteuerung der Motoren erfolgt im Balance-Controller (C-Code) nach Berechnung der Sollwerte. Bereits während der Initialisierung werden die Motoren konfiguriert: Listing 4 zeigt, wie der Lenkmotor und der Radmotor als Devices geholt und in die gewünschten Modi versetzt werden. Für den Lenkantrieb wird die Position initial auf 0.0 gestellt (*Lenker gerade*). Für den Hinterradantrieb wird `wb_motor_set_position(wheel_motor, INFINITY)` gesetzt, was – wie oben beschrieben – den Geschwindigkeitsmodus aktiviert. Beide Motoren würden standardmäßig mit `velocity = 0` starten; der Hinterradmotor erhält später im laufenden Betrieb eine Startgeschwindigkeit (Basiswert).

Im Regelprozess selbst (Hauptschleife) werden dann die aktuellen Stellbefehle übergeben:

Listing 3: Motorsteuerung im Regelkreis

```
wb_motor_set_position(handlebars_motor, -final_steer);  
wb_motor_set_velocity(wheel_motor, target_speed);
```

Dabei ist wichtig zu erwähnen, dass der Lenkwinkel mit negativem Vorzeichen gesetzt wird. Dies rührt von der Achsdefinition her – je nach Koordinatensystem ist eine positive Rotation der Lenkachse evtl. als Linkseinschlag definiert, während der Regler positive Werte als Rechtsdrehung interpretiert (oder umgekehrt). Durch das Vorzeichen wird sichergestellt, dass z. B. ein positiver Reglerausgang (Korrektur nach rechts) tatsächlich den Lenker nach rechts steuert. Solche Vorzeichenkonventionen sind in der Modellierung zu beachten.

Der Wert `target_speed` wird in Rad/Sekunde an das Hinterrad übergeben. Um einen Eindruck zu geben: Eine Zielgeschwindigkeit von z. B. 4 m/s entspricht (bei ~ 0.7 m Raddurchmesser) ungefähr 11.4 rad/s Winkelgeschwindigkeit.

Das Logging im Code zeigt typischerweise Werte um 10–15 rad/s für die Grundgeschwindigkeit. Nachdem die Sollwerte gesetzt sind, greift die Webots-Physik die neuen Sollwerte im nächsten Zeitschritt auf und beschleunigt/verstellt die Motoren entsprechend. Im Code werden nach dem Setzen der Motoren noch Statuspakete versendet und Logging betrieben, was für die Aktuatorwirkung selbst aber keine Rolle mehr spielt.

Insgesamt ist die Motoransteuerung in Webots sehr direkt – ein Funktionsaufruf genügt, um das physikalische Stellglied zu beeinflussen. Dies erlaubt es, die Regelalgorithmen unkompliziert mit der

Simulationswelt zu koppeln. Listing 4 fasst die wichtigsten Schritte zusammen. Hier sind sowohl die Initialisierung (Modussetzen) als auch die Laufzeitschleifen der Motoren zu sehen, mit deutschen Kommentaren erläutert. Man erkennt, wie die Aktuator-Schnittstelle an die zuvor beschriebenen Regelungsgrößen gebunden ist: `final_steer` (in rad) geht an den Lenkmotor, `target_speed` (in rad/s) an den Radmotor. Diese Werte stammen direkt aus der Regelung (siehe vorherigen Abschnitt) – es findet keine weitere Transformation mehr statt, da die Größeneinheiten konsistent mit dem Webots-Modell gewählt wurden.

```

1 // Motoren-Devices abrufen
2 handlebars_motor = wb_robot_get_device("motor::handlebars");
3 wheel_motor      = wb_robot_get_device("motor::wheel");
4 if (handlebars_motor == 0 || wheel_motor == 0) {
5     exit(1);
6 }
7 // Initialisierung der Motoren
8 // Lenkmotor: Positionsmodus, Startwinkel = 0 rad
9 wb_motor_set_position(handlebars_motor, 0.0);
10 // Hinterradmotor: Geschwindigkeitsmodus aktivieren
11 wb_motor_set_position(wheel_motor, INFINITY);
12 // (Velocity bleibt zunaechst 0, wird spaeter gesetzt)
13
14 //...(im Reglerloop, nach PID/MPC-Berechnung von final_steer/target_speed)
15
16 // Lenkantrieb: Soll-Lenkwinkel setzen
17 wb_motor_set_position(handlebars_motor, -final_steer);
18 // Radantrieb: Soll-Drehgeschwindigkeit setzen
19 wb_motor_set_velocity(wheel_motor, target_speed);

```

Listing 4: IMU-Initialisierung und -Abfrage im C-Controller (Balance-Regelung)

Durch diese Implementierung wird das Zusammenwirken aller Komponenten deutlich: **Sensoren** (IMU, Kamera, Encoder) liefern den aktuellen Zustand, der **Regler** (PID & MPC) berechnet daraus Stellgrößen, und die **Aktuatoren** (Motoren) führen diese Stellgrößen am physikalischen Modell aus. Die Webots-Simulation ermöglicht es, all dies in einem deterministischen Umfeld zu testen – etwaige Fehlanpassungen (wie zu schwache Motoren oder unzureichende Sensorfrequenzen) würden sofort im Verhalten sichtbar und könnten iterativ justiert werden, bevor der Algorithmus auf einen realen Prototyp übertragen wird.

3.6 Controller

Ein Webots-Controller ist ein separates Programm (Prozess), das einen Roboter in der Simulation steuert und über eine definierte API mit der Simulationswelt kommuniziert. Für jeden Roboter kann ein Controller in C/C++, Python, Java oder MATLAB laufen, wobei Webots den Datenaustausch (Sensorwerte, Aktuatorbefehle) bei jedem Simulationsschritt synchronisiert. Typischerweise durchläuft ein Controller eine Endlosschleife, in der er Sensoren liest, Berechnungen durchführt und Aktuatoren ansteuert, wobei am Ende jeder Iteration die Funktion `wb_robot_step()` aufgerufen werden muss. Dieser Aufruf übergibt die gewünschte Control-Step-Dauer (in Millisekunden) an den Simulator und bewirkt, dass Webots die Simulation um genau diesen Zeitschritt fortsetzt und dabei alle bis dahin vom Controller gesetzten Befehle anwendet. Danach erhält der Controller die aktualisierten Sensorwerte des neuen Simulationszustands zurück. Abbildung 3.6 veranschaulicht diese Synchronisation [6].

Alle Anweisungen vor dem nächsten Zeitschritt (`wb_robot_step`-Aufruf) werden zunächst gesammelt; mit dem Step-Aufruf rechnet der Simulator den nächsten Physikschrift und aktualisiert die Sensoren, bevor der Controller weiterläuft. Auf diese Weise laufen Simulation und Controller *synchron* in gleichmäßigen Zeitschritten. Standardmäßig wartet Webots in diesem synchronen Modus darauf, dass jeder Controller seinen `wb_robot_step` ausführt, bevor der nächste Simulationsschritt erfolgt. Dies garantiert Konsistenz, erlaubt aber auch differierende Abtastraten: Der Kontrollschritt muss ein ganzzahliges Vielfaches des Simulations-Basischritts sein.

Beispielsweise kann bei einer Weltzeit-schrittauflösung von 2 ms ein Controller mit 2 ms, 10 ms oder 50 ms Schrittweite betrieben werden — Webots führt dann pro Controller-schritt entsprechend 1, 5 bzw. 25 Simulationsschritte aus und wartet am Ende ggf. auf den Controller. Diese Entkopplung nutzt Webots, um auch langsamere Controller (z. B. in Python) in eine schnelle Physiksimulation einzubetten, ohne die Synchronisation zu verlieren.

Um auf Sensoren und Aktuatoren zuzugreifen, stellt Webots gerätespezifische API-Funktionen bereit. Im C-Controller werden z. B. Geräte über `wb_robot_get_device("name")` referenziert und Sensoren mit `wb_sensor_enable()` aktiviert. Entsprechende Methoden existieren in Python (`robot.getDevice()`, `device.enable()`). Ein Sensor liefert erst ab dem nächsten `wb_robot_step()` gültige Messwerte, da die Simulationszeit dann fortgeschritten ist.

Aktuatorbefehle (z. B. `wb_motor_set_position()`

oder `motor.setPosition()` in Python) werden zunächst lokal gepuffert—die tatsächliche Ausführung in der Physik-Engine erfolgt erst am nächsten Step-Synchronisationspunkt. Daher ist es sinnlos, in derselben Schleifeniteration zwei unterschiedliche Positionen für denselben Motor zu setzen: Nur der zuletzt vor `wb_robot_step()` gesetzte Wert wird im kommenden Schritt ausgeführt. Ebenso bleiben zwei unmittelbar nacheinander gelesene Sensorsamples identisch, solange kein Simulationsschritt dazwischen liegt. Dieses deterministische Schritt-für-Schritt-Ausführungsmodell erleichtert die Reproduzierbarkeit und verhindert *race conditions* zwischen Physik und Reglercode.

Für das selbstbalancierende Fahrrad wurden zwei Controller-Prozesse implementiert, die in Webots zeitgleich laufen und über die oben beschriebene Mechanik gekoppelt sind: Einerseits der *Balance-Controller* auf dem Fahrrad (in C, hoher Takt), andererseits ein *Vision-Controller* auf




Figure 9: Synchronisation zwischen Controller und Simulation.

einem Supervisor-Knoten (in Python, langsamer Takt). Die Welt ist so konfiguriert, dass das Fahrrad einen **Receiver** und einen **Emitter** trägt, während der Supervisor das komplementäre Gegenstück besitzt; damit entsteht ein bidirektionaler Nachrichtenkanal innerhalb der Simulation:

```

1  Robot {
2      Controller "balance_control_c"
3      Receiver { name "command_rx" channel 1 bufferSize 64 }
4      Emitter { name "status_tx" channel 2 bufferSize 64 }
5  }
6  Supervisor {
7      Controller "vision_control_py"
8      Emitter { name "command_tx" channel 1 bufferSize 64 }
9      Receiver { name "status_rx" channel 2 bufferSize 64 }
10 }

```

Listing 5: Nachrichtenkanal zwischen Controller und Simulation

Über Channel 1 sendet der Vision-Controller Steuerkommandos an das Fahrrad, und über Channel 2 übermittelt der Balance-Controller seinerseits Statusdaten zurück (z.B. aktueller Rollwinkel, Lenkwinkel, Geschwindigkeit). Beide Controller laufen im *synchronen Modus*, d. h. Webots hält die Physik so lange an, bis sowohl der schnelle C-Controller (alle 2 ms) als auch der langsamere Python-Controller ihren Schritt abgearbeitet haben [7] [8]. Praktisch bedeutet dies: Der Balance-Regler berechnet bei jedem Simulationsschritt neue Motorbefehle, während der Vision-Algorithmus nur alle 25 Schritte (50 ms) ein neues Lenkkommando liefert. Die folgenden Punkte fassen Aufgaben und Interaktion zusammen:

- *Balance-Controller (C, 500 Hz)*: Liest hochfrequent IMU- (Rollwinkel) und Radsensoren aus, regelt den Balancierwinkel mittels PID und steuert den Lenkmotor sowie den Antriebsmotor kontinuierlich an. Verarbeitet eingehende Sollkommandos der Vision-Ebene (z.B. Lenkwinkel) und kombiniert sie mit dem internen Regleroutput. Sendet zyklisch seinen Status (Stabilitätsmaß, aktuelle Geschwindigkeit etc.) über den Emitter aus. Bei Ausbleiben externer Kommandos hält er das Fahrzeug selbständig im Gleichgewicht (Fallback auf reinen Balance-Modus).
- *Vision-Controller (Python, ~20 Hz)*: Läuft als Supervisor-Controller mit Zugriff auf globale Informationen. Nutzt die am Fahrzeug montierte Kamera (Bildrate ca. 20 Hz) zur Fahrbahnerkennung (z.B. YOLO-Segmentierung) und berechnet auf dieser Basis einen Trajektorien- bzw. Lenksollwert mittels modellprädiktiver Regelung (MPC) oder wahlweise eines PID. Dieses Sollkommando wird paketbasiert an den Balance-Controller gesendet (**Emitter** auf Kanal 1). Zudem überwacht der Vision-Controller den empfangenen Fahrzeugzustand (**Receiver** auf Kanal 2), um die Regelgüte zu beurteilen oder Logging durchzuführen. Gegebenenfalls passt er seine Fahrstrategie an (etwa Geschwindigkeitsanpassung bei großen Balance-Fehlern).

Durch diese Aufteilung konnte eine zweistufige Regelungsarchitektur realisiert werden: Der innere C-Regler stabilisiert das Fahrrad auf kurzen Zeitskalen autonom, während der äußere Python-Regler in größeren Abständen Kurskorrekturen vorgibt. Webots gewährleistet die Synchronisierung beider Teilprozesse, sodass Kommandos verlustfrei und deterministisch am Step-Synchronisationspunkt ausgetauscht werden. Im Ergebnis reagiert das Gesamtsystem echtzeitnah auf Störungen (Balance) und plant zugleich vorausschauend seine Fahrtrajektorie; die Kopplung konnte in der Simulation umfassend getestet und für den späteren Hardware-Einsatz vorbereitet werden.

3.7 Angebundene GUI

Die Simulationsumgebung verfügt über ein tkinter-basiertes GUI-Kontrollzentrum, mit dem sich die Regelungsparameter des selbstbalancierenden Fahrrads in Echtzeit anpassen und die Fahrdaten live überwachen lassen. Dieses GUI bietet eine benutzerfreundliche Oberfläche, um während der laufenden Webots-Simulation Einstellungen zu ändern, ohne die Simulation unterbrechen zu müssen. Es gliedert sich in mehrere Tabs, von denen insbesondere “Parameter” und “Monitoring” für die Laufzeitanpassung und -beobachtung relevant sind. Im Folgenden wird erläutert, wie diese Tabs funktionieren und wie die Laufzeitanpassung der Parameter sowie das Live-Monitoring umgesetzt sind.

Parameter-Tab - Laufzeitfähige Parameteranpassung: Der Parameter-Tab ermöglicht die direkte Einstellung der Regelungsparameter während der Simulation. Über Slider und Eingabefelder können z. B. PID-Reglergrößen (K_p , K_i , K_d) und andere Steuerungsgrößen komfortabel angepasst werden. Dabei werden die aktuellen Werte in Echtzeit im GUI angezeigt und validiert, während der Nutzer sie ändert. Einzelne Parametergruppen (etwa Winkel-PID, Geschwindigkeitsregelung, mechanische Limits) sind übersichtlich gruppiert, sodass man nicht auf die Details jedes Parameters eingehen muss, aber einen strukturierten Überblick behält.

Wesentlich ist, dass Änderungen unmittelbar wirksam werden, ohne die Simulation neu zu starten. Technisch geschieht dies durch ein SON-basiertes Konfigurationssystem im Hintergrund. Das GUI lädt zu Beginn die aktuellen Parameter aus einer Konfigurationsdatei (z. B. `balance_config.json`) und schreibt geänderte Werte bei Bedarf zurück. Wird ein Wert verändert, kann der Nutzer die neue Konfiguration speichern und anwenden (Schaltflächen “Speichern” bzw. “Anwenden” im GUI). Die laufende Regelungssoftware erkennt diese Aktualisierung dank eines Hot-Reload-Mechanismus: Der Balance-Controller lädt die JSON-Config in kurzen Intervallen oder auf Befehl neu, sodass geänderte Parameter sofort in den Regler einfließen.

Monitoring-Tab – Live-Datenvisualisierung und CSV-Logging: Im *Monitoring*-Tab werden Fahr- und Regeldaten *live* visualisiert, um das Verhalten des Fahrrads während der Simulation nachvollziehen zu können. Abbildung 9 zeigt den Monitoring-Tab mit Echtzeitdiagrammen. Der Tab bietet interaktive Plots, die zentrale Größen über der Zeit darstellen — etwa den Rollwinkel, den Lenkausgang des Reglers, die aktuelle und Ziel-Geschwindigkeit sowie die PID-Regleranteile (P, I, D). Über Auswahlkästchen kann gezielt gesteuert werden, welche Kurven angezeigt werden, um den Überblick zu behalten; beispielsweise lassen sich nur die Balance-Controller-Daten oder nur die PID-Terme ein- oder ausblenden. Zusätzlich stehen Zoom-Regler zur Verfügung, um den dargestellten Zeitraum einzugrenzen und Details zu analysieren.

Die Datengrundlage bilden CSV-Protokolldateien, die vom Balance-Controller während jeder Fahrt automatisch erzeugt werden. Jede Simulation (bzw. Fahrt) wird lückenlos in einer Log-Datei festgehalten — mit Zeitstempel und den relevanten Mess- und Steuergrößen (u. a. Winkel, Geschwindigkeiten, Reglerausgänge, Fehlerwerte). Der Monitoring-Tab listet diese Aufzeichnungen und ermöglicht sowohl das nachträgliche Laden einer aufgezeichneten CSV-Datei als auch den Live-Stream der jeweils neuesten Datei. Im Live-Modus wählt das System automatisch die aktuell von der Simulation beschriebene Log-Datei aus und aktualisiert die Plots fortlaufend; alternativ kann der Benutzer eine frühere Aufzeichnung vollständig laden und visualisieren. In beiden Fällen normalisiert das GUI die eingelesenen CSV-Daten (z. B. Umrechnung von Radmaß in Grad oder m/s in km/h) und zeichnet zweigeteilt: typischerweise erscheinen Winkel- und Lenkdaten im oberen Diagramm, die PID-Terme sowie Geschwindigkeiten im unteren, jeweils mit gemeinsamer Zeitachse.




Figure 10: Monitoring-Tab mit Echtzeitdiagrammen.

Ergänzend zur grafischen Darstellung bietet der Monitoring-Tab Statusanzeigen, die u. a. den aktuell geladenen Logfile-Namen, den Zeitpunkt der letzten Aktualisierung und den Laufzustand des Controllers ausweisen. So bleibt stets transparent, ob die Verbindung zur Simulation aktiv ist und welche Datenquelle visualisiert wird. Zusammengenommen stellt der Monitoring-Tab ein leistungsfähiges Werkzeug dar, um die Auswirkungen von Parameteränderungen sofort sichtbar zu machen und das Systemverhalten mittels aufgezeichneter Daten zu analysieren. Die Kombination aus laufzeitfähiger Parameteranpassung und Live-Monitoring ermöglicht ein effizientes Trial-and-Error-Tuning des selbstbalancierenden Fahrrads, unterstützt durch intuitive GUI-Interaktion und automatisierte Datenaufzeichnung.

4 Kombinierte Regelung

4.1 Portierung des Balance-PID (Zander)

Jonah Zanders Bachelorarbeit (2023) behandelt die Entwicklung einer Regelung für ein selbst-balancierendes Fahrrad [38]. ein Ansatz stützte sich auf eine mehrstufige Kaskadenregelung, um die Balance des Fahrrads trotz realer Sensor- und Aktorbeschränkungen sicherzustellen. In der Original-Hardwarearchitektur erfassen ein *BNO055*-IMU-Sensor und ein *BeagleBone-Black*-Einplatinencomputer den Neigungswinkel (Rollwinkel) des Fahrrads. Diese Information wird in einer *primären* PID-Schleife — dem “Angle-to-Steering”-Regler — verarbeitet, der aus dem Rollwinkelabweichungssignal einen Ziel-Lenkswinkel berechnet. Zander wählte dafür relativ hohe proportionale ($K_p \approx 10$) und differentielle Verstärkungen ($K_d \approx 2,2$) und verzichtete auf einen Integralanteil ($K_i = 0$). Diese Parametrierung reagiert schnell und ausreichend gedämpft auf Neigungsabweichungen, ohne driftbedingtes Aufintegrieren — ein wichtiger Aspekt, um Aufschaukeln im realen System zu vermeiden. Der resultierende Lenkwinkel-Sollwert wird anschließend an eine *sekundäre* PID-Schleife übergeben. Diese zweite Regelstufe regelt den elektrischen *Lenkmotor* (über einen MD49-Motorcontroller) so, dass der Lenker den vorgegebenen Sollwinkel tatsächlich einnimmt. Aufgrund von Reibung, Trägheit und Totzeit des Lenkantriebs sind hier wesentlich höhere Reglerverstärkungen erforderlich (im Original z.B. $K_p \approx 850$, $K_i \approx 300$) sowie eine Ausgangsbegrenzung, um das physische System nicht zu übersteuern. Als *dritte* Stufe implementierte Zander eine einfache Geschwindigkeitsregelung für den Antrieb des Fahrrads. Diese war in seiner Umsetzung stark vereinfacht: Über eine Fernbedienung konnte eine konstante Vorwärtsgeschwindigkeit (ca. 3 m/s) ein- oder ausgeschaltet werden. Damit wurde gewährleistet, dass das Fahrrad eine minimale Fahrt erreicht — notwendig, da ein selbstbalancierendes Fahrrad bei Nullgeschwindigkeit instabil ist.

Zusätzlich integrierte Zander sicherheitskritische Mechanismen wie einen Watchdog-Thread und eine mehrsträngige Programmausführung, um unterschiedliche Abtast- und Regelpfade in Echtzeit ablaufen zu lassen (z.B. IMU-Abtastung mit 200 Hz, Lenkregelung mit 1000 Hz). Diese Maßnahmen kompensieren hardwarebedingte Latenzen und mögliche Sensorausfälle und stellten die Balance in der Praxis robust sicher.




Figure 11: Kombimierter Regler.

Im Rahmen dieser Arbeit wurde Zanders Balance-PID-Regler in einer Webots-Simulation nachge-

bildet — jedoch in vereinfachter Form, da die Simulationsumgebung viele reale Komplexitäten abfängt. Die Sensorik in Webots liefert z.B. den Rollwinkel ohne nennenswertes Rauschen oder Verzögerung, wodurch aufwändige Filterung oder Sensorfusion nicht notwendig sind; ein einfacher gleitender Mittelwert über wenige Schritte genügt zur Glättung. Ebenso erlaubt die Simulations-Aktuatorik direkten Zugriff auf den Lenkmotor: Anstatt wie im realen System einen separaten PID-Regler für die Lenkposition und einen Motorcontroller anzusteuern, kann der simulierte Lenkwinkel direkt gesetzt werden. Konkret wird in jedem Simulations-Timestep zunächst der aktuelle Rollwinkel berechnet und dann der Balance-PID (mit denselben Parametern K_p, K_i, K_d wie bei Zander) ausgeführt. Dessen Ausgang — anstelle eines Encoder-Sollwerts — wird unmittelbar als Stellwert an den virtuellen Lenkmotor übergeben, der den Lenker entsprechend positioniert. Die zweite Regelstufe (Steering-Position-PID) entfällt somit, da Webots intern den Motor auf die Position eigenständig hält. Auch die Thread-Struktur kann stark vereinfacht werden: Webots arbeitet mit einer einzigen synchronen Hauptschleife, die Sensoraktualisierung und Stellgrößenberechnung in festen Zeitschritten kombiniert. Das eliminiert die Notwendigkeit paralleler Threads und spezieller Watchdogs — Timing und Stabilität werden durch die Simulationsengine garantiert.

Trotz dieser Vereinfachungen wurden die Kernprinzipien von Zanders Regelung beibehalten. Insbesondere stellt der Rollwinkel-PID weiterhin das zentrale Element dar, das die Balance regelt. Die gleiche Abstimmung ($K_p = 10, K_i = 0, K_d = 2,2$) hat sich auch in der Simulation als geeignet erwiesen, um ein schnelles Ausregeln mit moderater Dämpfung zu erreichen — analog zu den realen Tests von Zander [38]. Unterschiede ergeben sich vor allem durch die Randbedingungen: Zanders physisches System war verschiedenen Umwelteinflüssen (Bodenebenenheiten, Windstöße, Reibungsschwankungen) ausgesetzt, während die Webots-Simulation idealisierte Bedingungen bietet.

Ein weiterer Unterschied liegt in der Geschwindigkeitssteuerung. Während im realen Aufbau eine konstante Mindestgeschwindigkeit manuell vorgegeben wurde, nutzt die Simulation eine adaptive Geschwindigkeitsanpassung: Die Antriebsdrehzahl wird dynamisch reduziert, wenn starke Lenkeingriffe (große Stellgrößen des Balance-PID) auftreten. Diese direkte Kontrolle im Simulator erhöht die Stabilität, indem das „Fahrrad“ bei drohender Instabilität automatisch abbremst. Zander musste hingegen einen Sicherheitsabstand einplanen: Sein System durfte nicht zu langsam werden, da ein reales Fahrrad unter $\approx 3 \text{ m/s}$ kaum stabil bleibt. Die Simulation erlaubt hier flexible Anpassungen, da keine Sturzgefahr für ein echtes Gerät besteht und Parameter gefahrlos variiert werden können.

Die Portierung des Zander’schen PID-Reglers in die Webots-Umgebung zeigt, dass ein vereinfachtes Regeldesign genügt, wenn Sensorik und Aktorik idealisiert sind. Viele Komplexitäten der realen Implementierung (zusätzliche Regelkreise, Echtzeit-Threading, Hardware-Toleranzen) mussten in der Simulation nicht nachgebildet werden, was die Implementierung schlanker machte. Dennoch basiert die Regelung auf dem gleichen Prinzip wie bei Zander: der stabilisierenden Rückkopplung des Rollwinkels auf den Lenkwinkel. Die erfolgreiche Balance in der Simulation bestätigt die Wirksamkeit von Zanders Ansatz unter erleichterten Bedingungen und bildet die Grundlage für weiterführende Regelungs- und Steuerungsstrategien in dieser Arbeit.

4.2 Portierung des Fahrtrichtungs-MPC (Giray)

Yasin Giray entwickelte in seiner Masterarbeit einen vision-basierten Fahrtrichtungsregler auf Basis von Model Predictive Control (MPC), um das selbstbalancierende Fahrrad autonom der Fahrspur folgen zu lassen. Dieser Regler modelliert die Fahrzeugdynamik mittels Einspurmodell und nutzt

zwei Steuergrößen — aktuelle Geschwindigkeit v und Lenkwinkel ϕ — als Eingaben für die Prädiktion. Der MPC berechnet also auf Grundlage von v und Lenkeinschlag die Fahrzeugbewegung voraus. Für den prädiktiven Regler wird ein Zustandsvektor $x = [x, y, v, \text{yaw}]$ (Position, Geschwindigkeit, Gierwinkel) und ein Eingangsvektor $u = [\text{accel}, \text{steer}]$ definiert. Giray wählte einen Zeithorizont von etwa 2 s und formulierte ein Optimierungsproblem, das die Abweichung von einer Soll-Trajektorie minimiert sowie Steuerungsaufwand und -änderungen penalisiert. Die Kostenfunktion des MPC addiert quadrierte Abweichungen der Zustände und Eingriffe über den Horizont sowie eine Endzustands-Strafe, z. B. $J = \sum (x^T Q x + u^T R u + \Delta u^T R_d \Delta u) + x_{\text{final}}^T Q_f x_{\text{final}}$. Neben den Kosten werden physikalische Nebenbedingungen wie maximaler Lenkwinkel, Lenkwinkelrate und Geschwindigkeit im Optimierungsproblem berücksichtigt, um realistische Lösungen zu gewährleisten.

Wesentliche Voraussetzung für den Fahrtrichtungs-MPC ist eine geeignete Referenztrajektorie der Straße. Giray implementierte hierfür eine Computer-Vision-Pipeline auf Basis von YOLOv8-Segmentierung, welche im Kamerabild die befahrbare Straße und deren Verlauf erkennt. Aus den segmentierten Bilddaten wird eine Reihe von Stützpunkten der Fahrbahn extrahiert (z. B. die Mittellinie oder Fahrbahnrande). Anschließend wird mittels Spline-Interpolation eine glatte Kurve durch diese Punkte gelegt, die als Referenzkurve für den MPC dient. Der MPC nutzt diese prognostizierte Straßenspur, um vor auszuplanen: Er simuliert auf Basis des Einspurmodells die Fahrzeugbewegung und berechnet die optimalen Steuerbefehle, damit das Fahrrad der Kurve bestmöglich folgt. In Girays Umsetzung wird der Regler zyklisch mit ca. 10 Hz ausgeführt (Tickrate 100 ms). Pro Zyklus initialisiert der Controller den aktuellen Fahrzeugzustand (Position, Geschwindigkeit, Orientierung) und berechnet aus der ersten Sollkurve einen Vorhersagepfad. Die Optimierung (z. B. gelöst mit `cvxpy`) liefert dann eine Stellgrößen-Sequenz für Beschleunigung und Lenkwinkel. Tatsächlich wird nur der erste Lenkwinkel-Impuls umgesetzt (Receding Horizon Control), welcher als neuer Lenkbefehl an das Fahrzeug geht. Im nächsten Zyklus wird der MPC erneut mit aktualisiertem Zustand und ggf. angepasster Referenz gestartet. Giray konnte in Simulationen zeigen, dass der MPC-Regler das Fahrrad effektiv der vorgegebenen Spur folgen lässt: Die geplante Spline-Trajektorie (rot) und die vom MPC gefahrene Ist-Trajektorie (blaue Punkte) stimmen eng überein, was die Güte der prädiktiven Regelung belegt.

In der vorliegenden Arbeit wird Girays Fahrtrichtungs-MPC nahtlos in die Webots-Simulationsumgebung portiert und mit dem Balance-Regler gekoppelt. Die Umsetzung erfolgt durch einen Vision-Controller in Python, der analog zum Ansatz von Giray einen modellprädiktiven Lenkwinkel-Regler realisiert. Auch hier kommt ein vereinfachtes Bicycle-Modell ($x = [x, y, v, \text{yaw}]$, $u = [\text{accel}, \text{steer}]$) zum Einsatz, und die prädiktive Optimierung berücksichtigt ähnliche Stellgrößen- und Zustandskosten sowie Begrenzungen (Lenkwinkel, Lenkrate, Geschwindigkeit). Einige Anpassungen waren jedoch nötig: Anstatt einer komplexen Kurvenextraktion aus dem Kamerabild nutzt der Vision-Controller einen direkten Querfehler zur Fahrspur als Eingang. Die laterale Abweichung des Fahrrads von der Fahrbahnmitte (z. B. normiert zwischen ± 0.5) wird laufend aus der Bildsegmentierung oder einem Fallback-Verfahren ermittelt. Aus diesem Fehler wird eine Zielführung abgeleitet: der Soll-Gierwinkel des Fahrrads wird proportional zum Querfehler angepasst, sodass das Fahrzeug zurück zur Spurmitte dreht. Konkret wird ein `target_yaw` berechnet, der vom aktuellen `yaw`-Winkel um einen Korrekturterm (proportional zum Fehler) abweicht. Zwischen aktuellem `yaw` und diesem Ziel-`yaw` erzeugt das System eine kurze Referenztrajektorie über den Horizont T : das Fahrrad soll in T Schritten gleichmäßig von der aktuellen Ausrichtung zur Zielausrichtung drehen. Dazu werden über $T = 3$ diskrete Zeitschritte (mit $\Delta t = 0,1$ s) Zwischenausrichtungen interpoliert und die entsprechenden vorwärts projizierten Positionen berechnet. Die resultierende Trajektorie ist im Wesentlichen eine sanfte Kurve zurück zur Fahrbahnmitte. Dieses

Verfahren vereinfacht die Pfadplanung erheblich und ist ausreichend für die Spurhaltung, ohne im Rahmen dieses Kapitels tief in die Bildverarbeitung einsteigen zu müssen (die Details der Fahrbahnerkennung folgen in einem späteren Kapitel).

Auf Basis der generierten Referenz führt der Vision-MPC in Webots die Optimierung durch. Der Prädiktionshorizont ist mit 3 Schritten ($\approx 0,3\text{s}$) bewusst kurz gehalten, um die Rechenzeit gering zu halten. Innerhalb dieses Horizonts minimiert der MPC Abweichungen zwischen Fahrzeug und Referenzpfad sowie plötzliche Änderungen der Steuerbefehle. Es gelten harte Constraints: Der Lenkwinkel ist z. B. auf $\pm 30^\circ$ begrenzt, die Lenkwinkeländerung pro Zeitschritt auf ca. $20^\circ/\text{s}$, die Geschwindigkeit auf ca. 8 m/s (bzw. wird nicht unter $\sim 0,5\text{ m/s}$ fallen). Diese Grenzen orientieren sich an den physikalischen Fähigkeiten des simulierten Fahrrads und entsprechen teils den in Girays Arbeit genutzten Werten. Der Optimierer (`cvxpy`) berechnet dann die Eingangssequenz $u_{0..T-1}$; wenn ein optimales Ergebnis gefunden wird, entnimmt der Controller den ersten Steuerbefehl (Beschleunigung und Lenkausschlag) als Sollwert. Falls das Optimierungsproblem nicht zu lösen ist oder zu lange dauert, greift ein Fallback-Regler: In diesem Fall wird etwa ein einfacher P-Regler genutzt, der den Lenkwinkel proportional zum aktuellen Querfehler setzt. In der Praxis zeigte sich jedoch, dass der MPC mit den reduzierten Dimensionen echtzeitfähig läuft (die `cvxpy`-Lösung erfolgt in wenigen Millisekunden).

Die vom Vision-MPC berechneten Sollgrößen — kontinuierlicher Lenkwinkel (`steer_rad`) und gewünschte Beschleunigung bzw. Geschwindigkeit (`accel`) — werden anschließend für die Ausführung skaliert und geglättet. Insbesondere wird der Lenkwinkel auf den normierten Bereich $[-1, 1]$ abgebildet, der dem Stellbereich des Lenkservos entspricht. Zudem begrenzt ein Rate-Limiter plötzliche Änderungen (z. B. maximal $\pm 0,005$ pro Zeitschritt in der normierten Größe), um ruckfreie Lenkbewegungen zu gewährleisten. Auch die aus `accel` abgeleitete Zielgeschwindigkeit wird auf 0 bis 1 normiert. Dieser Wert dient als grober Speed-Befehl, obgleich die tatsächliche Geschwindigkeitsregelung in unserem System primär auf der C-Seite erfolgt (siehe unten).

Die eigentliche Integration des portierten MPC in die Simulationsregelung geschieht durch eine Kaskadierung mit dem Balance-Controller. Wie in Abbildung 4.2 (Signalflussdiagramm) skizziert, arbeitet der Vision-Controller (Python) auf niedriger Frequenz ($\sim 20\text{ Hz}$) und sendet periodisch seine berechneten Steuerbefehle an den Balance-Controller (C). Der Balance-Controller läuft mit dem Webots-Basis-Zyklus (2–10 ms Schritte, also $> 100\text{ Hz}$) und stabilisiert das Fahrzeug über einen PID-Regler auf den Rollwinkel. Konkret regelt er den Lenkwinkel so, dass das Fahrrad aufrecht bleibt (Rollabweichung $\rightarrow$ Lenkimpuls). Die vom Vision-MPC kommende Lenkvorgabe wird nun mit der Balance-Korrektur überlagert. In der Implementierung wird eine feste Gewichtung von 50:50 verwendet: der finale Lenksollwert an den Motor ist der Mittelwert aus Vision-Output und Balance-PID-Output. Damit wird verhindert, dass die Fahrtrichtungsregelung das Stabilisieren stört — das Fahrrad bleibt primär durch den PID aufrecht, während der MPC langsam die Richtung vorgibt. Zusätzlich beeinflusst der Vision-Befehl die Geschwindigkeit: Der Balance-Controller enthält einen unterlagerten Geschwindigkeitsregler, der bei großen Lenkausschlägen die Vortriebsleistung reduziert (ähnlich einer Kurvenverzögerung). Ist also der visionäre Lenkwunsch stark (scharfe Kurve), bremst der Balance-Controller das Hinterrad etwas ab, um Kippgefahr zu minimieren.

Die Kommunikation zwischen den beiden Reglern erfolgt über einen IPC-Kanal innerhalb von Webots. Der Vision-Controller sendet seine Sollwerte als strukturiertes Paket (Lenkkommando, Geschwindigkeitskommando, Gültigkeits-Flag und einige Diagnosewerte) an den Balance-Controller. Dieser liest das Paket (`Device command_rx`) in jedem Zyklus aus und nutzt die enthaltenen Sollgrößen in seiner Regelung. Umgekehrt schickt der Balance-Controller in festen Intervallen Status-

daten zurück – insbesondere den aktuellen Rollwinkel, den resultierenden Lenkbefehl und Informationen zur Stabilität – damit der Vision-Controller z. B. im Overlay Feedback anzeigen oder bei Kontrollverlust eingreifen kann. Insgesamt ermöglicht diese Architektur eine echtzeitfähige Portierung von Girays Fahrtrichtungs-MPC in die virtuelle Umgebung: Der prädiktive Lenkwinkel-Regler arbeitet mit dem Kamerabild und gibt Sollwerte vor, während der vorhandene Balance-Regler die kurzfristige Stabilisierung übernimmt.

4.3 Strategien der Spurführung

4.3.1 YOLO-Segmentierung (YOLOv8) + MPC

In dieser Strategie kommt ein auf YOLOv8 basierendes Segmentierungsmodell zum Einsatz, um die Fahrspur im Kamerabild zu erkennen. YOLOv8 (Ultralytics) ermöglicht die Echtzeit-Objekterkennung mit Segmentierung – hier wird es genutzt, um den Straßenbereich im Bild als Klasse “Straße” zu identifizieren. Ziel der YOLO-Strategie ist es, den lateralen Spurabweichungsfehler robust und präzise zu bestimmen, indem ein vortrainiertes neuronales Netz die Fahrbahnmarkierungen und -fläche erkennt. Der daraus resultierende Fehlerwert wird anschließend an einen Model Predictive Controller (MPC) übergeben, der optimale Lenk- und Beschleunigungsbefehle berechnet, um das Fahrrad auf Kurs zu halten.

Initialisierung: Beim Start des Vision-Controllers (`vision_control_py.py`) wird das YOLO-Modell einmalig geladen. Die Methode `_init_yolo()` versucht, eine trainierte Gewichtsdatei (z. B. `best.pt`) aus dem Projektverzeichnis zu laden. Ist die `ultralytics`-Bibliothek verfügbar (`YOLO_AVAILABLE=True`) und die Datei vorhanden, wird ein YOLOv8-Segmentierungsmodell in `self.yolo_model` geladen und auf das vorhandene Rechenggerät (GPU oder CPU) übertragen. Der folgende Codeausschnitt zeigt diese Initialisierung – es werden mehrere Pfade nach der Gewichtsdatei durchsucht, das Modell geladen und bei Erfolg aktiviert. Falls kein Modell gefunden wird, deaktiviert das System YOLO und wechselt automatisch in den Fallback-Modus:

```

1  if YOLO_AVAILABLE:
2      possible_paths = [
3          "../balance_control_c/yolo_vision/runs/segment/train/weights/best.pt",
4          "yolo_weights/best.pt",
5          "best.pt"
6      ]
7      for path in possible_paths:
8          if os.path.exists(path):
9              try:
10                 device = "mps" if torch.backends.mps.is_available() else \
11                     ("cuda" if torch.cuda.is_available() else "cpu")
12                 self.yolo_model = YOLO(path).to(device)
13                 print(f"[OK] YOLO-Modell geladen: {path} (Device: {device})")
14                 break
15             except Exception as e:
16                 print(f"[WARN] Fehler beim Laden von {path}: {e}")
17                 continue
18  if not self.yolo_model:
19      print("[WARN] Kein YOLO-Modell gefunden - Fallback-Vision aktiviert")
20  YOLO_AVAILABLE = False

```

Listing 6: YOLO-Modell Initialisierung

Im Echtzeitbetrieb (ca. 20 Hz) wird jedes Kamerabild durch YOLO analysiert. Die Funktion `get_vision_error_yolo()` führt eine Inferenz auf dem aktuellen Frame aus und filtert dabei nur Objekte der Klasse “Straße” (Klassen-ID 2) heraus. YOLO liefert für erkannte Straßenbereiche *Bounding Boxes* und zugehörige Segmentierungsmasken. Aus allen erkannten Bounding Boxes der Klasse 2 werden die Mittelpunkte berechnet und gemittelt, um einen durchschnittlichen Straßenmittelpunkt zu erhalten. Die laterale Abweichung (**error**) ergibt sich dann aus der horizontalen Differenz zwischen diesem Straßenmittelpunkt und der Bildmitte, normiert durch die Bildbreite. Der folgende Codeausschnitt illustriert die Berechnung des Fehlers **error**: Alle Erkennungen mit `cls == 2` (“Straße”) werden gesammelt, ihre x-Mitteltwerte berechnet und daraus die Abweichung vom Bildzentrum bestimmt. Ein positiver Fehlerwert bedeutet, dass die Straße im Bild links der Fahrzeugmitte liegt (das Fahrrad muss nach links gegensteuern), ein negativer Wert entsprechend, dass die erkannte Spur rechts liegt. Typischerweise liegt **error** im Bereich von etwa -0.5 bis $+0.5$ (dimensionslos):




Figure 12: YOLOv8-Segmentierung.

```

1  street_indices = [idx for idx, cls in enumerate(r.bboxes.cls) if cls == 2]
2  if street_indices:
3      x_centers = []
4      for idx in street_indices:
5          xxyy = r.bboxes.xxyy[idx] # Koordinaten der Bounding Box
6          x_center = float((xxyy[0] + xxyy[2]) / 2.0)
7          x_centers.append(x_center)
8      avg_x_center = sum(x_centers) / len(x_centers)
9      frame_center = frame.shape[1] / 2
10     error = (frame_center - avg_x_center) / frame.shape[1] # Normiert
11     self._store_valid_values(error, mask, self.vision_mask_coverage)
12     return error, mask

```

Listing 7: YOLO-Modell Error Berechnung

Zusätzlich zur Fehlerberechnung wird eine Binärmaske der erkannten Straße erzeugt (**mask**). Alle Segmentierungspixel der Klasse Straße werden dazu vereinigt, und es wird die prozentuale Maskenabdeckung im Bild (**vision_mask_coverage**) berechnet. Diese Informationen dienen vor allem der

Visualisierung und Diagnose. Für die Regelung wird ausschließlich der Fehlerwert verwendet, nicht die gesamte Maske.

Um bei Aussetzern der Detektion stabil zu bleiben, implementiert das System eine Ausfallüberbrückung: Der zuletzt gültige Fehlerwert (`last_valid_error`) und die Maske werden zwischengespeichert (`_store_valid_values`). Bleibt eine YOLO-Detektion in einem Zyklus aus (z. B. temporäres Nichterkennen der Spur), greift der Controller auf die zuletzt gültigen Werte zurück. Bei längerer Detektionspause wird der gespeicherte Fehler schrittweise mit einem Faktor < 1 multipliziert (Decay), sodass sein Betrag allmählich abnimmt. Nach einer definierten Anzahl von Ausbleib-Zyklen fällt der Fehler auf 0 zurück, um ein Ausbrechen des Fahrrads zu verhindern. Durch diese Maßnahme werden abrupte Änderungen vermieden und der MPC-Regler bleibt auch bei kurzzeitig fehlender Bildinformation stabil.

MPC-Regelung. Der mittels YOLO ermittelte Spurfehler wird an den Vision-MPC-Controller übergeben, der daraufhin einen Lenksollwert und optional einen Geschwindigkeitssollwert berechnet. Intern nutzt der MPC ein einfaches Bicycle-Modell des Fahrzeugs und einen kurzen Prädiktionshorizont, um die Trajektorie zu optimieren. Ist die Optimierungs-Bibliothek verfügbar, wird ein Quadratikprogramm (`CVXPY`) gelöst, das den Querfehler sowie Änderungen des Lenkwinkels in die Kostenfunktion einbezieht; andernfalls fällt der Controller auf einen einfachen P-Regler zurück, der den Fehler proportional in einen Lenkwinkel umsetzt. Das Ergebnis der MPC-Berechnung ist ein Lenkwinkel (in Rad) sowie eine Beschleunigung bzw. Zielgeschwindigkeit. Diese werden im Python-Controller noch normalisiert und geglättet – der Lenkwert `steer_rad` wird durch den maximalen Lenkwinkel dividiert und zu `steer_cmd` $\in [-1, 1]$ skaliert, anschließend durch einen Rate-Limiter nur begrenzt verändert (max. Änderung ± 0.005 pro Schritt, Begrenzung auf ± 0.08). Der normierte Lenkbefehl sowie ein entsprechender Geschwindigkeitsbefehl werden schließlich als Vision Command an den Balance-Controller (C-Prozess) gesendet. Dort wird dieser Soll-Lenkwert mit dem stabilisierenden Lenkoutput des Balance-PID-Reglers kombiniert (standardmäßig 50/50-Gewichtung).




Figure 13: MPC-Strategie.

Limitierungen. Die YOLO-basierte Spurführung hängt stark von einem geeigneten vortrainierten Modell und ausreichender Rechenleistung ab. In Szenarien, die stark von den Trainingsdaten abweichen, kann es zu Fehl- oder Nichterkennungen kommen – in solchen Fällen muss der oben beschriebene Abkling-Mechanismus greifen. Zudem wird aus der Segmentierung derzeit lediglich ein einzelner Querfehlerwert extrahiert; Informationen über den Straßenverlauf (z. B. Krümmung) bleiben ungenutzt, obwohl die Segmentierungsmaske solche Details prinzipiell liefert. Zukünftige Erweiterungen könnten diese zusätzlichen Informationen verwenden, um vorausschauendere Lenkentscheidungen zu ermöglichen. Insgesamt bietet die YOLO+MPC-Strategie eine präzise Spurhaltung, ist aber auf eine funktionierende KI-Erkennung angewiesen.

4.3.2 Fallback-Strategie (Kanten/ROI) + MPC

Falls das YOLO-Modell nicht verfügbar oder die Erkennung unsicher ist, greift eine Fallback-Strategie auf klassische Bildverarbeitung zurück. Diese Methode nutzt Kanten- und Bereichserkennung innerhalb einer ROI (Region of Interest), um weiterhin einen Spurhaltefehler zu bestimmen. Ziel der Fallback-Strategie ist es, eine grundlegende Spurführung auch ohne trainiertes Modell zu gewährleisten – auf Kosten der Robustheit und Genauigkeit. Statt einer neuronalen Segmentierung werden einfache Farb- und Konturfilter verwendet, um die “Straßenkante” bzw. Fahrbahn im Kamerabild zu erkennen. Dadurch kann das System im Notfall den lateralen Fehler abschätzen und den MPC weiterhin mit sinnvollen Sollwerten versorgen.




Figure 14: Fallback-Strategie.

Vorgehen. Zu Beginn setzt der Vision-Controller die Fallback-Methode ein, wenn kein YOLO-Modell geladen wurde (oder falls sie in der Konfiguration ausdrücklich gewählt ist). Der Algorithmus definiert zunächst eine feste ROI im Kamerabild, in der die Straße zu vermuten ist. Diese ROI ist trapezförmig: im oberen Bildbereich schmaler und nach unten breiter, um der Perspektive einer Straße nach vorne gerecht zu werden. Standardmäßig beginnt die ROI bei ca. 40% der Bildhöhe und erstreckt sich über $\sim 2\%$ der Bildhöhe als horizontaler Streifen. Sie liegt mittig im Bild und erfasst den Bereich einige Meter vor dem Fahrrad, in dem sich die Fahrspur voraussichtlich befindet. Innerhalb dieser ROI werden die Bilddaten in den HSV-Farbraum konvertiert, um Farbschwellen für die Straßenerkennung anzuwenden. Der Fallback-Algorithmus segmentiert gezielt dunkelgraue Farbtöne (typisch für Asphalt) sowie weiße Bereiche (Markierungslinien): Ein Pixel gilt als “Straße”, wenn es entweder geringe Sättigung und mittlere Helligkeit (Grau) oder sehr geringe Sättigung und hohe Helligkeit (Weiß) aufweist. Nach dieser Farbfilterung werden morphologische Operationen (Schließen und Öffnen) durchgeführt, um Rauschen zu entfernen und verbleibende Bereiche zu verbinden. Anschließend erfolgt eine Konturenerkennung in der bereinigten Binärmaske. Der folgende Codeauszug veranschaulicht diesen Ablauf – es werden zwei Binärmasken für Straße und Markierungen erstellt, vereinigt und daraus Konturen extrahiert. Die größte gefundene Kontur wird als Straßenbereich angenommen, und aus ihr wird der Querfehler bestimmt.

```

1  mask_road = cv2.inRange(hsv, road_lower, road_upper)      # Graue Strasse
    filtern
2  mask_white = cv2.inRange(hsv, white_lower, white_upper)   # Weisse Markierungen
    filtern
3  mask0 = cv2.bitwise_or(mask_road, mask_white)
4  mask0 = cv2.morphologyEx(mask0, cv2.MORPH_CLOSE, kernel)
5  mask0 = cv2.morphologyEx(mask0, cv2.MORPH_OPEN, kernel)
6  contours, _ = cv2.findContours(mask0, cv2.RETR_LIST, cv2.CHAIN_APPROX_SIMPLE)
7  if contours:
8      largest_contour = max(contours, key=cv2.contourArea)
9      x, y, w, h = cv2.boundingRect(largest_contour)
10     center_x = int(x + w / 2)
11     error = (x_set - center_x) / float(max(1, width))      # Fehler normiert an
        Bildbreite
12     mask = np.zeros((height, width), dtype=np.uint8)
13     cv2.drawContours(mask, [largest_contour], -1, 255, -1)
14     ... # (Berechnung der Maskenabdeckung)
15     self._store_valid_values(error, mask, self.vision_mask_coverage)
16     return error, mask

```

Listing 8: Fallback-Modell Error Berechnung

Wie oben ersichtlich, wird die größte Kontur in der Maske ermittelt (vermutlich entspricht diese der Straße im Sichtbereich). Aus der umschließenden Bounding Box dieser Kontur berechnet der Code den Mittelpunkt `center_x`. Die Differenz zwischen diesem Konturmittelpunkt und der Bildmitte (`x_set`, entspricht hier der halben Bildbreite) ergibt den lateralen Fehler `error`, welcher – analog zur YOLO-Methode – durch die Bildbreite normiert wird. Auch in der Fallback-Strategie ist `error > 0` definiert als Spur links der Mitte, `error < 0` als Spur rechts der Mitte. Der berechnete Fehler und die zugehörige Konturmaske werden als neue gültige Werte gespeichert (`_store_valid_values`), sodass sie bei der nächsten Iteration zur Verfügung stehen. Wird keine Kontur gefunden (etwa wenn die Filter keine zusammenhängende Fläche ergeben), greift das System auch hier auf die zuletzt bekannten Werte zurück. In diesem Fall setzt die gleiche Decay-Logik ein wie bei der YOLO-Strategie: Der alte Fehlerwert wird weiterverwendet und schrittweise abgeschwächt, um ruckartige Lenkbewegungen zu vermeiden. Damit überbrückt der Fallback-Ansatz kurze Erkennungsverluste ähnlich robust.

MPC und Steuerung: Der so ermittelte Fehlerwert fließt wiederum in den MPC-Regler ein, der – wie bereits in Abschnitt 4.3.1 beschrieben – einen Lenksollwert berechnet. Die weiteren Schritte (Normierung, Glättung und Übergabe an den Balance-Controller) sind identisch zur YOLO-Strategie. Der Fallback unterscheidet sich also hauptsächlich in der Vision-Fehlerermittlung, während der Regelteil (MPC) unverändert bleibt.

Limitierungen: Die Fallback-Strategie ist einfacher, aber auch anfälliger für Störungen. Sie setzt voraus, dass sich die Straßenfarbe und -markierungen ausreichend deutlich vom Hintergrund abheben. Variierende Lichtverhältnisse, Schatten oder unkonventionelle Straßenbeläge können die fest eingestellten Schwellenwerte unbrauchbar machen. Zudem erfasst die schmale ROI nur einen begrenzten Bereich voraus – plötzliche Krümmungen oder Hindernisse außerhalb dieses Ausschnitts würden nicht rechtzeitig erkannt. Insgesamt bietet der Fallback-Ansatz eine geringere Präzision und Robustheit als die YOLO-Lösung. Er stellt jedoch sicher, dass das Fahrrad notfalls weiter stabil in der Spur gehalten werden kann, selbst wenn die KI-basierte Erkennung temporär ausfällt. In der

Praxis dient diese Strategie somit als Notfallmodus, bis die vollwertige Vision-Erkennung (YOLO) wieder greift.

4.4 Gesamtregelung




Figure 15: Gesamtregelung.

5 Ergebnisse

5.1 Fahrrad Datenblatt

Die folgenden Abschnitte beschreiben eine in Webots aufgebaute Simulation als digitalen Zwilling des realen Testfahrrads. Ziel ist, Masse-, Trägheits- und Reibungsparameter sowie Sensor-/Aktorschnittstellen so realitätsnah zu spiegeln, dass das Fahrverhalten und die Reglerkopplung mit dem Prototyp übereinstimmen. Auf Basis der ODE-Physik in Webots und der Controller-API (C/Python) wird die in der Hardware verwendete Architektur nachgebildet: eine schnelle innere Balance-Schleife und eine langsamere, vision-gestützte MPC-Spurführung. Eine Supervisor-Instanz ermöglicht reproduzierbare Versuchsreihen, Resets und Logging, sodass Parameterstudien und Kalibrierungen unter identischen Bedingungen erfolgen. Damit dient die Simulation als sichere Vorstufe für reale Fahrversuche und als Referenz für die im Anschluss dokumentierten physikalischen Eigenschaften und Regelungsparameter.




Figure 16: Datenblatt

- **Masse und Schwerpunkt:** Der Rahmen des simulierten Fahrrads wiegt 3,5 kg; zusammen mit den Rädern beträgt die Gesamtmasse ca. 5,1 kg. Der Schwerpunkt liegt etwa 5 cm über dem Boden, was ein stabiles Balanceverhalten begünstigt.
- **Trägheitssensor:** Im Webots-Modell ist der Trägheitssensor als Array in der Form

$$[I_{xx} \ I_{xy} \ I_{xz} \ I_{xy} \ I_{yy} \ I_{yz} \ I_{xz} \ I_{yz} \ I_{zz}]$$

angegeben. Für den Fahrradrahmen ergibt sich ein annähernd diagonal dominanter Trägheitstensor mit $I_{xx} \approx I_{yy} = 0,1$ und $I_{zz} = 0,05 \text{ kg m}^2$. Der kleinere Wert um die Hochachse

(Yaw-Trägheit) erleichtert schnelle Lenkbewegungen; die Off-Diagonaleinträge sind Null, was bedeutet, dass die Hauptträgheitsachsen mit den Achsen des Modells ausgerichtet sind.

- **Räder:** Die beiden Räder haben einen Radius von 5,5 cm und jeweils etwa 0,8 kg Masse. Durch die rotierende Masse entsteht ein kleiner gyroskopischer Stabilisierungs-Effekt (Trägheitsmoment pro Rad ca. $1 \times 10^{-3} \text{ kg m}^2$), der zur Gesamtstabilität beiträgt, aber aufgrund des geringen Werts nur begrenzten Einfluss hat.
- **Reibungsparameter:** Die Radnaben besitzen eine viskose Lagerdämpfung (`dampingConstant` = 0,1) sowie Haftreibung (`staticFriction` = 0,1). Diese Parameter simulieren Lagerverluste und verhindern z. B. ein freies Schwingen oder Durchrutschen der Räder im Stillstand. Zwischen Reifen und Untergrund sorgt ein Coulomb-Reibungskoeffizient von etwa 0,8 für gute Traktion; ein geringer Rückprallkoeffizient von 0,1 begrenzt die Sprungelastizität des Reifenkontakts.

5.2 Teststrecken

5.2.1 Kurvenfahrt

Die Fahrbahn ist als texturierte Ebene von 64m x 64m realisiert; die effektive Spurbreite beträgt an der Referenzlinie etwa 3.6 m. Die Strecke kombiniert eine lange Linkskurve (großer Radius) mit einem engen Rechtsknick und eignet sich damit zur Bewertung von Spurtreue und Balance unter gekrümmter Führung. Sofern nicht anders angegeben, sind für die Balance der *PID*-Satz $K_p=2.0$, $K_i=0.2$, $K_d=0.5$, der zulässige Lenkwinkelbereich $\delta \in [-0.3, 0.3]$ rad sowie $v_{\text{base}}=7 \text{ km/h}$ (Grenzen 5 km/h bis 7 km/h) aktiv. Mechanische Plausibilitäts Grenzen sind mit $\delta_{\text{phys,max}}=1.5 \text{ rad}$ und $\varphi_{\text{roll,max}}=45^\circ$ gesetzt. Für die visuelle Spurführung kann wahlweise YOLO (Konfidenz 0.5) oder eine robuste ROI-Fallback-Erkennung verwendet werden (`roi_top_frac` = 0.5, `roi_height_frac` = 0.06); Lenkbefehle werden durch `max_delta` = 0.001 und `max_steer_cmd` = 0.06 geglättet und begrenzt. Ziel ist die Fahrt von der ersten zur zweiten roten Markierung bei möglichst mittiger Spurhaltung und stabiler Balance.




Figure 17: Kurvenfahrt

Einsatz eines vereinfachten Balance-P-Reglers Für eine Baseline wurde der Balance-Regler auf einen reinen P-Anteil gesetzt ($K_p=2.0$, $K_i=0.0$, $K_d=0.0$). Figure 18 zeigt die gemessenen Größen der Fahrt, Figure 19 den zugehörigen ROI-Querfehler und Figure 20 die Trajektorie auf der Strecke.




Figure 18: Kurvenfahrt mit reinem P-Regler (Zeitreihen)

Bereits nach wenigen Sekunden setzt ein wachsendes Aufschaukeln ein: Der durch den Rollwinkel induzierte Stellbefehl (`final_steer`) treibt den Lenkeinschlag alternierend nach links/rechts, bis die Phasenreserve erschöpft ist. Infolge der reinen Proportionalrückführung, der Aktuatorbegrenzungen und der unvermeidlichen Latenzen entsteht ein unterdämpftes Verhalten; das Fahrrad kippt nach rund 15 s nach rechts.




Figure 19: ROI-Querfehler während der P-Regler-Fahrt

Der ROI-Querfehler zeigt eine ausgeprägte Kopplung zum Rollwinkel: Das Pendeln der Balance überträgt sich phasenverschoben auf die seitliche Abweichung. Zur Stabilisierung ist daher ein kleiner Integralanteil (Elimination stationärer Abweichung mit Anti-Windup) und insbesondere ein Derivatanteil (Phasenführung/Dämpfung) erforderlich; in Kombination mit `Rate(max_delta)` und Amplitudenbegrenzung (`max_steer_cmd`) wird das Überschwingen reduziert und ein Kippen verhindert.




Figure 20: Gefahrene Trajektorie (P-Regler)

Einsatz des erweiterten Balance-PID-Reglers Für diese Versuchsfahrt wurden die erweiterten PID-Parameter $K_p = 2.0$, $K_i = 0.2$ und $K_d = 0.5$ eingesetzt. Die Spurführung erfolgte mittels YOLO-basierter Bildverarbeitung. Während die Parameterwahl eine Verbesserung der Stabilität gegenüber reinen P-Reglern bewirkte, zeigte sich nach etwa 35 s dennoch ein Kippen des Fahrrads, ausgelöst durch abrupte Richtungsänderungen in der vom Vision-Modell vorgegebenen Trajektorie.




Figure 21: Kurvenfahrt mit PID-Regler und YOLO-Spurführung

Die Fehleranalyse bestätigt, dass die Fahrbahnerkennung zum Zeitpunkt der Versuche noch unzureichend trainiert war. Ab Sekunde 31 steigt der Querfehler abrupt an und fällt kurz darauf wieder ab (Sekunde 34). Dieses unstete Verhalten überträgt sich auf den Rollwinkel, dessen zunehmendes Pendeln schließlich eskaliert und zum Umkippen des Fahrrads nach rechts führt.




Figure 22: ROI-Querfehler während der PID-Regler-Fahrt (YOLO)

Trotz dieser Limitierungen lässt sich durch die Kombination von Integral- und Differentialanteil eine verbesserte Spurhaltung mit reduzierten Querabweichungen beobachten. Insbesondere werden stationäre Fehler kompensiert und Überschwinger wirksam gedämpft, sodass das Fahrrad über weite Teile der Strecke stabil bleibt – auch bei eingeschränkter Fahrbahnerkennung. Kurz vor dem Ziel versagt die Kompensation jedoch, und das System verliert seine Stabilität. Dies verdeutlicht, dass die Reglererweiterung eine deutliche Verbesserung bewirkt, die Robustheit aber maßgeblich von der Qualität der visuellen Erkennung abhängt.




Figure 23: Gefahrene Trajektorie (PID-)

Die Abbildungen 24a und 24b verdeutlichen Limitierungen der *YOLO*-Segmentierung: Abschnitte der Fahrbahn werden nur teilweise bzw. falsch klassifiziert; insbesondere die Trennung zwischen Fahrbahn und Nebenflächen (z.B. Rand-/Grünstreifen) ist inkonsistent. Links (a) ist die Spur weitgehend korrekt maskiert, rechts (b) werden Randbereiche fälschlich als Straße erkannt. Diese Fehlklassifikationen verschieben die geschätzte Spurmitte, erzeugen sprunghafte Querfehler und können instabile Lenkbefehle auslösen.




Figure 24: Strecke gut und schlecht nebeneinander.

Einsatz der ROI-Fallback-Erkennung In dieser Versuchsfahrt wurde die ROI-Fallback-Erkennung eingesetzt, um die in Abschnitt 4.3.1 beschriebenen Schwächen der *YOLO*-Segmentierung zu umgehen. Die Pipeline nutzt klassische Bildverarbeitung innerhalb eines definierten Bildausschnitts (ROI): farbbasierte Segmentierung der Fahrbahn und Kantenfilter werden kombiniert, die Spurmittellinie wird aus der ROI-Maske abgeleitet und zeitlich geglättet. Sämtliche Reglerparameter (*PID*) sowie die übrigen Versuchsbedingungen entsprechen exakt denen der *YOLO*-Konfiguration; die beobachteten Unterschiede sind daher allein auf die Wahrnehmung (Erkennung) zurückzuführen.




Figure 25: Kurvenfahrt mit PID-Regler und ROI-Fallback-Erkennung

Die Ergebnisse in Figure 25 zeigen einen deutlichen Qualitätsgewinn gegenüber der *YOLO*-Erkennung: sprunghafte Querfehler treten praktisch nicht mehr auf, und das Fahrrad fährt über weite Strecken stabil. Kurzzeitige Anregungen (z. B. zwischen Sekunde 20 und 25) führen zwar zu einer temporären Erhöhung der Stellgrößen, werden jedoch vom PID-Regler sauber kompensiert. Der anfängliche Anstieg des *Final-Steer* ist auf das Einfädeln in die Spur zurückzuführen; nach kurzer Transiente regelt sich das System auf einen kleinen stationären Fehler ein.




Figure 26: ROI-Querfehler während der PID-Regler-Fahrt (ROI)

Im Fehlerverlauf (Figure 26) ist außerdem ersichtlich, dass ab etwa Sekunde 35 die (rote) Schwelle zur scharfen Kurve überschritten wird und der Querfehler ansteigt. Dieses Verhalten ist konsistent mit den in der Regelkette gesetzten Lenkwinkel- und Ratenbegrenzungen (`max_steer_cmd`, `max_delta`): Bei hoher Streckenkrümmung gerät der Regler kurzzeitig in Sättigung, bevor der Fehler wieder abgebaut wird. Die zugehörige Trajektorie (Figure 27) belegt dennoch eine insgesamt mittige und ruhige Spurführung; Abweichungen konzentrieren sich auf den Scheitel der Kurve und bleiben begrenzt.

Fazit. Die ROI-Fallback-Erkennung erhöht die Robustheit der Spurführung, indem sie Ausreißer in der visuellen Messung reduziert und so die Kopplung zum Balance-Regelkreis entlastet. Ihre Wirksamkeit ist allerdings an Szenen mit gut trennbaren Fahrbahn-/Nebenflächen gebunden; für variable Beleuchtung, Texturen oder komplexe Hintergründe ist eine verbesserte (oder zusätzlich trainierte) lernbasierte Segmentierung weiterhin wünschenswert.




Figure 27: Gefahrene Trajektorie (PID-Regler, ROI)

5.2.2 S-Kurve




Figure 28: Fallback Strecke S-Kurve




Figure 29: Fallback Strecke S-Kurve




Figure 30: YOLO Daten S-Kurve




Figure 31: Error YOLO S-Kurve




Figure 32: Fallback Strecke S-Kurve






Figure 33: Fallback Strecke S-Kurve

5.2.3 Gerade Strecke mit Seitenwind

5.2.4 Gerade Strecke mit Höhenunterschied



(a) Hugel



(b) Tunnel

Figure 34: Hugel und Tunnel nebeneinander.

5.3 Balance-Stabilitat

5.4 Spurtreue & Querabweichung

5.5 Rechenzeit & Echtzeitfahigkeit

6 Grenzen der Arbeit

7 Zukünftige Arbeiten (Sensor-Fusion, Reinforcement Learning, Hardware-in-the-Loop)

8 Fazit

9 Literaturverzeichnis

References

- [1] D. Andreo, V. Cerone, D. Dzung, and D. Regruto. Experimental results on lpv stabilization of a riderless bicycle. In *Proc. American Control Conference (ACC)*, pages 3124–3129, 2009.
- [2] N. Aphiratsakun and K. Techakittiroj. Autonomous au bicycle: self balancing and tracking control (ausb 2). In *Proc. IEEE Int. Conf. on Robotics and Biomimetics (ROBIO)*, pages 480–485, 2013.
- [3] Bosch Sensortec. Bno055 intelligent 9-axis absolute orientation sensor. <https://www.bosch-sensortec.com>, 2020.
- [4] Concurrent Real-Time. Inverted pendulum, 2024.
- [5] Cyberbotics. Webots – open source robot simulator. <https://cyberbotics.com>, 2025.
- [6] Cyberbotics Ltd. Controller programming. <https://cyberbotics.com/doc/guide/controller-programming>, 2025. Zugriff am 27.08.2025.
- [7] Cyberbotics Ltd. Emitter. <https://cyberbotics.com/doc/reference/emitter>, 2025. Zugriff am 27.08.2025.
- [8] Cyberbotics Ltd. Receiver. <https://cyberbotics.com/doc/reference/receiver>, 2025. Zugriff am 27.08.2025.
- [9] Wenda Deng, Simon Moore, Jonathan Bush, Michael Mabey, and Wei Zhang. Towards automated bicycles: achieving self-balance using steering control. In *ASME Dynamic Systems and Control Conference (DSCC)*, volume 2, pages 1–9, 2018.
- [10] Devantech Ltd. Md49 dual motor driver datasheet. <https://www.robot-electronics.co.uk>, 2019.
- [11] do-mpc development team. Basics of model predictive control, 2024. Accessed 23 August 2025.
- [12] Yassin Ghidaei. Video- und sensorgestütztes autonomes fahren für ein selbstbalancierendes fahrrad. Master’s thesis, Goethe-Universität Frankfurt am Main, 2024.
- [13] Yassin Ghidaei and Amine Karabila. Yolo-based vision control for self-balancing bicycle. Internal project documentation, 2024. Vision controller implementation using YOLO for path detection and MPC for trajectory planning.
- [14] Yasin Giray, Amine Karabila, Jonah Zander, et al. Vision controller readme for self-balancing bicycle. https://github.com/arabila/selfbalancingbicycle/tree/master/Regelsteuerung/controllers/vision_control_py/README.md, 2023. Describes the MPC-based vision controller and its integration with the balance controller.
- [15] GitHub contributors. Webots simulation framework. <https://github.com/cyberbotics/webots>, 2025. Zugriff am 24.08.2025.
- [16] Li Guo, Qing Liao, Shuai Wei, and Yong Huang. A kind of bicycle robot dynamic modeling and nonlinear control. In *Proc. 2010 IEEE International Conference on Information and Automation (ICIA)*, pages 1613–1617, 2010.

- [17] R. Gupta and S. Lee. Evaluating webots as digital-twin platform for multi-robot systems. In *Proc. IEEE ICRA*, 2023.
- [18] M. et al. Hadi. Soft-gripper simulation in webots. *Soft Robotics*, 11(2):123–135, 2024.
- [19] John Hedengren et al. Proportional integral derivative (pid). <https://apmonitor.com/pdc/index.php/Main/ProportionalIntegralDerivative>, 2024.
- [20] Alex Hunziker. Autonomous steering of an electric bicycle based on sensor fusion using model predictive control. Master’s thesis, Goethe-Universität Frankfurt am Main, 2019.
- [21] Infineon Technologies. Bts7960 high-current half-bridge driver. <https://www.infineon.com>, 2018.
- [22] Glenn Jocher, Ayush Chaurasia, and Jing Qiu. Yolo by ultralytics. <https://github.com/ultralytics/ultralytics>, 2023.
- [23] K. Kanjanawanishkul. Lqr and mpc controller design and comparison for a stationary self-balancing bicycle robot with a reaction wheel. *Kybernetika*, 54(1):173–191, 2015.
- [24] Amine Karabila. Auf dem weg zum selbstfahrenden fahrrad: Analyse und implementierung einer regelung der balance. Master’s thesis, Goethe-Universität Frankfurt, 2022.
- [25] P. Y. Lam and T. K. Sin. Gyroscopic stabilization of a self-balancing robot bicycle. *International Journal of Automation Technology*, 5(6):916–923, 2011.
- [26] Wenjia Li, Paris Francis, Robert McClosky, and Alexander Brown. WeBikes: a configurable, open-source add-on for simulating single-track vehicle dynamics in the Webots robot simulation software. *Advances in Transportation Studies*, Special Issue Vol. 4:73–88, 2024.
- [27] Cyberbotics Ltd. Inertialunit. <https://cyberbotics.com/doc/reference/inertialunit>, 2025. Geräte-Referenz, Zugriff: 24.08.2025.
- [28] Olivier Michel. Cyberbotics Ltd. Webots: Professional mobile robot simulation. *International Journal of Advanced Robotic Systems*, 1(1):39–42, 2004.
- [29] OpenMMLab and Ultralytics. Dive into yolov8: How does this state-of-the-art model work?, 2023. Accessed 23 August 2025.
- [30] Sang-Hyun Park and Seung-Yun Yi. Active Balancing Control for Unmanned Bicycle Using Scissored-pair Control Moment Gyroscope. *International Journal of Control, Automation and Systems*, 18(1):217–224, 2020.
- [31] Anna Ranz. Entwicklung eines selbstbalancierenden fahrradprototyps. Master’s thesis, HWR Berlin, 2021.
- [32] A. Shafiekhani, M. J. Mahjoob, and M. Akraminia. Design and implementation of an adaptive critic-based neuro-fuzzy controller on an unmanned bicycle. *Mechatronics*, 28:115–123, 2015.
- [33] N. Tamaldin et al. Design of a Self-balancing Bicycle. In *Proceedings of Mechanical Engineering Research Day 2017*, pages 160–161, 2017.
- [34] Wikipedia contributors. Model predictive control, 2024. Accessed 23 August 2025.

- [35] Wikipedia contributors. Image segmentation, 2025. Accessed 23 August 2025.
- [36] Wikipedia contributors. You only look once, 2025. Accessed 23 August 2025.
- [37] Jiaming Xiong, Ruihan Yu, and Caishan Liu. Steering control and stability analysis for an autonomous bicycle: Part ii—experiments and a modified linear control law. *Nonlinear Dynamics*, 112(4):3107–3132, 2024.
- [38] Jonah Zander. Entwurf einer Steuerung für ein selbstbalancierendes Fahrrad. Bachelorarbeit, Frankfurt University of Applied Sciences, 2023.
- [39] Xu Zhao, Wenchao Ding, Yongqi An, Yinglong Du, Tao Yu, Min Li, Ming Tang, and Jinqiao Wang. Fast segment anything. arXiv:2306.12156 [cs.CV], 2023.
- [40] Karl J. Åström, Richard E. Klein, and Anders Lennartsson. Bicycle dynamics and control: adapted bicycles for education and research. *IEEE Control Systems Magazine*, 25(4):26–47, 2005.