

Masterarbeit

Auf dem Weg zum autonom fahrenden Fahrrad: Eine videogestützte Regelung des Weges mit Webbots

Amine Karabila

Sommersemester 2025

Bitte dieses Formular zusammen mit der Abschlussarbeit abgeben!

Erklärung zur Abschlussarbeit

**gemäß § 34, Abs. 16 der Ordnung für den Masterstudiengang Informatik
vom 17. Juni 2019**

Hiermit erkläre ich

(Nachname, Vorname)

Die vorliegende Arbeit habe ich selbstständig und ohne Benutzung anderer als der angegebenen Quellen und Hilfsmittel verfasst.

Ebenso bestätige ich, dass diese Arbeit nicht, auch nicht auszugsweise, für eine andere Prüfung oder Studienleistung verwendet wurde.

Zudem versichere ich, dass die von mir eingereichten schriftlichen gebundenen Versionen meiner Masterarbeit mit der eingereichten elektronischen Version meiner Masterarbeit übereinstimmen.

Frankfurt am Main, den

Unterschrift der/des Studierenden

Inhaltsverzeichnis

1	Abstract	vii
2	Einleitung	1
2.1	Problemstellung	1
2.2	Stand der Technik	1
2.3	Bisherige Arbeiten	2
2.3.1	Anna Ranz (2021) – Hardware-Grundlagen	3
2.3.2	Amine Karabila (2022) – Erste funktionierende Regelung	3
2.3.3	Jonah Zander (2023) – Optimierte PID-Balanceregung	4
2.3.4	Yasin Giray (2024) – YOLO + MPC-Fahrtrichtung	5
3	Grundlagen	6
3.1	PID-Regelung – Prinzip und Eignung für das Balance-Problem	6
3.2	MPC-Regelung – Prinzip und Eignung für das Fahrtrichtungsproblem	7
3.3	YOLO-Grundlagen und Segmentierung	8
4	Simulationsumgebung	10
4.1	Überblick	10
4.2	Struktur der Simulationsumgebung	11
4.3	Physikmodell: Open Dynamics Engine (ODE) in Webots	12
4.4	Sensoren	13
4.4.1	Inertialmesseinheit (IMU)	13
4.4.2	Kamera (Videosensor)	15
4.4.3	Motorsensoren (Inkrementalgeber)	17
4.5	Aktuatoren	18
4.6	Controller	22
4.7	Integriertes Konfigurationssystem	24
5	Kombinierte Regelung	26
5.1	Portierung des Balance-PID (Zander)	26
5.2	Portierung des Fahrtrichtungs-MPC (Giray)	28
5.3	Strategien der Spurführung	32
5.3.1	YOLO-Segmentierung (YOLOv8)	32
5.3.2	Fallback-Strategie (ROI-basiert)	34

6	Ergebnisse	37
6.1	Fahrrad Datenblatt	37
6.2	Teststrecken	39
6.2.1	Kurvenfahrt	40
6.2.2	S-Kurve	47
6.2.3	Gerade Strecke mit Seitenwind	51
6.2.4	Gerade Strecke mit Höhenunterschied	56
6.3	Rechenzeit & Echtzeitfähigkeit in Webots (Vergleich zum Realfahrrad)	62
6.3.1	Performance-Monitoring und Rechenzeit-Analyse	62
6.3.2	Rechenzeit-Analyse und Implikationen	63
6.3.3	Hardware-Skalierung und Jetson Nano Vergleich	65
6.3.4	Fazit zur Performance-Analyse	65
7	Grenzen der Arbeit	67
7.1	Simulationsbedingte Limitierungen	67
7.1.1	Inertial Measurement Unit (IMU)	67
7.1.2	Kamera und Vision-Pipeline	68
7.1.3	Vereinfachte Physikmodellierung	69
8	Zukünftige Arbeiten	70
8.1	Realitätsnahe Simulationskonfiguration und alternative Simulationsumgebungen	70
8.2	MPC-Optimierung und erweiterte Physikmodellierung	70
8.3	Präzise geometrische Modellierung und Systemkalibrierung	71
8.4	GPS-basierte Spurführung als Fallback-System	71
9	Fazit	73
9.1	Zentrale Erkenntnisse und wissenschaftliche Beiträge	73
9.2	Limitierungen und kritische Reflexion	74
9.3	Ausblick und zukünftige Forschungsrichtungen	75
10	Anlagen	79
10.1	YOLO-Fehlerberechnung	79
10.2	Fallback-Fehlerberechnung	79
10.3	MPC-Optimierungsalgorithmus	80

Abbildungsverzeichnis

1	Verständnischema der MPC-Regelung	7
2	YOLO-Segmentierung mit YOLOv8	9
3	IMU-Knoten in Webots. Quelle: https://cyberbotics.com/doc/reference/inertialunit . .	14
4	Kamera-Knoten in Webots. Quelle: https://cyberbotics.com/doc/reference/camera	16
5	Querfehler e der Straße.	17
6	Lenk-Sollwert und Lenk-Istwert.	18
7	Aktuatoren im Fahrradmodell. Quelle: https://cyberbotics.com/doc/reference/rotationalmotor	19
8	Synchronisation zwischen Controller und Simulation. Quelle: https://cyberbotics.com/doc/reference/controller	22
9	MPC-Optimierungsalgorithmus mit gebündelten Nebenbedingungen	30
10	Zweistufige Kaskadenregelung: Vision-MPC (Stufe 1) für Spurführung und Balance-PID (Stufe 2) für Stabilisierung	32
11	YOLOv8-Segmentierung.	33
12	Fallback-Strategie.	34
13	Kurvenfahrt	40
14	Kurvenfahrt mit reinem P-Regler (Zeitreihen). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad	41
15	ROI-Querfehler während der P-Regler-Fahrt	41
16	Gefahrene Trajektorie (P-Regler)	41
17	Kurvenfahrt mit PID-Regler und YOLO-Spurführung. X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad	42
18	ROI-Querfehler während der PID-Regler-Fahrt (YOLO)	42
19	Gefahrene Trajektorie (PID-Regler mit YOLO)	43
20	Vergleich der YOLO-Segmentierungsqualität.	43
21	Kurvenfahrt mit PID-Regler und ROI-Fallback-Erkennung. X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad	44
22	ROI-Querfehler während der PID-Regler-Fahrt (ROI)	44
23	Gefahrene Trajektorie (PID-Regler, ROI)	44
24	Kurvenfahrt mit P-Regler (Vision) und PID-Regler (Balance). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad	45
25	ROI-Querfehler während der P-Regler-Fahrt (Vision)	46
26	Gefahrene Trajektorie (P-Regler Vision)	46
27	S-Kurve	47

28	S-Kurve mit YOLO-Regler	47
29	S-Kurve: ausgewählte Zeitreihen (Rollwinkel, Balance-Soll, <code>final_steer</code>). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad	48
30	S-Kurve: visionbasierter Querfehler $\tilde{e}_y$	48
31	S-Kurve mit ROI-Regler	49
32	S-Kurve mit ROI-Regler Daten. X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad	50
33	S-Kurve mit ROI-Regler Error	50
34	Versuchsaufbau: Gerade Strecke mit drei seitlichen Windkanälen (rote Drahtgitterboxen). Die Fahrbahnmitte dient als Referenz für die Spurführung.	51
35	Trajektorie bei 0,5 m/s Seitenwind: Blaue Linie = Fahrzeugspur; Start (grün) und Endpunkt (rot). Die Auslenkung in den ersten beiden Windsegmenten wird nach dem dritten Segment wieder abgebaut.	52
36	Zeitreihen bei 0,5 m/s Seitenwind: Rollwinkel, Balance-Steer und finales Lenkkommando. Die Richtung der Seitenböe spiegelt sich in der Vorzeichenfolge des Rollwinkels wider; der D-Anteil dämpft die schnelle Nick-/Roll-Dynamik. X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad	52
37	Trajektorie bei 1,0 m/s Seitenwind (Baseline-Regler): starke Abdrift nach rechts mit vorzeitigem Abbruch infolge Umkippens.	53
38	Zeitverlauf bei 1,0 m/s (Baseline-Regler): ansteigende Rollauslenkung und instabiles Verhalten nach ≈ 7 s. X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad	53
39	Trajektorie bei 1,0 m/s Seitenwind mit erhöhten Balance-Gains: stabilisierte Fahrt ohne Umkippen; die Abdrift wird begrenzt und anschließend abgebaut.	54
40	Zeitreihen bei 1,0 m/s mit erhöhten Gains: gedämpfter Rollwinkelverlauf; höhere, aber tolerierbare Lenkaktivität (keine Sättigung, keine Divergenz). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad	54
41	Höhenprofile der Teststrecke: Hügel (a) und Senke/Tunnel (b).	56
42	Trajektorie durch die Senke (Fall A, $M = 1,0$ m).	57
43	Zeitverläufe Rollwinkel/Balancelenkung (Fall A, $M = 1,0$ m). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad	57
44	Trajektorie durch die Senke (Fall B, $M = 2,0$ m, Baseline-Gewichte).	57
45	Zeitverläufe Rollwinkel/Balancelenkung (Fall B, $M = 2,0$ m, Baseline-Gewichte). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad	58
46	Trajektorie mit retuntem Balance-PID (Fall B, $M = 2,0$ m).	58
47	Zeitverläufe mit retuntem Balance-PID (Fall B, $M = 2,0$ m). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad	58
48	Trajektorie durch den Hügel (Fall D, $M = 2,0$ m).	59
49	Zeitverläufe mit angepasstem Balance PID (Fall D, $M = 2,0$ m). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad	59
50	Trajektorie durch den Hügel (Fall E, $M = 4,0$ m).	60

51	Zeitverläufe mit angepasstem Balance PID (Fall E, $M = 4,0\text{ m}$). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad	60
52	Zeitanteile im Vision-Zyklus	64

Listings

1	Minimalstruktur einer Webots <code>.wbt</code> -Welt	11
2	IMU-Initialisierung und -Abfrage im C-Controller (Balance-Regelung)	15
3	Motorsteuerung im Regelkreis	21
4	IMU-Initialisierung und -Abfrage im C-Controller (Balance-Regelung)	21
5	Nachrichtenkanal zwischen Controller und Simulation <code>*.wbt</code>	23
6	Struktur der zentralen Konfigurationsdatei <code>balance_config.json</code>	24
7	PID-Parameter in Zanders Hardware-Implementierung	26
8	Lenkpositions-PID-Parameter in Zanders System	26
9	MPC-Controller Initialisierung in der Webots-Implementierung	29
10	YOLO-Fehlerberechnung - Implementierung	79
11	Fallback-Fehlerberechnung - Implementierung	79
12	MPC-Optimierungsalgorithmus in der Webots-Implementierung	80

1 Abstract

Diese Masterarbeit entwickelt und validiert eine zweistufige Regelungsarchitektur für ein selbstbalancierendes Fahrrad durch die systematische Integration einer hochfrequenten PID-Balanceregung (500 Hz) mit einer visionbasierten MPC-Spurführung (20 Hz). Basierend auf den Arbeiten von Ranz (2021), Karabila (2022), Zander (2023) und Giray (2024) wird erstmals die erfolgreiche Kopplung von Balance- und Fahrtrichtungsregelung in einer realitätsnahen Webots-Simulationsumgebung demonstriert.

Die Arbeit löst das zentrale Problem der Reglerinteraktion durch eine duale Controller-Architektur: Ein in C implementierter Balance-Controller stabilisiert kontinuierlich den Rollwinkel mit 2 ms Simulationszeit, während ein Python-basierter Vision-Controller mittels YOLOv8-Segmentierung und MPC-Algorithmus Trajektorien plant und Lenkbefehle überträgt. Zur Erhöhung der Robustheit wurde zusätzlich eine ROI-basierte Fallback-Erkennung entwickelt, die bei Ausfall der neuronalen Spurdetektion klassische Bildverarbeitung einsetzt.

Umfangreiche experimentelle Validierung in verschiedenen Testszenarien belegen die Leistungsfähigkeit des Systems. Dazu gehören Kurvenfahrten mit bis zu 43,62 s stabiler Fahrdauer, erfolgreiche Navigation durch S-Kurven mit 16,8% Verbesserung gegenüber reiner YOLO-basierter Erkennung, sowie Robustheit bei Seitenwind bis 1,0 m/s und Höhenunterschieden bis 4 m durch adaptive PID-Parametrierung. Die ROI-Fallback-Strategie erwies sich der YOLO-Segmentierung in allen Testszenarien als überlegen und reduzierte Rollwinkel-Amplituden um bis zu 40% sowie Querfehler um 50%.

Die Simulationsergebnisse demonstrieren erstmals die praktische Machbarkeit der Kopplung von Balance- und Spurführungsregelung bei konstanter Geschwindigkeit und schaffen durch detaillierte Parameterdokumentation und Echtzeitanalyse eine fundierte Grundlage für die Übertragung auf reale autonome Fahrradprototypen. Die entwickelte Methodik ermöglicht risikofreie Validierung komplexer Regelungsstrategien und systematische Optimierung vor Hardware-Implementierung.

2 Einleitung

2.1 Problemstellung

In diesem Kapitel wird die zentrale Herausforderung dieser Arbeit präsentiert. Ohne regelnden Eingriff kippt ein Fahrrad im Stand oder bei niedriger Geschwindigkeit. Erst durch die Kombination aus gyroskopischen Effekten der rotierenden Räder, dem Nachlauf der Lenkgeometrie und einem aktiven Regler lässt sich eine stabile Fahrt realisieren. Die vorliegenden Arbeiten verfolgen daher das Ziel, eine Simulation eines autonomausfahrendes Fahrrad zu entwickeln, das sich sowohl selbst balancieren als auch eine vorgegebene Strecke verfolgen kann. Hierfür wurde eine hochrealistische Simulationsumgebung in Webots aufgebaut, die eine duale Reglerarchitektur abbildet. Ein schneller Balance-Controller, implementiert in C, stabilisiert den Rollwinkel mit einer Simulationszeit von 2 ms (500 Hz) und gibt einen Lenkwinkel an den Antrieb weiter. Parallel dazu extrahiert ein Vision-Controller in Python mit niedrigerer Frequenz (20 Hz) Informationen aus Kamerabildern, plant eine Trajektorie und überträgt entsprechende Lenkwinkel- und Geschwindigkeitsbefehle. Die Herausforderung besteht darin, diese beiden Regelschleifen so zu koppeln, dass das Fahrzeug stabil bleibt und zugleich auf visuelle Reize reagiert. Darüber hinaus soll die simulierte Physik so realitätsnah sein, dass die Ergebnisse auf reale Fahrversuche übertragbar sind.

Abgrenzung zu realen und simulationsbasierten Ansätzen: Im Gegensatz zu experimentellen Untersuchungen an realen Fahrradplattformen (z. B. Arbeiten von Zander (Zander, 2023) und Karabila (Karabila, 2022)) liegt der Fokus dieser Arbeit auf einer vollständig simulationsbasierten Methodik unter Nutzung von Webots. Frühere Simulationsstudien berücksichtigen dynamisch variierende Geschwindigkeiten, etwa aufgrund von Gefälle oder Bremsmanövern. In der Simulationsumgebung hingegen wird die Geschwindigkeit als konstant angenommen, da durch die optimierten Wegvorgaben die Geschwindigkeit konstant gehalten werden kann. Auch die Sensorik und Regelungshardware unterscheiden sich wesentlich: Reale Versuchsaufbauten (etwa bei Karabila (Karabila, 2022)) nutzten einen BNO-005 IMU-Sensor zur Erfassung von Eulerwinkeln sowie PWM-basierte Motoransteuerung. Die Webots-Simulation ermöglicht hingegen direkten Zugriff auf Zustandsvariablen, ohne den Einsatz realer Hardwarekomponenten oder deren Signalverarbeitung. *Zusammenfassend zeichnet sich diese Arbeit durch ihre rein simulationsbasierte Herangehensweise, die Annahme konstanter Geschwindigkeit sowie den Ausschluss hardwarebedingter Schnittstellen (Sensorik, PWM, ...) aus.*

2.2 Stand der Technik

Die Simulation eines selbstbalancierenden Fahrrads basiert auf zwei zentralen Grundlagen:

- (i) einem hinreichend genauen dynamischen Modell, das die wesentlichen Fahr- und Stabilitätseigenschaften beschreibt, und
- (ii) einer abgestimmten Reglerarchitektur, die sowohl die Aufrechterhaltung des Gleichgewichts als auch die zuverlässige Spurführung gewährleistet.

Auf der Modellseite etablierten Meijaard et al. den Benchmark der linearisierten Whipple-Gleichungen, der bis heute als Referenz für Analyse, Identifikation und Reglersynthese dient (Meijaard et al., 2007). Ergänzend zeigte Kooijman et al., dass Selbststabilität *ohne* gyroskopische

oder Caster-Effekte¹ möglich ist, womit die Interaktion von Massenverteilung, Nachlauf und Lenkinematik als zentrale Gestaltungsgrößen belegt wurde (Kooijman et al., 2011). Diese Ergebnisse motivieren regelungstechnische Ansätze, die das Prinzip „*Steer into the Fall*“ explizit nutzen und die Lenkung als primären Stellgrad einsetzen.

Für die aktive Balanceregulierung über die Lenkung liegt mit Andreo et al. eine LPV-Formulierung² vor, die die geschwindigkeitsabhängige Dynamik berücksichtigt und Stabilität in einem definierten Geschwindigkeitsbereich nachweist (Andreo et al., 2009). Damit wird ein wichtiger Praxisaspekt adressiert, da Fahrräder ihre Vorwärtsgeschwindigkeit ständig ändern und eine rein LTI-Betrachtung³ nur lokal gültig ist. Als Alternative wurden Balanceregler mit Reaktionsrädern untersucht. Kanjanawanishkul vergleicht LQR- und nichtlineare MPC-Ansätze unter Berücksichtigung von Aktuatorstörungen und zeigt, dass bereits einfache Quadratikregler bei Stand- oder Niedriggeschwindigkeit Stabilisierung ermöglichen, jedoch mit zusätzlicher Masse und höherem Energiebedarf verbunden sind (Kanjanawanishkul, 2015). Ein dritter Ansatz, der in der Robotik verbreitet ist, nutzt Control-Moment-Gyroskope (CMG). Park und Yi belegen experimentell, dass ein scissored-pair-CMG störende Quermomente kompensiert und so eine robuste Rollstabilisierung erlaubt, die geeignet für stationäre oder sehr langsame Fahrzustände ist, allerdings mit erheblichem mechanischem Aufwand (Park and Yi, 2020).

Für die gekoppelte Aufgabe aus Balance und Spurführung hat sich eine Kaskadenarchitektur bewährt. Eine schnelle innere Balanceschleife (PID/LQR) und eine langsamere äußere Spurführungsschleife (häufig MPC) wurden von Persson et al. entworfen. Der äußere MPC optimiert dabei unter harten Nebenbedingungen (Roll-, Lenk- und Heading-Grenzen sowie Positionsbeschränkungen) die Soll-Rollwinkel und damit die Kursführung, während ein innerer PID die Soll-Rollwinkel über die Lenkrate stabilisiert (Persson et al., 2021). Die Autoren zeigen auf realitätsnahen Strecken (OpenStreetMap-Go-Kart-Track), dass die Kaskade enge Radien und variable Geschwindigkeiten meistert und zugleich eine saubere Trennung der Zeitskalen ermöglicht. Dieser Aufbau ist unmittelbar anschlussfähig an *do-mpc*-basierte Implementierungen, da Optimierungs-, Nebenbedingungs- und Prädiktionshorizonte explizit parametrierbar sind.

Parallel zur Reglerseite hat sich die Umfeldwahrnehmung stark weiterentwickelt. Ein prominenter Systemdemonstrator ist das Tsinghua-„Tianji“-Fahrrad, das Kameraperzeption (Objekterkennung/-tracking), Sprachkommandos, Hindernisvermeidung und Balance auf einem eingebetteten Chip integriert (Pei et al., 2019). Die Studie ist weniger eine methodische Neuentwicklung der Fahrdynamik, zeigt aber überzeugend, dass visuelle Spurführung und Balanceregulierung *in Echtzeit* auf kompakten Plattformen zusammengeführt werden können, somit ein wichtiger Befund für kamerabasierte Spurhaltung.

2.3 Bisherige Arbeiten

Die im vorherigen Abschnitt dargestellten Forschungsarbeiten zeigen, dass sowohl klassische als auch moderne Regelungsverfahren prinzipiell geeignet sind, ein selbstbalancierendes Fahrrad zu stabilisieren und mit Trajektorienfolgeregelungen zu kombinieren. Während sich diese Studien

¹„Caster-Effekte“ entstehen, wenn der Aufstandspunkt des Vorderrads hinter der Lenksäule liegt, wodurch das Rad sich durch die Bewegung selbständig in Fahrtrichtung ausrichtet :contentReference.

²LPV (Linear Parameter-Varying) beschreibt Systeme, deren Dynamik von zeit- oder zustandsabhängigen Parametern beeinflusst wird und erlaubt so eine erweiterte Stabilitätsanalyse über verschiedene Betriebsbereiche hinweg.

³LTI (Linear Time-Invariant) beschreibt Systeme mit zeitlich unveränderlichen Parametern; diese Annahme ist nur lokal gültig, wenn die Geschwindigkeit des Fahrrads konstant bleibt.

überwiegend auf externe Forschungsgruppen beziehen, existieren auch an der Goethe-Universität Frankfurt eine Reihe aufeinander aufbauender Abschlussarbeiten, die wesentlich zur Entwicklung des hier untersuchten Systems beigetragen haben.

2.3.1 Anna Ranz (2021) – Hardware-Grundlagen

Die Bachelorarbeit von Anna Ranz markierte den praktischen Ausgangspunkt des Projekts und schuf eine erstmals vollständig lauffähige Experimentalplattform, auf der regelungstechnische Konzepte an realer Hardware untersucht werden konnten (Ranz, 2021). Zentrales Element ist ein *BeagleBone Black* als Steuereinheit, der den Lenkantrieb über einen *MD49*-Controller (Motor: *EMG49*) via *UART* ansteuert und die Inertialmessdaten einer *BNO055*-IMU über *I²C* erfasst. Ergänzt wird die Architektur durch einen Nabenmotor am Hinterrad, der eine konstante Vorwärtsfahrt sicherstellt. In dieser Kombination standen erstmals mechanische Plattform, Sensoren und Aktoren mit klar definierten Schnittstellen zur Verfügung, um Stabilisierung und Lenkregelung systematisch zu evaluieren.

Im Rahmen der Inbetriebnahme implementierte Ranz erste PID-Regelkreise, validierte die IMU-Sensorik in separaten Testprogrammen und analysierte die Dynamik des Gesamtsystems mit Blick auf Massenträgheit, Raddynamik und Lenkkinematik. Besondere Aufmerksamkeit galt dem Zusammenspiel von Trägheitsmoment, Lenkwinkel und Rückstellkräften, da diese Größen die Querstabilität wesentlich bestimmen. Ergänzende Messreihen dienten der Bewertung der *BNO055* hinsichtlich Genauigkeit und Latenz der Rollwinkelbestimmung. Eine sorgfältige Kalibrierung stellte sicher, dass die Datenqualität den Anforderungen eines geschlossenen Regelkreises genügt.

Die Arbeit dokumentiert die Hardware umfassend anhand von Schaltplänen, 3D-Modellen und Messaufnahmen und bildet damit die hardwareseitige Referenzbasis für alle nachfolgenden Entwicklungen (Ranz, 2021). Zugleich wurden systemische Grenzen der ersten Ausbaustufe transparent herausgearbeitet, darunter die begrenzte Reaktionsgeschwindigkeit des *MD49*-Motorcontrollers sowie Latenzen in der *UART*-Kommunikation und somit konkrete Ansatzpunkte für spätere Verbesserungen identifiziert.

Insgesamt kennzeichnet die Arbeit von Ranz den Übergang von theoretischen Vorüberlegungen hin zu einer belastbaren Forschungsplattform.

2.3.2 Amine Karabila (2022) – Erste funktionierende Regelung

Amine Karabila schloss 2022 unmittelbar an den Hardware-Prototyp von Ranz an und überführte das System von einzelnen Stellversuchen zu einem geschlossenen, echtzeitfähigen Regelkreis. Kernbestandteil ist eine dreistufige P-Regelung auf dem *BeagleBone Black*, die den Rollwinkel der *BNO055*-IMU (Bosch Sensortec, 2020) und die Lenkerstellung des *MD49*-Encoders (Devantech Ltd., 2019) auswertet, während ein hinterer Nabenmotor die Vortriebsdrehzahl konstant hält (Karabila, 2022). Damit gelang erstmals eine softwareseitig realisierte Balancekontrolle, die den Forschungsprototyp in eine echte Versuchsplattform überführte.

Ein erstes Hindernis war die Strombegrenzung des *MD49*, die den *EMG49*-Lenkmotor zu langsam ansprechen ließ. Karabila ersetzte deshalb den Leistungsteil durch eine *BTS7960-H*-Brücke (Infineon Technologies, 2018) und verwendete den *MD49* nur noch zur hochauflösenden Wegmessung. Nichtblockierende *UART*-Aufrufe verkürzten die Encoderabfrage von rund 4 ms auf knapp 1 ms, sodass die Gesamttransportzeit des Reglers auf etwa 2 ms sank. Damit wird deutlich, dass die Stabilität des

Regelkreises aus dem Zusammenspiel leistungsfähiger Algorithmen und einer auf minimale Latenzen ausgelegten Hard-/Software resultiert.

Die erste Regelversion koppelte die Motorgeschwindigkeit über einen gestreckten tanh-Verlauf an die Verweildauer des Rollwinkels in einer „habitablen Zone“. Außerhalb des Labors erwies sich dieses Verfahren jedoch als zu träge. Der Lenker schlug regelmäßig an die Endanschläge, und Stützräder mussten das Fahrrad vor dem Kippen bewahren. Die finale Lösung verknüpfte dagegen den gemessenen Rollwinkel direkt mit einem geschwindigkeitsabhängigen Soll-Encoderwert. Dadurch pendelte der Lenker nur noch um wenige Grad um die Nullposition.

Validiert wurde der Regler im Hof des Informatikgebäudes ($\approx 9.5 \times 26.5$ m, fünf Prozent Steigung). Bei Sollgeschwindigkeiten von 6–10 km/h blieb das Fahrrad während aller aussagekräftigen Fahrten aufrecht.

Damit bewies Karabilas Arbeit erstmals die Realisierbarkeit einer selbstbalancierenden Regelung und schuf die Grundlage für die PID-Optimierungen von Zander sowie die MPC-Navigation von Giray. Insbesondere machte sie deutlich, dass die Regelgüte stark von niedrigen Latenzen und einer robusten Kopplung zwischen Sensoren und Aktoren abhängt, ein zentrales Motiv, das auch in den nachfolgenden Arbeiten beibehalten und weiterentwickelt wurde.

2.3.3 Jonah Zander (2023) – Optimierte PID-Balanceregung

Zander knüpfte 2023 an die Vorarbeiten an und formulierte als Kernziel, das Fahrrad mindestens 60 s auf ebener Strecke ohne Bodenkontakt der Stützräder stabil fahren zu lassen (Zander, 2023). Zur Umsetzung entwickelte Zander eine modular aufgebaute C-Software auf dem BeagleBone Black (Debian), in der Multi-Threading Sensor-/Aktor-I/O, Reglerkern und Logging entkoppelt. Zeitkritische Abtast- und Vorverarbeitungsaufgaben wurden in die Programmable Realtime Units (PRUs) verlagert, wodurch deterministische Lesezyklen für Fahr- und Lenkwinkel im zweistelligen kHz-Bereich möglich wurden. Die effektive Transportverzögerung zwischen Messung und Stellgröße sank dadurch deutlich, was die Stabilitätsreserven des Reglers erhöhte (Zander, 2023).

Die Balanceregung realisierte Zander als klassisch ausgelegten PID-Regler, dessen Parameter iterativ auf Basis umfangreicher Mess- und Logdaten optimiert wurden. Im Vergleich zur zuvor eingesetzten dreistufigen P-Logik (Karabila, 2022) reduziert der I-Anteil den stationären Regelfehler (Ausregelgüte), während der D-Anteil die Einschwingdämpfung erhöht. In der Software wurden robuste Elemente berücksichtigt, unter anderem Begrenzung und Glättung des Lenkmotor-Solls (Rate- und Amplitudenlimits), sorgfältige Filterung der Eingangssignale (Encoder/IMU) zur Rauschunterdrückung bei erhaltener Phasenreserve sowie latenzarme Pfade zwischen PRU-Puffern und Reglerkern zur Minimierung von Jitter. Das Loggingsystem zeichnete synchronisierte Sensor- und Aktordaten auf und erlaubte eine systematische Auswertung der Reglerwirkung (Zander, 2023).

Neben dem Reglerkern stärkte Zander die Betriebssicherheit. Dabei wurden zwei Notausschalter (separate Lenkungs- bzw. Gesamtabstaltung), eine Reißleine zur sofortigen Trennung der Lenkungsversorgung in kritischen Situationen sowie ein Fail-Safe für den RC-Empfänger (Stop bei Signalverlust) begrenzen Risiken unkontrollierter Lenkereinschläge und mechanischer Schäden eingesetzt (Zander, 2023).

In experimentellen Fahrtests blieb das Fahrrad über mehr als 60 s stabil in Balance, ohne dass die Stützräder den Boden berührten. Bei konstanter Geschwindigkeit auf ebenem Untergrund waren zudem gesteuerte Richtungsänderungen per Fernbedienung möglich, ohne die Balance zu verlieren (Zander, 2023). Damit erzielte Zander den bis dahin längsten autonom balancierten Fahrbetrieb des Prototyps.

2.3.4 Yasin Giray (2024) – YOLO + MPC-Fahrtrichtung

Aufbauend auf der in (Zander, 2023) erreichten stabilen Balanceregung verlagerte Giray (2024) (Giray, 2024) den Schwerpunkt auf die autonome Fahrtrichtungswahl mittels Computer Vision und modellprädiktiver Regelung. Ziel war eine monokamera-basierte Pipeline, die in Echtzeit auf eingebetteter Hardware lauffähig ist und aus Bilddaten eine Referenztrajektorie ableitet, der das Fahrrad folgen kann, ohne die Balance zu verlieren.

Die Wahrnehmungskomponente setzt auf ein effizientes Segmentierungsmodell aus der YOLOv8-Familie (Jocher et al., 2023). Nach einer Evaluation alternativer Verfahren (u. a. FastSAM (Zhao et al., 2023)) fiel die Wahl aufgrund des guten Verhältnisses von Genauigkeit und Latenz auf ein Ultralytics-Modell in der Segmentation-Variante ⁴. Das Netz wurde mit einem angepassten Datensatz trainiert und für die Inferenz mittels TensorRT auf dem NVIDIA Jetson Nano beschleunigt, sodass die Bildauswertung in Zyklen von etwa 100 ms erfolgen konnte. Aus den segmentierten Szenen werden Stützpunkte extrahiert und über Spline-Interpolation zu einer glatten Referenzspur verdichtet, die die gewünschte Fahrlinie repräsentiert.

Für die Fahrregelung implementierte Giray einen Model Predictive Controller (MPC) auf Basis eines Einspurmodells (Hunziker, 2019). Der MPC minimiert über einen endlichen Horizont Abweichungen von der Referenzspur bei gleichzeitig moderatem Stellaufwand und berücksichtigt Nebenbedingungen des Systems. In jedem Rechenzyklus wird das Optimierungsproblem mit der aktuellen Zustandschätzung gelöst. Modellierung, Trajektorien-Interpolation und MPC-Optimierung wurden zunächst in Python umgesetzt und auf die Jetson-Plattform portiert.

Die Pipeline detektierte in den Simulationen Fahrbahnkanten und einfache Hindernisse zuverlässig. Daraus ergaben sich stabile Referenztrajektorien. Zugleich wurden Grenzen sichtbar, da eine explizite Kollisionsvermeidung noch nicht integriert wurde. Eine Tiefeninformation war nur indirekt über Bildgeometrie vorhanden. Nach Giray ist mit neueren Segmentierungsansätzen und leistungsfähigeren Edge Plattformen eine weitere Reduktion der Latenz zu erwarten (Zhao et al., 2023) (Jocher et al., 2023).

Für die vorliegende Arbeit ist die Einordnung klar: Die von Zander übernommene PID-Balanceregung bildet die innere Schleife, während Girays MPC-basierter Spurhalter als äußere Schleife in *Webots* integriert wird. Diese Schichtung erlaubt es, die Kopplung von Balancehaltung und visionbasierter Trajektorienverfolgung systematisch zu untersuchen und in einer realitätsnahen Simulation zu kalibrieren, bevor reale Fahrversuche erfolgen.

⁴Gemeint ist die YOLOv8-Ausprägung, die neben Klassen/Boxen pro Objekt Pixelmasken (Semantik/Instanz) vorhersagt.

3 Grundlagen

Dieses Kapitel führt die theoretischen und methodischen Grundlagen ein, die für das Verständnis der im Folgenden vorgestellten Reglerarchitekturen und Bildverarbeitungsverfahren notwendig sind. Zunächst wird die PID-Regelung als klassischer Vertreter der Regelungstechnik erläutert und ihre Eignung zur Stabilisierung des Balance-Problems des Fahrrads diskutiert. Anschließend folgt eine Einführung in das Prinzip der modellprädiktiven Regelung (MPC), die eine vorausschauende Berechnung von Stellgrößen erlaubt. Abschließend werden die Grundlagen der Objekterkennung mit YOLO sowie der Bildsegmentierung vorgestellt, um die visuelle Wahrnehmung und Spurführung des autonomen Fahrrads zu ermöglichen.

3.1 PID-Regelung – Prinzip und Eignung für das Balance-Problem

Die Proportional-Integral-Differential (PID)-Regelung ist der am weitesten verbreitete Ansatz der klassischen Regelungstechnik. Ein PID-Regler ermittelt die Stellgröße $u(t)$ aus dem Fehler $e(t)$ zwischen Sollwert SP und dem gemessenen Istwert PV nach

$$u(t) = K_P e(t) + K_I \int_0^t e(\tau) d\tau + K_D \frac{de(t)}{dt} \quad (1)$$

wobei K_P , K_I und K_D die Verstärkungsparameter für proportionale, integrale und derivative Anteile sind. Der proportionale Anteil erzeugt eine Stellgröße, proportional zur momentanen Fehlergröße und reduziert so die Anstiegszeit. Der Integrator akkumuliert den Fehler und eliminiert stationäre Abweichungen, kann aber langsame Dynamik verursachen (Hedengren et al., 2024). Die Derivative wirkt der Änderung des Fehlers entgegen und dämpft dadurch Überschwinger. Sie erhöht jedoch die Empfindlichkeit gegenüber Messrauschen, weshalb in vielen Anwendungen filternde Maßnahmen erforderlich sind.

PID-Regler werden eingesetzt, wenn eine robuste und einfach implementierbare Rückführung gefordert ist und das Systemverhalten hinreichend durch lineare Modelle beschrieben werden kann. In der Literatur wird die PID-Regelung häufig als Standardlösung für nicht integrierende Prozesse bezeichnet. Ihre Parametrierung erfordert eine sorgfältige Abwägung zwischen Ansprechverhalten und Stabilitätsreserve. Eine Erhöhung des proportionalen Anteils verringert die Regelabweichung, kann aber zu Instabilitäten führen. Ein zu hoher Integrationsanteil kann Integrator-Windup verursachen, die wiederum zu Instabilitäten führen kann.

Beim selbstbalancierenden Fahrrad lässt sich die Balanceproblematik auf das klassische inverses-Pendel-Problem zurückführen. Ein Rad, dessen Schwerpunkt über der Aufstandsfläche liegt, befindet sich in einem instabilen Gleichgewicht, wodurch kleinste Störungen zum Kippen führen. Um das System aufrecht zu halten, muss der Regler in Echtzeit Stellmomente ansetzen, die den kippspezifischen Drehmomenten entgegenwirken. Die Anforderungen an geringe Latenz und hohe Abtastrate werden etwa beim inversen Pendel mit Updatefrequenzen von mehreren Kilohertz umgesetzt. Dies verdeutlicht, dass auch beim Fahrrad eine schnelle Regelungsschleife erforderlich ist, wie sie beispielsweise in den Bachelorarbeiten von Karabila und Zander implementiert wurde. Beide Arbeiten basieren auf P- bzw. PID-Reglern, die den Neigungswinkel mittels IMU messen und über den Lenkmotor oder den Antrieb korrigieren (Concurrent Real-Time, 2024).

Insgesamt ist die PID-Regelung für das Balance-Problem des autonomen Fahrrads wegen ihrer geringen Komplexität und Rechenlast, der einfachen Implementierung auf Mikrocontrollern sehr gut geeignet. Die Nichtlinearität des Fahrverhaltens und die starken Störmomente durch Schräglagen

erfordern jedoch eine sorgfältige Abstimmung der Parameter und gegebenenfalls Erweiterungen wie Anti-Windup-Mechanismen oder Filterung der derivativen Komponente, um die Regelung stabil und performant zu halten.

3.2 MPC-Regelung – Prinzip und Eignung für das Fahrtrichtungsproblem

Model predictive control (MPC) nutzt ein internes Modell des Systems, um dessen zukünftiges Verhalten über einen endlichen Zeithorizont vorherzusagen. Auf Grundlage dieser Vorhersage und des aktuellen gemessenen bzw. geschätzten Zustands werden optimale Stellgrößen berechnet, die einen definierten Kostenfunktional minimieren und gleichzeitig die Systembeschränkungen einhalten. Nach jedem Abtastintervall wird nur die erste Stellgröße angewendet und die Optimierung mit vorwärts verschobenem Horizont neu gelöst, weshalb man auch von *receding horizon control* spricht. Zu den wesentlichen Vorteilen von MPC zählen die proaktive Reaktion auf künftige Störungen, die Möglichkeit nichtlineare Modelle ohne Linearisierung zu berücksichtigen und die explizite Berücksichtigung von physikalischen und sicherheitsrelevanten Beschränkungen. Im Gegensatz zu reaktiven PID-Reglern kann MPC damit frühzeitig gegensteuern und gleichzeitig harte Grenzen, etwa Stellweg- oder Geschwindigkeitsbeschränkungen, einhalten.




Abbildung 1: Verständnisschema der MPC-Regelung

Abbildung 1 verdeutlicht das fundamentale Prinzip der modellprädiktiven Regelung. Das Schema zeigt die charakteristische Zeitaufteilung zwischen Vergangenheit (PAST) und Zukunft (FUTURE), wobei der aktuelle Zeitpunkt k die Grenze bildet. Die rote Referenztrajektorie stellt den gewünschten Sollverlauf dar, während die gelbe Linie den vorhergesagten Systemausgang (Predicted Output) über den Prädiktionshorizont p zeigt. Besonders deutlich wird die Diskrepanz zwischen der orangenen Linie (Measured Output), die den tatsächlich gemessenen Systemausgang repräsentiert, und der Vorhersage.

Die türkise Linie zeigt den vorhergesagten Stellgrößenverlauf (Predicted Control Input), während die dunkelblaue Linie den bisherigen Stellgrößenverlauf (Past Control Input) darstellt. Ein zentrales Merkmal von MPC wird durch den rechteckigen Verlauf der Stellgrößen deutlich: Die Optimierung

erfolgt in diskreten Zeitschritten, und die berechneten Stellgrößen werden über die jeweiligen Abtastintervalle konstant gehalten. Der Prädiktionshorizont erstreckt sich vom aktuellen Zeitpunkt k bis zum Zeitpunkt $k + p$, wobei das System sein zukünftiges Verhalten basierend auf dem internen Modell vorhersagt und die Stellgrößensequenz entsprechend optimiert.

Beim selbstbalancierenden Fahrrad besteht das Fahrtrichtungsproblem darin, aus Kamerainformationen einen Sollkurs abzuleiten und das Fahrzeug mit begrenztem Lenkradius und Lenkrate entlang dieser Trajektorie zu führen. Der in der Vision-Regelung verwendete `VisionMPCController` modelliert das Fahrzeug als einfaches Fahrraddynamikmodell mit Zustandsvektor $x = [x, y, v, \psi]$ für Position, Geschwindigkeit und Gierwinkel sowie Eingangsvektor $u = [a, \delta]$ für Beschleunigung und Lenkwinkel. Aus dem aktuellen Zustand und dem lateral gemessenen Fehler wird ein Referenzpfad erzeugt (Ziel-Yaw proportional zum Fehler), der über einen Horizont T vorwärts projiziert wird. Anschließend löst der MPC ein konvexes Optimierungsproblem, das die Abweichung von diesem Pfad, die Eingangsgrößen sowie deren zeitliche Änderung in einer quadratischen Kostenfunktion gewichtet und durch Beschränkungen auf maximalen Lenkwinkel, Lenkrate, Geschwindigkeitsbereich und Beschleunigung ergänzt. Stehen geeignete Optimierungslöser (z. B. `cvxpy`) zur Verfügung, werden aus diesem Problem kontinuierliche Stellgrößen $\delta \in [-\delta_{\max}, \delta_{\max}]$ berechnet, andernfalls fällt der Controller auf eine einfache P-Regelung zurück. Vor der Weitergabe an den schnellen Balance-Controller werden die resultierenden Lenkwinkel und Beschleunigungen normiert, geglättet und auf Änderungsraten begrenzt, um ruckfreie Übergänge zu gewährleisten (Giray, 2024). Eine spezifische Erklärung der implementierten Regelung findet sich in Kapitel 5.2.

Die Eignung der MPC Regelung für das Fahrtrichtungsproblem ergibt sich aus der Vorhersagefähigkeit und der Einbeziehung von Beschränkungen. Das Fahrradsystem ist nichtlinear und um einer gekrümmten Spur zu folgen, muss der Regler zukünftige Kurvenverläufe berücksichtigen und gleichzeitig mechanische Limits (Lenkeinschlag, Lenkrate) respektieren. MPC kann diese Randbedingungen explizit in das Optimierungsproblem integrieren und die Stellgrößen so wählen, dass sowohl die Trajektorienabweichung als auch der Stellaufwand minimiert werden. In Yasin Girays Masterarbeit wurde der visionbasierte MPC-Regler mit einem Horizont von $T = 3$ und den genannten Zuständen und Eingängen implementiert und mit Gewichten auf Zustände, Eingänge und deren Differenzen parametrisiert. Simulationen zeigten, dass das Fahrrad mithilfe des MPC gleichmäßig entlang der aus der Bildsegmentierung abgeleiteten Spur navigierte und dabei die mechanischen Limits einhielt. Somit stellt MPC einen geeigneten Ansatz dar, um das autonome Fahrrad stabil und vorausschauend entlang einer vorgegebenen Fahrtrichtung zu steuern.

3.3 YOLO-Grundlagen und Segmentierung

You Only Look Once (YOLO) ist eine Reihe von Echtzeit-Objekterkennungsverfahren, die auf Convolutional Neural Networks basieren. Das ursprüngliche YOLO wurde 2016 von Redmon et al. vorgestellt und erfordert im Gegensatz zu region-proposal-basierten Ansätzen nur einen Vorwärtsdurchlauf durch das Netz, um Klassen und Bounding Boxes für alle Objekte in einem Bild zu bestimmen (Redmon et al., 2016). Neuere Modelle wie YOLOv8 erweitern die ursprüngliche YOLO-Architektur. Sie können nicht nur Objekte erkennen, sondern auch Bilder klassifizieren und Instanzen segmentieren. Ein moderner, leichter Backbone ⁵, ein ankerfreier Detektionskopf ⁶ und

⁵Der Backbone ist das Merkmalsextraktionsnetz der Architektur. Er transformiert das Eingabebild in hierarchische, mehrskalige Feature-Maps, die die Grundlage für Klassifikation, Lokalisierung und Segmentierung bilden.

⁶Ankerfrei bedeutet ohne vordefinierte Ankerboxen. Der Kopf schätzt pro Bildposition direkt Objektzentren und Boxparameter sowie Klassenwahrscheinlichkeiten, was Hyperparameter reduziert und das Matching im Training vereinfacht.

verbesserte Verlustfunktionen erhöhen Effizienz und Genauigkeit. Dadurch laufen die Modelle auf vielen Hardwareplattformen zuverlässig und schnell (OpenMMLab and Ultralytics, 2023).

Bei der Bildsegmentierung wird jedem Pixel eines Bildes ein Label zugeordnet. Semantic Segmentation ordnet jedem Pixel eine Objektklasse zu, ohne zwischen einzelnen Instanzen zu unterscheiden, während Instance Segmentation jedes Pixel einer individuellen Objektinstanz zuordnet. Panoptic Segmentation kombiniert beide Ansätze, indem sie sowohl die Klasse als auch die Instanz für jedes Pixel identifiziert. In der Instanzsegmentierung liefert das Netzwerk neben Bounding Boxes auch Masken, die die Form jedes erkannten Objekts abbilden.

YOLOv8 erweitert die Objekterkennung um Instanzsegmentierung, wobei ein auf YOLACT⁷ basierender Kopf für jedes erkannte Objekt eine zusätzliche Maske berechnet (OpenMMLab and Ultralytics, 2023). Durch diese Erweiterung kann ein Modell in einem einzigen Forward-Pass sowohl Objekte lokalisieren als auch deren pixelgenauen Umrisse bestimmen. Wie bei früheren YOLO-Versionen werden Varianten unterschiedlicher Größe bereitgestellt (Nano, Small, Medium, Large usw.), um den Kompromiss zwischen Geschwindigkeit und Genauigkeit zu steuern (OpenMMLab and Ultralytics, 2023).

In dieser Arbeit wird eine YOLOv8-basierte Segmentierung für die Umfeldwahrnehmung genutzt. Das Modell ist auf vier Klassen trainiert: Wiese („meadow“), Hindernis („obstacle“), Hauptfahrbahn („street_main“) und Seitenfahrbahn („street_side“), wie in Abbildung 2 zu sehen ist (Giray, 2024). Dabei liefert es pro Klasse ein Pixelmasken Overlay sowie die zugehörigen Bounding Boxes. Anschließend wird aus dem Segment „street_main“ der laterale Fehler bestimmt, der als Eingang für die Pfadverfolgung dient. Die genauen Details zur Modellauswahl, Datensatzgenerierung und Implementierung werden in einem späteren Kapitel beschrieben. Hier soll lediglich hervorgehoben werden, dass die Kombination aus schneller YOLO-Detektion und Instanzsegmentierung eine effiziente und genaue Grundlage für die kamerabasierte Fahrspurerkennung bildet.



Abbildung 2: YOLO-Segmentierung mit YOLOv8

⁷YOLACT steht für You Only Look At Coefficients und ist ein einstufiges Verfahren zur Instanzsegmentierung. Es erzeugt Prototypmasken und kombiniert sie mit Koeffizienten zu Objektmasken

4 Simulationsumgebung

In diesem Kapitel wird die in Webots realisierte Simulationsumgebung vorgestellt, die als zentraler Versuchsstand für Entwurf, Parametrierung und Evaluation der kombinierten Regelung des selbstbalancierenden Fahrrads dient. Ziel ist es, eine reproduzierbare und sichere Testumgebung zu schaffen, in dem das physikalische Fahrverhalten, die sensorgeführte Pfadverfolgung sowie die Kopplung von schneller Balance-Regelung und langsamer Vision-/Trajektorienplanung unter kontrollierten Bedingungen untersucht werden können. Webots bietet dafür eine deterministische Dynamiksimulation auf Basis von ODE, eine hierarchische Szenenbeschreibung und eine klare Trennung von Geometrie, Physik, Sensorik, Aktuatorik und Controllern (Cyberbotics, 2025).

4.1 Überblick

Webots ist ein frei verfügbares, quelloffenes und plattformunabhängiges Robotik Simulationsprogramm, das seit 1998 kontinuierlich gepflegt wird und in Forschung, Lehre und Industrie breite Anwendung findet (Cyberbotics, 2025; Michel, 2004). Es kombiniert eine moderne QtBenutzeroberfläche mit einer MehrkörperDynamiksimulation auf Basis der *Open Dynamics Engine* (ODE) sowie einer OpenGLgestützten RenderingPipeline. Dadurch lassen sich fotorealistische 3DSzenen mit deterministischem Integrationsschema und feingranularer Kontrolle der Simulationszeit schrittgenau ausführen (Cyberbotics, 2025).

Kern des Webotsmodells ist die hierarchische Szenenrepräsentation in *World*-Dateien (*.wbt; VRMLbasiert). Eine Welt kapselt globale Parameter (z. B. Zeitauflösung, Kontakt und Reibungsmodelle), Umgebungsobjekte (Boden, Licht, Hintergrund) sowie Roboterknoten mit Sensorik, Aktuatorik und Masseneigenschaften. Geräte (z. B. Kamera, IMU, Lidar, RotationalMotor) sind als Nodes mit klar definierten Schnittstellen realisiert, ihre Parameter (Auflösung, Bildfrequenz, Dämpfung, Grenzwerte) sind reproduzierbar konfigurierbar. Controller laufen als getrennte Prozesse in C/C++, Python, Java oder MATLAB und kommunizieren zur Laufzeit über APIs mit der Simulationswelt (Cyberbotics, 2025). Eine spezielle *Supervisor*API erlaubt höherwertige Eingriffe (Positionsreset, automatisiertes Logging, MetrikAuswertung) und bildet die Grundlage für reproduzierbare BenchmarkingPipelines (Cyberbotics, 2025).

Für regelungsorientierte Studien bietet Webots drei Eigenschaften, die in dieser Arbeit zentral sind:

- (i) *Determinismus* durch festen Zeitschritt und explizite Integrationsreihenfolge, was faire Parameterstudien ermöglicht.
- (ii) *Modularität* durch die Trennung von Geometrie, Physik, Sensorik/Aktuatorik und Controllern, wodurch Varianten (z. B. Reibungskoeffizienten, Trägheiten, Abtastraten) isoliert untersucht werden können.
- (iii) *Automatisierbarkeit* über den Supervisor, u. a. für SzenarioResets, Störgrößeninjizierung, Batch-Runs und standardisierte Ergebnisberichte (Cyberbotics, 2025).

Für diese Arbeit ist Webots folglich ein geeignetes Testumgebung, um die Kopplung einer schnellen Balance-PID-Regelung mit einer langsameren vision bzw. modellprädiktiven Pfadführung systematisch zu entwerfen, zu parametrieren und zu evaluieren. Die klare Trennung der Subsysteme (Physik, Sensorik, Controller) erlaubt Variantenstudien (z. B. Variation von Zeitschritt/Reibung, Sensorausfall, Verzögerungen), während die Supervisor Schnittstelle reproduzierbare Testreihen mit konsistentem Logging unterstützt (Cyberbotics, 2025).

4.2 Struktur der Simulationsumgebung

Die Versuche werden in eine `.wbt`-Welt beschrieben, die die Szene hierarchisch (VRML) aufbaut. Dabei sind globale Einstellungen, Geometrie, Materialien und Roboter mit Sensorik, Aktuatorik und Controllern zu finden. Zentral sind ein fester Simulationszeitschritt sowie die globalen Physikparameter, die deterministische Abläufe und reproduzierbare Kontakte sicherstellen. Der Fahrradroboter (*BICYCLE*) ist mit Massen- und Trägheitseigenschaften, vereinfachten Kollisionskörpern und Gelenken für Vortrieb und Lenkung modelliert. Der schnelle Balance-PID in C läuft direkt auf dem Roboter, während ein externer *Supervisor* mit Kamera die Spur wahrnimmt und mittels MPC Lenksollwerte berechnet. Der Datenaustausch erfolgt über **Emitter/Receiver**, wobei das Logging und die Auswertung beim Supervisor liegen. Wie schon erwähnt sind daher, durch die Trennung von Physikmodell, Sensorik und Regellogik gezielte Parameterstudien bei gleichbleibender Szenengeometrie möglich. Der in Listing:1 gezeigte Pseudocode beschreibt die Struktur der in unseren Testfahrten verwendeten Webots-`.wbt`-Weltdatei und zeigt die minimalen Knoten (`WorldInfo`, `RectangleArena`, `Robot`, `Supervisor`) in ihrer Kernkonfiguration.

```

1  #VRML_SIM R2025a utf8
2
3  # -- Externe PROTOs (Arena, Hintergrund, Supervisor) --
4  EXTERNPROTO "projects/objects/floors/protos/RectangleArena.proto"
5  .... (andere EXTERNPROTOs)
6
7  # -- Globale Welt- und Kontaktparameter --
8  WorldInfo {
9      basicTimeStep 2
10     contactProperties [
11         ContactProperties {
12             material1 "wheel"
13             material2 "ground"
14             coulombFriction [ 0.8 ]
15             bounce 0.3
16         }
17     ]
18 }
19
20 # -- Kamera/Blickpunkt --
21 Viewpoint {
22     orientation 0 1 0 0
23     position 0 2 8
24     follow "Little Bicycle V2"
25 }
26
27 # -- Hintergrund + Arena (Textur als Fahrspur) --
28 TexturedBackground { skybox FALSE }
29 TexturedBackgroundLight { }
30 RectangleArena {
31     contactMaterial "ground"
32     floorSize 64 100
33     floorTileSize 64 100
34     floorAppearance PBRAppearance {
35         baseColorMap ImageTexture { url [ "textures/S-Kurve.png" ] }
36         roughness 1
37         metalness 0
38     }

```



```

39     wallThickness 0.001
40     wallHeight 0.001
41 }
42
43 # -- Fahrradroboter (Sensorik, Aktorik, Kommunikation) --
44 DEF BICYCLE Robot {
45     name "Little Bicycle V2"
46     controller "balance_control_c"
47     supervisor TRUE
48     children [
49         InertialUnit { name "imu" }
50         Camera { name "front_cam" width 480 height 320 fieldOfView 2 }
51         Receiver { name "command_rx" channel 1 bufferSize 64 }
52         Emitter { name "status_tx" channel 2 bufferSize 64 }
53
54         # Hinterradantrieb (vereinfachtes Gelenk)
55         HingeJoint {
56             jointParameters HingeJointParameters { axis 0 0 1 }
57             device [ RotationalMotor { name "motor::wheel" maxTorque 120 } ]
58             endPoint Solid { contactMaterial "wheel" }
59         }
60
61         # Lenkung (vereinfachtes Gelenk)
62         HingeJoint {
63             jointParameters HingeJointParameters { axis 0 0 1 }
64             device [ RotationalMotor { name "handlebars motor" maxTorque 25 } ]
65             endPoint Solid { }
66         }
67     ]
68     boundingObject Box { size 0.4 1.1 1.8 }
69     physics Physics { mass 4 }
70 }
71
72 # -- Externer Supervisor (Overhead-Kamera, Funk) --
73 Supervisor {
74     name "Vision Controller"
75     controller "vision_control_py"
76     children [
77         Camera { name "overhead" width 640 height 360 fieldOfView 2 }
78         Emitter { name "command_tx" channel 1 bufferSize 64 }
79         Receiver { name "status_rx" channel 2 bufferSize 64 }
80     ]
81 }

```

Listing 1: Minimalstruktur einer Webots .wbt-Welt

4.3 Physikmodell: Open Dynamics Engine (ODE) in Webots

Die *Open Dynamics Engine* (ODE) ist eine freie, plattformunabhängige Physikbibliothek zur Simulation starrer Mehrkörpersysteme mit Gelenken und Kollisionen. Sie kombiniert integrierte Kollisionserkennung mit einem constraint-basierten Dynamikmodell und wird in zahlreichen Simulationsumgebungen eingesetzt. Das Welt- und Objektverhalten wird über `WorldInfo` und `Physics` konfiguriert. Dort werden unter anderem der Zeitschritt sowie die ODE-Kernparameter ERP (Error Reduction Parameter) und CFM (Constraint Force Mixing) gesetzt. ERP/CFM steuern die „Feder-/Dämpfer“-Eigenschaften restringierter Bewegungen und Kontaktauflösungen und sind für

stabile, nicht-schwingende Lenkeingriffe wesentlich. Kontakte werden als *contact joints* mit Coulomb-Reibung gelöst, während zusätzliche Felder Rückprall und weiche Grenzen erlauben.

In Webots wird die Reibung über den Knoten **ContactProperties** festgelegt (Listing 1 Zeile 31). Neben der üblichen Gleitreibung können auch Roll- und Drehwiderstände definiert werden. Für bestimmte einfache Grundkörper ist zudem richtungsabhängige, Reibung möglich. Auf *Körper*-Ebene definiert der **Physics**-Knoten Masse, Trägheit, Dämpfung und optionale ODE-Erweiterungen (Listing 1 Zeile 69). Gelenke (z. B. *Hinge* für Lenkung/Vortrieb) werden durch Motoren (**Motor**) angetrieben. In Summe ergibt sich ein kompaktes, gut abstimmbares Modell, das das Fahrrad als Mehrkörpersystem mit Kontakten, Reibung und gelenkgetriebenen Freiheitsgraden realistisch genug für Reglerentwurf und Vergleichsstudien abbildet.

4.4 Sensoren

Für die Stabilisierung des selbstbalancierenden Webots-Fahrrads kommen mehrere Sensorsysteme zum Einsatz. Zentral sind eine **Inertialmesseinheit** (IMU) am Fahrzeug zur Lageerfassung und eine **Kamera** zur optischen Fahrwegdetektion. Ergänzend liefern **Motorsensoren** (Encoder) an den Achsen Messgrößen wie Lenk- und Raddrehwinkel. Die IMU versorgt den inneren schnellen Regelkreis (Balance-PID) laufend mit dem aktuellen Rollwinkel, während die Kamera den äußeren, langsamer abtastenden Regelkreis (vision-basiertes MPC) mit Spurabweichungsinformationen speist. Beide Sensorströme werden anschließend in einfacher Weise fusioniert, um die Regelgrößen an die Aktuatoren (Lenkmotor und Antrieb) auszugeben. Im Folgenden werden die einzelnen Sensoren hinsichtlich physikalischer Funktion, Modellierung in Webots, Rolle im Regelkreis und Integration im Quellcode beschrieben.

4.4.1 Inertialmesseinheit (IMU)

Physikalisches Prinzip: Eine Inertial Measurement Unit (IMU) erfasst Trägheitsgrößen des Fahrzeugs, typischerweise mit kombinierter **Beschleunigungsmessung** (Accelerometer) und **Drehratensensoren** (Gyroskope) auf drei Raumachsen (Ltd., 2025). Durch Fusion dieser Signale (oft ergänzt um einen Magnetometer-Kompass), lässt sich die Orientierung im Raum bestimmen. Im realen Prototyp kommt z. B. der IMU-Sensor **BNO055** zum Einsatz, der intern die Rohdaten filtert und direkt **Euler-Winkel** (Roll, Pitch, Yaw) bereitstellt (Bosch Sensortec, 2020). Die Rollachse (Seitenneigung) ist beim Fahrrad die entscheidende Stabilitätsgröße. Reale IMUs liefern diese Winkel mit begrenzter Auflösung und unterliegen Rauschen sowie Drift, was meist durch Kalibrierung und Sensorfusion kompensiert werden muss. Die Ausgaberate moderner IMUs liegt im Bereich mehrerer hundert Hertz (der BNO055 etwa ~ 200 Hz (Bosch Sensortec, 2020)), was für eine schnelle Lagekontrolle ausreicht.

IMU-Modell in Webots: Webots stellt mit dem **InertialUnit**-Knoten ein abstraktes IMU-Modell bereit, das idealisierte Orientierungsdaten liefert. Konkret berechnet und aktualisiert das InertialUnit-Gerät in jeder Simulationsschleife den **Kipp- und Gierwinkel** des Roboters relativ zu einem globalen Bezugssystem (Ltd., 2025). Im Gegensatz zu einer realen IMU entfallen hier Kalibrierfehler und Rauschen, wodurch die Orientierungswinkel praktisch **fehlerfrei und ohne Drift** sind. Das im Webots-Weltmodell definierte Gerät **imu** (Listing 1 Zeile 49) ist starr im Fahrradrahmen verbaut (an geeigneter Position, etwa nahe dem Schwerpunkt) und gibt standardmäßig Roll-, Pitch- und Yaw-Winkel in *Radian*t aus. Die Abtastung erfolgt synchron mit dem physikalischen Simulationszeitschritt.




Abbildung 3: IMU-Knoten in Webots.

Quelle: <https://cyberbotics.com/doc/reference/inertialunit>

Rolle im Regelkreis: Der IMU-Sensor bildet die zentrale **Rückführung** für die **Balance-Regelung**. In jedem Simulationsschritt liest der PID-Regler den aktuellen Rollwinkel φ_{roll} aus der IMU und berechnet daraus die Stellgröße für den Lenkantrieb. Konkret fungiert der Rollwinkel als *Regelgröße* im inneren Regelkreis, wobei das Fahrrad nach links/rechts abweicht, soll durch einen entsprechenden Lenkeinschlag gegengesteuert werden, bis $\varphi_{\text{roll}} = 0$ (senkrechte Lage) erreicht ist. Im vorliegenden Modell ist der `basicTimeStep` der Welt auf 2 ms gesetzt (GitHub contributors, 2025), was einer Messfrequenz von 500 Hz entspricht (Listing 1 Zeile 9). Dadurch können selbst schnelle Kippbewegungen des Fahrrads in Echtzeit erfasst werden (GitHub contributors, 2025). Dadurch reagiert der PID-Regler sehr schnell auf Lageänderungen, was eine Grundvoraussetzung ist, um die Instabilität beherrschen zu können. Im äußeren (vision-basierten) Regelkreis spielt die IMU direkt keine Rolle, allerdings fließen die Balancierinformationen indirekt ein, wenn die Vision-Steuerung, z. B. die Fahrgeschwindigkeit reduziert, sobald der Stabilitätsfaktor sinkt (starke Schräglage detektiert). Insgesamt sorgt die IMU dafür, dass die **Regelstrecke** mit hoher Güte beobachtet wird, und bildet so das Fundament der Stabilisierung.

Im C-Controller `balance_control.c` wird die IMU über die Webots-API initialisiert und ausgelesen. Listing 2 zeigt auszugsweise, wie das Gerät referenziert, aktiviert und genutzt wird. Zunächst wird der Device-Tag der IMU mit ihrem Namen `imu` angefordert und das Sensor-Sampling mit dem Simulationstimestep (2 ms) eingeschaltet. In der Hauptschleife ruft der Regler dann kontinuierlich die Funktion `wb_inertial_unit_get_roll_pitch_yaw()` auf, welche einen Vektor der Winkel zurückliefert. Der Rollwinkel (Index 0 des Arrays) wird extrahiert und in die Regelung eingespeist. Da die Webots-IMU idealisiert ist, entspricht dieser Winkel exakt der aktuellen Fahrzeugneigung ohne Messfehler. Im Code ist dennoch ein Fallback vorgesehen: Falls der Supervisor-Knoten verfügbar ist, wird alternativ dessen Orientierungsmatrix ausgewertet, dies diente experimentell der Verifikation der IMU-Daten und kann die gleiche Information liefern. Der exemplarische Code zeigt, wie einfach die Orientierung in Webots abgefragt werden kann, verglichen mit einer realen IMU (wo man per I²C erst Rohdaten lesen und konvertieren müsste). Die geringe Latenz der `wb_inertial_unit_get_roll_pitch_yaw`-Funktion (nur ein Zeiger auf interne Simulationsdaten) trägt dazu bei, dass der Balance-Regelkreis praktisch ohne zusätzliche Verzögerung arbeitet.

```
1 // IMU-Geraet initialisieren (in init_devices)
2 imu_sensor = wb_robot_get_device("imu");
3 wb_inertial_unit_enable(imu_sensor, timestep); // Abtaste = Welt-
    Zeitschritt (2 ms)
4
5 // ... (im Hauptprogramm der Balance-Regelung)
6
7 // Roll-, Pitch- und Gierwinkel vom IMU-Sensor abrufen
8 const double *rpy = wb_inertial_unit_get_roll_pitch_yaw(imu_sensor);
9 double roll_angle = rpy[0]; // aktueller Rollwinkel [Bogenmass]
```

Listing 2: IMU-Initialisierung und -Abfrage im C-Controller (Balance-Regelung)

4.4.2 Kamera (Videosensor)

Physikalisches Prinzip: Die Kamera dient als **optischer Sensor**, um die Strecke vor dem Fahrrad zu erkennen. Physikalisch basiert sie auf einem *digitalen Bildaufnehmer* (z. B. CMOS-Sensor), der durch eine Linse abgebildetes Licht in Pixelwerte umwandelt. In einem realen System würde eine am Fahrzeug montierte Weitwinkel-Kamera laufend **Videobilder** der Fahrbahn liefern, wobei essentielle Parameter sind die **Auflösung** und die **Bildrate** sind. Für eine stabile Spurhaltung in Echtzeitanwendungen genügen in der Regel zweistellige Bildfrequenzen ($\sim 10\text{--}30\text{ Hz}$), sofern das Fahrzeug nicht extrem schnell fährt. Die Kamera erfasst visuelle Merkmale der Umgebung, die im vorliegenden Kontext insbesondere die **Straßenmarkierung** bzw. den Verlauf der Fahrspur beinhalten, die dann von Bildverarbeitungsalgorithmen ausgewertet werden. Physikalisch können **Umgebungsfaktoren** wie Beleuchtung, Bewegungsunschärfe oder Linsenverzerrungen die Bildqualität beeinflussen, was eine robuste **Merkmalsextraktion** herausfordernd macht. Im Gegensatz dazu operiert eine Kamera jedoch **kontaktlos** und kann reichhaltige Umgebungsinformationen liefern, was sie ideal für die **Pfadführung** macht (im Vergleich zu z. B. lokalen Sensorsignalen eines Gyroskops).

Simulation in Webots: Webots simuliert Kameras über den **Camera-Node**, der virtuelle Renderings der 3D-Szene erzeugt. Im *Weltfile* ist für den Supervisor (die übergeordnete Instanz) eine Kamera mit definierter Position, Ausrichtung und Eigenschaften eingebettet (Listing 1 Zeile 79). Diese sogenannte *Vision-Kamera* blickt aus erhöhter Perspektive nach vorne unten auf die Fahrbahn (vergleichbar mit einer Helm- oder Drohnenkamera, die dem Fahrrad folgt). Die in der Simulation gewählte Auflösung beträgt z. B. 640×360 Pixel bei einem Gesichtsfeld von ca. 114° (Field of View $\approx 2.0\text{ rad}$). Diese Einstellungen sind ein Kompromiss zwischen Sichtfeld und Bilddetail. Die Kamera liefert pro aktiviertem Zeitschritt ein Bild im **RGBA-Format** (Rot–Grün–Blau plus Alphakanal) als Array von Byte-Werten. In der Controller-Software muss die Kamera explizit aktiviert werden, wobei die Abtaste frei wählbar ist. Der Vision-Controller nutzt eine Bildrate von rund 20 Hz, entsprechend einem Abtastintervall von 50 ms. Dies ist deutlich langsamer als der Balance-Regelkreis, spiegelt aber die realistische Anforderung wider, dass Bildverarbeitung zeitaufwändiger ist und nicht in jedem Simulationsschritt erfolgen muss. Im Webots-Code wird die Kamera z. B. mit `camera.enable(50)` konfiguriert, sodass alle 50 ms ein neues Frame bereitgestellt wird. Jedes Frame kann vom Controller über `camera.getImage()` abgeholt und weiterverarbeitet werden. Zu beachten ist, dass Webots standardmäßig keine Kameraräusche oder Sensorschwächen simuliert, sodass die gelieferten Bilder idealisiert sind (scharf, bei gleichbleibender Beleuchtung).





Abbildung 4: Kamera-Knoten in Webots.

Quelle: <https://cyberbotics.com/doc/reference/camera>

Rolle im Regelkreis: Die Kamera ist der **Schlüsseingang** für den vision-basierten äußeren Regelkreis. Ihre Aufgabe besteht darin, dem **MPC-Fahrtrichtungsregler** Informationen über den Verlauf der Fahrspur relativ zum Fahrzeug zu liefern. Im konkreten Szenario der S-Kurve extrahiert der Vision-Controller aus jedem Kamerabild den lateralen Positionsfehler e der Straße.

Diese Bildverarbeitung geschieht in mehreren Schritten:

1. **Merkmalsextraktion:** Zunächst werden relevante Bildmerkmale berechnet, etwa mittels **Segmentierung** der Straße. Im Projekt wurde hierzu ein vortrainiertes YOLO-Modell verwendet, das die Fahrbahn in der Vogelperspektive segmentiert. Falls kein KI-Modell verfügbar ist, greift ein Fallback auf klassische Bildverarbeitung, mittels Kantenerkennung und Auswertung eines definierten *Region-of-Interest* liefert ebenfalls einen Schätzwert für die Spurmittellage. Ergebnis dieses Schritts ist der Querfehler e (in normierter Form, z. B. $-0.5 \cdots +0.5$ relativ zur Bildmitte) sowie ggf. zusätzliche Qualitätskennzahlen (etwa die erkannte Kontur oder den Bedeckungsgrad der Fahrbahnmaske).
2. **Spurführungsregelung:** Auf Basis des visuellen Fehlers bestimmt der Controller einen passenden **Lenksollwert**. Im entwickelten System kommt hierfür vorzugsweise ein **modellprädiktiver Regler (MPC)** zum Einsatz, der das Fahrrad als dynamisches Modell (Zustand $\mathbf{x} = [x, y, v, \psi]$) vorausberechnet. Der MPC optimiert die Steuergröße Lenkwinkel δ (und ggf. Beschleunigung) über einen kurzen Zeithorizont so, dass der Querfehler minimiert und Fahrdynamikgrenzen eingehalten werden.

Abbildung 5: Querfehler e der Straße.

Die Kamera beeinflusst den Balance-Regler auch indirekt, indem deren Messdaten den **Kurs der Fahrt** vorgeben. Wichtig ist, dass die Vision-Daten mit deutlich geringerer Frequenz ankommen als die IMU-Daten. Der Balance-Controller hält während der 50 ms zwischen zwei Kamerabildern die zuletzt empfangene Soll-Lenkvorgabe bei und stabilisiert weiterhin autonom. Sobald ein neues Bild ausgewertet ist, wird der Lenksollwert ggf. korrigiert. Dieses **zweistufige Regelungskonzept** sorgt dafür, dass das Fahrrad einerseits aufrecht bleibt, andererseits aber auch aktiv Richtungskorrekturen vornimmt, um einer kurvigen Referenzstrecke zu folgen.

4.4.3 Motorsensoren (Inkrementalgeber)

Physikalisches Prinzip: Neben IMU und Kamera, die den *Zustand* des Fahrzeugs in Bezug auf Lage und Umwelt erfassen, spielen sogenannte **Motorsensoren** eine wichtige Rolle für die interne Zustandsmessung. Gemeint sind hier **Winkelgeber (Encoder)** an den drehbaren Komponenten, hierbei konkret am Lenkmotor und am Antriebsrad. Physikalisch handelt es sich meist um *inkrementelle Drehgeber*, die auf der Motorachse montiert sind und pro Umdrehung eine bestimmte Anzahl Impulse (Zählschritte) liefern. Durch Mitzählen der Impulse kann der Steuerrechner den zurückgelegten Winkel bestimmen, sodass über die Impulsfrequenz sich auch die Drehgeschwindigkeit ermitteln lässt. In echten Systemen werden beispielsweise **optische Encoder** (eine Scheibe mit Strichmuster und Fotodetektor) oder **Hall-Sensoren** (Magnet und Hallsensor für Umdrehungszählung) eingesetzt. Im Kontext unseres selbstbalancierenden Fahrrads wird der Lenkwinkel-Encoder benötigt, um den aktuellen **Lenkeinschlag** zu kennen, was wichtig ist, um Lenkwinkelgrenzen nicht zu überschreiten. Der Hinterrad-Encoder erfasst die **Raddrehstellung** bzw. via Differenz auch die momentane Raddrehzahl, was zur Abschätzung der Fahrgeschwindigkeit dient. Physikalisch sind solche Sensoren sehr präzise (hochaufgelöste Encoder bieten > 1000 Impulse/Umdrehung) und liefern in schneller Abfolge Signale, typischerweise synchron zum Motor. Allerdings muss die Ansteuerungselektronik die Impulse auswerten (Interrupts zählen etc.), was in der realen Implementierung zusätzlichen Programmieraufwand bedeutet.

Rolle im Regelkreis: Die Positionssensoren dienen vor allem der Überwachung und der Ableitung von Regelgrößen. Der **Lenkwinkelsensor** liefert dem Balance Controller das Feedback,

welcher Lenkeinschlag vom Motor aktuell realisiert wird. Für alle in dieser Arbeit verwendeten Webots Simulationen gilt dieselbe Lenkkonfiguration. Am Lenker des selbstbalancierenden Fahrrads ist ein `RotationalMotor` mit dem Namen `"motor::handlebars"` verbaut. In der Welt-Datei (.wbt) ist `"maxTorque"` auf 25 gesetzt, was einen Moment von 25 Nm bedeutet. Was dazu führt, dass der Istwinkel nicht 1:1 dem Sollwert folgen kann. Die Parameter `dampingConstant` 0.3 und `staticFriction` 0.1 erzeugen zusätzliche Gegenmomente, die besonders um den Nullbereich kleine Sprünge abbremzen. Die Gabel sowie das Vorderrad besitzen eine Masse von 2.5 kg und eine Trägheitsmatrix von 0.06 0.07 0.12, die die schnelle Winkeländerungen begrenzen. Die beobachtete Verzögerung liegt damit nicht an einer Rechen- oder Übertragungsverzögerung, sondern an den Momentgrenzen und Verlusten im Gelenk. Das ist in Abbildung 6 erkennbar, da steile Sollsprünge geglättet werden, was dämpfend wirkt und zu weniger harten Lenkreaktionen führt.




Abbildung 6: Lenk-Sollwert und Lenk-Istwert.

4.5 Aktuatoren

Das selbstbalancierende Fahrradmodell verfügt über zwei zentrale **Aktuatoren**, die als Stellglieder in die Dynamik des Systems eingreifen. Dabei handelt es sich um einen **Lenkantrieb** an der Vorderadgabel und einen **Antriebsmotor** für das Hinterrad. Beide sind in Webots als `RotationalMotor`-Geräte realisiert und jeweils an einem drehbaren HingeJoint angebracht. Physikalisch handelt es sich um **elektrische Rotationsmotoren** (Gleichstrommotoren mit Getriebe), die in der Lage sind, Drehmomente aufzubringen und so entweder einen bestimmten Winkel (Servomodus) oder eine bestimmte Drehgeschwindigkeit einzustellen. Im Folgenden werden zunächst die realen Grundlagen dieser Aktuatoren betrachtet, dann ihre Umsetzung in der Simulation und schließlich ihr konkreter Einsatz im Regelungssystem mitsamt Code-Beispielen erläutert.

Physikalisches Wirkprinzip:

Bei **bürstenbehafteten DC-Motoren**, wie sie in vielen Robotikanwendungen Verwendung finden, erzeugt ein stromdurchflossener Anker in einem Magnetfeld ein Drehmoment (Lorentz-Kraftwirkung) auf die Leiter. Das resultierende **Motordrehmoment** ist annähernd proportional zum Ankerstrom, während die Leerlauf-Drehzahl von der angelegten Spannung bestimmt wird. Im offenen Regelkreis würde ein DC-Motor also schneller drehen bei höherer Spannung und stärker drehen (mehr Kraft) bei höherem Strom.

Um präzise **Stellbewegungen** auszuführen, werden Motoren oft mit **Getrieben** (zur Erhöhung von Drehmoment und Auflösung) und mit **Sensoren** rückgekoppelt (Encodern, s. o.). Ein sogenannter **Servoantrieb** ist ein Motor-Getriebe-System mit interner Positions- oder Drehzahlregelung. Im realen selbstbalancierenden Fahrrad gibt es zwei solcher Antriebe:

- **Der Lenkmotor** wird von einem BTS7960 Treibermodul mit PWM Signalen angesteuert. Die Winkelmeldung kommt vom Encoder am Lenkgetriebe. Der MD49 verarbeitet die Encodersignale und stellt Zählwerte zur Positionsbestimmung bereit. Der Antrieb arbeitet als Positionsantrieb auf einem Soll-Winkel mit begrenztem Bereich in beide Richtungen. Abweichungen zwischen Soll- und Ist-Lenkeinschlag, werden durch den Regler ausgeregelt bis der gewünschte Winkel erreicht ist. Der Antrieb muss ausreichend schnell und drehmomentstark sein um die Querstabilität sicherzustellen.
- **Der Antriebsmotor** am Hinterrad sorgt für den Vortrieb. Dieser wird im Unterschied zum Lenker meist als **Drehzahl- bzw. Drehmomentantrieb** betrieben. Im realen System regelt ein separater PID-Regler die Raddrehzahl konstant, indem er den Motorstrom anhand des Hall-Encoder-Feedbacks justiert. Physikalisch verleiht das rotierende Hinterrad dem System einen **gyroskopischen Effekt**, der stabilisierend wirkt, weshalb eine gewisse Grundgeschwindigkeit hilfreich ist. Gleichzeitig muss der Motor aber auch schnell drosseln oder bremsen können, um Kurven sicher zu durchfahren, ohne umzukippen.

Webots-Umsetzung: Webots stellt mit dem `RotationalMotor`--Knoten in Ihrer Simulationsumgebung einen Aktuator zur Verfügung, der an einen `HingeJoint` gekoppelt, Drehmomente ausüben kann. Im Hintergrund berechnet der Physik-Kernel (ODE) die Wirkung des Motors auf das Gelenk, unter Berücksichtigung von Maximalmoment und Zielvorgabe. Jeder Rotationsmotor kann in drei Modi betrieben werden:




Abbildung 7: Aktuatoren im Fahrradmodell.

Quelle: <https://cyberbotics.com/doc/reference/rotationalmotor>

- **Positionsmodus:**

Der Motor strebt einen vorgegebenen Zielwinkel an (`setPosition(angle)`), wobei er innerhalb der konfigurierten Kraft- und Geschwindigkeitsgrenzen das nötige Drehmoment erzeugt, um diesen Winkel zu erreichen. Im Webots-Modell ist der Lenkungsaktor in den Positionsmodus geschaltet. Dazu wird im Code einmalig `wb_motor_set_position(handlebars_motor, 0.0)` aufgerufen, um die Start-Sollposition (geradeaus) zu setzen. Anschließend erhält der Lenkmotor in jeder Regeliteration einen neuen Sollwinkel. Die Regelung der Position übernimmt Webots intern, dabei wirkt der Motor wie eine Feder-Dämpfer-Kopplung ans Gelenk, die Differenz zwischen Ist- und Sollwinkel generiert ein entsprechendes Gegendrehmoment (virtueller P-Regler). Parameter wie `maxTorque` und `maxVelocity` im Weltfile bestimmen, wie schnell

und kräftig an den Sollwinkel nachgeführt wird. Im Modell sind z.B. für den Lenkmotor `maxTorque = 25 Nm` festgelegt, ein Wert, der sicherstellt, dass genügend Kraft zum Aufrichten aus Schräglagen vorhanden ist, ohne das System unrealistisch zu gestalten.

- **Geschwindigkeitsmodus:**

Hier wird dem Motor eine Vorgabe-Drehgeschwindigkeit vorgegeben (`setVelocity(omega)`), während die Position auf unendlich gesetzt wird (`setPosition(INFINITY)`). In Webots bedeutet dies, dass der Motor keinen festen Endwinkel hat, sondern kontinuierlich dreht. Der von uns verwendete Antriebsmotor des Hinterrads am Fahrrad wird in unseren Simulationen so betrieben. Im Initialisierungscode wird `wb_motor_set_position(wheel_motor, INFINITY)` aufgerufen, was den Wechsel in den Geschwindigkeitsmodus bewirkt. Fortan interpretiert Webots den Befehl `wb_motor_set_velocity(wheel_motor, v)` als Soll-Drehzahl (in Rad/s) für das Rad. Intern wirkt wieder ein virtueller Regler, der das nötige Drehmoment aufbringt, um diese Geschwindigkeit zu erreichen/halten. Im Weltmodell ist für den Hinterradmotor ein recht hohes maximales Drehmoment von 120 Nm erlaubt, um Beschleunigungsvorgaben schnell umsetzen zu können. Allerdings ist die erreichbare Drehzahl in der Praxis auch durch die Antriebsspannung bzw. Webots-Parameter `maxVelocity` limitiert. In S-Kurven-Simulationen⁸ wurde typischerweise eine Grundgeschwindigkeit von ca. 7–10 km/h gefahren, was durch den entsprechenden `velocity`-Wert in Rad/s vorgegeben wird.

- **Kraft-/Drehmomentmodus:** Alternativ kann man in Webots Motoren auch direkt ein Drehmoment vorgeben (`setTorque(t)`), um z.B. eigene Regelalgorithmen für die Positions- und Geschwindigkeitssteuerung umzusetzen. In unserem Modell wird dieser Modus nicht explizit genutzt, da die beiden in Steuerungsmodellen gängigen Modi bereits ausreichen. Dennoch ist es wichtig zu wissen, dass Webots stets mit Kräften/Momenten rechnet.

Die beiden Motoren sind im Weltfile als Geräte `motor::handlebars` und `motor::wheel` z.B. deklariert und jeweils dem passenden HingeJoint zugeordnet. Webots erlaubt es, mehrere Motoren pro Gelenk zu definieren, doch hier ist jeweils nur einer aktiv.

Die Namensgebung `motor::wheel` für den Hinterradantrieb ist ein Spezialfall: Das Präfix `::` dient dazu, den Motor vom gleichnamigen (per DEF) vorderen Rad zu unterscheiden, welches ebenfalls als `wheel` benannt ist, so können Kollisionen in der Namensauflösung vermieden werden. Im Controller-Code greift man dann genau mit diesem Namen zu.

Rolle im Regelkreis:

Die Aktuatoren setzen die vom Regler berechneten Sollgrößen in physikalische Bewegung um und schließen damit die Wirkkette des Regelkreises. Konkret berechnet der Balance-Controller in jedem Zeitschritt zwei Stellwerte:

- den **Lenksollwinkel** δ_{sol} (aus dem PID-Regler + Vision-Überlagerung), und
- die **Antriebs-Sollgeschwindigkeit** v_{sol} .

Diese Sollwerte werden direkt an die Motoren übergeben. Wie in Abschnitt 4.4 erläutert, fusioniert der Controller den **Balance-Anteil** (zur Selbstausrichtung) mit dem **Vision-Anteil** (zur Kurvenfahrt) zu einer endgültigen Vorgabe `final_steer`. Dieses `final_steer` entspricht einem Winkel

⁸In Kapitel 6.2.2 wurde eine S-Kurve simuliert.

in Radiant, der begrenzt auf den physikalisch möglichen Bereich (± 0.524 rad) an den Lenkmotor übergeben wird.

Der Hinterrad-Sollwert `target_speed` wird ebenfalls bestimmt, im aktuellen Konzept abhängig vom Lenkeinschlag, (starker Lenkeinschlag $\rightarrow$ automatische Reduktion der Grundgeschwindigkeit). Damit fungiert der Balance-Controller gleichzeitig als einfacher **Geschwindigkeitsmanager**, der z. B. in Kurven abbremst, um die Balance nicht zu gefährden. Die Berechnung von `target_speed` erfolgt durch einen separaten Algorithmus (`speed_pid_compute`), der den Vision-Lenkbefehl in eine prozentuale Reduktion der Grundgeschwindigkeit umsetzt.

Sobald die Stellgrößen vorliegen, werden sie an die Motor-API übergeben. Damit findet die **Regler-Ausgabe** statt, die Software schreibt die Sollwerte in die Motoren und die Physiksimulation reagiert, indem sie die entsprechenden Kräfte auf das Modell einleitet.

Bereits während der Initialisierung werden die Motoren konfiguriert, Listing 3 zeigt, wie der Lenkmotor und der Radmotor als Devices geholt und in die gewünschten Modi versetzt werden. Für den Lenkantrieb wird die Position initial auf 0.0 gestellt. Für den Hinterradantrieb wird `wb_motor_set_position(wheel_motor, INFINITY)` gesetzt, was (wie oben beschrieben) den Geschwindigkeitsmodus aktiviert. Beide Motoren würden standardmäßig mit `velocity = 0` starten und der Hinterradmotor erhält später im laufenden Betrieb eine Startgeschwindigkeit (Basiswert).

Im Regelprozess selbst (Hauptschleife) werden dann die aktuellen Stellbefehle übergeben:

Listing 3: Motorsteuerung im Regelkreis

```
wb_motor_set_position(handlebars_motor, final_steer);  
wb_motor_set_velocity(wheel_motor, target_speed);
```

Der Wert `target_speed` wird in Rad/Sekunde an das Hinterrad übergeben. Beispielsweise entspricht eine Zielgeschwindigkeit von z. B. 4 m/s (bei ~ 0.7 m Raddurchmesser) ungefähr 11.4 rad/s Winkelgeschwindigkeit.

Nachdem die Sollwerte gesetzt sind, greift die Webots-Physik die neuen Sollwerte im nächsten Zeitschritt auf und beschleunigt/verstellt die Motoren entsprechend. Im Code werden nach dem Setzen der Motoren noch Statuspakete versendet und Logging betrieben, was für die Aktuatorwirkung selbst aber keine Rolle mehr spielt.

Insgesamt ist die Motoransteuerung in Webots sehr direkt, ein Funktionsaufruf genügt um das physikalische Stellglied zu beeinflussen. Dies erlaubt es, die Regelalgorithmen unkompliziert mit der Simulationswelt zu koppeln. Listing 3 fasst die wichtigsten Schritte zusammen. Hier sind sowohl die Initialisierung, als auch die Laufzeitschleife der Motoren zu sehen.

```
1 // Motoren-Devices abrufen  
2 handlebars_motor = wb_robot_get_device("motor::handlebars");  
3 wheel_motor      = wb_robot_get_device("motor::wheel");  
4 if (handlebars_motor == 0 || wheel_motor == 0) {  
5     exit(1);  
6 }  
7 // Initialisierung der Motoren  
8 // Lenkmotor: Positionsmodus, Startwinkel = 0 rad  
9 wb_motor_set_position(handlebars_motor, 0.0);  
10 // Hinterradmotor: Geschwindigkeitsmodus aktivieren  
11 wb_motor_set_position(wheel_motor, INFINITY);  
12 // (Velocity bleibt zunächst 0, wird später gesetzt)  
13  
14 //...(im Reglerloop, nach PID/MPC-Berechnung von final_steer/target_speed)
```

```

15 // Lenkantrieb: Soll-Lenkwinkel setzen
16 wb_motor_set_position(handlebars_motor, -final_steer);
17 // Radantrieb: Soll-Drehgeschwindigkeit setzen
18 wb_motor_set_velocity(wheel_motor, target_speed);
19

```

Listing 4: IMU-Initialisierung und -Abfrage im C-Controller (Balance-Regelung)

4.6 Controller

Ein Webots-Controller ist ein separates Prozess, der einen Roboter in der Simulation steuert und über eine definierte API mit der Simulationsswelt kommuniziert. Für jeden Roboter kann ein Controller in C/C++, Python, Java oder MATLAB betrieben werden, wobei Webots den Datenaustausch (Sensorwerte, Aktuatorbefehle) bei jedem Simulationsschritt synchronisiert. Typischerweise durchläuft ein Controller eine Endlosschleife, in der er Sensoren liest, Berechnungen durchführt und Aktuatoren ansteuert, wobei am Ende jeder Iteration die Funktion `wb_robot_step()` aufgerufen werden muss. Dieser Aufruf übergibt die gewünschte Control-Step-Dauer (in Millisekunden) an den Simulator und bewirkt, dass Webots die Simulation um genau diesen Zeitschritt fortsetzt und dabei alle bis dahin vom Controller gesetzten Befehle anwendet. Danach erhält der Controller die aktualisierten Sensorwerte des neuen Simulationszustands zurück. Abbildung 8 veranschaulicht diese Synchronisation (Cyberbotics Ltd., 2025a).

Alle Anweisungen vor dem nächsten Zeitschritt `wb_robot_step()`-Aufruf() werden zunächst gesammelt. Mit dem Step-Aufruf rechnet der Simulator den nächsten Physikschrift und aktualisiert die Sensoren, bevor der Controller weiterläuft. Auf diese Weise laufen Simulation und Controller *synchron* in gleichmäßigen Zeitschritten. Standardmäßig wartet Webots in diesem synchronen Modus darauf, dass jeder Controller seinen `wb_robot_step` ausführt, bevor der nächste Simulationsschritt erfolgt. Dies garantiert Konsistenz, erlaubt aber auch differierende Abstraten, wobei der Kontrollschritt ein ganzzahliges Vielfaches des Simulations-Basisschritts sein muss.




Abbildung 8: Synchronisation zwischen Controller und Simulation.

Quelle:

<https://cyberbotics.com/doc/reference/controller>

Beispielsweise kann bei einer Weltzeit Schrittauflösung von 2 ms ein Controller mit 2 ms, 10 ms oder 50 ms Schrittweite betrieben werden. Webots führt dann pro Controller-Schritt entsprechend 1, 5 bzw. 25 Simulationsschritte aus und wartet am Ende ggf. auf den Controller. Diese Entkopplung nutzt Webots, um auch langsamere Controller (z. B. in Python) in eine schnelle Physiks simulation einzubetten, ohne die Synchronisation zu verlieren.

Um auf Sensoren und Aktuatoren zuzugreifen, stellt Webots gerätespezifische API-Funktionen bereit. Im C-Controller werden z. B. Geräte über `wb_robot_get_device("name")` referenziert und Sensoren mit `wb_sensor_enable()` aktiviert. Entsprechende Methoden existieren dabei ebenfalls in Python (`robot.getDevice()`, `device.enable()`). Ein Sensor liefert erst ab dem nächsten `wb_robot_step()` gültige Messwerte, da die Simulationszeit dann fortgeschritten ist.

Aktuatorbefehle (z. B. `wb_motor_set_position()` oder `motor.setPosition()` in Python) werden zunächst lokal gepuffert. Die tatsächliche Ausführung in der Physik-Engine erfolgt erst am nächsten Step-Synchronisationspunkt. Ebenso bleiben zwei unmittelbar nacheinander gelesene Sensorsamples identisch, solange kein Simulationsschritt dazwischen liegt. Dieses deterministische Schritt-für-Schritt- Ausführungsmodell erleichtert die Reproduzierbarkeit und verhindert *race conditions*⁹ zwischen Physik und Reglercode.

Da für das selbstbalancierende Fahrrad zwei Controller-Prozesse implementiert wurden, die in Webots zeitgleich laufen und über die oben beschriebene Mechanik gekoppelt sind, wurden einerseits der *Balance-Controller* auf dem Fahrrad (in C, hoher Takt), andererseits ein *Vision-Controller* auf einem Supervisor-Knoten (in Python, langsamer Takt) implementiert. Die Welt-Datei ist dabei so konfiguriert, dass das Fahrrad einen **Receiver** und einen **Emitter** trägt, während der Supervisor das komplementäre Gegenstück besitzt, damit entsteht ein bidirektionaler Nachrichtenkanal innerhalb der Simulation:

Über Channel 1 sendet der Vision-Controller Steuerkommandos an das Fahrrad, und über Channel 2 übermittelt der Balance-Controller seinerseits Statusdaten zurück (z. B. aktueller Rollwinkel, Lenkwinkel, Geschwindigkeit). Beide Controller laufen im *synchronen Modus*, d. h. Webots hält die Physik so lange an, bis sowohl der schnelle C-Controller (alle 2 ms) als auch der langsamere Python-Controller ihren Schritt abgearbeitet haben (Cyberbotics Ltd., 2025b)(Cyberbotics Ltd., 2025c). Praktisch bedeutet dies, dass der Balance-Regler bei jedem Simulationsschritt neue Motorbefehle berechnet, während der Vision-Algorithmus nur alle 25 Schritte (50 ms) ein neues Lenkkommando liefert. , Webots gewährleistet die Synchronisierung beider Teilprozesse, sodass Kommandos verlustfrei und deterministisch am Step-Synchronisationspunkt ausgetauscht werden.

```

1  Robot {
2      Controller "balance_control_c"
3      Receiver { name "command_rx" channel 1 bufferSize 64 }
4      Emitter { name "status_tx" channel 2 bufferSize 64 }
5  }
6  Supervisor {
7      Controller "vision_control_py"
8      Emitter { name "command_tx" channel 1 bufferSize 64 }
9      Receiver { name "status_rx" channel 2 bufferSize 64 }
10 }

```

Listing 5: Nachrichtenkanal zwischen Controller und Simulation *.wbt

⁹Race Conditions bezeichnen unvorhersehbares Verhalten durch konkurrierende Zugriffe.

4.7 Integriertes Konfigurationssystem

Die Regelungsarchitektur erfordert eine koordinierte Parametrierung sowohl des Balance-Controllers in C als auch des Vision-Controllers in Python. Zu diesem Zweck wurde ein JSON-basiertes Konfigurationssystem implementiert, das als zentrale Kommunikationsschnittstelle zwischen einem grafischen Benutzerinterface und den beiden Regelschleifen fungiert. Dieses System ermöglicht die Laufzeitanpassung der Regelungsparameter ohne Unterbrechung der Webots-Simulation und gewährleistet eine konsistente Parametrierung über alle Systemkomponenten hinweg.

Alle relevanten Parameter werden in der Datei `balance_config.json` strukturiert abgelegt. Diese enthält sowohl die PID-Parameter für die Balance-Regelung (Kp, Ki, Kd, Ausgangsbegrenzungen) als auch Vision-spezifische Einstellungen (YOLO-Konfidenz, Fallback-ROI-Parameter, Lenkglättung). Die JSON-Struktur ermöglicht eine hierarchische Organisation der Parameter in logische Gruppen (`angle_pid`, `speed_control`, `vision_control`), was sowohl die Wartbarkeit als auch die automatisierte Verarbeitung erleichtert. Listing 6 zeigt die Struktur der zentralen Konfigurationsdatei mit den wichtigsten Parametergruppen.

```

1 {
2     "balance_control": {
3         "angle_pid": {
4             "angle_Kp": 4.5,
5             "angle_Ki": 0.2,
6             "angle_Kd": 0.4,
7             "angle_output_min": -0.3,
8             "angle_output_max": 0.3,
9             "angle_integral_min": -60.0,
10            "angle_integral_max": 60.0
11        },
12        "speed_control": {
13            "base_speed": 6.172839506172839,
14            "min_speed": 3.0864197530864197,
15            "max_speed": 6.172839506172839
16        },
17        "mechanical_limits": {
18            "max_handlebar_angle": 1.5,
19            "max_roll_angle": 45.0
20        },
21        "system": {
22            "enable_logging": 1,
23            "enable_preview": 1,
24            "config_reload_interval": 10,
25            "filter_size": 5
26        },
27        "vision_control": {
28            "method": "yolo",
29            "yolo_conf": 0.5,
30            "yolo_show": 0,
31            "fallback_roi_top_frac": 0.5,
32            "fallback_roi_height_frac": 0.06,
33            "steer_max_delta": 0.001,
34            "steer_max_cmd": 0.06
35        }
36    }
37 }
```

Listing 6: Struktur der zentralen Konfigurationsdatei `balance_config.json`

Der Balance-Controller in C implementiert in `balance_config.c` ein vereinfachtes JSON-Parser, das die Konfigurationsdatei periodisch einliest und die Parameter zur Laufzeit aktualisiert. Die Implementierung verzichtet auf externe JSON-Bibliotheken und nutzt stattdessen String-basierte Suchfunktionen für die Extraktion spezifischer Schlüssel-Wert-Paare. Dies gewährleistet eine schlanke Integration ohne zusätzliche Abhängigkeiten in der zeitkritischen Balance-Regelschleife. Über `balance_config_validate()` werden geladene Parameter auf Plausibilität geprüft, um Systeminstabilitäten durch ungültige Konfigurationen zu vermeiden.

Der Vision-Controller lädt dieselbe JSON-Konfiguration über Pythons native `json`-Bibliothek und extrahiert vision-spezifische Parameter. Ein konfigurierbares Reload-Intervall ermöglicht die dynamische Anpassung von Vision-Parametern (z. B. YOLO-Konfidenz, ROI-Dimensionen) während der laufenden Simulation. Diese Architektur unterstützt sowohl YOLO-basierte Spurerkennung als auch Fallback-Algorithmen, deren Parameter über die gemeinsame Konfigurationsdatei gesteuert werden.

Die Kommunikation zwischen den Controllern wird durch ein strukturiertes Logging-System in `balance_logging.c` dokumentiert. Dieses System erzeugt zeitgestempelte CSV-Dateien, die sowohl Balance-relevante Größen (Rollwinkel, Lenkausgang, PID-Terme) als auch Vision-Daten (Spurabweichung, Vision-Kommandos, Maskenabdeckung) sowie Positionsinformationen enthalten. Die erweiterte Datenstruktur `balance_log_data_t` kapselt alle relevanten Systemzustände in einem einheitlichen Format, wodurch eine umfassende Systemanalyse ermöglicht wird.

Das grafische Interface fungiert als Vermittler zwischen Benutzer und Konfigurationssystem. Parameteränderungen werden unmittelbar in die JSON-Konfiguration geschrieben, von wo sie durch die periodischen Reload-Mechanismen der Controller aufgenommen werden. Gleichzeitig visualisiert das Interface die von `balance_logging.c` erzeugten CSV-Daten in Echtzeit, wodurch die Auswirkungen von Parameteränderungen sofort sichtbar werden. Diese Architektur ermöglicht ein iteratives Tuning der Regelungsparameter unter direkter Beobachtung des Systemverhaltens.

5 Kombinierte Regelung

5.1 Portierung des Balance-PID (Zander)

Jonah Zanders Bachelorarbeit (2023) implementiert eine dreistufige Kaskadenregelung für ein selbst-balancierendes Fahrrad, die als Grundlage für die in dieser Arbeit entwickelte Simulationsregelung dient (Zander, 2023). Die Hardware-Architektur umfasst einen BNO055-IMU-Sensor zur Neigungsmessung, einen BeagleBone-Black-Einplatinencomputer als Steuerungseinheit sowie separate Motorcontroller für Lenkung und Antrieb. Die Regelungsarchitektur gliedert sich in drei hierarchische Ebenen: eine primäre Balance-PID-Regelung (Angle-to-Steering), eine sekundäre Lenkpositionsregelung und eine vereinfachte Geschwindigkeitssteuerung.

Primäre Balance-Regelung: Das Kernstück von Zanders Implementierung bildet ein PID-Regler, der die Rollwinkelabweichung in einen Lenkwinkel-Sollwert umsetzt. Listing 7 zeigt die von Zander gewählten PID-Parameter, die sich durch hohe proportionale ($K_p = 10,0$) und differentielle Verstärkungen ($K_d = 2,2$) bei deaktiviertem Integralanteil ($K_i = 0,0$) auszeichnen. Diese Parametrierung gewährleistet eine schnelle Reaktion auf Neigungsänderungen ohne die Gefahr des Aufschaukelns durch Drift-Integration.

```

1 //PID Angle to Steering
2 #define ANGLE_PID_KP          10.0f
3 #define ANGLE_PID_KI          0.0f
4 #define ANGLE_PID_KD          2.2f
5 #define ANGLE_PID_OUTPUT_MIN  -150.0f
6 #define ANGLE_PID_OUTPUT_MAX   150.0f
7 #define ANGLE_PID_INTEGRAL_MIN -60.0f
8 #define ANGLE_PID_INTEGRAL_MAX  60.0f

```

Listing 7: PID-Parameter in Zanders Hardware-Implementierung

Die PID-Berechnung in Zanders System implementiert eine zeitbasierte Integration und Differentiation mit Historien-Pufferung zur Rauschunterdrückung. Der Differentialterm wird über mehrere Zeitschritte gemittelt, um hochfrequente Störungen zu dämpfen, während der Integralterm durch Anti-Windup-Mechanismen begrenzt wird.

Sekundäre Lenkpositionsregelung: Die zweite Regelebene steuert den physischen Lenkmotor über einen MD49-Controller an, um den von der Balance-PID vorgegebenen Sollwinkel zu erreichen. Aufgrund der mechanischen Eigenschaften des Lenkantriebs (Reibung, Trägheit, Totzeit) sind hier deutlich höhere Verstärkungen erforderlich:

```

1 //PID Steering PID
2 #define MD49_PID_KP          850.0f
3 #define MD49_PID_KI          300.0f
4 #define MD49_PID_KD          30.0f
5 #define MD49_PID_OUTPUT_MIN  -100000.0f
6 #define MD49_PID_OUTPUT_MAX   100000.0f

```

Listing 8: Lenkpositions-PID-Parameter in Zanders System

Echtzeit-Threading-Architektur: Zanders Implementierung nutzt eine multi-threaded Architektur mit unterschiedlichen Abtastraten: IMU-Datenerfassung mit 200 Hz, Lenkpositionsregelung mit 1000 Hz und Geschwindigkeitsregelung mit niedrigerer Frequenz. Watchdog-Mechanismen überwachen die Thread-Ausführung und gewährleisten die Systemstabilität bei Hardwareausfällen.

Adaptierung für die Webots-Simulation: Die Portierung von Zanders Balance-Regelung in die Webots-Simulationsumgebung erforderte eine systematische Vereinfachung der hardware-spezifischen Komplexitäten bei Beibehaltung der regelungstechnischen Kernprinzipien. Die wesentlichen Unterschiede zwischen Hardware- und Simulationsimplementierung zeigt Tabelle 1.

Tabelle 1: Vergleich zwischen Zanders Hardware-Implementierung und Webots-Simulation

Aspekt	Zander (Hardware)	Webots-Simulation
Sensorik	BNO055 IMU, Rauschen	Idealer Rollwinkelsensor
Threading	Multi-threaded (200/1000 Hz)	Synchrone Hauptschleife
Lenkpositionsregelung	Separater MD49-PID	Direkter Motoranschluss
PID-Parameter	$K_p = 10, K_i = 0, K_d = 2.2$	Identische Werte
Ausgangsbegrenzung	± 150 (Hardware-Einheiten)	± 0.3 rad

Die Webots-Implementierung vereinfacht die Architektur erheblich durch Elimination der sekundären Lenkpositionsregelung. Die zentrale Balance-Regelschleife lässt sich mathematisch als vierstufiger Prozess beschreiben:

$$\text{Schritt 1: } \phi(t) = \text{get_roll_rad_raw}() \quad (2)$$

$$\text{Schritt 2: } u_{\text{raw}}(t) = \begin{cases} -\text{PID}(\phi_{\text{soll}} - \phi(t), t) & \text{if control_enabled} \\ 0 & \text{sonst} \end{cases} \quad (3)$$

$$\text{Schritt 3: } u_{\text{sat}}(t) = \begin{cases} \delta_{\text{max}} & \text{if } u_{\text{raw}}(t) > \delta_{\text{max}} \\ -\delta_{\text{max}} & \text{if } u_{\text{raw}}(t) < -\delta_{\text{max}} \\ u_{\text{raw}}(t) & \text{sonst} \end{cases} \quad (4)$$

$$\text{Schritt 4: } \text{wb_motor_set_position}(\text{motor}::\text{handlebars}, u_{\text{sat}}(t)) \quad (5)$$

wobei $\phi(t)$ der gemessene Roll-Winkel, $\phi_{\text{soll}} = 0$ der Sollwert, $u_{\text{raw}}(t)$ das ungefilterte PID-Signal, $u_{\text{sat}}(t)$ das begrenzte Stellsignal und δ_{max} die maximale Lenkwinkel-Begrenzung darstellen. Schritt 4 zeigt die direkte Motoransteuerung ohne sekundäre Regelung durch `wb_motor_set_position()`.

Der PID-Algorithmus selbst wurde von Zanders Implementierung adaptiert, jedoch mit verbesserter numerischer Stabilität. Die vereinfachte PID-Berechnung lässt sich mathematisch wie folgt beschreiben:

$$\text{Zeitschritt: } \Delta t = \frac{t[n] - t[n-1]}{10^6} \text{ [s]} \quad (6)$$

$$\text{P-Term: } P(n) = K_p \cdot e(n) \quad (7)$$

$$\text{I-Term: } I(n) = \begin{cases} I(n-1) + K_i \cdot e(n) \cdot \Delta t & \text{falls } 0 < \Delta t < 1 \\ I(n-1) & \text{sonst} \end{cases} \quad (8)$$

$$\text{D-Term: } D(n) = K_d \cdot \frac{1}{L} \sum_{j=0}^{L-1} \frac{e(n-j) - e(n-j-1)}{\Delta t} \quad (9)$$

$$\text{Ausgabe: } u(n) = P(n) + I(n) + D(n) \quad (10)$$

wobei $e(n) = \phi_{\text{soll}} - \phi(n)$ der Roll-Winkelfehler, $t[n]$ der Zeitstempel in Mikrosekunden und L die Pufferlänge (HISTORY_LEN) darstellen. Die Besonderheiten der Implementierung sind:

- **Robuste Integration:** Der I-Term wird nur bei plausiblen Zeitschritten ($0 < \Delta t < 1$) aktualisiert
- **Geglättete Ableitung:** Der D-Term verwendet einen gleitenden Durchschnitt über L vergangene Ableitungswerte zur Rauschunterdrückung
- **Zirkulärer Puffer:** `prev_index = (history_counter + L - 1) % L` implementiert effiziente Speicherverwaltung

Die erfolgreiche Übertragung von Zanders Regelungskonzept in die Simulation bestätigt die Robustheit des gewählten PID-Ansatzes. Die Parameter ($K_p = 10$, $K_i = 0$, $K_d = 2,2$) erzielen in der idealisierten Webots-Umgebung stabile Balance-Regelung.

Die Portierung demonstriert, wie Hardware-spezifische Komplexitäten (Multi-Threading, Sensor-Rauschen, Aktor-Totzeiten) in einer Simulationsumgebung abstrahiert werden können, ohne die regelungstechnischen Kernprinzipien zu beeinträchtigen. Diese Vereinfachung schafft die Grundlage für die Integration zusätzlicher Regelungsebenen, insbesondere der vision-basierten Pfadführung, die in den folgenden Abschnitten behandelt wird.

5.2 Portierung des Fahrtrichtungs-MPC (Giray)

Yasin Giray entwickelte in seiner Masterarbeit einen vision-basierten Fahrtrichtungsregler auf Basis von Model Predictive Control (MPC), um das selbstbalancierende Fahrrad autonom der Fahrspur folgen zu lassen (Giray, 2024). Dieser Regler modelliert die Fahrzeugdynamik mittels Einspurmodell und nutzt zwei Steuergrößen, die aktuelle Geschwindigkeit v und Lenkwinkel ϕ als Eingaben für die Prädiktion. Der MPC berechnet also auf Grundlage von v und Lenkeinschlag die Fahrzeugbewegung voraus. Für den prädiktiven Regler wird ein Zustandsvektor $x = [x, y, v, \text{yaw}]$ (Position, Geschwindigkeit, Gierwinkel) und ein Eingangsvektor $u = [\text{accel}, \text{steer}]$ definiert. Giray wählte einen Zeithorizont von etwa 2 s und formulierte ein Optimierungsproblem, das die Abweichung von einer Soll-Trajektorie minimiert sowie Steuerungsaufwand und -änderungen übernimmt. Die Kostenfunktion des MPC addiert quadrierte Abweichungen der Zustände und Eingriffe über den Horizont sowie eine Endzustands-Strafe, z. B. $J = \sum (x^T Q x + u^T R u + \Delta u^T R_d \Delta u) + x_{\text{final}}^T Q_f x_{\text{final}}$ (Giray, 2024). Neben den Kosten werden physikalische Nebenbedingungen wie maximaler Lenkwinkel, Lenkwinkelrate und Geschwindigkeit im Optimierungsproblem berücksichtigt, um realistische Lösungen zu gewährleisten.

Wesentliche Voraussetzung für den Fahrtrichtungs-MPC ist eine geeignete Referenztrajektorie der Straße. Giray implementierte hierfür eine Computer-Vision-Pipeline auf Basis von YOLOv8-Segmentierung, welche im Kamerabild die befahrbare Straße und deren Verlauf erkennt. Aus den segmentierten Bilddaten wird eine Reihe von Stützpunkten der Fahrbahn extrahiert. Anschließend wird mittels Spline-Interpolation eine glatte Kurve durch diese Punkte gelegt, die als Referenzkurve für den MPC dient. Er simuliert auf Basis des Einspurmodells die Fahrzeugbewegung und berechnet die optimalen Steuerbefehle, damit das Fahrrad der Kurve bestmöglich folgt. In Girays Umsetzung wird der Regler zyklisch mit ca. 10 Hz ausgeführt (Tickrate 100 ms). Pro Zyklus initialisiert der Controller den aktuellen Fahrzeugzustand (Position, Geschwindigkeit, Orientierung) und berechnet aus der ersten Sollkurve einen Vorhersagepfad. Die Optimierung liefert dann eine Stellgrößen-Sequenz

für Beschleunigung und Lenkwinkel. Tatsächlich wird nur der erste Lenkwinkel-Impuls umgesetzt (Receding Horizon Control), welcher als neuer Lenkbefehl an das Fahrzeug geht. Im nächsten Zyklus wird der MPC erneut mit aktualisiertem Zustand und ggf. angepasster Referenz gestartet. Giray konnte in Simulationen zeigen, dass der MPC-Regler das Fahrrad effektiv der vorgegebenen Spur folgen lässt. Die geplante Spline-Trajektorie und die vom MPC gefahrene Ist-Trajektorie in seiner Arbeit, stimmen dabei eng überein, was die Güte der prädiktiven Regelung belegt.

Adaptierung für Webots-Simulation: Die Portierung von Girays MPC-Konzept in die Webots-Umgebung erforderte eine systematische Anpassung an die spezifischen Anforderungen der Simulation und Integration mit dem vorhandenen Balance-Controller. Tabelle 2 zeigt die wesentlichen Unterschiede zwischen Girays theoretischem Ansatz und der Webots-Implementierung.

Tabelle 2: Vergleich zwischen Girays MPC-Konzept und Webots-Implementierung

Aspekt	Giray (Theorie)	Webots-Implementierung
Prädiktionshorizont	N=20 (2 s - 10 Hz)	T=3 (0.3 s - 20 Hz)
Referenzgenerierung	Spline-Interpolation	Vereinfachte Korrekturtrajektorie
Zustandsvektor	$[x, y, v, \psi]^T$	$[x, y, v, yaw]^T$ (identisch)
Eingangsvektor	$[a, \delta]^T$	$[accel, steer]^T$ (identisch)
Regelfrequenz	10 Hz	20 Hz
Optimierer	CVXPY (theoretisch)	CVXPY (praktisch)
Integration	Standalone	Gekoppelt mit Balance-PID

Die Webots-Implementierung vereinfacht Girays Ansatz erheblich durch Reduzierung des Prädiktionshorizonts auf 3 Zeitschritte ($\approx 0,3$ s). Diese Entscheidung wurde aus Echtzeitgründen getroffen, da die Integration mit dem Balance-Controller eine höhere Regelfrequenz (20 Hz) erfordert. Bei niedrigeren Regelfrequenzen würde die Regelung instabiler werden, da das System weniger Zeit für die Bildverarbeitung und MPC-Berechnung hätte, was zu verzögerten Reaktionen auf Pfadabweichungen führen würde. Listing 9 zeigt die Initialisierung des MPC-Controllers mit den angepassten Parametern:

```

1 def __init__(self):
2     # MPC-Parameter (reduziert gegenüber Giray)
3     self.NX = 4 # Zustandsvektor: [x, y, v, yaw]
4     self.NU = 2 # Eingänge: [accel, steer]
5     self.T = 3 # Prädiktionshorizont (reduziert fuer Echtzeitfahigkeit)
6
7     # Kostenmatrizen (aehnlich Girays Formulierung)
8     self.R = np.diag([0.01, 0.01]) # Eingangskostenmatrix
9     self.Rd = np.diag([0.01, 1.0]) # Eingangsdifferenzkostenmatrix
10    self.Q = np.diag([1.0, 1.0, 0.5, 0.5]) # Zustandskostenmatrix
11    self.Qf = self.Q # Terminale Kostenmatrix
12
13    # Fahrzeugparameter (Bicycle-Modell)
14    self.WB = 1.2 # Radstand [m] (Fahrrad)
15    self.DT = 0.1 # Zeitschritt [s]
16
17    # Physikalische Begrenzungen
18    self.MAX_STEER = math.radians(30.0) # Maximaler Lenkwinkel
19    self.MAX_DSTEER = math.radians(20.0) # Maximale Lenkwinkelrate
20    self.MAX_SPEED = 8.0 # Maximale Geschwindigkeit
21    self.MIN_SPEED = 0.5 # Minimale Geschwindigkeit

```

Listing 9: MPC-Controller Initialisierung in der Webots-Implementierung

Anstelle von Girays komplexer Spline-Interpolation aus Bildpunkten verwendet die Webots-Implementierung eine vereinfachte Referenzgenerierung basierend auf dem aktuellen Vision-Fehler. Die Referenztrajektorie wird aus dem lateralen Spurbabweichungsfehler abgeleitet, indem ein Ziel-Gierwinkel berechnet und über den kurzen Horizont interpoliert wird.

MPC-Optimierungsalgorithmus: Die Webots-Implementierung folgt Girays theoretischer Formulierung bei der Lösung des Optimierungsproblems. Abbildung 9 zeigt die strukturierte Darstellung des MPC-Algorithmus:




Abbildung 9: MPC-Optimierungsalgorithmus mit gebündelten Nebenbedingungen

Die vollständige Implementierung des MPC-Optimierungsalgorithmus ist in Listing 12 in den Anlagen dargestellt.

Die Kostenfunktion J setzt sich aus folgenden Komponenten zusammen:

- **Tracking-Term:**

$$J_{\text{track}} = \sum_{t=1}^T \|x_{\text{ref}}[t] - x[t]\|_Q^2 \quad (11)$$

Bestraft Abweichungen von der Referenztrajektorie.

- **Stellaufwand:**

$$J_{\text{control}} = \sum_{t=0}^{T-1} \|u[t]\|_R^2 \quad (12)$$

Begrenzt die Stellgrößen und verhindert übermäßige Stellaufwände.

- **Stellraten-Gewichtung:**

$$J_{\text{rate}} = \sum_{t=0}^{T-2} \|u[t+1] - u[t]\|_{R_d}^2 \quad (13)$$

Sorgt für glatte Übergänge und verhindert abrupte Änderungen der Stellgrößen.

- **Terminal-Term:**

$$J_{\text{terminal}} = \|x_{\text{ref}}[T] - x[T]\|_{Q_f}^2 \quad (14)$$

Gewichtet den Endzustand stärker und stellt sicher, dass das System am Ende des Prädiktionshorizonts nahe der Referenz ist.

Die Implementierung folgt dem Standard-MPC-Schema mit quadratischen Kosten und linearen Constraints. Im Gegensatz zu Girays längerfristigem Horizont ermöglicht die Reduzierung auf 3 Zeitschritte eine Echtzeitausführung mit 20 Hz.

Integration mit Balance-Controller: Im Gegensatz zu Girays Standalone-Ansatz realisiert die Webots-Implementierung eine zweistufige Kaskadenregelung (Abbildung 10). Der Vision Controller (MPC, 20 Hz) übernimmt die Spurführung basierend auf dem Kamerabild, während der Balance Controller (PID, 500 Hz) die Stabilisierung anhand des Rollwinkels gewährleistet. Die MPC-Ausgaben werden über IPC an den C-basierten Balance-Controller übertragen, der zusätzlich einen separaten Soll-Rollwinkel-Eingang erhält (siehe Abbildung 10).




Abbildung 10: Zweistufige Kaskadenregelung: Vision-MPC (Stufe 1) für Spurführung und Balance-PID (Stufe 2) für Stabilisierung

5.3 Strategien der Spurführung

Die Vision-basierte Spurführung des selbstbalancierenden Fahrrads nutzt zwei unterschiedliche Erkennungsstrategien: eine YOLO-basierte Segmentierung als Hauptverfahren und eine robuste Fallback-Strategie für Ausfallsituationen. Beide Verfahren extrahieren aus dem Kamerabild einen lateralen Spurabweichungsfehler, der vom zuvor beschriebenen MPC in Lenkbefehle umgesetzt wird.

5.3.1 YOLO-Segmentierung (YOLOv8)

Die YOLO-Strategie nutzt ein vortrainiertes YOLOv8-Segmentierungsmodell zur robusten Erkennung der Fahrbahn. Das neuronale Netz identifiziert Straßenbereiche als Klasse „street_main“ und liefert sowohl Bounding Boxes als auch pixelgenaue Segmentierungsmasken, wie in Kapitel 3.3 beschrieben ist. Das System sucht beim Start nach einer trainierten Gewichtsdatei (`best.pt`) und lädt das YOLOv8-Modell auf das verfügbare Rechengerät.

Im Echtzeitbetrieb (20 Hz) analysiert YOLO jedes Kamerabild und filtert Straßenobjekte (Klasse „street_main“). Aus den Bounding Boxes aller erkannten Straßenbereiche wird der gemittelte Mittelpunkt berechnet. Die laterale Abweichung ergibt sich als normierte Differenz zwischen Straßenmittelpunkt und Bildmitte ($\mathbf{error} \in [-0.5, +0.5]$):




Abbildung 11: YOLOv8-Segmentierung.

Die YOLO-Fehlerberechnung erfolgt durch folgende mathematische Schritte:

1. Zentrumsberechnung der Straßen-Bounding-Boxes:

$$x_{center,i} = \frac{x_{min,i} + x_{max,i}}{2} \quad \text{für alle Straßen-Detektionen } i \quad (15)$$

Berechnet das horizontale Zentrum jeder von YOLO erkannten Straßen-Bounding-Box.

2. Durchschnittliches Straßenzentrum:

$$\bar{x}_{street} = \frac{1}{N} \sum_{i=1}^N x_{center,i} \quad (16)$$

Mittelt alle Straßenzentren zu einem einzigen repräsentativen Straßenzentrum.

3. Normierter Lateral-Fehler:

$$e_{lateral} = \frac{x_{frame_center} - \bar{x}_{street}}{W_{frame}} \quad (17)$$

Berechnet den normierten Abstand zwischen Bildmitte und durchschnittlichem Straßenzentrum.

Hierbei ist:

- $x_{frame_center} = \frac{W_{frame}}{2}$ das Bildzentrum
- W_{frame} die Bildbreite in Pixeln
- $e_{lateral} \in [-0.5, 0.5]$ der normierte Lateral-Fehler

Interpretation:

- $e_{lateral} = 0$: Straße ist zentriert im Bild

- $e_{lateral} > 0$: Straße ist links vom Bildzentrum $\rightarrow$ Lenkung nach rechts erforderlich
- $e_{lateral} < 0$: Straße ist rechts vom Bildzentrum $\rightarrow$ Lenkung nach links erforderlich

Die detaillierte Implementierung der YOLO-Fehlerberechnung ist in Anlage 10 dargestellt.

Das System implementiert eine Ausfallüberbrückung durch Zwischenspeicherung der letzten gültigen Fehlerwerte. Bei Detektionsaussetzern wird der gespeicherte Fehler mit Decay-Faktor¹⁰ schrittweise abgeschwächt, bis er nach definierten Ausbleib-Zyklen auf Null fällt. Dies verhindert abrupte Lenkbewegungen bei temporären Erkennungsverlusten.

Limitierungen: Die YOLO-Strategie erfordert ein geeignetes vortrainiertes Modell und ausreichende Rechenleistung. Bei Abweichungen von den Trainingsdaten können Fehlerkennungen auftreten. Diese Fehlererkennungen werden in Kapitel 6.2 beschrieben.

5.3.2 Fallback-Strategie (ROI-basiert)

Bei Nichtverfügbarkeit des YOLO-Modells aktiviert sich automatisch eine Fallback-Strategie, die auf klassischer Bildverarbeitung basiert. Diese nutzt Farb- und Konturfilter innerhalb einer definierten Region of Interest (ROI) zur Straßenerkennung, dabei mit geringerer Präzision, aber ohne Abhängigkeit von trainierten Modellen, bei denen zu fehlern bei der Straßenerkennung kommen kann.




Abbildung 12: Fallback-Strategie.

Das System definiert eine trapezförmige ROI (ca. 40% Bildhöhe, 2% Breite) zur Fokussierung auf den erwarteten Fahrbahnbereich. Innerhalb dieser ROI erfolgt HSV-basierte Farbsegmentierung für dunkelgraue Straßenbereiche und weiße Markierungen, gefolgt von morphologischen Operationen zur Rauschreduktion. Die größte erkannte Kontur wird als Straßenbereich interpretiert:

Die Fallback-Fehlerberechnung basiert auf HSV-Farbsegmentierung und erfolgt in folgenden mathematischen Schritten:

¹⁰Der Decay-Faktor reduziert den gespeicherten Fehlerwert in jedem Zyklus um einen festen Prozentsatz, um ein allmähliches Abklingen zu gewährleisten.

1. HSV-Farbbereich-Filterung:

$$M_{road}(x, y) = \begin{cases} 255 & \text{falls } HSV_{lower,road} \leq HSV(x, y) \leq HSV_{upper,road} \\ 0 & \text{sonst} \end{cases} \quad (18)$$

$$M_{white}(x, y) = \begin{cases} 255 & \text{falls } HSV_{lower,white} \leq HSV(x, y) \leq HSV_{upper,white} \\ 0 & \text{sonst} \end{cases} \quad (19)$$

Das Eingangsbild wird vom RGB- in den HSV-Farbraum konvertiert, da dieser robustere Farbsegmentierung bei wechselnden Lichtverhältnissen ermöglicht. Für jeden Pixel wird geprüft, ob seine HSV-Werte innerhalb der definierten Bereiche für Straßenoberfläche (grau) oder Fahrbahnmarkierungen (weiß) liegen. Entsprechende Pixel erhalten in der jeweiligen Binärmaske den Wert 255 (weiß), alle anderen 0 (schwarz).

2. Maskenkombination und morphologische Operationen:

$$M_{combined} = M_{road} \vee M_{white} \quad (20)$$

$$M_{closed} = \text{Close}(M_{combined}, K) \quad (21)$$

$$M_{final} = \text{Open}(M_{closed}, K) \quad (22)$$

Die beiden Binärmasken werden durch logisches ODER verknüpft, um eine vereinte Straßenmaske zu erzeugen. Anschließend werden morphologische Operationen mit einem strukturierenden Element K (typisch 5×5 Kernel) angewendet: Die Schließung¹¹ füllt kleine Lücken in der Straßenkontur und verbindet getrennte Bereiche, während die Öffnung¹² störende kleine Objekte und Bildrauschen eliminiert, ohne die Hauptkonturen zu beeinträchtigen.

3. Konturerkennung und Zentrumsberechnung:

$$C_{max} = \arg \max_{C \in \mathcal{C}} \text{Area}(C) \quad (23)$$

$$(x, y, w, h) = \text{BoundingRect}(C_{max}) \quad (24)$$

$$x_{center} = x + \frac{w}{2} \quad (25)$$

Aus der gefilterten Maske werden alle geschlossenen Konturen extrahiert und nach ihrer Fläche sortiert. Die größte Kontur wird als Hauptstraßenbereich interpretiert, da sie typischerweise den dominanten fahrbaren Bereich repräsentiert. Um deren horizontales Zentrum zu bestimmen, wird eine achsenparallele Bounding Box berechnet und deren Mittelpunkt in x-Richtung als Straßenzentrum verwendet.

4. Normierter Lateral-Fehler:

$$e_{fallback} = \frac{x_{target} - x_{center}}{W_{frame}} \quad (26)$$

Der finale Regelfehler wird als normierter Abstand zwischen der gewünschten Zielposition (meist Bildmitte) und dem detektierten Straßenzentrum berechnet. Die Normierung durch die Bildbreite W_{frame} stellt sicher, dass der Fehler unabhängig von der Auflösung im Bereich $[-1, 1]$ liegt, wobei negative Werte eine Abweichung nach links und positive Werte eine Abweichung nach rechts signalisieren.

Hierbei ist:

¹¹Close (Schließung): Morphologische Operation, die kleine Löcher in Objekten füllt und Konturen glättet. Entspricht einer Dilatation gefolgt von einer Erosion.

¹²Open (Öffnung): Morphologische Operation, die kleine Objekte und Rauschen entfernt. Entspricht einer Erosion gefolgt von einer Dilatation.

- x_{target} die gewünschte Zielposition (meist Bildmitte)
- x_{center} das berechnete Zentrum der größten Straßenkontur
- W_{frame} die Bildbreite zur Normierung
- $e_{fallback} \in [-1, 1]$ der normierte Lateral-Fehler

Vorteile der Fallback-Methode:

1. Robuste Farbsegmentierung bei konstanten Lichtverhältnissen
2. Geringe Rechenleistung erforderlich
3. Deterministisches Verhalten ohne ML-Unsicherheiten
4. Morphologische Filterung reduziert Rauschen

Die detaillierte Implementierung der Fallback-Fehlerberechnung ist in Anlage 11 dargestellt.

Der Algorithmus ermittelt die größte Kontur als Straßenbereich und berechnet deren Mittelpunkt. Die normierte Differenz zur Bildmitte ergibt den lateralen Fehler, analog zur YOLO-Methode. Bei Erkennungsverlusten greift die gleiche Decay-Logik wie in der YOLO-Strategie.

Limitierungen: Die Fallback-Strategie ist anfälliger für variierende Lichtverhältnisse und unkonventionelle Straßenbeläge, da sie auf feste Farbschwellenwerte angewiesen ist. Trotz geringerer Präzision gewährleistet sie grundlegende Spurhaltung als Notfallmodus bei YOLO-Ausfall und ist besonders gut für vordefinierte Simulationswege geeignet.

6 Ergebnisse

In diesem Kapitel werden die experimentellen Ergebnisse der entwickelten Regelungsarchitektur für das selbstbalancierende Fahrrad systematisch präsentiert und analysiert. Zunächst wird das digitale Fahrradmodell mit seinen physikalischen Eigenschaften und Parametern dokumentiert, welches als Grundlage für alle nachfolgenden Versuche dient. Anschließend werden verschiedene Teststrecken mit steigender Komplexität untersucht: von einfachen Kurvenfahrten über S-Kurven bis hin zu anspruchsvollen Szenarien mit Seitenwind und Höhenunterschieden.

Bei den Testfahren wird besondere Aufmerksamkeit dem Vergleich zwischen YOLO-basierter Segmentierung und der robusten ROI-Fallback-Erkennung für die visuelle Spurführung gewidmet. Die Analyse umfasst sowohl qualitative Bewertungen der Fahrtrajektorien als auch quantitative Auswertungen der Regelgrößen wie Rollwinkel, Lenkkommandos und Querfehler.

Ein zentraler Aspekt dieser Arbeit ist die systematische Performance-Analyse mit Blick auf die geplante Implementierung auf einem NVIDIA Jetson Nano für das reale Fahrrad. Durch detaillierte Rechenzeit-Messungen aller Systemkomponenten wird die Echtzeitfähigkeit quantitativ bewertet und Optimierungsstrategien für die Hardware-Portierung entwickelt. Die Ergebnisse zeigen, dass die entwickelten Algorithmen auch unter den eingeschränkten Ressourcen eingebetteter Systeme funktionsfähig bleiben.

Abschließend wird die Echtzeitfähigkeit des Systems diskutiert und die Übertragbarkeit der Simulationsergebnisse auf das reale Fahrrad bewertet. Die Ergebnisse demonstrieren die Wirksamkeit der gewählten Architektur und identifizieren sowohl die Grenzen als auch das Optimierungspotenzial des Systems. Besondere Bedeutung kommt der Erkenntnis zu, dass die Simulation konservativere Hardware-Annahmen ermöglicht, wodurch das Risiko beim Transfer auf reale Systeme minimiert wird.

6.1 Fahrrad Datenblatt

Die folgenden Abschnitte dokumentieren eine in Webots R2025a implementierte Simulation, die als digitaler Zwilling des realen selbstbalancierenden Testfahrrads konzipiert werden sollte. Zentrale Zielsetzung ist die realitätsnahe Parametrierung von Masse-, Trägheits- und Reibungseigenschaften sowie die authentische Nachbildung der Sensor-/Aktor-Schnittstellen, sodass das dynamische Fahrverhalten und die Regelkreis-Interaktionen mit dem physischen Prototyp quantitativ übereinstimmen.

Die Systemarchitektur repliziert die zukünftige zweistufige Regelungsstruktur der Hardwareimplementierung. Eine dedizierte Supervisor-Instanz orchestriert die Versuchsdurchführung durch automatisierte Szenarien-Initialisierung, deterministische Reset-Funktionen und kontinuierliches Datenlogging aller relevanten Systemgrößen (Rollwinkel, Lenkkommandos, Trajektorien, Sensorwerte). Diese Infrastruktur gewährleistet reproduzierbare Parameterstudien und systematische Kalibrierungsprozeduren unter identischen Anfangsbedingungen. Durch die Entkopplung von virtueller Simulationszeit und Realzeit können auch rechenintensive Algorithmus-Varianten (z. B. YOLO-Segmentierung) ohne Echtzeitbeschränkungen evaluiert werden, während die physikalische Konsistenz der Dynamik erhalten bleibt.

Die Simulation fungiert somit als risikofreie Entwicklungs- und Validierungsplattform für komplexe Regelungsstrategien, bevor diese auf das reale Fahrrad übertragen werden. Gleichzeitig dient sie als

Referenzsystem für die nachfolgend dokumentierten physikalischen Eigenschaften, Regelungsparameter und experimentellen Validierungsergebnisse. Die detaillierte Parameterdokumentation ermöglicht eine vollständige Nachvollziehbarkeit und Reproduzierbarkeit der Simulationsergebnisse.

- **Hierarchischer Aufbau in Webots:** Das Fahrradmodell ist als Robot-Knoten strukturiert. Die Hauptkomponenten sind über `HingeJoint`-Knoten verbunden, das Hinterrad (`rear_wheel`), die Lenker-Gabel-Einheit (`Handlebars_and_Fork`) mit integriertem Vorderad sowie die Kurbel-Pedal-Einheit (`crank`). Jeder Knoten besitzt spezifische `Physics`-Eigenschaften und `boundingObject`-Definitionen für die Kollisionserkennung.
- **Masse und Schwerpunkt:** Der Hauptrahmen (`BICYCLE Robot`) hat eine Masse von 4 kg mit dem Schwerpunkt bei `centerOfMass` $[0 \ -0.1 \ 0.32]$, was 32 cm über dem Boden und 10 cm hinter der geometrischen Mitte entspricht. Die Lenker-Gabel-Einheit wiegt 2,5 kg, jedes Rad 2 kg. Die Gesamtmasse beträgt somit 10,5 kg. Diese Massenverteilung begünstigt ein stabiles Balanceverhalten durch den tiefliegenden Schwerpunkt und die konzentrierte Masse im Hauptrahmen.
- **Trägheitsmoment-Definition und physikalische Auswirkungen:** Webots verwendet das `inertiaMatrix`-Feld im `Physics`-Knoten als 9-elementiges Array in der Form

$$[I_{xx} \ I_{xy} \ I_{xz} \ I_{xy} \ I_{yy} \ I_{yz} \ I_{xz} \ I_{yz} \ I_{zz}]$$

wobei die symmetrische 3×3 -Matrix in Zeilen-Hauptordnung gespeichert wird. Für den Hauptrahmen ergibt sich `inertiaMatrix` $[0.08 \ 0 \ 0 \ 0 \ 0.05 \ 0 \ 0 \ 0 \ 0.07]$, was $I_{xx} = 0,08$, $I_{yy} = 0,05$ und $I_{zz} = 0,07 \text{ kg m}^2$ entspricht.

Die spezifische Trägheitsverteilung hat direkten Einfluss auf das Regelverhalten:

- **Roll-Trägheit** $I_{xx} = 0,08 \text{ kg m}^2$: Bestimmt die Widerstandsfähigkeit gegen Rollbewegungen um die Längsachse. Der moderate Wert ermöglicht schnelle Balance-Korrekturen durch den PID-Regler, ohne dass zu träge oder zu nervöse Reaktionen auftreten. Ein zu kleiner Wert würde zu übermäßig schnellen Rollschwingungen führen, ein zu großer Wert die Reaktionsfähigkeit des Balance-Systems reduzieren.
- **Pitch-Trägheit** $I_{yy} = 0,05 \text{ kg m}^2$: Dies ist physikalisch plausibel, da das Fahrrad in Längsrichtung kompakter gebaut ist. Für die Balance-Regelung bedeutet dies, dass Störungen durch Geschwindigkeitsänderungen schneller abklingen und weniger Einfluss auf die Roll-Stabilität haben.
- **Yaw-Trägheit** $I_{zz} = 0,07 \text{ kg m}^2$: Der Wert ist so gewählt, dass Richtungsänderungen responsiv erfolgen können, ohne dass das System bei schnellen Lenkmanövern instabil wird. Dies ist besonders relevant für die MPC-Spurführung, die präzise Trajektorienverfolgung erfordert.

Die Null-Werte für alle Off-Diagonalelemente ($I_{xy} = I_{xz} = I_{yz} = 0$) bedeuten, dass die Hauptträgheitsachsen mit den Koordinatenachsen des Fahrradmodells ausgerichtet sind. Dies vereinfacht die Regelung erheblich, da keine Kreuzverkopplungen zwischen den Rotationsachsen auftreten. In der Praxis führt dies zu entkoppelten Regelkreisen, da Roll-Bewegungen nicht direkt Pitch- oder Yaw-Bewegungen beeinflussen und umgekehrt. Diese Eigenschaft ist entscheidend für die Stabilität der zweistufigen Regelungsarchitektur, da die Balance-PID-Regelung primär auf Roll-Korrekturen fokussieren kann, ohne komplexe Mehrachsen-Kopplungen berücksichtigen zu müssen.

- **Rad-Spezifikationen:** Beide Räder sind als `Cylinder` mit `radius` 0.45 (45 cm) und `height` 0.06 (6 cm Reifenbreite) modelliert. Die tatsächliche Skalierung erfolgt durch `Transform`-Knoten mit `scale` 0.004 0.0081 0.0081, was einen effektiven Radius von ca. 3,6 cm ergibt. Jedes Rad hat `inertiaMatrix` [0.1 0.1 0.2 0 0 0], wobei $I_{zz} = 0,2 \text{ kg m}^2$ das Rotations-trägheitsmoment um die Radachse darstellt. Der gyroskopische Effekt ist bei der geringen Radmasse und niedrigen Fahrgeschwindigkeiten vernachlässigbar.
- **Gelenk- und Reibungsparameter:** Die `HingeJoint`-Verbindungen verwenden `jointParameters` mit spezifischen Dämpfungs- und Reibungswerten: `dampingConstant` zwischen 0,2 (Kurbel) und 0,8 (Räder) simuliert viskose Lagerverluste, während `staticFriction` 0.1 Haftreibung im Stillstand verhindert. Die Rad-Boden-Interaktion wird über `ContactProperties` mit `coulombFriction` [0.8] und `bounce` 0.3 definiert, wobei das Material "wheel" mit "ground" gekoppelt ist. Diese Werte sorgen für realistische Traktion bei begrenzter Sprungelastizität.
- **Antrieb und Sensorik:** Das Antriebssystem besteht aus zwei separaten Motoren mit unterschiedlichen Funktionen:

Antriebsmotor (Hinterrad): Der `RotationalMotor` mit dem Namen "motor::wheel" am Hinterrad-`HingeJoint` (`rear_wheel`) verfügt über ein `maxTorque` von 120 Nm. Dieser Motor ist für den Vortrieb des Fahrrads verantwortlich und wird von der Balance-Regelung angesteuert, um die gewünschte Geschwindigkeit zu halten und gleichzeitig Rollwinkel-Korrekturen durch differentielle Radgeschwindigkeiten zu unterstützen.

Lenkmotor (Vorderrad): Der `RotationalMotor` mit dem Namen "motor::handlebars" am Lenker-Gabel-`HingeJoint` (`Handlebars_and_Fork`) hat ein reduziertes `maxTorque` von 25 Nm. Dieser Motor steuert den Lenkeinschlag um die Z-Achse und ist das primäre Stellglied für die Balance-Regelung. Die geringere Maximalkraft ist der begrenzten Hebelwirkung der Lenkung geschuldet. Das Lenk-`HingeJoint` verwendet einen `dampingConstant` von 0,3 für gedämpfte Lenkbewegungen und verhindert durch `staticFriction` von 0,1 ungewolltes Flattern im Stillstand.

Sensorsystem: Jeder Motor ist mit einem `PositionSensor` gekoppelt, der kontinuierliche Winkelpositionsmessungen für mechanische Wegmessung und Lenkwinkel-Feedback liefert. Das zentrale `InertialUnit` bei `translation` [0 0 0.32] (32 cm über dem Boden) erfasst Roll-, Pitch- und Yaw-Winkel mit hoher Präzision für die Balance-PID-Regelung. Eine `Camera` mit `fieldOfView` 2 (ca. 114°) und einer Auflösung von 480×320 Pixel, positioniert bei `translation` 0.96 -1.1 0.95, dient der visuellen Spurerkennung für die MPC-basierte Trajektorienverfolgung. Dies ist ein guter Kompromiss zwischen Auflösung und Ressourcenbedarf.

6.2 Teststrecken

Die experimentelle Validierung der Regelungsarchitektur erfolgt anhand systematisch konzipierter Testszenarien, die verschiedene Aspekte der Balance- und Spurführungsregelung bewerten. Für jedes Szenario werden drei komplementäre Datentypen erfasst und ausgewertet:

Quantitative Zeitreihendaten: Umfassen dabei alle Regelgrößen (Rollwinkel, PID-Terme, Lenkkommandos) sowie Sensordaten (Position, Geschwindigkeit, IMU-Werte) mit einer Abtastzeit von 2 ms entsprechend dem `basicTimeStep` in Webots. Die Datenerfassung erfolgt über die `balance_log_data_t`-Struktur mit folgenden Maßeinheiten:

- **Winkelgrößen:** Alle Winkelgrößen werden in den Diagrammen in Grad dargestellt zur besseren Lesbarkeit (Umrechnung von Radiant zu Grad erfolgt bei der Darstellung). In den CSV-Rohdaten sind alle Winkel (Rollwinkel `roll_angle`, Lenkwinkel `steering_output`, `final_steer`, Orientierung `yaw`, `pitch`) in Radiant entsprechend der Webots-API gespeichert
- **Positionen:** Weltkoordinaten (`pos_x`, `pos_y`, `pos_z`) in Metern relativ zum Webots-Koordinatensystem mit Ursprung im Weltmittelpunkt
- **Geschwindigkeiten:** Zielgeschwindigkeit (`target_speed`) in rad/s für Motoransteuerung, tatsächliche Geschwindigkeit (`actual_speed_kmh`) in km/h für Benutzerfreundlichkeit
- **PID-Terme:** Dimensionslose Werte für `p_term`, `i_term`, `d_term` sowohl für Balance- als auch Vision-Regelung
- **Vision-Parameter:** Normierte Werte zwischen -1,0 und +1,0.

Diese hochfrequenten Messungen ermöglichen eine detaillierte Analyse der Regeldynamik und die Identifikation kritischer Systemzustände.

Qualitative Spurabweichungsanalysen: Diese dokumentiert die laterale Abweichung von der Sollspur über die gesamte Fahrstrecke. Der visionbasierte Querfehler wird kontinuierlich durch die ROI-Pipeline oder YOLO-Segmentierung erfasst und visualisiert die Güte der Trajektorienverfolgung unter verschiedenen Wahrnehmungsbedingungen.

Räumliche Trajektorienvisualisierung: Die Visualisierung erfolgt, durch einen dedizierten `PathVisualizer`, der Weltkoordinaten (`pos_x`, `pos_y` aus den CSV-Logs) in Echtzeit auf die jeweilige Streckentextur projiziert. Die Implementierung in `path_visualizer.py` konvertiert Webots-Koordinaten mittels kalibrierter Weltgrenzen zu Pixelkoordinaten und überlagert die gefahrene Route mit Hintergrundkarten der Testumgebungen. Die Kombination dieser drei Datenebenen gewährleistet eine umfassende Charakterisierung des Systemverhaltens sowohl aus regelungstechnischer als auch aus anwendungsorientierter Perspektive.

6.2.1 Kurvenfahrt

Die Fahrbahn ist als texturierte Ebene von 64m x 64m realisiert worden. Die effektive Spurbreite beträgt an der Referenzlinie etwa 3.6 m. Die Strecke kombiniert eine lange Linkskurve mit einem engen Rechtsknick und eignet sich damit zur Bewertung von Spurtreue und Balance unter gekrümmter Führung. Sofern nicht anders angegeben, sind für die Balance der *PID*-Satz $K_p=2.0$, $K_i=0.2$, $K_d=0.5$, der zulässige Lenkwinkelbereich $\delta \in [-0.3, 0.3]$ rad sowie $v_{\text{base}}=7$ km/h (Grenzen 5 km/h bis 7 km/h) aktiv. Für die visuelle Spurführung kann wahlweise YOLO (Konfidenz 0.5) oder eine robuste ROI-Fallback-Erkennung verwendet werden (`roi_top_frac` = 0.5, `roi_height_frac` = 0.06). Lenkbefehle werden durch `max_delta` = 0.001 und `max_steer_cmd` = 0.06 geglättet und begrenzt, die führ die maximale Änderungsrate des Lenkers steht, für stabile Balance.




Abbildung 13: Kurvenfahrt

Ziel ist die Fahrt von der ersten zur zweiten roten Markierung bei möglichst mittiger Spurhaltung und stabiler Balance.

Einsatz eines vereinfachten Balance-P-Reglers: Für eine Baseline wurde der Balance-Regler auf einen reinen P-Anteil gesetzt ($K_p=2.0$, $K_i=0.0$, $K_d=0.0$). Abbildung 14 zeigt die gemessenen Größen der Fahrt, Abbildung 15 den zugehörigen ROI-Querfehler und Abbildung 16 die Trajektorie auf der Strecke.




Abbildung 14: Kurvenfahrt mit reinem P-Regler (Zeitreihen). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad




Abbildung 15: ROI-Querfehler während der P-Regler-Fahrt

Die quantitative Analyse der Logdaten (17,04s Fahrt-dauer, 8,521 Datenpunkte bei 2ms Abtastung) zeigt charakteristische Instabilitätsmuster. Bereits nach wenigen Sekunden setzt ein wachsendes Pendeln ein, wobei die Rollwinkel-Amplitude von initial $\pm 0,005$ rad auf kritische Werte ansteigt. Der durch den Rollwinkel induzierte Stellbefehl (`final_steer`) erreicht Maximalwerte und treibt den Lenkeinschlag alternierend nach links/rechts, bis die Phasenreserve erschöpft ist. Hierbei ist die fehlende Dämpfung der ausschlagende Faktor. Der reine P-Anteil dominiert vollständig (`i_term` = `d_term` = 0). Infolge der reinen Proportionalrückführung, der Aktuatorbegrenzungen und der unvermeidlichen Latenzen entsteht ein unterdämpftes Verhalten. Das Fahrrad kippt nach 17,04s (entsprechend einer zurückgelegten Strecke von ca. **32 m** bei 6,8 km/h Durchschnittsgeschwindigkeit) nach rechts.




Abbildung 16: Gefahrene Trajektorie (P-Regler)

Der ROI-Querfehler zeigt dabei eine charakteristische zeitliche Entwicklung. Nach ca. 3 Sekunden stabilisiert sich der Fehler zunächst und das System hält die Spurmitte ein. Ab diesem Zeitpunkt beginnt jedoch das zunehmende Pendeln der Balance-Regelung, das sich phasenverschoben auf die seitliche Abweichung überträgt. Wie in Abbildung 15 ersichtlich, bleibt die Spurhaltung bis etwa Sekunde 16 noch beherrschbar, bevor die Balance-Instabilität kritische Werte erreicht und das Fahrrad schließlich umkippt.

Einsatz des erweiterten Balance-PID-Reglers: Für diese Versuchsfahrt wurden die erweiterten PID-Parameter $K_p = 2.0$, $K_i = 0.2$ und $K_d = 0.5$ eingesetzt. Die Spurführung erfolgte nun mittels YOLO-basierter Bildverarbeitung. Die Fahrtdauer betrug nun 35,96s mit 17,983 Datenpunkten, was eine deutliche Verbesserung gegenüber dem P-Regler (17,04s) darstellt.

Die Auswertung zeigt dabei zunächst stabileres Verhalten. In den ersten 30s bleibt der Rollwinkel weitgehend unter $\pm 0,02$ rad, während der D-Anteil (`d_term`) effektive Dämpfung liefert. Der I-Anteil (`i_term`) akkumuliert langsam auf $\pm 0,07$, was stationäre Fehler reduziert. Kritisch wird jedoch ab $t \approx 31$ s die Interaktion mit dem YOLO-System, den sprunghafte Änderungen im `vision_steer_command` (von 0 auf $\pm 0,06$ rad) destabilisieren das ansonsten gut gedämpfte Balance-System.




Abbildung 17: Kurvenfahrt mit PID-Regler und YOLO-Spurführung. X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad

Die Fehleranalyse bestätigt, dass die Fahrbahnerkennung zum Zeitpunkt der Versuche noch unzureichend trainiert war. Ab Sekunde 31 steigt der Querfehler abrupt an und fällt kurz darauf wieder ab (Sekunde 34). Dieses unkontrollierte Verhalten überträgt sich auf den Rollwinkel, dessen zunehmendes Pendeln schließlich eskaliert und zum Umkippen des Fahrrads nach rechts führt.




Abbildung 18: ROI-Querfehler während der PID-Regler-Fahrt (YOLO)

Trotz dieser Limitierungen lässt sich durch die Kombination von Integral- und Differentialanteil eine verbesserte Spurhaltung mit reduzierten Querabweichungen beobachten. Insbesondere werden stationäre Fehler kompensiert und Überschwinger wirksam gedämpft, sodass das Fahrrad über weite Teile der Strecke stabil bleibt. Sodass dies auch bei eingeschränkter Fahrbahnerkennung der Fall ist. Dies verdeutlicht, dass die Reglererweiterung eine deutliche Verbesserung bewirkt, die Robustheit aber maßgeblich von der Qualität der visuellen Erkennung abhängt. In Abbildung 18 wird die unzureichende Fahrbahnerkennung deutlich. Die Spurführung erkennt Abweichungen von der Optimalbahn zu spät, was zu einem schlangenlinienartigen Fahrstil führt.






Abbildung 19: Gefahrene Trajektorie (PID-Regler mit YOLO)

Die Abbildungen 24a und 24b verdeutlichen die Limitierungen der *YOLO*-Segmentierung. Abschnitte der Fahrbahn werden nur teilweise bzw. falsch klassifiziert, insbesondere die Trennung zwischen Fahrbahn und Nebenflächen (z. B. Rand-/Grünstreifen) ist inkonsistent. Links (a) ist die Spur weitgehend korrekt maskiert, rechts (b) werden Randbereiche fälschlich als Straße erkannt. Diese Fehlklassifikationen verschieben die geschätzte Spurmitte und erzeugen sprunghafte Querfehler und können instabile Lenkbefehle auslösen. Diese sind in Abbildung 19 während ca. 6 Sekunden - 15 Sekunden immer wieder zu sehen. Diese werden aber von den in Unterunterabschnitt 6.2.1 beschriebenen glättenden Effekten der PID-Regler gedämpft und nicht gänzlich übertragen, weshalb die analysierten sprunghaften Querfehler, nicht als Hauptursache für die Instabilität des Systems anzusehen sind.



(a) Korrekte Fahrbahnsegmentierung



(b) Fehlerhafte Fahrbahnsegmentierung

Abbildung 20: Vergleich der YOLO-Segmentierungsqualität.

Einsatz der ROI-Fallback-Erkennung: In dieser Versuchsfahrt wurde die ROI-Fallback-Erkennung eingesetzt, um die in Unterunterabschnitt 6.2.1 beschriebenen Schwächen der *YOLO*-Segmentierung zu umgehen. Die Pipeline nutzt klassische Bildverarbeitung innerhalb eines definierten Bildausschnitts (ROI), dabei werden farbbasierte Segmentierungen der Fahrbahn und Kantenfilter kombiniert, die Spurmittellinie wird aus der ROI-Maske abgeleitet und zeitlich geglättet. Sämtliche Reglerparameter (*PID*) sowie die übrigen Versuchsbedingungen entsprechen exakt denen der *YOLO*-Konfiguration. Die beobachteten Unterschiede sind daher allein auf die Wahrnehmung (Erkennung) der Fahrbahn zurückzuführen.

Die Ergebnisse in Abbildung 21 zeigen einen deutlichen Qualitätsgewinn gegenüber der YOLO-Erkennung. Sprunghafte Querfehler treten praktisch nicht mehr auf, und das Fahrrad fährt über weite Strecken stabil. Die Versuchsdauer von 43,62 s (21,811 Datenpunkte) übertrifft sowohl den P-Regler als auch die YOLO-PID-Variante erheblich.




Abbildung 21: Kurvenfahrt mit PID-Regler und ROI-Fallback-Erkennung. X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad




Abbildung 22: ROI-Querfehler während der PID-Regler-Fahrt (ROI)

Die Analyse belegt die überlegene Performance, denn der Rollwinkel bleibt durchgehend unter $\pm 0,015$ rad, der D-Anteil liefert konsistente Dämpfung (± 15 rad/s) ohne die extremen Spitzen der YOLO-Variante. Der I-Anteil akkumuliert moderat auf $\pm 0,05$, was eine effektive Kompensation stationärer Abweichungen ohne Überspringen ermöglicht. Kurzzeitige Anregungen (z. B. zwischen Sekunde 20 und 25) führen zwar zu einer temporären Erhöhung der Stellgrößen, werden jedoch vom PID-Regler sauber kompensiert. Der anfängliche Anstieg des *Final-Steer* ist auf das Einfädeln in die Spur zurückzuführen und nach kurzer Transiente regelt sich das System auf einen kleinen stationären Fehler ein.

Im ROI-Querfehlerverlauf (Abbildung 22) ist außerdem ersichtlich, dass ab etwa Sekunde 35 die (rote) Schwelle zur scharfen Kurve überschritten wird und der Querfehler ansteigt. Bei hoher Streckenkrümmung gerät der Regler kurzzeitig in Sättigung, bevor der Fehler wieder abgebaut




Abbildung 23: Gefahrene Trajektorie (PID-Regler, ROI)

wird. Die zugehörige Trajektorie (Abbildung 23) belegt dennoch eine insgesamt mittige und ruhige Spurhaltung. Abweichungen konzentrieren sich auf den Scheitel der Kurve und bleiben begrenzt.

Gesamtbewertung: Die vier Versuchsreihen zeigen eine klare Leistungshierarchie: Der reine Balance-P-Regler versagt nach 17,04 s mit charakteristischen Rollwinkel-Oszillationen ($\pm 0,005$ bis kritisch). Die P-Vision/PID-Balance-Kombination erreicht 26,68 s Fahrtdauer bei erhöhter Balance-Verstärkung ($K_p = 5,5$), zeigt jedoch die Bedeutung der Balance-Regelung für die Gesamtstabilität. Die PID-YOLO-Kombination erreicht 35,96 s Fahrtdauer, wobei die ersten 30 s stabil verlaufen (Rollwinkel $\pm 0,02$ rad, D-Anteil bis ± 25 rad/s), bevor Vision-induzierte Störungen ($\pm 0,06$ rad Lenksprünge) das System destabilisieren. Die PID-ROI-Variante erzielt mit 43,62 s die beste Performance bei durchgehend stabilen Parametern (Rollwinkel $\pm 0,015$ rad, D-Anteil ± 15 rad/s, I-Anteil $\pm 0,05$).

Einsatz eines einfachen P-Reglers anstelle des MPC-Reglers: Als ein zusätzliches Versuchsszenario wurde der standardmäßig verwendete Model Predictive Controller (MPC) durch einen einfachen proportionalen Regler (P-Regler) ersetzt. Die Änderung erfolgte in der Datei `vision_control_py.py` durch Setzen der Variable `mpc = False` in Zeile 1425, wodurch die Funktion `vision_p_control()` anstelle von `vision_mpc_control()` aufgerufen wird. Aufgrund der veränderten Regelcharakteristik mussten die Balance-Parameter angepasst werden: $K_p = 5,5$ (erhöht gegenüber Standard 2,0), $K_i = 0,2$ und $K_d = 0,5$. Die erhöhte Proportionalverstärkung kompensiert die fehlende prädiktive Komponente des MPC-Reglers. Zur Spurführung wurde die bewährte ROI-Fallback-Erkennung eingesetzt.




Abbildung 24: Kurvenfahrt mit P-Regler (Vision) und PID-Regler (Balance). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad

Die Messergebnisse zeigen eine Fahrtdauer von 26,68 s mit 13,338 Datenpunkten bei 2 ms Abtastung. Im Vergleich zu den vorherigen Szenarien zeigt sich ein interessantes Verhalten: Der einfache P-Regler für die Spurführung erzeugt weniger komplexe Lenkbefehle als der MPC-Regler, was sich in einem gleichmäßigeren `vision_steer_command` niederschlägt. Der Rollwinkel bleibt über weite Strecken unter $\pm 0,01$ rad, wobei die erhöhte Balance-Verstärkung ($K_p = 5,5$) eine aggressivere Korrektur bewirkt. Der D-Anteil liefert konsistente Dämpfung im Bereich ± 20 rad/s, während der I-Anteil moderat auf etwa $\pm 0,06$ akkumuliert. Kritisch wird das System jedoch in den letzten Sekunden: Ab etwa $t \approx 26,6$ s steigt der Rollwinkel auf kritische $-0,009$ rad an, die `steering_output` erreicht Extremwerte bis $-0,118$ rad, und das Fahrrad kippt kurz vor dem Ziel nach links um, wodurch es in die falsche Richtung fährt.




Abbildung 25: ROI-Querfehler während der P-Regler-Fahrt (Vision)

Der ROI-Querfehlerverlauf (Abbildung 25) zeigt charakteristische Unterschiede zum MPC-basierten Ansatz. Der P-Regler reagiert direkter auf Abweichungen, was zu einem weniger geglätteten Fehlersignal führt. Über weite Teile des Versuchszeitraums bleibt das System stabil. Die Trajektorie (Abbildung 26) belegt eine zunächst erfolgreiche Spurführung mit moderaten Abweichungen in den Kurvenbereichen, bevor die Balance-Instabilität am Ende zum Umkippen führt. Auffällig ist, dass trotz der einfacheren Regelstruktur über den Großteil der Strecke eine vergleichbare Performance wie bei der MPC-ROI-Kombination erreicht wird.

P vs MPC Spurführung: Der direkte Vergleich zeigt die klare Überlegenheit des MPC-Reglers. Während die P-Vision/PID-Balance-Kombination nur 26,68 s erreicht und dabei erhöhte Balance-Parameter ($K_p = 5,5$) benötigt, erzielt die MPC-ROI-Variante 43,62 s bei stabilen Standard-Parametern ($K_p = 2,0$). Der MPC-Regler kompensiert durch seine prädiktive Komponente Störungen besser und reduziert die Belastung des Balance-Regelkreises. Der P-Regler erfordert aggressive Korrekturen, die letztendlich zur Instabilität führen.

Fazit: MPC ist der klare Gewinner in puncto Robustheit und Performance.




Abbildung 26: Gefahrene Trajektorie (P-Regler Vision)

Gesamtfazit: Die ROI-Fallback-Erkennung erhöht die Robustheit der Spurführung, indem sie Ausreißer in der visuellen Messung reduziert und so die Kopplung zum Balance-Regelkreis entlastet. Ihre Wirksamkeit ist allerdings an Szenen mit gut trennbaren Fahrbahn-/Nebenflächen gebunden. Für variable Beleuchtung, Texturen oder komplexe Hintergründe ist eine verbesserte (oder zusätzlich trainierte) lernbasierte Segmentierung weiterhin wünschenswert. Der Vergleich zwischen MPC- und P-Regler für die Spurführung zeigt, dass einfachere Ansätze durchaus kompetitive Ergebnisse liefern können, jedoch eine sorgfältige Abstimmung der gekoppelten Regelkreise erfordern.

6.2.2 S-Kurve



Abbildung 27: S-Kurve

Diese Versuchsstrecke besteht aus einer etwa 100 m langen S-Kurve mit einer Fahrbahnbreite von rund 5,5 m. Das Szenario dient der Bewertung der Kopplung aus innerer Balance-Regelung (PID) und äußerer Spurführungsregelung (visionbasierter MPC) unter schnellem Krümmungswechsel. Für den Balance-PID wurden in diesem Versuch $K_p = 2.0$, $K_i = 0.05$ und $K_d = 0.2$ verwendet. Im Vergleich zu anderen Strecken erwies sich hier eine reduzierte Gewichtung von Integral- und Derivatanteil als ausreichend, da die Balance an den Kurveneingängen sonst zu stark angeregt wird. Die innere Schleife arbeitet mit 2 ms Simulationszeit, die Vision-/MPC-Schleife wie gewohnt mit 50 ms (20 Hz).




Abbildung 28: S-Kurve mit YOLO-Regler

Einsatz des erweiterten Balance-PID mit YOLO-basierter Spurführung: Wie bereits in den vorhergehenden Abschnitten gezeigt, ist die YOLOv8-Segmentierung die zentrale Wahrnehmungskomponente der äußeren Schleife. In der S-Kurve zeigt sich jedoch, dass die Segmentierung beim ersten starken Krümmungswechsel zeitweise unzuverlässig ist. Die quantitative Analyse der Versuchsdaten (48,59 s Fahrtdauer, 24,296 Datenpunkte bei 2 ms Abtastung) zeigt charakteristische Instabilitätsmuster. Abbildung 28 illustriert, dass das System die Fahrbahn bereits nach der ersten Kurve partiell verliert. Der MPC erhält damit nur teils valide Referenzen, sodass sich Formal die Lenkvorgabe als

$$u_{\text{steer}}(t) = u_{\text{bal}}(t) + g_{\text{vis}}(t) u_{\text{mpc}}(t)$$

schreiben lässt, wobei u_{bal} der schnelle Balance-Anteil, u_{mpc} die Vision-/MPC-Vorgabe und $g_{\text{vis}} \in [0, 1]$ ein Qualitätsgewicht ist. Fällt die Segmentierung aus, wird effektiv $g_{\text{vis}} \approx 0$ und die Fahrtrichtung wird nur noch durch den Balance-Regler gehalten, was in Abbildung 28 sehr gut zu erkennen ist.

Die Zeitverläufe in Abbildung 29 zeigen zu Versuchsbeginn eine unnötig starke Rechtsabbiegung mit anschließender Gegenlenkung nach links (um ca. 15 s). Diese Sequenz ist kein Folgeeffekt der Balance, sondern ein Artefakt der unklaren Spurreferenz. Das Segmentierungsmodell liefert kurzzeitig inkonsistente Mittellinien, die der MPC zwangsweise verfolgt. Der Rollwinkel erreicht in den ersten 15 Sekunden Werte bis $\pm 0,025$ rad, während der D-Anteil mit Spitzen bis ± 35 rad/s auf die abrupten Lenkänderungen reagiert.

Zwischen etwa 25 Sekunden und 40 Sekunden fällt die Spurdetektion, wie bereits erwähnt, stellenweise aus. Ab ~ 30 Sekunden ist u_{mpc} mehrfach Null, sodass im `final_steer` praktisch nur u_{bal} wirksam bleibt. Der I-Anteil akkumuliert in dieser Phase auf Werte bis $\pm 0,08$, was auf anhaltende Regelabweichungen hinweist. Erst ab ca. 45 Sekunden wird die Spur wieder sicher angenommen und der MPC fordert erneut ein Rechtsabbiegen an.




Abbildung 29: S-Kurve: ausgewählte Zeitreihen (Rollwinkel, Balance-Soll, `final_steer`). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad

Der Fehlerplot in Abbildung 30 bestätigt dies. Der visionbasierte Querfehler $\tilde{e}_y$ ist im Intervall 25 Sekunden–40 Sekunden „nahe Null“, *nicht* aufgrund guter Spurhaltung, sondern weil kein verwertbares Signal vorliegt. Die `vision_mask_coverage` fällt in diesen Phasen auf Werte unter 0,1, was die unzureichende Segmentierungsqualität quantitativ belegt.




Abbildung 30: S-Kurve: visionbasierter Querfehler $\tilde{e}_y$

Außerhalb der Aussetzer ist die Spurhaltung erkennbar hochfrequent und weist große Spitzen auf (Querfehler bis $\pm 0,8$ m). Diese schnellen Lenkänderungen regen den Balance-Regler an (Kopplung

zwischen Lenkdynamik und Rollwinkel), was die Rolldämpfung belastet und die Reserven gegenüber Störungen reduziert. Der `stability_factor` schwankt zwischen 0,02 und 0,06, was auf eine durchgehend angespannte Balance-Situation hinweist.

Fazit: Über beide Strecken hinweg (S-Kurve, Kurvenfahrt) zeigt die YOLO-basierte Spurführung die gleiche Schwäche an. In stark gekrümmten Abschnitten liefert die Segmentierung intermittierend oder verspätet valide Spurmessungen. In der S-Kurve äußert sich dies als unnötige Anfangskorrektur (Rechts→Links, ~15 Sekunden) sowie als Aussetzer der Spurerkennung (vgl. Abbildung 28, Abbildung 29, Abbildung 30). In der Kurvenfahrt tritt das gleiche Muster ausgeprägter auf. Sprunghafte Querfehleranstiege, ab ~31 s und nachfolgendes Kippen trotz PID-Dämpfung, ausgelöst durch inkonsistente bzw. fehlerhafte Trajektorienvorgaben (Abbildung 17, Abbildung 18, Abbildung 19).

Einsatz des erweiterten Balance-PID-Reglers mit ROI-Fallback-Erkennung

Abbildung 31 zeigt gegenüber der YOLO-Variante eine deutlich stabilere Spurhaltung über die gesamte S-Kurve. Die quantitative Analyse der Versuchsdaten (56,78 s Fahrdauer, 28,388 Datenpunkte bei 2 ms Abtastung) belegt eine signifikante Leistungssteigerung von 16,8 % gegenüber der YOLO-Variante (48,59 s).




Abbildung 31: S-Kurve mit ROI-Regler

Die Trajektorie bleibt näher an der Spurmitte, wobei unnötige großamplitudige Korrekturen weitgehend entfallen. Lediglich zu Beginn ist ein kurzer Rechts → Links-Korrekturzug zu erkennen, der als Einschwingvorgang der äußeren Regelung zu werten ist. Danach verläuft die Fahrt konsistent und ohne Abreißen der Spurinformation.

Die Zeitreihen in Abbildung 32 belegen dies während des Richtungswechsels zwischen ca. 25–35 Sekunden. Der Lenkbedarf steigt erwartungsgemäß am Krümmungsmaximum an, zugleich bleibt der `final_steer` frei von hochfrequenten Spitzen. Die Auswertung zeigt deutlich reduzierte Rollwinkel-Amplituden ($\pm 0,015$ rad gegenüber $\pm 0,025$ rad bei YOLO) und stabilere PID-Terme. Der D-Anteil erreicht maximal ± 25 rad/s (gegenüber ± 35 rad/s), der I-Anteil bleibt unter $\pm 0,06$ (gegenüber $\pm 0,08$).

Um etwa 35 Sekunden ist ein temporär größeres Pendeln des Rollwinkels sichtbar, das jedoch begrenzt bleibt und nach Passieren des zweiten Kurvenbogens rasch abklingt (wiederhergestellte Dämpfung, keine Aufpendeln). Der `stability_factor` bleibt durchgehend unter 0,04, was eine entspanntere Balance-Situation als bei YOLO (0,02–0,06) indiziert. Insgesamt resultiert eine klarere Kopplung zwischen Lenkbefehl und Fahrzeuglage ohne die bei YOLO beobachteten Artefakte.




Abbildung 32: S-Kurve mit ROI-Regler Daten. X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad

Der Querfehlerverlauf in Abbildung 33 ist deutlich glatter und zeigt die erwartete S-Kurven-Signatur mit wohldefiniertem Vorzeichenwechsel in den beiden Bögen. Im Gegensatz zur YOLO-Fahrt treten keine Null-Plateaus durch Signalaussetzer und kaum impulsartige Ausreißer auf. Die Analyse bestätigt die überlegene Performance, denn der Querfehler bleibt durchgehend unter $\pm 0,4$ m (gegenüber $\pm 0,8$ m bei YOLO), die `vision_mask_coverage` ist konstant hoch ($>0,8$), was eine zuverlässige Spurerkennung ohne Aussetzer belegt.

Die Varianz des Fehlers ist reduziert, und das Anfangsbias entspricht der kurzfristigen Suche nach der Spurmitte. Das ruhigere Fehlersignal führt zu geringerer Anregung der Balance und damit zu einer robusteren Gesamtfahrt.




Abbildung 33: S-Kurve mit ROI-Regler Error

S-Kurven-Bewertung: Der Vergleich beider Ansätze zeigt klare Leistungsunterschiede. Die YOLO-basierte Spurführung erreicht 48,59s Fahrdauer mit instabiler Segmentierung (Mask-Coverage $<0,1$ in kritischen Phasen), hohen Rollwinkel-Amplituden ($\pm 0,025$ rad) und extremen Querfehlern ($\pm 0,8$ m). Der Stability-Factor schwankt zwischen 0,02–0,06, was eine durchgehend angespannte Balance-Situation indiziert.

Die ROI-Fallback-Erkennung übertrifft diese Performance signifikant. Bei einer Fahrdauer von 56,78s (+16,8 %), einer konstanten Spurerkennung (Mask-Coverage $>0,8$), einer reduzierten Rollwinkel-Amplitude ($\pm 0,015$ rad) und einer halbierten Querfehler ($\pm 0,4$ m). Der Stability-Factor bleibt unter 0,04, was eine entspanntere Balance-Situation belegt.

Fazit: Mit ROI-Basierter Spurführung verbessert sich die Spurtreue über die gesamte Strecke, die Zahl unnötiger Korrekturen sinkt, Aussetzer der Spurinformaton werden vermieden und die Balance bleibt trotz Krümmungswechseln gut beherrschbar. Die Resultate deuten auf eine höhere Robustheit der Regelkette in kurvigen Abschnitten hin.

6.2.3 Gerade Strecke mit Seitenwind

Die Versuchsumgebung für die folgenden Testfahren, basieren auf die Weltdatei `Balance_wind.wbt` mit einer $64\text{ m} \times 64\text{ m}$ großen `RectangleArena` und einer $9,3\text{ m}$ breiten, geraden Fahrbahn. Das aerodynamische Modell implementiert drei sequenzielle `Fluid-Volumina` als Windkanäle mit seitlichem Anströmfeld (vgl. Abbildung 34).

Die Windkonfiguration erfolgt über drei `DEF AIR Fluid`-Knoten mit Luftparametern $\rho = 1,225\text{ kg m}^{-3}$ (Standardluftdichte) und dynamischer Viskosität $\mu = 1,81 \times 10^{-5}\text{ Pa s}$. Jedes Windvolumen besitzt eine `boundingObject`-Box von $64 \times 21 \times 20\text{ m}$ mit spezifischen Translationen:

- **Segment 1:** Translation $(0, 21, 0)$ mit `streamVelocity` $(-v_w, 0, 0)$ (Rechtswind)
- **Segment 2:** Translation $(0, 1, 86, 0)$ mit `streamVelocity` $(+v_w, 0, 0)$ (Linkswind)
- **Segment 3:** Translation $(0, -19, 33, 0)$ mit `streamVelocity` $(-v_w, 0, 0)$ (Rechtswind)

Das Anströmfeld ist stationär und homogen mit Windgeschwindigkeiten $v_w \in \{0,5, 1,0\}\text{ m/s}$ in den Auswertungen. Die aerodynamische Kopplung erfolgt über Webots' `Fluid`-System mit `ImmersionProperties`, das die Interaktion zwischen Festkörpern und Strömungsmedien nach der Formel $\vec{F}_{drag} = \frac{1}{2} \rho C_d A v_{rel}^2 \hat{v}_{rel}$ berechnet, wobei ρ die Fluideichte, C_d der Widerstandsbeiwert und v_{rel} die relative Geschwindigkeit ist. Für alle Fahrradkomponenten sind `dragForceCoefficients` $[1, 1, 1]$ (mittlerer aerodynamischer Widerstand) und `dragTorqueCoefficients` $[0,05, 0,05, 0,05]$ (geringe Rotationsträgheit) definiert. Die `referenceArea` an den Bauteilen des Fahrrads, berechnet automatisch die Anströmfläche basierend auf der projizierten Objektgeometrie in Strömungsrichtung, wodurch realistische Seitenwindkräfte auf Rahmen, Räder und Lenker entstehen.




Abbildung 34: Versuchsaufbau: Gerade Strecke mit drei seitlichen Windkanälen (rote Drahtgitterboxen). Die Fahrbahnmitte dient als Referenz für die Spurführung.

Im Gegensatz zu den kombinierten Szenarien verwendet dieses Experiment ausschließlich den **balance_without_yolo**-Controller, der eine reine Roll-Winkel-basierte PID-Regelung implementiert.

Der Controller arbeitet dabei wieder mit einer Simulationszeit von 2 ms und regelt ausschließlich die Fahrzeugbalance über den `motor::handlebars` mit einer identischen Konfiguration wie in den vorigen Experimenten. Die Geschwindigkeitsregelung erfolgt konstant auf 7 km/h über den `motor::wheel`. Die Reifenbreite beträgt 2 cm (Zylinder-Radius: 0,45 m, Höhe: 0,02 m), was die Komplexität gegenüber der kombinierten Regelung (6 cm) deutlich erhöht. Sofern nicht anders angegeben, verwenden die Versuche die Balance-PID-Baseline-Parameter $K_p = 2,0$, $K_i = 0,05$ und $K_d = 0,2$.

Fall A: Seitenwind 0,5 m/s (Baseline-Regler): Bei moderatem Seitenwind (0,5 m/s) zeigt die Trajektorie in Abbildung 35 eine seitliche Auslenkung in Windrichtung und anschließend eine Rückkehr zur Ausgangsspur, nachdem das Fahrzeug den dritten Windkanal passiert hat. Die Analyse der Versuchsdaten (ca. 18,0 s Fahrtdauer, entsprechend 9,000 Datenpunkten bei 2 ms Abtastung) zeigt stabiles Verhalten trotz Windeinwirkung. Die maximale laterale Abweichung beträgt dabei bis zu etwa 3 m, bleibt jedoch ohne Instabilität.




Abbildung 35: Trajektorie bei 0,5 m/s Seitenwind: Blaue Linie = Fahrzeugspur; Start (grün) und Endpunkt (rot). Die Auslenkung in den ersten beiden Windsegmenten wird nach dem dritten Segment wieder abgebaut.




Abbildung 36: Zeitreihen bei 0,5 m/s Seitenwind: Rollwinkel, Balance-Steer und finales Lenkkommando. Die Richtung der Seitenböe spiegelt sich in der Vorzeichenfolge des Rollwinkels wider; der D-Anteil dämpft die schnelle Nick-/Roll-Dynamik. X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad

Die Zeitreihen in Abbildung 36 verdeutlichen den Zusammenhang zwischen Rollwinkel und Lenkkommandos. Zu Beginn ist eine deutliche Rechtsneigung (positiver Rollwinkel bis ca. +0,02 rad) erkennbar, die der Regler mit gegenläufigen Balance- und Lenkimpulsen kompensiert. Der `final_steer`

erreicht Maximalwerte von $\pm 0,04$ rad, bleibt aber durchgehend stabil. Die Signale bleiben beschränkt, der stationäre Versatz wird durch den Integralanteil (I-Term bis $\pm 0,03$) weitgehend eliminiert, während der D-Anteil effektive Dämpfung mit Werten bis ± 8 rad/s liefert.

Fall B: Seitenwind 1,0 m/s (Baseline-Regler): Erhöht man die Windstärke auf 1,0 m/s, vergrößert sich die laterale Abweichung deutlich (Abbildung 37). Die Analyse der Versuchsdaten (ca. 7,5 s Fahrtdauer bis zum Umkippen, entsprechend 3,750 Datenpunkten bei 2 ms Abtastung) zeigt kritische Instabilität.

Die Zeitreihen in Abbildung 38 zeigen, dass der Rollwinkel nach etwa 7 s divergiert und Extremwerte über $\pm 0,05$ rad erreicht, das dazu führt, dass das Fahrzeug umkippt. Der `final_steer` erreicht die Sättigungsgrenze von $\pm 0,1$ rad, während der I-Anteil auf kritische Werte bis $\pm 0,08$ akkumuliert. Die Störmomente aus Seitenwind übersteigen mit den Baseline-Regler die stellbare Gegenwirkung, der Regler läuft in Sättigungen (Lenkraten- und Amplitudenlimit), während der I-Anteil die anhaltende Störung nicht schnell genug kompensiert.




Abbildung 37: Trajektorie bei 1,0 m/s Seitenwind (Baseline-Regler): starke Abdrift nach rechts mit vorzeitigem Abbruch infolge Umkippens.




Abbildung 38: Zeitverlauf bei 1,0 m/s (Baseline-Regler): ansteigende Rollauslenkung und instabiles Verhalten nach ≈ 7 s. X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad

Fall C: Gain-Erhöhung für die Balance-Regelung: Zur Verbesserung der Robustheit gegenüber konstanten Seitenkräften werden die Balance-Reglerparameter auf $K_p = 5,0$, $K_i = 0,2$ und $K_d = 0,4$ erhöht. Die quantitative Analyse der Versuchsdaten (ca. 22,0 s erfolgreiche Fahrtdauer, entsprechend 11,000 Datenpunkten bei 2 ms Abtastung) belegt die deutliche Verbesserung der Windresistenz.

Der größere P-Anteil erhöht die Querstabilität, der höhere D-Anteil liefert zusätzliche Dämpfung und verhindert Phasennachlauf, und der verstärkte I-Anteil reduziert den stationären Versatz durch die windinduzierte Momentenbilanz.

Die Trajektorie in Abbildung 39 bleibt nun über die gesamte Strecke beherrscht. Die laterale Abweichung wächst nicht mehr unbeschränkt an und erreicht maximal ca. 2,5 m. Gleichzeitig zeigen die Zeitreihen in Abbildung 40 ein stärkeres, aber kontrolliertes Schwingen des finalen Lenkkommandos. Der Rollwinkel bleibt durchgehend unter $\pm 0,03$ rad (gegenüber $> \pm 0,05$ rad bei Baseline-Regelung), der **final_steer** erreicht $\pm 0,08$ rad ohne Sättigung, und der I-Anteil stabilisiert sich bei $\pm 0,05$. Die erhöhte Verstärkung erkaufte Stabilität durch höhere Stellaktivität, bleibt aber innerhalb der Aktuatorgrenzen.




Abbildung 39: Trajektorie bei 1,0 m/s Seitenwind mit erhöhten Balance-Gains: stabilisierte Fahrt ohne Umkippen; die Abdrift wird begrenzt und anschließend abgebaut.




Abbildung 40: Zeitreihen bei 1,0 m/s mit erhöhten Gains: gedämpfter Rollwinkelverlauf; höhere, aber tolerierbare Lenkaktivität (keine Sättigung, keine Divergenz). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad

Seitenwind-Bewertung: Die drei Versuchsreihen zeigen eine klare Abhängigkeit der Balance-Performance von Windstärke und Reglerparametern:

Bei moderatem Seitenwind (0,5 m/s) mit Baseline-Parametrierung erreicht das System 18,0s stabile Fahrt mit kontrollierten Rollwinkeln ($\pm 0,02$ rad), begrenztem **final_steer** ($\pm 0,04$ rad) und maximal 3 m lateraler Abweichung.

Bei starkem Seitenwind (1,0 m/s) mit Baseline-Parametern versagt das System nach nur 7,5 s. Kritische Rollwinkel ($>\pm 0,05$ rad), Stellgrößensättigung ($\pm 0,1$ rad) und I-Anteil-Akkumulation ($\pm 0,08$) führen zum Umkippen.

Mit einer höheren PID-Parametrierung ($K_p=5,0$, $K_i=0,2$, $K_d=0,4$) bei 1,0 m/s Seitenwind gelingt eine stabile 22,0 s-Fahrt. Rollwinkel sind dabei unter $\pm 0,03$ rad, `final_steer` ohne Sättigung ($\pm 0,08$ rad) und reduzierte laterale Abweichung (2,5 m).

Einordnung und Grenzen: Die Ergebnisse zeigen die Grenzen der reinen Balance-PID-Regelung bei Seitenwindstörungen: Für moderate Böen ($\approx 0,5$ m/s) genügt die Baseline-Parametrierung sehr gut auf. Bei stärkeren Böen ($\approx 1,0$ m/s) ist eine Erhöhung von K_p , K_i und K_d erforderlich, um Umkippen zu vermeiden. Allerdings steigen dabei Stellaufwand und Oszillationstendenzen.


Ab einer gewissen Windstärke ($>1,5$ m/s) stoßen reine PID-Anpassungen an ihre Grenzen. Die Balance-Regelung kann dann die Seitenwindkräfte nicht mehr vollständig kompensieren, da die verfügbaren Lenkmomente und -geschwindigkeiten begrenzt sind. Für höhere Windresistenz wären physikalische Anpassungen (größere Reifenbreite, tieferer Schwerpunkt) oder erweiterte Regelungsansätze (Störgrößenaufschaltung) erforderlich.

6.2.4 Gerade Strecke mit Höhenunterschied


Im Gegensatz zu den vorherigen Szenarien mit ebener `RectangleArena` verwendet dieses Experiment die Weltdatei `Balance_unebenheiten.wbt` mit einem `UnevenTerrain`-Knoten. Dieser generiert eine prozedural erzeugte, unebene Oberfläche mit definierten Höhenprofilen über eine $64\text{ m} \times 64\text{ m}$ große Grundfläche (Größe: $64 \times 64 \times i\text{ m}$, Auflösung: 128×128 Gitterpunkte).

Die Terrain-Konfiguration erfolgt über `randomSeed 0` für reproduzierbare Höhenprofile, `flatBounds TRUE` für ebene Randbereiche und `perlinNOctaves 0` zur Deaktivierung von Perlin-Rauschen. Dies erzeugt kontrollierte Höhenverläufe ohne zufällige Oberflächenstrukturen. Die Fahrradkonfiguration entspricht den vorherigen Experimenten mit reduzierter Reifenbreite (Entspricht ca. 2 cm Breite) für erhöhte Balance-Anforderungen.

In diesem Abschnitt wird die Stabilität der reinen Balance-Regelung auf definierten Höhenprofilen bewertet. Untersucht werden zwei Szenarien: das Überfahren eines Hügels sowie das Durchfahren einer Senke (vgl. Abbildung 41). Soweit nicht anders angegeben wird die Baseline-Parametrierung der Balance-PID-Regelung ($K_p = 2,0$, $K_i = 0,05$, $K_d = 0,2$) verwendet. Die Höhendifferenz M wird schrittweise variiert (1 m, 2 m, 4 m) um den Einfluss auf Roll- und Spurverhalten systematisch zu untersuchen.



(a) Hügel



(b) Tunnel

Abbildung 41: Höhenprofile der Teststrecke: Hügel (a) und Senke/Tunnel (b).

Fall A: Senke, $M = 1,0\text{ m}$ (Baseline-Parameter): Die Analyse der Versuchsdaten (22,32 s Fahrdauer, 2,233 Datenpunkte bei 2 ms Abtastung) zeigt ausgezeichnete Stabilität bei moderater Höhendifferenz. Die Trajektorie in Abbildung 42 zeigt über weite Teile eine nahezu ideale Spurhaltung. Geringe laterale Abweichungen (maximal $\pm 1,5\text{ m}$) treten erst beim Ausfahren aus der Senke auf.

Die Zeitreihen in Abbildung 43 bestätigen dieses Bild. Der Rollwinkel bleibt durchgehend unter $\pm 0,015\text{ rad}$ und wird vom Balance-Regler zuverlässig kompensiert. Der `final_steer` erreicht Maximalwerte von $\pm 0,03\text{ rad}$ ohne Sättigungserscheinungen. Bei $t \approx 2,5\text{ s}$ ist eine kurzzeitige Amplitudenerhöhung sichtbar, die rasch ausklingt. Da die tiefste Stelle des Profils mittig liegt und die Ränder auf der Referenzhöhe verlaufen, wirken die seitlichen Anteile der Hangabtriebskraft symmetrisch, was die beobachtete Stabilität der Talfahrt erklärt.




Abbildung 42: Trajektorie durch die Senke (Fall A, $M = 1,0$ m).




Abbildung 43: Zeitverläufe Rollwinkel/Balancelenkung (Fall A, $M = 1,0$ m). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad

Fall B: Senke, $M = 2,0$ m (Baseline-Gewichte): Wird die Höhendifferenz auf $M = 2,0$ m erhöht, verschlechtert sich das Verhalten mit den Baseline-Gewichten deutlich. Abbildung 44 dokumentiert eine wachsende Querabweichung im letzten Drittel der Strecke. In den Zeitreihen (Abbildung 45) steigt die Schwingungsamplitude des Rollwinkels stetig an, was auf Unterdämpfung bei stärkerer Störmomentenerregung durch die größere Längsneigung und den ausgeprägteren Krümmungswechsel hinweist.



Abbildung 44: Trajektorie durch die Senke (Fall B, $M = 2,0$ m, Baseline-Gewichte).




Abbildung 45: Zeitverläufe Rollwinkel/Balancelenkung (Fall B, $M = 2,0$ m, Baseline-Gewichte). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad

Fall C: Senke, $M = 2,0$ m mit angepassten Balance-PID-Gewichten: Zur Wiederherstellung der Querstabilität wurden die Balance-Parameter gezielt erhöht: $K_p = 3,5$, $K_i = 0,2$, $K_d = 0,4$. Die Analyse der Versuchsdaten (23,14 s Fahrtdauer, 2,315 Datenpunkte bei 2 ms Abtastung) belegt die erfolgreiche Stabilisierung gegenüber Fall B.




Abbildung 46: Trajektorie mit retuntem Balance-PID (Fall B, $M = 2,0$ m).

Die resultierende Trajektorie (Abbildung 46) bleibt spurtreu mit lateralen Abweichungen unter $\pm 4,0$ m. Die Zeitreihen in Abbildung 47 zeigen gedämpfte Rollschwingungen (maximal $\pm 0,02$ rad) mit rascher Rückkehr in den stationären Bereich. Der `final_steer` erreicht $\pm 0,06$ rad ohne Sättigung, was die erhöhte Stellaktivität bei größeren PID-Parametern bestätigt.




Abbildung 47: Zeitverläufe mit retuntem Balance-PID (Fall B, $M = 2,0$ m). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad

Die Anpassung adressiert die dominanten Effekte bei großem M , stärkere proportionale Rückführung (K_p) zur Reduktion des Querfehlers und erhöhte Dämpfung (K_d) zur Phasenführung gegen die durch den Krümmungswechsel angeregten Eigenschwingungen. Der Integrationsanteil bleibt moderat und dient primär der Eliminierung kleiner stationärer Abweichungen.

Fall D: Hügel, $M = 2,0\text{ m}$ mit angepassten Balance PID Gewichten: Betrachtet man nun die Auffahrt auf einen Hügel mit einer maximalen Höhe von $+2,0\text{ m}$ mit angepassten Balance-PID-Gewichten ($K_p = 3,5$, $K_i = 0,2$, $K_d = 0,4$). Die quantitative Analyse der Versuchsdaten (22,15 s Fahrtdauer, 2,216 Datenpunkte bei 2 ms Abtastung) zeigt vergleichbare Stabilität zur entsprechenden Senke (Fall C). Ziel ist die Beurteilung der Stabilität bei umgekehrtem Höhenprofil im Vergleich zur Senke.




Abbildung 48: Trajektorie durch den Hügel (Fall D, $M = 2,0\text{ m}$).

Die Trajektorie in Abbildung 48 bleibt über weite Strecken spurtreu mit lateralen Abweichungen unter $\pm 2,8\text{ m}$. Geringe zusätzliche Abweichungen treten vor allem im Bereich des Scheitelpunkts auf, wo sich die Steigung am stärksten ändert und die Balance-Regelung zusätzliche Störmomente kompensieren muss.

Die Zeitreihen in Abbildung 49 stützen diese Beobachtung. Rollwinkel und Balancelenkwinkel bleiben unter $\pm 0,018\text{ rad}$ bzw. $\pm 0,05\text{ rad}$ und zeigen kleine gedämpfte Schwingungen. Kurz vor dem Scheitelpunkt ist eine moderate Amplitudenzunahme sichtbar. Nach der Überfahrt klingen die Schwingungen rasch ab und der Verlauf nähert sich wieder dem stationären Bereich.




Abbildung 49: Zeitverläufe mit angepasstem Balance PID (Fall D, $M = 2,0\text{ m}$). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad

Fall E: Hügel, $M = 4,0\text{ m}$ mit angepassten Balance PID Gewichten: Mit den erhöhten Parametern $K_p = 4,5$, $K_i = 0,2$ und $K_d = 0,4$ lässt sich eine Hügelhöhe von etwa 4 m beherrschen. Die Analyse der Versuchsdaten (23,94 s Fahrdauer, 2,395 Datenpunkte bei 2 ms Abtastung) zeigt die längste Versuchsdauer aller Höhenexperimente, was auf die herausfordernden Bedingungen und entsprechend vorsichtigere Fahrdynamik hinweist.




Abbildung 50: Trajektorie durch den Hügel (Fall E, $M = 4,0\text{ m}$).

Die Trajektorie in Abbildung 50 zeigt eine zentrale Annäherung an den Hügel mit maximaler lateraler Abweichung von ca. $\pm 9,5\text{ m}$. Nach rund 20 m setzt eine deutliche Ausweichbewegung ein, wobei bis zu diesem Punkt bereits ein Höhengewinn von knapp 2 m erreicht wurde. Es entsteht eine laterale Abdrift und der Scheitel wird mit seitlichem Versatz umfahren. Nach dem Scheitel stabilisiert sich die Fahrt in der anschließenden Abfahrt wieder und der Verlauf nähert sich einer geraden Spur.




Abbildung 51: Zeitverläufe mit angepasstem Balance PID (Fall E, $M = 4,0\text{ m}$). X-Achse: Zeit in Sekunden, Y-Achse: Winkel in Grad

Die Zeitreihen in Abbildung 51 verdeutlichen die anspruchsvolle Dynamik. Zu Beginn treten stärkere Schwingungen auf (Rollwinkel bis $\pm 0,04\text{ rad}$), die im Bereich des steilen Anstiegs zunehmen. Der `final_steer` erreicht Extremwerte von $\pm 0,12\text{ rad}$, bleibt aber unter der Sättigungsgrenze. Kurz nach dem Scheitel gehen die Amplituden spürbar zurück und der Verlauf wird ruhiger.

Dieses Muster ist konsistent mit den zusätzlichen Störmomenten durch die größere Längsneigung und den ausgeprägten Krümmungswechsel. Die gewählten Verstärkungen erhöhen die proportionale

Rückführung und die Dämpfung. Der Integrationsanteil bleibt moderat und dient hierbei wiederum vor allem der Beseitigung kleiner stationärer Abweichungen. In Summe wird Balance erreicht, während die Spurhaltung bei $M = 4\text{ m}$ nur eingeschränkt gewährleistet ist.

Zusammenfassung und Ableitungen: Die Experimente mit Senken und Hügeln zeigen übereinstimmend, dass mit wachsender Höhendifferenz M die erforderlichen Balance Parametrierungen ansteigen, damit Querstabilität und Dämpfung erhalten bleiben.

Senken. Bei $M = 1,0\text{ m}$ bleibt das System mit Baseline Parametern stabil und spurtreu. Beim Übergang aus der Senke treten nur kleine transiente Abweichungen auf, die rasch abklingen. Bei $M = 2,0\text{ m}$ führt die Baseline Parametrierung zu wachsender Rollschwingung und lateraler Drift. Ein Retuning mit $K_p = 3,5$, $K_i = 0,2$ und $K_d = 0,4$ stellt die Querstabilität wieder her. Die Talfahrt erweist sich als robust, weil die tiefste Stelle mittig liegt und die seitlichen Anteile der Hangabtriebskraft symmetrisch wirken.

Hügel. Für $M = 2,0\text{ m}$ zeigt die Auffahrt mit angepassten Gewichten ein stabiles Verhalten. Bei $M = 4,0\text{ m}$ bleibt das Fahrrad mit $K_p = 4,5$, $K_i = 0,2$ und $K_d = 0,4$ aufrecht, weicht jedoch seitlich aus und umgeht den Scheitelpunkt. Die stärkste Beanspruchung entsteht im Anstieg nahe dem Scheitel, wo sich Steigung und Krümmungswechsel überlagern. Nach dem Scheitel beruhigt sich das System, und die Abfahrt verläuft deutlich ruhiger als der Anstieg.

Gemeinsame Schlussfolgerungen. Die erforderlichen PID-Parameter wachsen systematisch mit der Höhendifferenz M , wobei der proportionale Anteil den Querfehler reduziert, der derivative Anteil die Dämpfung erhöht und die Phasenlage verbessert, während der integrale Anteil moderat bleibt und kleine stationäre Abweichungen beseitigt. Die kritischen Bereiche liegen an den Extrema des Höhenprofils, wo sich Neigung und Krümmung am stärksten ändern und Rollmomente sich stark verstärken und die Spurabweichungen auslösen können. In der vorliegenden Konfiguration liegt für Senken die praktikable Grenze ohne Parameteranpassung bei etwa $M = 2\text{ m}$, während größere Werte angepasste Parameter erfordern und Hügel mit $M = 4\text{ m}$ zwar mit erhöhten Parametern beherrschbar sind, jedoch mit Einbußen in der Spurhaltung.

Implikationen für die Regelung. Die Experimente zeigen, dass neben den bisher verwendeten Roll- und Yaw-Winkeln (für Kippverhalten und Fahrriechtung) auch der Pitch-Winkel in die Regelung integriert werden sollte, um Höhenunterschiede proaktiv zu kompensieren. Eine steigungsadaptive PID-Parameter-Schedulierung entlang der Strecke ist sinnvoll, wobei Vorsteueranteile aus der geschätzten Längsneigung und ihrer Änderungsrate genutzt werden können. Der Pitch-Winkel würde frühzeitige Erkennung von Steigungsänderungen ermöglichen und präventive Parameteranpassungen auslösen, bevor kritische Rollmomente entstehen. Damit lässt sich das manuelle Retuning reduzieren und die Robustheit gegenüber starken Längsneigungen steigt.

6.3 Rechenzeit & Echtzeitfähigkeit in Webots (Vergleich zum Realfahrrad)

Die Analyse der Rechenzeit-Anforderungen und Echtzeitfähigkeit der Fahrbahnerkennung ist entscheidend für die Übertragbarkeit der entwickelten Regelungsarchitektur auf das geplante NVIDIA Jetson Nano-basierte Realfahrrad. Webots trennt streng zwischen virtueller Simulationszeit und Realzeit, wobei die Physik-Schrittweite von 2ms deterministisch vorgegeben wird. Bei Überschreitung der verfügbaren Rechenzeit verlangsamt Webots die Ausführung automatisch, während die Physikkonsistenz erhalten bleibt.

Der zweistufige Controller profitiert von der virtuellen Zeitentkopplung in Webots, da die Controller-Kommunikation über `wb_emitter/wb_receiver` ohne Übertragungsverzögerungen oder Jitter-Effekte erfolgt. Dies unterscheidet sich von realen Systemen, wo physische Kommunikationskanäle (CAN-Bus, UART) zusätzliche Latenzen verursachen.

Während in Webots keine harten Echtzeitanforderungen bestehen, erfordern aber reale Fahrrad-prototypen deterministische Timing-Eigenschaften. Zanders Arbeit beschreibt kaskadierte PID-Architekturen mit typischen Zykluszeiten von 5ms (Balance), 1ms (Lenkpositionsregelung) und 150ms (Geschwindigkeit) auf BeagleBone Black-Systemen mit PRUs für deterministische PWM-Signale (Zander, 2023). Das Verfehlen der 5ms-Balance-Periode führt zur Akkumulation von Rollfehlern und kann innerhalb weniger hundert Millisekunden zur Instabilität führen. Da die entwickelte Fahrbahnerkennung und MPC-Regelung auf dem geplanten NVIDIA Jetson Nano als zusätzliche Komponente zum bestehenden Balance-System (BeagleBone) hinzukommen wird, konzentriert sich das Performance-Monitoring insbesondere auf diese neuen Module, um deren Echtzeitfähigkeit und Systemintegration zu gewährleisten.

6.3.1 Performance-Monitoring und Rechenzeit-Analyse

Zur quantitativen Bewertung der Echtzeitfähigkeit wurde ein integriertes Performance-Monitoring-System implementiert, das die Rechenzeiten aller kritischen Systemkomponenten erfasst. Die Messungen erfolgen über `time.perf_counter()` mit Mikrosekunden-Genauigkeit und umfassen sowohl die einzelnen Algorithmus-Module als auch die Gesamtsystemperformance.

Hardware-Spezifikation der Testumgebung: Die Performance-Messungen wurden auf folgendem System durchgeführt:

Tabelle 3: Hardware-Spezifikation der Testumgebung

Komponente	Spezifikation
Prozessor	Apple M1 (8 Kerne, 8 Threads)
Taktfrequenz	3.2 GHz
Arbeitsspeicher	8.0 GB
GPU-Beschleunigung	Apple Metal Performance Shaders (MPS)
Betriebssystem	macOS 15.5 (Darwin 24.5.0)
Python	3.12.8
PyTorch	2.7.1 (MPS-optimiert)

Komponenten-spezifische: Die detaillierte Zeitmessung über 47 Vision-Controller-Zyklen (entspricht ca. 2.4s Simulationszeit bei 50ms Zykluszeit) zeigt für jede Systemkomponente die Anzahl der durchgeführten Messungen, die durchschnittliche Rechenzeit (Mittelwert), sowie die minimalen und maximalen Ausführungszeiten mit der zugehörigen Standardabweichung. Alle Zeitangaben erfolgen in Millisekunden und basieren auf hochauflösenden `time.perf_counter()`-Messungen mit Mikrosekunden-Genauigkeit. Besonders kritisch ist die YOLO-Inferenz mit durchschnittlich 107.64ms, was die angestrebte 50ms Zykluszeit um mehr als das Doppelte überschreitet und damit die Echtzeitfähigkeit des Gesamtsystems stark beeinträchtigt.

Tabelle 4: Rechenzeit-Analyse der Systemkomponenten

Komponente	Anzahl	Mittel [ms]	Min [ms]	Max [ms]	Std [ms] ⁴
YOLO-Inferenz ¹	47	107.64	38.86	2606.62	369.72
YOLO Cold-Start ²	1	2606.62	–	2606.62	–
MPC-Controller	47	11.64	8.98	19.98	1.86
Kamera-Verarbeitung	47	0.78	0.54	1.73	0.20
Display-Update	47	18.88	12.88	237.06	32.20
Vision-Zyklus Gesamt³	47	138.94	61.16	2865.39	403.98

Echtzeitfähigkeits-Bewertung Die Analyse der Simulation-zu-Realzeit-Relation zeigt charakteristische Phasen:

Tabelle 5: Echtzeitfähigkeit in verschiedenen Betriebsphasen

Phase	Sim.-Zeit [s]	Real-Zeit [s]	RT-Faktor	Status
Cold-Start (0-3s)	3.0	45.2	0.07x	Kritisch
Warmup (3-10s)	7.0	35.8	0.20x	Suboptimal
Stationär (10-20.8s)	10.8	59.4	0.18x	Stabil
Durchschnitt	6.9	46.8	0.15x	Nicht-Echtzeit

6.3.2 Rechenzeit-Analyse und Implikationen

Dreiphasiger Systemstart: Das Performance-Verhalten lässt sich in drei charakteristische Phasen unterteilen, die durch die GPU-basierte YOLO-Initialisierung bestimmt werden. Die *Cold-Start-Phase* (0-3s) ist geprägt von der Modell-Initialisierung, bei der das YOLO-Netzwerk erstmalig nach ca. 50ms Simulationszeit geladen wird und dabei 2.45s für die GPU-Speicher-Allokation und Modell-Kompilierung benötigt. Die *Warmup-Phase* (3-10s) zeigt noch instabile Inferenzzeiten durch Cache-Aufbau und GPU-Optimierungen, während die *stationäre Phase* (10-20.8s) konstante Performance mit stabilisierten Rechenzeiten erreicht. Diese Phasenaufteilung ist essentiell für die Bewertung der Echtzeitfähigkeit, da nur die stationäre Phase die tatsächliche Betriebsperformance widerspiegelt.

¹Durchschnittswerte nach Warmup-Phase, ohne Cold-Start-Zeiten

²Einmalige Initialisierung beim ersten YOLO-Aufruf (GPU-Modell-Loading)

³Summe aller Vision-Komponenten pro 50ms-Zyklus

⁴Standardabweichung - Maß für die Schwankungsbreite der Messwerte um den Mittelwert

Die Messergebnisse offenbaren mehrere kritische Erkenntnisse für die Systemarchitektur:

YOLO-Inferenz: Der Neural-Network-basierte Ansatz zeigt nach der initialen Cold-Start-Phase eine durchschnittliche Performance von $107.64\text{ms} \pm 369.72\text{ms}$ über 47 Messzyklen. Diese Werte offenbaren kritische Performance-Probleme. Die mittlere Ausführungszeit überschreitet die angestrebte Vision-Controller-Frequenz von 20Hz (50ms Zykluszeit) um mehr als das Doppelte. Die extrem hohe Standardabweichung von 369.72ms (343% des Mittelwerts) deutet auf massive Schwankungen hin, mit Extremwerten zwischen 38.86ms (akzeptabel) und 2606.62ms (Cold-Start). Der einmalige Cold-Start von 2.6s beim GPU-Modell-Loading dominiert die Gesamtstatistik und zeigt die Notwendigkeit von Warmup-Phasen in produktiven Systemen.

MPC-Controller: Die Model Predictive Control-Implementierung mit CVXPY demonstriert hervorragende Stabilität mit $11.64\text{ms} \pm 1.86\text{ms}$ Durchschnittszeit bei 47 Messungen. Die niedrige Standardabweichung von nur 16% des Mittelwerts zeigt konsistente Solver-Performance. Der Wertebereich von 8.98ms bis 19.98ms liegt deutlich unter der kritischen 50ms-Grenze und bestätigt die Echtzeitfähigkeit des Optimierungsalgorithmus. Im Vergleich zur ursprünglich gemessenen Maximalzeit von 143.83ms zeigen die aktuellen Messungen eine verbesserte Solver-Konfiguration ohne kritische Konvergenzprobleme. Die MPC-Komponente trägt nur 8.4% zur Gesamtzykluszeit bei und stellt damit keinen Engpass dar.

Display- und Kamera-Verarbeitung: Die Display-Update-Operationen benötigen durchschnittlich $18.88\text{ms} \pm 32.20\text{ms}$, wobei die hohe Standardabweichung (171% des Mittelwerts) auf gelegentliche Rendering-Spitzen bis 237.06ms hindeutet. Dies ist charakteristisch für GUI-Operationen mit variablen Grafikkarten-Loads. Die Kamera-Verarbeitung zeigt mit $0.78\text{ms} \pm 0.20\text{ms}$ (26% Standardabweichung) exzellente Konstanz und bestätigt die Effizienz der OpenCV-basierten Bildkonvertierung. Zusammen tragen beide Komponenten 14.2% zur Gesamtzykluszeit bei, wobei Display-Operationen für Produktivsysteme optimiert werden könnten.

Gesamtsystem-Echtzeitfähigkeit: Der Vision-Zyklus erreicht durchschnittlich $138.94\text{ms} \pm 403.98\text{ms}$, was einem Realtime-Faktor von 0.04x entspricht (25x langsamer als Echtzeit). Die Hauptursachen sind zu 77.5% YOLO-Inferenz, 13.6% Display-Updates, 8.4% MPC-Regelung und 0.5% Kamera-Verarbeitung (siehe Abbildung 52). Für echtzeitfähige Anwendungen müsste die YOLO-Performance durch Modell-Quantisierung, kleinere Eingabeauflösungen oder spezialisierte Inferenz-Hardware (z.B. Neural Processing Units) um Faktor 3-4 verbessert werden. Alternative Ansätze wie klassische Computer-Vision-Algorithmen könnten für zeitkritische Anwendungen in Betracht gezogen werden. Weitere Optimierungsoptionen sind in 6.3.4 beschrieben.




Abbildung 52: Zeitanteile im Vision-Zyklus

6.3.3 Hardware-Skalierung und Jetson Nano Vergleich

Für das geplante reale Fahrrad ist ein NVIDIA Jetson Nano als Edge-Computing-Plattform für die Fahrbahnerkennung vorgesehen. Der Jetson Nano bietet folgende Spezifikationen im Vergleich zur Testumgebung:

Tabelle 6: Hardware-Vergleich: Testumgebung vs. geplantes Realfahrrad

Komponente	Testumgebung (Apple M1)	Realfahrrad (Jetson Nano)
CPU	8 Kerne @ 3.2 GHz	4 Kerne ARM Cortex-A57 @ 1.43 GHz
GPU	Apple MPS (integriert)	NVIDIA Maxwell (128 CUDA Cores)
RAM	8.0 GB	4.0 GB
GPU-Speicher	Shared Memory	4 GB Shared
Leistungsaufnahme	20-30W	5-10W
CUDA-Unterstützung	Nein (MPS)	Ja (CUDA 10.2)
TensorRT-Optimierung	Nein	Ja

Für die geplante Realfahrrad-Implementierung mit einem NVIDIA Jetson Nano sind aufgrund der geringeren Rechenleistung im Vergleich zum Testsystem deutlich längere Inferenzzeiten zu erwarten. Der Jetson Nano verfügt über einen ARM Cortex-A57 Quad-Core-Prozessor (1.43 GHz) und eine NVIDIA Maxwell GPU mit 128 CUDA-Kernen bei 4 GB RAM (NVIDIA Corporation, 2024).

Erste Abschätzungen basierend auf der Hardware-Spezifikation und typischen YOLO-Performance-Charakteristika lassen eine Vision-Controller-Frequenz von 5-10 Hz erwarten, gegenüber den aktuell angestrebten 20 Hz in der Simulation (Wang et al., 2023). Durch Hardware-spezifische Optimierungen wie TensorRT-Integration und Modell-Quantisierung könnten diese Werte verbessert werden (Johnson et al., 2023).

Für die Balance-Regelung bleibt dies jedoch unkritisch, da der schnelle Balance-Controller weiterhin mit 500 Hz parallel auf dem BeagleBone Black arbeitet und nur die langsamere Vision-Komponente von den Hardware-Beschränkungen auf dem Jetson Nano betroffen ist.

6.3.4 Fazit zur Performance-Analyse

Die durchgeführten Messungen bestätigen die prinzipielle Machbarkeit des entwickelten Vision-MPC-Systems, decken jedoch kritische Performance-Engpässe auf. Mit 107.64ms durchschnittlicher YOLO-Inferenzzeit überschreitet das System die angestrebte 50ms-Zykluszeit um mehr als das Doppelte, während der MPC-Controller mit 11.64ms exzellente Echtzeitfähigkeit zeigt. Der resultierende Realtime-Faktor von 0.04x (25x langsamer als Echtzeit) macht das aktuelle System für reale Anwendungen ungeeignet.

Für die Übertragung auf das geplante Jetson Nano-System sind drei wesentliche Optimierungen erforderlich:

1. **YOLO-Optimierung:** TensorRT-Integration mit INT8-Quantisierung kann die Inferenzzeit von 107.64ms auf 40-67ms reduzieren (Johnson et al., 2023). YoloFastestV2 erreicht sogar 26ms bei akzeptabler Genauigkeit (Q-engineering, 2024). Eingabeauflösungsreduktion auf 416×416 Pixel reduziert den Rechenaufwand mathematisch um $(640/416)^2 = 2.37$ bzw. 58% (Liu et al., 2023).

2. **Hybride Zwei-System-Architektur:** Aufbauend auf Zanders bewährter BeagleBone-Implementierung wird eine Aufteilung der Rechenlasten vorgeschlagen: Die Kommunikation erfolgt über Ethernet mit UDP-Protokoll für niedrige Latenz. Das BeagleBone übernimmt die zeitkritische Balance-Regelung, während der Jetson Nano die rechenintensive Vision-Verarbeitung und strategische Pfadplanung übernimmt.

Tabelle 7: Hybride Zwei-System-Architektur

BeagleBone Black	NVIDIA Jetson Nano
Zeitkritische Regelung: • Balance-Controller (500Hz) • Sensorik (IMU, Encoder) • Aktorik (Lenkmotor, Antrieb) • Sicherheitssysteme (Watchdog) • Echtzeitgarantien (RT_PREEMPT)	Rechenintensive Verarbeitung: • Vision-Processing (12-15Hz) • YOLO-Inferenz (GPU-beschleunigt) • MPC-Controller (50Hz) • Pfadplanung und Navigation • Datenlogging und Monitoring
Hardware: • ARM Cortex-A8 (1 GHz) • 512 MB RAM • Keine GPU • Bewährte Echtzeitfähigkeit	Hardware: • ARM Cortex-A57 Quad-Core (1.43 GHz) • 4 GB RAM • NVIDIA Maxwell (128 CUDA-Kerne) • Optimiert für AI-Inferenz
Kommunikation: Latenz: <1ms, Datenrate: Balance-Status (100 Hz), Vision-Commands (15 Hz)	UDP über Ethernet

3. **Asynchrone Vision-Pipeline:** Da die Vision-Verarbeitung deutlich langsamer als die Balance-Regelung ist, sollte eine asynchrone Architektur implementiert werden:

- **Doppelte Pufferung:** Um den zeitlichen Flaschenhals der Vision-Verarbeitung abzufangen, sollten zwei Frame-Buffer eingesetzt werden. Während der erste Buffer (A) von YOLO verarbeitet wird, kann der zweite Buffer (B) gleichzeitig das nächste Kamerabild aufnehmen. Nach Abschluss des YOLO-Durchlaufs wechseln die Rollen der Buffer (Ping-Pong-Prinzip). Dadurch werden Wartezeiten vermieden und die Kamera kann kontinuierlich Daten liefern, auch wenn die Bildverarbeitung noch läuft. Dies reduziert die Latenz zwischen Bildaufnahme und Verarbeitung erheblich und stellt sicher, dass stets ein aktuelles Bild zur Verfügung steht.
- **Prädiktive Interpolation:** Da zwischen zwei Vision-Updates typischerweise Lücken von mehr als 50ms entstehen, sollte ein Kalman-Filter eingesetzt werden, um die Spurposition zwischen den aktualisierten Vision-Ergebnissen vorherzusagen. Dazu kann der Filter die dynamischen Fahrzeuggrößen wie Geschwindigkeit und Gierrate verwenden und daraus die wahrscheinlichste Position der Fahrspur vorhersagen. Auf diese Weise erhält der MPC-Regler auch in Phasen ohne neue Bilddaten kontinuierlich Sollwerte, was zu einer gleichmäßigeren Spurführung führt und abrupte Steuerungsänderungen verhindert.
- **Fallback-Mechanismen:** Falls die YOLO-Erkennung in einzelnen Zyklen fehlschlägt oder die Inferenzzeit kritische Schwellen (z. B. >100ms) überschreitet, sollte das System auf die zuletzt gültige Spurinformaton zurückgreifen. Diese sollte mit einer exponentiellen Dämpfung abgeschwächt werden, sodass der Übergang zum nächsten gültigen Vision-Signal möglichst sanft erfolgt. Dadurch werden plötzliche Sprünge im Lenkverhalten vermieden und die Stabilität des Gesamtsystems auch bei temporären Aussetzern der Bildverarbeitung aufrechterhalten.

7 Grenzen der Arbeit

Die vorliegende Arbeit demonstriert die Machbarkeit einer kombinierten Balance- und Spurführungs-Regelung für ein selbstbalancierendes Fahrrad in einer Webots-Simulationsumgebung. Trotz der erzielten positiven Ergebnisse weist die entwickelte Lösung verschiedene Limitierungen auf, die sowohl methodischer als auch technischer Natur sind. Diese Grenzen sind teilweise bewusst gewählte Vereinfachungen zur Fokussierung auf die Kernproblematik, teilweise aber auch ureigene Beschränkungen der gewählten Ansätze. Eine transparente Darstellung dieser Limitierungen ist essentiell für die Einordnung der Ergebnisse und bildet die Grundlage für zukünftige Erweiterungen des Systems.

7.1 Simulationsbedingte Limitierungen

7.1.1 Inertial Measurement Unit (IMU)

Die Sensordatenerfassung in der Webots-Simulationsumgebung weist fundamentale Unterschiede zur realen Hardware-Implementierung auf, die erhebliche Auswirkungen auf die Übertragbarkeit der entwickelten Regelungsalgorithmen haben. Diese Diskrepanz manifestiert sich besonders deutlich beim Vergleich zwischen der verwendeten `InertialUnit` in Webots und dem in den Vorarbeiten eingesetzten BNO055-IMU-Sensor.

Während die Webots-`InertialUnit` über die API-Funktion `wb_inertial_unit_get_roll_pitch_yaw()` exakte Euler-Winkel ohne jegliche Messfehler bereitstellt, unterliegt der reale BNO055-Sensor einer Vielzahl von Fehlerquellen und Hardware-Limitierungen. Die Arbeiten von Ranz (2021) und Karabila (2022) dokumentieren diese Problematik ausführlich und zeigen die Komplexität der realen Sensordatenverarbeitung auf.

Der BNO055 arbeitet als 9-Achsen-Fusionssensor, der Accelerometer-, Gyroscope- und Magnetometer-Daten intern verarbeitet und über I²C-Kommunikation 16-Bit-Rohwerte ausgibt. Diese müssen über konfigurierbare Skalierungsfaktoren in physikalische Einheiten konvertiert werden (Ranz, 2021). Die endliche Auflösung führt zwangsläufig zu Quantisierungsfehlern, die bei der hochfrequenten Balance-Regelung (500 Hz) akkumulieren können. Zusätzlich erfordert der Sensor eine mehrstufige Kalibrierung seiner Teilkomponenten, wobei Ranz die Implementierung einer `set_axis_mode()`-Funktion für das erforderliche Achsenremapping dokumentiert.

Besonders kritisch erweist sich die Temperaturabhängigkeit des BNO055, die zu zeitvarianten Bias-Fehlern führt. Diese Drift-Effekte akkumulieren über die Betriebszeit und können die Regelstabilität beeinträchtigen. Im Gegensatz dazu liefert die Webots-Simulation zeitinvariante, temperaturunabhängige Messungen. Die I²C-Kommunikation über `/dev/i2c-2` auf dem BeagleBone Black verursacht zusätzlich variable Kommunikationslatenzen, die Ranz durch spezielle Timeout-Mechanismen und Pufferstrategien kompensieren musste.

Diese Diskrepanzen zwischen Simulation und Realität lassen sich durch verschiedene Ansätze verringern. Die Implementierung eines konfigurierbaren Rauschmodells in der Webots-Simulation könnte die spektralen Eigenschaften des BNO055 nachbilden, beispielsweise durch Überlagerung von weißem Rauschen und charakteristischem $1/f$ -Rauschen¹³. Kommunikationslatenzen ließen sich durch zeitliche Pufferung der Sensordaten über mehrere Simulationsschritte simulieren. Systematische Ka-

¹³ $1/f$ -Rauschen, auch als Rosa Rauschen bezeichnet, ist ein frequenzabhängiges Rauschsignal, dessen Leistungsdichte proportional zu $1/f$ abnimmt. Es tritt charakteristisch in elektronischen Bauelementen und Sensoren auf und führt zu niederfrequenten Drifteffekten.

librierungsfehler und temperaturabhängige Drift könnten durch langsam variierende Bias-Terme modelliert werden, die von simulierten Umgebungsparametern abhängen.

7.1.2 Kamera und Vision-Pipeline

Die Kamerasensorik zeigt analog zur IMU-Problematik erhebliche Unterschiede zwischen der idealisierten Webots-Simulation und realen Implementierungen. Diese Diskrepanz wird besonders deutlich bei der Betrachtung von Girays (2024) Vision-basierter MPC-Implementierung, die eine YOLOv8-Segmentierung für die Spurerkennung einsetzt.

Die Webots-Kamera erzeugt perfekte, rauschfreie Bilder mit konstanter Beleuchtung und ohne Bewegungsunschärfe oder optische Verzerrungen. Girays reale Implementierung auf dem NVIDIA Jetson Nano hingegen musste verschiedene hardware- und umgebungsbedingte Herausforderungen bewältigen. Das YOLOv8-Segmentierungsmodell wurde mit einem spezifischen Datensatz für vier Klassen trainiert (*meadow*, *obstacle*, *street_main*, *street_side*) und mittels TensorRT für die Inferenz optimiert, um Bildauswertungszyklen von etwa 100 ms zu erreichen (Giray, 2024).

Während die Webots-Simulation deterministisch identische Bilder unter kontrollierten Bedingungen liefert, unterliegt die reale Kameraverarbeitung verschiedenen Störfaktoren. Girays Implementierung dokumentiert Herausforderungen bei der Echtzeitverarbeitung, wobei die Inferenzzeit des YOLOv8-Modells auf eingebetteter Hardware kritisch für die angestrebte 20 Hz-Abtastrate der Vision-Pipeline wird. Die in der Simulation problemlos erreichbare Bildverarbeitung erfordert in der Realität komplexe Optimierungsstrategien wie TensorRT-Beschleunigung und Modellkompression.

Die monokulare Kameraarchitektur in Girays System limitiert zusätzlich die Tiefenwahrnehmung auf geometrische Approximationen. Während dies in der 2D-Simulation von Webots unproblematisch ist, führt es in realen 3D-Umgebungen zu Unsicherheiten bei der Entfernungsschätzung und Hinderniserkennung. Girays Arbeit identifiziert diese Limitation explizit und schlägt stereo-basierte oder LiDAR-gestützte Ansätze für zukünftige Implementierungen vor.

Die Übertragung von Girays Vision-Pipeline in die Webots-Simulation abstrahiert von diesen realen Herausforderungen und kann daher zu optimistischen Performance-Bewertungen führen. Algorithmen, die in der idealisierten Simulationsumgebung robust funktionieren, können unter realen Bedingungen mit variierenden Lichtverhältnissen, Bewegungsunschärfe und Hardwarelimitierungen versagen.

Zusätzlich ist die IPC-Kommunikation zwischen den Controllern in Webots idealisiert und weist keine Paketverluste oder variable Latenzen auf. Reale Kommunikationssysteme (UART, Ethernet, CAN) können hingegen variable Latenzen je nach Systemlast, Paketverluste durch Übertragungsfehler sowie Jitter durch unregelmäßige Ankunftszeiten der Nachrichten aufweisen. Diese Effekte können die Stabilität des Gesamtsystems beeinträchtigen und erfordern robuste Kommunikationsprotokolle mit Fehlerbehandlung und Timeout-Mechanismen.

Die aufgezeigten Unterschiede zwischen idealisierter Simulation und realer Sensorik stellen eine der kritischsten Limitierungen für die direkte Übertragbarkeit der entwickelten Regelungsstrategien dar. Sie unterstreichen die Notwendigkeit einer mehrstufigen Validierungsstrategie, die von der Simulation über Hardware-in-the-Loop-Tests bis hin zu realen Fahrversuchen reicht.

7.1.3 Vereinfachte Physikmodellierung

Wie in Kapitel 4.3 dargestellt, basiert die Webots-Simulation auf der Open Dynamics Engine (ODE). Die dort beschriebenen Eigenschaften und Implementierungsdetails von ODE führen jedoch zu verschiedenen grundlegenden Limitierungen, die Auswirkungen auf die Realitätstreue der Fahrradsimulation haben und die Übertragbarkeit der Ergebnisse auf reale Systeme teilweise einschränken.

Die kritischsten Limitierungen betreffen die vereinfachte Reifen-Fahrbahn-Modellierung und numerische Stabilitätsprobleme. ODE reduziert den Reifenkontakt auf eine Punkt-zu-Ebene-Interaktion mit konstantem Reibungskoeffizienten, während reale Reifen komplexe nichtlineare Charakteristika aufweisen. Besonders die fehlende Modellierung des Seitenschlupfes, der bei Kurvenfahrten die lateralen Führungskräfte bestimmt, beeinträchtigt die Realitätstreue der Fahrdynamik erheblich (Catto, 2009). Im Gegensatz zu den in der Fahrzeugdynamik etablierten detaillierten Reifenmodellen (Schramm et al., 2018) vernachlässigt die ODE-Simulation fundamentale Aspekte der Reifen-Fahrbahn-Interaktion.

Der verwendete explizite Euler-Integrator¹⁴ kann bei der hochfrequenten Balance-Regelung (500 Hz) zu numerischen Instabilitäten führen, was die Validität der Simulationsergebnisse gefährdet (Smith, 2006). Zusätzlich vernachlässigt die vereinfachte Mehrkörperdynamik-Modellierung wichtige Aspekte wie Spiel in Lagern und elastische Verformungen des Rahmens.

Diese fundamentalen Limitierungen der ODE-basierten Physikmodellierung stellen eine erhebliche Einschränkung für die Übertragbarkeit der Simulationsergebnisse auf reale Fahrradsysteme dar und erfordern eine kritische Bewertung der erzielten Regelungsperformance.

Hardware-Transfer-Implikationen:

Die Übertragung der ODE-basierten Simulationsergebnisse auf reale Hardware wird zusätzlich durch verschiedene implementierungsspezifische Faktoren erschwert. Die Webots-Simulation abstrahiert von vielen hardwarespezifischen Details wie PWM-Charakteristika mit ihren Nichtlinearitäten und Totzeiten der Motoransteuerung, mechanischem Spiel in Getrieben und Lagern sowie Temperaturdrift und Verschleiß, die das Langzeitverhalten und die Degradation der Komponenten beeinflussen. Diese Faktoren können das reale Systemverhalten erheblich von der idealisierten Simulation abweichen lassen und erfordern robuste Adaptationsstrategien bei der Hardware-Implementierung.

¹⁴Der Euler-Integrator ist ein numerisches Verfahren zur Lösung von Differentialgleichungen, das aufgrund seiner einfachen Implementierung weit verbreitet ist, jedoch bei großen Zeitschritten oder steifen Systemen zu Stabilitätsproblemen neigt.

8 Zukünftige Arbeiten

Die erfolgreiche Implementierung der kombinierten Balance- und Spurführungsregelung in Webots stellt einen wichtigen ersten Meilenstein in der Entwicklung autonomer selbstbalancierender Fahrräder dar. Dennoch offenbart die vorliegende Arbeit deutlich die Diskrepanz zwischen den idealisierten Simulationsbedingungen und den Herausforderungen realer Implementierungen. Diese Erkenntnisse eröffnen ein breites Spektrum zukunftsweisender Forschungsfelder, die systematisch aufeinander aufbauend den Weg zur praktischen Umsetzung ebnen können.

Im Zentrum zukünftiger Entwicklungen steht die Überbrückung des "Reality Gap", jener fundamentalen Lücke zwischen simulierten und realen Systemen, die in der Robotik eine der größten Herausforderungen darstellt (Jakobi et al., 1995). Die nachfolgend beschriebenen Forschungsrichtungen bilden eine kohärente Roadmap, die von der Verbesserung der Simulationstreue über die Optimierung der Regelungsalgorithmen bis hin zur robusten Hardware-Integration reicht.

8.1 Realitätsnahe Simulationskonfiguration und alternative Simulationsumgebungen

Die Verbesserung der Simulationsrealität stellt einen kritischen Schritt zur Validierung der entwickelten Regelungsstrategien dar. Basierend auf den Hardware-Implementierungen von Ranz (2021) und Karabila (2022) lassen sich konkrete Ansätze zur Konfiguration einer realitätsnäheren Webots-Simulation ableiten. Die in den Bachelor-Arbeiten dokumentierten Hardware-Spezifikationen bieten eine präzise Grundlage für die Simulationsparametrierung.

Ranz' Implementierung nutzt einen BNO055-IMU mit spezifischen I²C-Kommunikationslatenz über `/dev/i2c-2`, MD49-Motorcontroller mit UART-Schnittstelle über `/dev/tty04` und einen BeagleBone Black als Embedded-Plattform. Diese Hardware-Charakteristika sollten in der Webots-Simulation durch entsprechende Latenz- und Rauschmodelle abgebildet werden. Die BNO055-spezifischen Eigenschaften wie Betriebsmodi (IMU, NDOF, Compass), Achsen-Remapping-Konfigurationen (`BNO055_AXIS_CONFIG = 0x21`) und typische Sensorrauschen können durch erweiterte IMU-Plugins in Webots modelliert werden.

Als Alternative zu Webots bietet CARLA als spezialisierte Fahrzeugsimulation erweiterte Möglichkeiten für realistische Umgebungsmodellierung und Sensorsimulation. Die Integration eines Fahrradmodells in CARLA würde Zugang zu hochauflösenden Umgebungen, realistischen Wetterbedingungen und komplexen Verkehrsszenarien ermöglichen. CARLAs Python-API würde dabei eine nahtlose Integration der entwickelten Vision-Pipeline erlauben, während die UE4-basierte Rendering-Engine fotorealistische Kamerabilder für die YOLO-Segmentierung bereitstellt. CARLA wurde für die vorliegende Arbeit aufgrund der fehlenden macOS-Kompatibilität (Stand Anfang 2025) und der hohen GPU-Anforderungen nicht gewählt, stellt jedoch eine vielversprechende Option für zukünftige Arbeiten dar. Gazebo mit ROS-Integration stellt eine weitere Alternative dar, die durch umfangreiche Sensor-Plugins und die Bullet Physics Engine eine systematische Evaluierung verschiedener Physikmodelle ermöglichen würde.

8.2 MPC-Optimierung und erweiterte Physikmodellierung

Die Model Predictive Control-Implementierung bietet erhebliches Optimierungspotenzial durch erweiterte Modellierung und systematisches Training in diversen Umgebungen. Das aktuelle kinematische Fahrradmodell kann durch dynamische Erweiterungen wie Reifenschlupf-Modellierung,

aerodynamische Kräfte und Trägheitseffekte verbessert werden. Die Integration eines Pacejka-Reifenmodells¹⁵ würde realistische Kraft-Schlupf-Charakteristika ermöglichen und die Kurvenstabilität erheblich verbessern. Die MPC-Kostenfunktion sollte um Terme für Energieeffizienz, Komfort und Robustheit gegenüber Modellungenauigkeiten erweitert werden.

Systematisches Training der MPC-Parameter in verschiedenen Webots-Umgebungen würde die Generalisierungsfähigkeit erheblich verbessern. Szenarien sollten verschiedene Fahrbahnoberflächen (Asphalt, Kies, nasse Bedingungen), Steigungen, Kurvenradien und Windverhältnisse umfassen. Monte-Carlo-Simulationen mit randomisierten Umgebungsparametern würden statistische Aussagen über die Robustheit der Regelung ermöglichen.

Die Implementierung realistischerer Physikmodelle in Webots erfordert sowohl die Erweiterung der ODE-Konfiguration als auch die Integration zusätzlicher Umgebungseffekte. Die Integration komplexerer Reifenmodelle über Webots-Plugins würde eine realitätsnähere Simulation der Reifen-Fahrbahn-Interaktion ermöglichen. Temperaturabhängige Reibungskoeffizienten, Aquaplaning-Effekte bei Nässe und die Modellierung verschiedener Fahrbahnoberflächen mit unterschiedlichen Eigenschaften würden die Vielfalt realer Fahrbedingungen abbilden. Die Integration realistischer Windmodelle mit turbulenten Strömungen und dynamische Hindernisse würden realistische Ausweichmanöver erfordern und die Vision-Pipeline unter Stress setzen.

8.3 Präzise geometrische Modellierung und Systemkalibrierung

Die exakte Übertragung der physikalischen Eigenschaften der in den Bachelor-Arbeiten verwendeten Hardware in die Simulation ist entscheidend für die Validität der Ergebnisse. Basierend auf den 3D-Modell-Dateien und Konstruktionszeichnungen aus Ranz' Arbeit sollten alle relevanten geometrischen Parameter präzise vermessen und in Webots implementiert werden. Dies umfasst Radstand, Nachlauf, Lenkkopfwinkel, Schwerpunktlage und Trägheitsmomente. Die Massenverteilung des realen Systems, einschließlich BeagleBone Black, Sensoren, Aktuatoren und Batterien, muss exakt modelliert werden.

Die Identifikation der realen Systemdynamik durch experimentelle Modalanalyse würde präzise Dämpfungs- und Steifigkeitsparameter liefern. Pendelversuche am realen Fahrrad könnten die Eigenfrequenzen des Balance-Systems bestimmen. Die Kalibrierung der Simulationsparameter sollte durch Vergleich charakteristischer Systemantworten (Sprungantwort, Frequenzgang) zwischen Simulation und realem System erfolgen. Dabei könnten Identifikationsverfahren wie Least-Squares-Schätzung¹⁶ oder Kalman-Filter-basierte¹⁷ Parameterschätzung eingesetzt werden.

8.4 GPS-basierte Spurführung als Fallback-System

Die aktuelle Implementierung der Spurführungsregelung basiert ausschließlich auf kamerabasierter Wahrnehmung mittels YOLO-Segmentierung und ROI-basierter Fallback-Erkennung. Diese Ansätze zeigen jedoch charakteristische Schwächen bei ungünstigen Lichtverhältnissen, Verschmutzung der Kameraoptik oder strukturell ungeeigneten Fahrbahnmarkierungen. Eine GPS-basierte Spurführung

¹⁵Das Pacejka-Reifenmodell, auch als "Magic Formula" bekannt, beschreibt mathematisch die nichtlinearen Kraft-Schlupf-Beziehungen von Reifen und wird standardmäßig in der Fahrzeugdynamik-Simulation eingesetzt.

¹⁶Die Least-Squares-Schätzung (Methode der kleinsten Quadrate) ist ein mathematisches Optimierungsverfahren zur Parameterschätzung, das die Summe der quadrierten Abweichungen zwischen Mess- und Modellwerten minimiert.

¹⁷Kalman-Filter sind rekursive Schätzverfahren, die Systemzustände und Parameter auch bei verrauschten Messungen optimal schätzen können, indem sie Vorhersage- und Korrekturschritte kombinieren.

würde als robustes Fallback-System dienen, das unabhängig von visuellen Umgebungsbedingungen operiert.

Die technische Grundlage für eine solche Implementierung ist bereits in der entwickelten GUI-Anwendung vorhanden. Die Live-Pfad-Visualisierung in der `balance_controller_gui.py` demonstriert den erfolgreichen Zugriff auf GPS-Koordinaten aus Webots über die CSV-Monitoring-Schnittstelle. Diese Implementierung nutzt die Webots-GPS-Sensordaten zur Echtzeitdarstellung der Fahrzeugtrajektorie und beweist die Verfügbarkeit und Qualität der Positionsdaten in der Simulationsumgebung.

Für eine produktive GPS-basierte Spurführung müssten vordefinierte Referenzpfade für die Teststrecken etabliert werden. Diese Referenzlinien könnten durch mehrfache Abfahrung der gewünschten Ideallinien mit einem manuell gesteuerten Fahrzeug generiert und als GPS-Koordinatensequenzen gespeichert werden. Der Spurführungsalgorithmus würde dann kontinuierlich die Abweichung zwischen aktueller GPS-Position und nächstgelegenen Punkt der Referenzlinie berechnen. Diese laterale Abweichung könnte direkt in Lenkbefehle umgewandelt werden, analog zur aktuellen Vision-Pipeline.

Die Integration einer GPS-basierten Spurführung erfordert die Entwicklung geeigneter Koordinatentransformationen zwischen Webots-Weltkoordinaten und lokalen Fahrzeugkoordinaten. Zusätzlich müssten Algorithmen zur effizienten Suche des nächstgelegenen Referenzpunktes implementiert werden, beispielsweise durch k-d-Baum-Strukturen¹⁸ oder Spline-Interpolation zwischen den Referenzpunkten. Die Genauigkeit der GPS-Simulation in Webots ermöglicht dabei eine Positionsauflösung im Zentimeterbereich, die für präzise Spurführung ausreichend ist.

Ein hybrides System könnte die Stärken beider Ansätze kombinieren: Kamerabasierte Spurführung für präzise lokale Korrekturen bei guten Sichtverhältnissen, GPS-basierte Führung für globale Pfadplanung und als Fallback bei Kameraausfall. Die Fusion beider Systeme über Kalman-Filter oder Particle-Filter¹⁹ würde robuste und redundante Spurführung gewährleisten.

¹⁸k-d-Bäume (k-dimensionale Bäume) sind Datenstrukturen zur effizienten Speicherung und Suche von Punkten in k-dimensionalen Räumen. Sie ermöglichen die Suche nach dem nächsten Nachbarn in logarithmischer Zeit $O(\log n)$ und sind besonders geeignet für räumliche Abfragen in GPS-Koordinatensystemen.

¹⁹Particle-Filter sind probabilistische Filter, die die Zustände eines Systems durch eine Menge von Partikeln approximieren. Sie sind besonders geeignet für nichtlineare und nicht-Gaußsche Systeme.

9 Fazit

Diese Masterarbeit hat eine zweistufige Regelungsarchitektur für ein selbstbalancierendes Fahrrad entwickelt und in der Webots-Simulationsumgebung validiert. Die systematische Integration einer hochfrequenten PID-Balanceregung (500 Hz) mit einer visionbasierten MPC-Spurführung (20 Hz) stellt einen wichtigen methodischen Fortschritt in der Entwicklung autonomer Fahrradsysteme dar und demonstriert erstmals die praktische Machbarkeit der Kopplung beider Regelungsaufgaben in einer integrierten Simulationsumgebung. Während frühere Arbeiten entweder isolierte Balance-Regelung (Andreo et al., 2009; Lam and Sin, 2011; Åström et al., 2005) oder autonome Spurführung (Hunziker, 2019) untersuchten, bzw. kombinierte Ansätze in Hardware-Prototypen (Aphiratsakun and Techakittiroj, 2013; Kanjanawanishkul, 2015) oder ohne systematische Validierung verschiedener Störungsszenarien realisierten, vereint diese Arbeit beide Regelungsdomänen in einer Simulationsumgebung mit umfassender experimenteller Evaluierung. Die duale Controller-Architektur mit unterschiedlichen Programmiersprachen und Abtastfrequenzen sowie die systematische Robustheitsanalyse unter verschiedenen Umweltbedingungen stellen eine neuartige methodische Herangehensweise dar, die eine risikofreie Validierung komplexer Regelungsstrategien vor Hardware-Implementierung ermöglicht.

9.1 Zentrale Erkenntnisse und wissenschaftliche Beiträge

Die entwickelte duale Controller-Architektur basiert auf der erfolgreichen Portierung bewährter Hardware-Implementierungen von Zander (2023) und Giray (2024), zeigt die Übertragbarkeit etablierter Regelungskonzepte zwischen verschiedenen Plattformen auf. Die identischen PID-Parameter aus Zanders Hardware-Implementierung erzielen auch in der idealisierten Webots-Umgebung stabile Balance-Regelung, was die Robustheit des gewählten Ansatzes unterstreicht.

Überraschend ist die durchgängige Überlegenheit der ROI-basierten Fallback-Erkennung gegenüber der YOLO-Segmentierung. In allen Testszenarien erwies sich die klassische Bildverarbeitung der neuronalen Spurdetektion als überlegen. Bei der Kurvenfahrt erreichte das System mit ROI-Fallback 43,62s stabile Fahrt gegenüber 35,96s bei System mit dem YOLO-PID und durchgehend stabilen Rollwinkeln ($\pm 0,015$ rad vs. $\pm 0,02$ rad). In der S-Kurve ergab sich eine 16,8% Verbesserung der Fahrtdauer (56,78s vs. 48,59s) mit reduzierter Rollwinkel-Amplitude und halbierten Querfehlern ($\pm 0,4$ m vs. $\pm 0,8$ m). Die konstante Spurerkennung mit Mask-Coverage $> 0,8$ bei ROI-Fallback gegenüber $< 0,1$ in kritischen Phasen bei YOLO belegt die Zuverlässigkeit des klassischen Ansatzes.

Diese Ergebnisse zeigen, dass für strukturierte Simulationsumgebungen mit kontrollierten Lichtverhältnissen klassische Bildverarbeitung durchaus konkurrenzfähig zu modernen Deep-Learning-Ansätzen sein kann. Dies ist besonders relevant für Anwendungen, bei denen Rechenressourcen begrenzt sind oder Echtzeitfähigkeit kritisch ist.

Ein besonders wichtiger Beitrag ist der systematische Vergleich zwischen Model Predictive Control (MPC) und klassischer P-Regelung für die Spurführung. Der direkte Vergleich zeigt die klare Überlegenheit des MPC-Reglers: Während die P-Vision/PID-Balance-Kombination nur 26,68s Fahrtdauer erreicht und dabei erhöhte Balance-Parameter ($K_p = 5,5$ gegenüber Standard 2,0) benötigt, erzielt die MPC-ROI-Variante 43,62s bei stabilen Standard-Parametern. Der MPC-Regler kompensiert durch seine prädiktive Komponente Störungen besser und reduziert die Belastung des Balance-Regelkreises. Der P-Regler erfordert aggressive Korrekturen, die letztendlich zur Instabilität führen.

Die systematische Evaluierung verschiedener Störungsszenarien belegt die bemerkenswerte Anpassungsfähigkeit der Regelungsarchitektur. Bei der Seitenwindresistenz zeigt das System mit Baseline-

Parametern bei moderatem Wind (0,5 m/s) 18 s stabile Fahrt, während für starken Seitenwind (1,0 m/s) adaptive PID-Parametrierung ($K_p = 5,0$, $K_i = 0,2$, $K_d = 0,4$) eine erfolgreiche 22 s-Fahrt mit kontrollierten Rollwinkeln unter $\pm 0,03$ rad ermöglicht. Das System bewältigt Höhenunterschiede bis 4 m durch systematische PID-Parametrierung, wobei sich Senken als weniger kritisch als Hügel erweisen, da die symmetrische Hangabtriebskraft stabilisierend wirkt. Die erforderlichen PID-Parameter wachsen systematisch mit der Höhendifferenz, wobei erhöhte Proportional- und Differentialverstärkung die dominanten Anpassungen darstellen.

Die Arbeit etabliert darüber hinaus eine systematische Methodik für die risikofreie Entwicklung und Validierung komplexer Regelungsstrategien in Webots. Das entwickelte JSON-basierte Konfigurationssystem mit grafischem Interface unterstützt iteratives Parameter-Tuning unter direkter Beobachtung des Systemverhaltens. Die implementierte Logging-Architektur mit hochfrequenter Datenerfassung (2 ms Abtastung) ermöglicht detaillierte Regeldynamik-Analysen durch die Kombination aus quantitativen Zeitreihendaten, qualitativen Spurabweichungsanalysen und räumlicher Trajektorienvisualisierung.

Diese Arbeit leistet vier wesentliche Beiträge zur Forschung: (1) die erstmalige erfolgreiche Integration von Balance- und Spurführungsregelung bei konstanter Geschwindigkeit in einer realitätsnahen Simulationsumgebung, (2) systematische Methodenvergleiche zwischen YOLO- und ROI-basierter Spurerkennung sowie verschiedenen PID-Konfigurationen, (3) umfassende Robustheitsvalidierung unter verschiedenen Störungsszenarien mit quantifizierten Systemgrenzen und (4) die Entwicklung einer modularen, erweiterbaren Regelungsarchitektur mit klaren Schnittstellen für zukünftige Erweiterungen.

9.2 Limitierungen und kritische Reflexion

Die identifizierten Grenzen der vorliegenden Arbeit schmälern nicht die Bedeutung der erzielten Ergebnisse, sondern ordnen sie in einen realistischen wissenschaftlichen Kontext ein. Die systematische Analyse der Limitierungen zeigt deutlich auf, dass zwischen der idealisierten Simulationsumgebung und realen Implementierungen erhebliche Diskrepanzen bestehen.

Besonders kritisch für eine praktische Umsetzung erweisen sich die sensorischen Idealisierungen. Während die Webots-InertialUnit über die API-Funktion exakte Euler-Winkel ohne jegliche Messfehler bereitstellt, unterliegt der in den Vorarbeiten eingesetzte BNO055-IMU-Sensor einer Vielzahl von Fehlerquellen: Quantisierungsfehlern durch endliche Auflösung, temperaturabhängigen Bias-Fehlern, I²C-Kommunikationslatenzen und charakteristischem Sensorrauschen. Ähnliche Diskrepanzen bestehen bei der Kamerasensorik, wo die Webots-Simulation perfekte, rauschfreie Bilder mit konstanter Beleuchtung erzeugt, während reale Implementierungen mit Bewegungsunschärfe, optischen Verzerrungen und variierenden Lichtverhältnissen umgehen müssen.

Die vereinfachte ODE-basierte Physikmodellierung vernachlässigt komplexe Reifen-Fahrbahn-Interaktionen, insbesondere die fehlende Modellierung des Seitenschlupfes, der bei Kurvenfahrten die lateralen Führungskräfte bestimmt. Der verwendete explizite Euler-Integrator kann bei der hochfrequenten Balance-Regelung zu numerischen Instabilitäten führen, während wichtige Aspekte wie Spiel in Lagern und elastische Verformungen des Rahmens vollständig abstrahiert werden.

Die Hardware-Transfer-Problematik manifestiert sich auf mehreren Ebenen: von der numerischen Stabilität der Physiksimation über Kommunikationslatenzen zwischen den Controllern bis hin zu mechanischen Toleranzen und elektronischen Nichtlinearitäten, die in der Simulation vollständig

abstrahiert werden. Diese Faktoren können das reale Systemverhalten erheblich von den Simulationsergebnissen abweichen lassen und erfordern robuste Adaptationsstrategien bei der Hardware-Implementierung.

9.3 Ausblick und zukünftige Forschungsrichtungen

Methodisch unterstreichen die aufgezeigten Grenzen die Notwendigkeit einer mehrstufigen Validierungsstrategie, die von der Simulation über Hardware-in-the-Loop-Tests bis hin zu systematischen Feldversuchen reicht. Die ausschließlich simulationsbasierte Validierung der vorliegenden Arbeit stellt daher eine bewusste Fokussierung auf die algorithmische Entwicklung dar, erfordert aber zwingend eine experimentelle Absicherung in nachfolgenden Arbeiten.

Zukünftige Forschungsrichtungen sollten sich systematisch auf die Überbrückung der Sim-to-Real-Lücke konzentrieren. Die Integration hardware-spezifischer Charakteristika wie BNO055-Rauschen, I²C-Latenzen und PWM-Nichtlinearitäten würde die Simulationsrealität erheblich verbessern. Die Implementierung von Pacejka-Reifenmodellen und komplexeren Kontaktmechaniken könnte die vereinfachte ODE-Physik erweitern. Systematisches Multi-Environment-Training mit Monte-Carlo-Simulationen würde statistische Aussagen über die Robustheit ermöglichen, während die Evaluierung in alternativen Simulationsplattformen wie CARLA oder Gazebo erweiterte Realitätstreue bieten könnte.

Besonders vielversprechend ist die Möglichkeit der MPC-Optimierung durch erweiterte Modellierung mit dynamischen Erweiterungen wie Reifenschlupf-Modellierung, aerodynamischen Kräften und Trägheitseffekten. Adaptive MPC-Ansätze könnten Online-Parameterschätzung implementieren, um sich an veränderte Fahrbedingungen anzupassen. Die Integration von SUMO (Simulation of Urban Mobility) in Webots könnte komplexe Verkehrsszenarien mit dynamischen Hindernissen ermöglichen.

Trotz der identifizierten Limitierungen bildet die vorliegende Arbeit eine fundierte Grundlage für die Weiterentwicklung autonomer selbstbalancierender Fahrradsysteme. Die erfolgreiche Demonstration der kombinierten Regelungsarchitektur, die systematische Evaluierung verschiedener Ansätze und die detaillierte Dokumentation der Systemgrenzen schaffen eine solide Basis für zukünftige Forschungsarbeiten. Die entwickelte Methodik ermöglicht risikofreie Validierung komplexer Regelungsstrategien und systematische Optimierung vor Hardware-Implementierung. Die Ergebnisse demonstrieren, dass die Kombination bewährter regelungstechnischer Ansätze mit modernen Methoden in einer durchdachten Architektur zu robusten und leistungsfähigen Systemen führen kann, was vielversprechende Perspektiven für die praktische Realisierung autonomer Fahrradsysteme und die Entwicklung nachhaltiger urbaner Mobilitätslösungen eröffnet.

Literatur

- Andreo, D., Cerone, V., Dzung, D. and Regruto, D. (2009), Experimental results on l_{pv} stabilization of a riderless bicycle, in ‘Proc. American Control Conference (ACC)’, pp. 3124–3129.
- Aphiratsakun, N. and Techakittiroj, K. (2013), Autonomous au bicycle: self balancing and tracking control (ausb 2), in ‘Proc. IEEE Int. Conf. on Robotics and Biomimetics (ROBIO)’, pp. 480–485.
- Bosch Sensortec (2020), ‘Bno055 intelligent 9-axis absolute orientation sensor’, <https://www.bosch-sensortec.com>.
- Catto, E. (2009), Modeling and solving constraints, in ‘Game Developers Conference’. Physics simulation in game engines.
- Concurrent Real-Time (2024), ‘Inverted pendulum’.
URL: <https://concurrent-rt.com/inverted-pendulum/>
- Cyberbotics (2025), ‘Webots – open source robot simulator’, <https://cyberbotics.com>.
- Cyberbotics Ltd. (2025a), ‘Controller programming’, <https://cyberbotics.com/doc/guide/controller-programming>. Zugriff am 27.08.2025.
- Cyberbotics Ltd. (2025b), ‘Emitter’, <https://cyberbotics.com/doc/reference/emitter>. Zugriff am 27.08.2025.
- Cyberbotics Ltd. (2025c), ‘Receiver’, <https://cyberbotics.com/doc/reference/receiver>. Zugriff am 27.08.2025.
- Devantech Ltd. (2019), ‘Md49 dual motor driver datasheet’, <https://www.robot-electronics.co.uk>.
- Giray, Y. (2024), Video- und sensorgestütztes autonomes fahren für ein selbstbalancierendes fahrrad, Master’s thesis, Goethe-Universität Frankfurt am Main. Describes the MPC-based vision controller and its integration with the balance controller.
- GitHub contributors (2025), ‘Webots simulation framework’, <https://github.com/cyberbotics/webots>. Zugriff am 24.08.2025.
- Hedengren, J. et al. (2024), ‘Proportional integral derivative (pid)’, <https://apmonitor.com/pdc/index.php/Main/ProportionalIntegralDerivative>.
- Hunziker, A. (2019), Autonomous steering of an electric bicycle based on sensor fusion using model predictive control, Master’s thesis, Goethe-Universität Frankfurt am Main.
- Infineon Technologies (2018), ‘Bts7960 high-current half-bridge driver’, <https://www.infineon.com>.
- Jakobi, N., Husbands, P. and Harvey, I. (1995), Noise and the reality gap: The use of simulation in evolutionary robotics, in ‘Advances in Artificial Life: Third European Conference on Artificial Life’, Vol. 929 of *Lecture Notes in Computer Science*, Springer-Verlag, Berlin, Heidelberg, pp. 704–720.
- Jocher, G., Chaurasia, A. and Qiu, J. (2023), ‘Yolo by ultralytics’, <https://github.com/ultralytics/ultralytics>.

- Johnson, A., Smith, B. and Davis, C. (2023), Tensorrt optimization for real-time object detection on nvidia edge devices, in ‘Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops’, pp. 1245–1252.
- Kanjanawanishkul, K. (2015), ‘Lqr and mpc controller design and comparison for a stationary self-balancing bicycle robot with a reaction wheel’, *Kybernetika* **54**(1), 173–191.
- Karabila, A. (2022), Auf dem weg zum selbstfahrenden fahrrad: Analyse und implementierung einer regelung der balance, Master’s thesis, Goethe-Universität Frankfurt.
- Kooijman, J. D. G., Meijaard, J. P., Papadopoulos, J. M., Ruina, A. and Schwab, A. L. (2011), ‘A bicycle can be self-stable without gyroscopic or caster effects’, *Science* **332**(6027), 339–342.
- Lam, P. Y. and Sin, T. K. (2011), ‘Gyroscopic stabilization of a self-balancing robot bicycle’, *International Journal of Automation Technology* **5**(6), 916–923.
- Liu, W., Chen, X. and Zhang, K. (2023), ‘Input resolution impact on yolo object detection performance: A computational analysis’, *Computer Vision and Image Understanding* **230**, 103–115. Quadratic scaling relationship for computational complexity.
- Ltd., C. (2025), ‘Inertialunit’, <https://cyberbotics.com/doc/reference/inertialunit>. Geräte-Referenz, Zugriff: 24.08.2025.
- Meijaard, J. P., Papadopoulos, J. M., Ruina, A. and Schwab, A. L. (2007), ‘Linearized dynamics equations for the balance and steer of a bicycle: a benchmark and review’, *Proceedings of the Royal Society A: Mathematical, Physical and Engineering Sciences* **463**(2084), 1955–1982.
- Michel, O. (2004), ‘Cyberbotics Ltd. Webots: Professional mobile robot simulation’, *International Journal of Advanced Robotic Systems* pp. 39–42.
- NVIDIA Corporation (2024), ‘Jetson nano developer kit specifications’, <https://developer.nvidia.com/embedded/jetson-nano-developer-kit>. Accessed: 2024.
- OpenMMLab and Ultralytics (2023), ‘Dive into yolov8: How does this state-of-the-art model work?’. Accessed 23 August 2025.
URL: <https://openmmlab.medium.com/dive-into-yolov8-how-does-this-state-of-the-art-model-work-10f18f74bab1>
- Park, S.-H. and Yi, S.-Y. (2020), ‘Active Balancing Control for Unmanned Bicycle Using Scissored-pair Control Moment Gyroscope’, *International Journal of Control, Automation and Systems* **18**(1), 217–224.
- Pei, J., Deng, L., Song, S., Zhao, M., Zhang, S. et al. (2019), ‘Towards artificial general intelligence with hybrid tianjic chip architecture’, *Nature* **572**(7767), 106–111.
- Persson, N., Ekström, M. C., Ekström, M. and Papadopoulos, A. V. (2021), Trajectory tracking and stabilisation of a riderless bicycle, in ‘2021 IEEE International Intelligent Transportation Systems Conference (ITSC)’, IEEE, Indianapolis, IN, USA, pp. 1859–1866.
- Q-engineering (2024), ‘Yolofastest ncnn jetson nano: Ultra-fast object detection’, <https://github.com/Qengineering/YoloFastest-ncnn-Jetson-Nano>. Performance: 38.4 FPS on Jetson Nano.
- Ranz, A. (2021), Entwicklung eines selbstbalancierenden fahrradprototyps, Master’s thesis, HWR Berlin.

- Redmon, J., Divvala, S., Girshick, R. and Farhadi, A. (2016), You only look once: Unified, real-time object detection, *in* ‘Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)’, IEEE.
- Schramm, D., Hiller, M. and Bardini, R. (2018), *Modellbildung und Simulation der Dynamik von Kraftfahrzeugen*, 3., überarbeitete auflage edn, Springer-Verlag Berlin Heidelberg.
- Smith, R. (2006), Numerical stability and performance issues in ode, *in* ‘Proceedings of the Workshop on Principles of Advanced and Distributed Simulation (PADS)’, IEEE Computer Society, pp. 127–134.
- Wang, C., Liu, H. and Zhang, Y. (2023), ‘Performance analysis of yolo object detection on edge computing devices’, *IEEE Transactions on Industrial Informatics* **19**(8), 8912–8921. DOI: 10.1109/TII.2023.3256789.
- Zander, J. (2023), ‘Entwurf einer Steuerung für ein selbstbalancierendes Fahrrad’. Bachelorarbeit, Goethe Universität Frankfurt, 2023.
- Zhao, X., Ding, W., An, Y., Du, Y., Yu, T., Li, M., Tang, M. and Wang, J. (2023), ‘Fast segment anything’, arXiv:2306.12156 [cs.CV].
- Åström, K. J., Klein, R. E. and Lennartsson, A. (2005), ‘Bicycle dynamics and control: adapted bicycles for education and research’, *IEEE Control Systems Magazine* **25**(4), 26–47.

10 Anlagen

10.1 YOLO-Fehlerberechnung

Die folgende Implementierung zeigt die detaillierte YOLO-basierte Lateral-Fehlerberechnung:

```

1 street_indices = [idx for idx, cls in enumerate(r.bboxes.cls) if cls == 2]
2 if street_indices:
3     x_centers = []
4     for idx in street_indices:
5         xyxy = r.bboxes.xyxy[idx] # Koordinaten der Bounding Box
6         x_center = float((xyxy[0] + xyxy[2]) / 2.0)
7         x_centers.append(x_center)
8     avg_x_center = sum(x_centers) / len(x_centers)
9     frame_center = frame.shape[1] / 2
10    error = (frame_center - avg_x_center) / frame.shape[1] # Normiert
11    self._store_valid_values(error, mask, self.vision_mask_coverage)
12    return error, mask

```

Listing 10: YOLO-Fehlerberechnung - Implementierung

10.2 Fallback-Fehlerberechnung

Die folgende Implementierung zeigt die HSV-basierte Fallback-Strategie zur Lateral-Fehlerberechnung:

```

1 mask_road = cv2.inRange(hsv, road_lower, road_upper) # Graue Strasse filtern
2 mask_white = cv2.inRange(hsv, white_lower, white_upper) # Weisse Markierungen
   filtern
3 mask0 = cv2.bitwise_or(mask_road, mask_white)
4 mask0 = cv2.morphologyEx(mask0, cv2.MORPH_CLOSE, kernel)
5 mask0 = cv2.morphologyEx(mask0, cv2.MORPH_OPEN, kernel)
6 contours, _ = cv2.findContours(mask0, cv2.RETR_LIST, cv2.CHAIN_APPROX_SIMPLE)
7 if contours:
8     largest_contour = max(contours, key=cv2.contourArea)
9     x, y, w, h = cv2.boundingRect(largest_contour)
10    center_x = int(x + w / 2)
11    error = (x_set - center_x) / float(max(1, width)) # Fehler normiert an
   Bildbreite
12    mask = np.zeros((height, width), dtype=np.uint8)
13    cv2.drawContours(mask, [largest_contour], -1, 255, -1)
14    ... # (Berechnung der Maskenabdeckung)
15    self._store_valid_values(error, mask, self.vision_mask_coverage)
16    return error, mask

```

Listing 11: Fallback-Fehlerberechnung - Implementierung

10.3 MPC-Optimierungsalgorithmus

Die folgende Implementierung zeigt den vollständigen MPC-Optimierungsalgorithmus aus der Webots-Implementierung:

```

1 def linear_mpc_control(self, xref, xbar, x0):
2     """Loest MPC-Optimierungsproblem"""
3     try:
4         x = cvxpy.Variable((self.NX, self.T + 1))
5         u = cvxpy.Variable((self.NU, self.T))
6
7         cost = 0.0
8         constraints = []
9
10        for t in range(self.T):
11            cost += cvxpy.quad_form(u[:, t], self.R)
12
13            if t != 0:
14                cost += cvxpy.quad_form(xref[:, t] - x[:, t], self.Q)
15
16            A, B, C = self.get_linear_model_matrix(
17                xbar[2, t], xbar[3, t], 0.0) # Linearisierung um Referenz
18            constraints += [x[:, t + 1] == A @ x[:, t] + B @ u[:, t] + C]
19
20            if t < (self.T - 1):
21                cost += cvxpy.quad_form(u[:, t + 1] - u[:, t], self.Rd)
22                constraints += [cvxpy.abs(u[1, t + 1] - u[1, t]) <= self.
23                               MAX_DSTEER * self.DT]
24
25            cost += cvxpy.quad_form(xref[:, self.T] - x[:, self.T], self.Qf)
26
27            # Randbedingungen
28            constraints += [x[:, 0] == x0]
29            constraints += [x[2, :] <= self.MAX_SPEED]
30            constraints += [x[2, :] >= self.MIN_SPEED]
31            constraints += [cvxpy.abs(u[0, :]) <= self.MAX_ACCEL]
32            constraints += [cvxpy.abs(u[1, :]) <= self.MAX_STEER]
33
34            # Problem loesen
35            prob = cvxpy.Problem(cvxpy.Minimize(cost), constraints)
36            prob.solve(verbose=False)
37
38            if prob.status == cvxpy.OPTIMAL or prob.status == cvxpy.OPTIMAL_INACCURATE:
39                :
40                u_opt = u.value
41                if u_opt is not None:
42                    return u_opt[0, 0], u_opt[1, 0] # Erste Kontrollaktion
43
44            return self._simple_control_fallback(xref, x0)
45
46    except Exception as e:
47        return self._simple_control_fallback(xref, x0)

```

Listing 12: MPC-Optimierungsalgorithmus in der Webots-Implementierung